

基于IAO-MCKD的电机轴承故障诊断*

刘福康 杨光永 王 林 吴大飞 徐天奇
(云南民族大学电气信息工程学院, 昆明 650000)

摘要: 针对电机轴承元件故障信号微弱的特点, 为提高诊断精度, 提出了一种基于改进AO(天鹰算法)优化MCKD(最大相关峭度反卷积)的诊断方法。首先, 通过优化参数后的MCKD算法对噪声信号进行降噪处理; 其次, 对故障信号的包络谱进行分析和诊断; 最后, 准确提取被强噪声淹没的轴承故障信号。实验结果表明, IAO-MCKD方法与其他经典优化算法相比, 能有效增强故障特征, 准确提取出故障信号, 且该方法具有收敛速度快、处理陷入局部最优问题更灵活等特点。

关键词: 电机轴承; MCKD算法; AO算法; 包络谱; 故障诊断

中图分类号: TH133.3; TG66

文献标识码: A

Fault Diagnosis Method of Motor Bearing Based on IAO-MCKD

LIU Fu-kang, YANG Guang-yong, WANG Lin, WU Da-fei, XU Tian-qi

(School of Electrical Information Engineering, Yunnan Minzu University, Kunming 650000, China)

Abstract: In view of the weak fault signal of motor bearing components, in order to improve the diagnosis accuracy, a diagnosis method based on improved AO (sky eagle algorithm) optimized MCKD (maximum correlation kurtosis deconvolution) is proposed. First, the noise signal is reduced by the MCKD algorithm with optimized parameters; secondly, the envelope spectrum of the fault signal is analyzed and diagnosed; finally, the bearing fault signal that is submerged by strong noise is accurately extracted. The experimental results show that compared with other classical optimization algorithms, the IAO-MCKD method can effectively enhance the fault characteristics and accurately extract the fault signal, and the method has the characteristics of fast convergence speed and more flexible handling of local optimal problems.

Key words: motor bearing; MCKD algorithm; AO algorithm; envelope spectrum; fault diagnosis

0 引言

针对电机轴承的故障研究, 目前有短时傅里叶变换与小波分析^[1]、最小熵反卷积^[2]、变分模态分解^[3]等。其中最小熵反卷积(MED)广泛应用于轴承的故障诊断^[4]。但MED对周期信号存在一定缺陷, 为了能有效提取周期性脉冲分量, 抑制信号噪声的影响, McDonald等2012年在MED的基础上提出了最大相关峭度反卷积(MCKD)^[5]。该方法以相关峭度值作为评价指标, 提取有用信号从而达到降噪目的。目前, MCKD已在滚动轴上对旋转机械零件, 如轴承^[6]、齿轮^[7]故障诊断时取得了显著成效。但MCKD参数的选择需要人工的设置, 且参数的不同对算法的影响较大, 为充分发挥MCKD算法的降噪性能, 提取有效信号, 文献[8]中采用粒子群算法实现了MCKD参数滤波器阶数 L 和周期 T 的自适应选择, 但其方法收敛速度较慢, 且容易陷入局部最优。

综上所述, 使用MCKD对信号进行处理时, 往往需要确定滤波器阶数 L , 周期 T 和位移数 M 等主要参

数。针对以上情况, 为了提高MCKD降噪效果, 本文提出了一种新的方法: 采用改进AO算法优化MCKD, 通过构造适应度函数, 对滤波器阶数 L 和周期 T 等参数实现自适应选择, 从而解决了人工选择参数对MCKD算法所造成的影响, 将改进后的AO算法与经典的天鹰算法^[9]、粒子群算法^[10]和麻雀算法^[11]做了对比实验, 实验证明, 改进后的AO算法具有收敛速度更快, 处理陷入局部最优问题更灵活等特点。

1 最大相关峭度反卷积

电机轴承故障信号可表达为:

$$y(k) = x(k) + e_n \quad (1)$$

式中, $y(k)$ 为传感器采集的观测信号; $x(k)$ 为轴冲击序列; e_n 为噪声分量。

最大相关峭度反卷积(maximum correlated kurtosis deconvolution)算法的实质是利用相关峭度来提取脉冲序列, 解决了峭度受单个或部分高阶脉冲的影响及无法全面考虑故障信号的周期性和连续性等问题。最大相关峭度可定义为:

收稿日期: 2021-11-08; 修回日期: 2021-12-20

* 基金项目: 国家自然科学基金项目(61761049, 61261022)

作者简介: 刘福康(1998—), 男, 硕士研究生, 研究方向为轴承诊断 (E-mail) liu18266277899@163.com; 通信作者: 杨光永(1970—), 男, 副教授, 博士, 研究方向为机器人学、传感器等 (E-mail) guangyong_yang@126.com。

$$CK_M(T) = \frac{\sum_{n=1}^N (\prod_{m=0}^M y_{n-mT})^2}{(\sum_{n=1}^N y_n^2)^{M+1}} \quad (2)$$

式中, T 为冲击信号周期; N 为样本信号个数; M 为位移数。

由式(2)可以看出相关峭度受周期 T 和滤波器阶数 L 的影响, 为寻找最有滤波器 $f(n)$, 从而使原始信号 $x(n)$ 的相关峭度最大, 因此式(2)可以更新为:

$$\max_f CK_M(T) = \max_f \frac{\sum_{n=1}^N (\prod_{m=0}^M y_{n-mT})^2}{(\sum_{n=1}^N y_n^2)^{M+1}} \quad (3)$$

式中, $f = (f_1 \ f_2 \ f_3 \ f_4 \ \dots \ f_L)^T$; L 为滤波器的阶数。

为确定最优滤波器 $f(n)$, 使得 $CK_M(T)$ 最大, 式(3)求得:

$$\frac{d}{df_k} CK_M(T) = 0 \quad k = 1, 2, \dots, L \quad (4)$$

最终求得滤波器系数结果为:

$$f = \frac{\|y\|^2}{2\| \beta \|^2} (x_0 x_0^T)^{-1} \sum_{m=0}^M X_{mT} \alpha_m \quad (5)$$

式中:

$$\alpha_m = \begin{bmatrix} y_{1-mT}^{-1} (y_1^2 y_{1-T}^2 \dots y_{1-MT}^2) \\ y_{2-mT}^{-1} (y_2^2 y_{2-T}^2 \dots y_{2-MT}^2) \\ \vdots \\ y_{N-mT}^{-1} (y_N^2 y_{N-T}^2 \dots y_{N-MT}^2) \end{bmatrix}$$

$$\beta = \begin{bmatrix} y_1 y_{1-T} \dots y_{1-MT} \\ y_2 y_{2-T} \dots y_{2-MT} \\ \vdots \\ y_N y_{N-T} \dots y_{N-MT} \end{bmatrix}$$

滤波器阶数 N 和反卷积周期 T 是 MCKD 的两个重要参数, 周期 T 的大小决定了 MCKD 能否提高故障频率。在处理不同信号时, 由于信号的特性各不相同, 参数的选择也并不固定, 因此需要根据信号的特性确定 MCKD 的参数, 周期 T 由采样频率和故障特征频率的比值确定即:

$$T = \frac{f_s}{f_g} \quad (6)$$

式中, f_s 为采样频率; f_g 为故障特征频率。

但实际问题中噪声信号往往是复杂多变的, 周期 T 的值与理论值存有一定误差, 且 T 和 L 互相影响, 所以在使用 MCKD 算法对噪声信号进行处理时, 周期 T 和滤波器阶数 L 的选择是信号处理结果的关键, 参数选择的不同, 导致信号处理的结果也大不相同。因此, 为解决 MCKD 算法的局限性, T 和 L 进行适应性选择的研究具有重要意义。

2 改进天鹰算法优化 MCKD

2.1 天鹰优化算法

天鹰算法(aquila optimizer)是一种新的元启发式优化算法, 该方法具有强大的搜索能力, 收敛性强, 处理问题灵活等特点。在 AO 中, 优化规则从候选种群开始如式(7)所示, 其候选解在给定问题的上界(UB)

和下界(LB)之间随机生成, 在每次迭代中, 最优解被确定为近似最优解。

(1) 拓展探索: 天鹰识别猎物区域, 并通过高跃和垂直弯曲来选择最佳狩猎区域。其表达式为:

$$X_i(t+1) = X_{best}(t) \times (1 - \frac{t}{T}) + (X_M(t) - X_{best}(t)) * rand \quad (7)$$

式中, X_i 为第 i 个解的决策值; $X_{best}(t)$ 为迭代之前得到的最优解; t 和 T 分别为当前迭代次数和最大迭代次数; $(1 - \frac{t}{T})$ 为控制扩展搜索通过迭代解的数量; $X_M(t)$ 为当前迭代解的平均值。

(2) 缩小探索范围: 当从高空发现猎物区域时, 天鹰在目标猎物上方盘旋, 准备着陆, 然后攻击。其表达式为:

$$X_2(t+1) = X_{best}(t) \times levy(D) + X_R(t) + (y - x) * rand \quad (8)$$

式中, $X_R(t)$ 是迭代在 $1 \sim N$ 范围内取的随机解;

$levy(D) = s \times \frac{u \times \sigma}{|v|^{\frac{1}{\beta}}}$; s 是固定为 0.01 的常数; U, V 是

0 ~ 1 之间的随机数。 σ 的取值由式(11)决定:

$$\sigma = \frac{\Gamma(1 + \beta) \times \sin(\frac{\pi\beta}{2})}{\Gamma(\frac{1+\beta}{2}) \times \beta \times 2^{(\frac{\beta-1}{2})}} \quad (9)$$

式中, β 是一个固定为 1.5 的常量; Γ 为标准的伽马函数。

(3) 扩大开发: 当猎物区域被精确捕捉时, 天鹰准备着陆和攻击, 垂直下降, 进行初步攻击, 观察猎物的反应。其表达式为:

$$X_3(t+1) = (X_{best}(t) - X_M(t)) \times \alpha - rand + ((UB - LB) \times rand + LB) \times \delta \quad (10)$$

式中, α 和 δ 是开采调整参数, 其值较小, 在 (0, 1) 的范围内。

(4) 缩小开发范围: 当天鹰接近猎物时, 天鹰根据自己的随机运动在陆地上空攻击猎物。其表达式为:

$$X_4(t+1) = QF \times X_{best}(t) - (G_1 \times X(t) \times rand) - G_2 \times levy(D) + rand \times G_1 \quad (11)$$

$$QF(t) = t^{\frac{2 \times rand() - 1}{(1-t)^2}};$$

$$G_1 = 2 \times rand - 1; G_2 = 2 \times (1 - \frac{t}{T}) \quad (12)$$

式中, $QF(t)$ 是迭代时的函数值。

2.2 Tent 混沌映射

在天鹰初始化种群的过程中, 由于采取的是随机分布, 所以会使初始种群个体分布不均匀, 容易导致算法陷入局部最优, 降低算法的全局搜索能力, 而混沌变量则具有随机性、遍历性和规律性等特点^[12], 且 Tent 映射比 Logistic 映射遍历均匀, 寻优效果更好, Tent 映射具有严格的数学推导过程, 所以采用 Tent 映射作为天鹰算法的混沌序列。

Tent 映射的表达式为:

$$x_{i+1} = \begin{cases} 2x_i & 0 \leq x_i \leq \frac{1}{2} \\ 2(1 - x_i) & \frac{1}{2} \leq x_i \leq 1 \end{cases} \quad (13)$$

Tent 映射经过伯努利移位变换后其表达式为:

$$x_{i+1} = (2x_i) \bmod 1 \quad (14)$$

2.3 IAO-MCKD 诊断流程

本文将滤波器阶数 L 和周期 T 作为待优化参数,以最大峭度作为适应度函数,假设天鹰在一个二维空间内进行搜索,判断猎物的情况,通过迭代不断更新个体位置,将 AO 算法引入 Tent 混沌搜索后,增强了算法的搜索能力,可以有效避免其陷入局部最优,从而以较快的速度和稳定性搜索到目标参数。

首先,初始化种群并引入混沌映射,确定待优化参数的上下界,并对参数 $[L, T]$ 的取值进行寻优,寻找到最佳的线性组合 $[L_0, T_0]$; 然后,对获取的样本进行降噪处理;最后,对信号进行解调,诊断故障类型,确定故障部位。

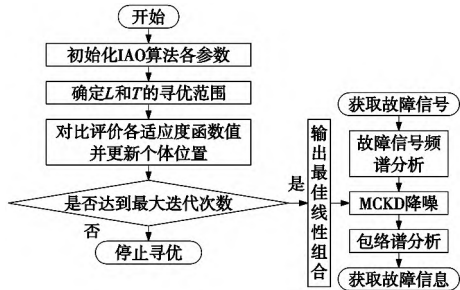


图1 基于 IAO-MCKD 诊断流程图

3 实例分析

为验证本文方法的有效性,以机械故障预防技术学会(MFPT)的轴承故障数据集进行试验并验证。

表1 轴承结构参数

轴承型号	滚轮直径/mm	间距直径/mm	元素数/个	接触角度/(°)
NICE	23.50	12.45	8	0

在该轴承中输入轴速率为 25 Hz,采样速率 48 828,持续时间 $sps = 3$ s。根据表 1 的轴承结构参数,计算出内圈故障频率 f_i 和外圈故障频率 f_o 分别为 81.13 Hz 和 118.7 Hz。

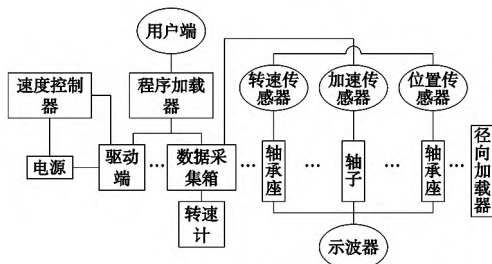


图2 NICE 实验原理平台

图 2 为实验台原理,实验台中的传感器可以采集多种类型的原始数据,包括转速振动数据、位移振动数据、加速度数据,传感器收集的原始数据存储于数据采集箱,为了模拟轴承的不同故障,实验采用电刻度方法分别在实验轴承的内圈和外圈刻划划痕来模拟故障特征,所采集试验信号的内圈和外圈的时域波形和频谱图,分别如图 3 和图 4 所示,从图中可以看出时域信号由于受到较强噪声的干扰几乎无法观测出任何冲击成分,频谱图也无法分析出故障脉冲信号成分。面对此情况便无法分析出故障特征,本文采用改进 AO 算法对 MCKD 算法中的两个参数:滤波器阶数和周期进行寻优,输出得到最佳线性组合后,再对信号进行降噪处理,得到信号故障特征。

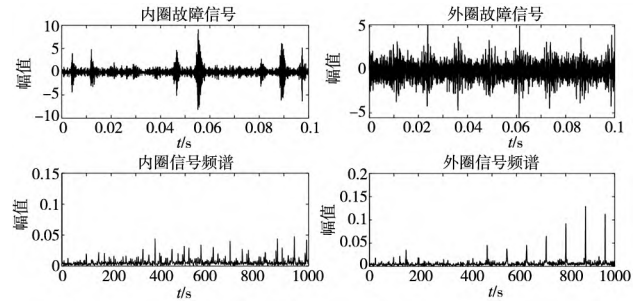


图3 内圈故障信号及频谱图

3.1 内圈故障诊断

通过改进后的 AO 算法对 MCKD 算法参数进行寻优后,得到最佳线性组合 $[L_0, T_0]$,将滤波器阶数设置为 $L = 399$,周期设置为 $T = 91$,通过参数优化后 MCKD 算法处理后的信号结果如图 5 所示,从时域信号可以看出内圈信号经过参数优化后的 MCKD 降噪处理,去噪效果以及故障冲击成分都更加明显,通过图 6 对信号进行包络谱分析可以分析得出 $f_1 \approx f_i$,且可以基本分析出 $f_1 \sim f_6$ 甚至更多的频率成分。




图5 内圈故障处理后信号




图6 内圈故障处理后信号包络谱

为验证 IAO-MCKD 方法对轴承内圈故障提取的有效性,将滤波器阶数和周期的线性组合设置为 $L_1 = 245; T_1 = 104$,处理后的信号包络谱如图 7 所示,图中只能分析出 $f_1 \sim f_4$,无法分析出更多的倍频成分。




图7 随机参数处理的内圈信号包络谱

3.2 外圈故障诊断

采用如 3.1 节相同的方法,对轴承外圈故障信号进行分析,通过改进后的 AO 算法对 MCKD 算法参数进行寻优后,将滤波器阶数设置为 $L = 398$,周期设置为 $T = 214$,处理后的信号结果图如图 8 所示。

可以明显看出通过优化后的 MCKD 算法,对故障信号进行处理后,冲击成分更突出,如图 9 所示外圈故障信号处理后的频谱图中故障特征频率 f_o 及其倍频的谱线清晰可见。




图8 外圈故障处理后信号

同样,为验证 IAO-MCKD 方法对轴承外圈故障信号提取的有效性,将滤波器阶数和周期的线性组合设置为 $L_1 = 298$; $T_1 = 114$, 处理后的信号包络谱如图 10 所示。




图 9 外圈故障处理后信号

图 10 随机参数处理的外圈信号包络谱

图中无法分析出有效的故障频率成分。从而验证了所提出的 IAO-MCKD 方法对轴承故障提取的优越性以及有效性。

3.3 实验对比

将 IAO-MCKD 方法与现有的基于 PSO 优化 MCKD 和 SSA 优化 MCKD 分别进行内圈寻优迭代次数和外圈寻优迭代次数对比,如图 11 和图 12 所示。




图 11 内圈寻优对比结果图




图 12 外圈寻优对比结果图

可以看出无论是内圈还是外圈寻优, AO 算法都表现出了强大的搜索能力和其最优特性。在寻找最优参数时, AO 算法通过跳出局部最优达到全局最优,收敛速度明显比 PSO 算法和 SSA 算法要快, AO 算法经过 Tent 混沌映射改进后,初始个体位置更均匀,增强了算法的搜索能力,在面对陷入局部最优解问题时, IAO 算法表现的比 AO 算法、PSO 算法和 SSA 算法更灵活。

4 结束语

在面对噪声干扰时,通过合理设置天鹰算法的目标参数及适应度函数来优化 MCKD 中滤波器阶数和周期等参数,可以有效解决无法提取被强噪声干扰的故障冲击信号,并且规避了人为选择参数可能造成的影响,从

而有效提取轴承内圈、外圈的故障信号周期频率成分。

通过实验分析, IAO 算法具有强大的搜索能力且收敛速度快,面对陷入局部最优解问题时, IAO 算法表现更灵活,可以有效避免陷入局部最优,从而证明了 IAO-MCKD 方法在诊断被强噪声掩盖的故障信号方面的优越性与必要性。

【参考文献】

- [1] 王普, 李天焱, 高学金, 等. 分层自适应小波阈值轴承故障信号降噪方法[J]. 振动工程学报, 2019, 32(3): 548-556.
- [2] 何林. 基于最小熵反卷积的齿轮故障增强检测技术研究[D]. 长沙: 国防科技大学, 2017.
- [3] 张瑞林, 涂兴华. 二次谐波的变分模态分解和小波阈值函数降噪[J]. 光学学报, 2022, 42(2): 80-87.
- [4] 乔志城, 刘永强, 廖英英. 改进经验小波变换与最小熵解卷积在铁路轴承故障诊断中的应用[J]. 振动与冲击, 2021, 40(2): 81-90, 118.
- [5] MCDONALD G L, ZHAO Q, ZUO M J. Maximum correlated kurtosis deconvolution and application on gear tooth chip fault detection[J]. Mechanical Systems and Signal Processing, 2012, 33(11): 237-255.
- [6] ZHANG G, WANG H, ZHANG T Q. Cascaded nonlinear mass fluctuation stochastic resonance system and its application in bearing fault diagnosis[J]. Fluctuation and Noise Letters, 2021, 20(5): 2150045.
- [7] 李东东, 刘宇航, 赵阳, 等. 基于改进生成对抗网络的风机行星齿轮箱故障诊断方法[J]. 中国电机工程学报, 2021, 41(21): 7496-7507.
- [8] 唐贵基, 王晓龙. 自适应最大相关峭度解卷积方法及其在轴承早期故障诊断中的应用[J]. 中国电机工程学报, 2015, 35(6): 1436-1444.
- [9] ABUALIGAH L, YOUSRI D, ELAZIZ M A, et al. Matlab code of aquila optimizer: A novel meta-heuristic optimization algorithm[J]. Computers & Industrial Engineering, 2021, 157(7): 107250.
- [10] 栗龙强. 基于粒子群优化 MCKD 的机车齿轮故障诊断方法研究[D]. 石家庄: 石家庄铁道大学, 2020.
- [11] 尹德鑫, 张达敏, 蔡朋宸, 等. 改进的麻雀搜索优化算法及其应用[J/OL]. 计算机工程与科学: 1-8 [2022-05-11]. <http://kns.cnki.net/kcms/detail/43.1258.TP.20210930.1242.002.html>.
- [12] 刘道华, 原思聪, 兰洋, 等. 混沌映射的粒子群优化方法[J]. 西安电子科技大学学报, 2010, 37(4): 764-769.

(编辑 祝智铭)

(上接第 70 页)

- [4] RICHMAN J S, RANDALL M J. Physiological time-series analysis using approximate entropy and sample entropy[J]. American Journal of Physiology Heart & Circulatory Physiology, 2000, 278(6): 2039-2049.
- [5] CHEN W T, ZHUANG J, YU W X, et al. Measuring complexity using FuzzyEn, ApEn, and SampEn[J]. Medical Engineering & Physics, 2009, 31(1): 61-68.
- [6] BANDT C, POMPE B. Permutation entropy: A natural complexity measure for time series[J]. Physical Review Letters, 2002, 88(17): 174102.
- [7] 郑近德, 程军圣, 杨宇. 基于多尺度熵的滚动轴承故障诊断方

法[J]. 湖南大学学报(自然科学版), 2012, 39(5): 38-41.

- [8] 郑近德, 陈敏均, 程军圣, 等. 多尺度模糊熵及其在滚动轴承故障诊断中的应用[J]. 振动工程学报, 2014, 27(1): 145-151.
- [9] 郑近德, 程军圣, 杨宇. 多尺度排列熵及其在滚动轴承故障诊断中的应用[J]. 中国机械工程, 2013, 24(19): 2641-2646.
- [10] WANG F R, SONG G B. Monitoring of multi-bolt connection looseness using a novel vibro-acoustic method[J]. Nonlinear Dynamics, 2020, 100(10): 243-254.
- [11] YUAN R, LV Y, KONG Q Z, et al. Percussion-based bolt looseness monitoring using intrinsic multiscale entropy analysis and BP neural network[J]. Smart Materials and Structures, 2019, 28(12): 125001.

(编辑 祝智铭)