

# 基于 PSO-VMD-MCKD 方法的风机轴承 微弱故障诊断<sup>\*</sup>

张俊<sup>1</sup>, 张建群<sup>1</sup>, 钟敏<sup>1</sup>, 郑近德<sup>2</sup>, 李习科<sup>1</sup>

(1.福州大学机械工程及自动化学院 福州,350116) (2.安徽工业大学机械工程学院 马鞍山,243032)

**摘要** 针对风机滚动轴承微弱故障信号所具有的非线性和非平稳特征及易被强背景噪声掩盖的特点,提出了一种变分模态分解(variational modal decomposition,简称VMD)和最大相关峭度解卷积(maximum correlated kurtosis deconvolution,简称MCKD)相结合的滚动轴承微弱故障诊断方法。为实现VMD和MCKD的参数自适应选择,采用粒子群优化算法(particle swarm optimization,简称PSO),对两种算法中的参数进行优化。首先,利用PSO优化VMD算法中的 $\alpha$ 和 $K$ ,再基于VMD对微弱故障信号分解后的结果,选取最优模态分量;其次,利用PSO优化MCKD算法中的 $L$ 和 $T$ ,再基于MCKD算法加强最优分量信号中的故障冲击成分;最后,通过包络谱提取出轴承微弱故障特征。仿真和试验均表明,此方法能够自适应增强轴承微弱故障中的冲击成分,有效提取出被强噪声淹没的轴承微弱故障特征。

**关键词** 故障诊断;滚动轴承;变分模态分解;最大相关峭度解卷积;粒子群优化

**中图分类号** TH133.3

## 引言

风机滚动轴承故障是影响风电机组正常运行的重要因素之一<sup>[1-2]</sup>。由于风机轴承早期故障产生的冲击十分微弱,易被系统噪声干扰,加上滚动轴承的振动传递路径复杂,使得其故障特征的提取非常困难。因此,如何有效地对滚动轴承原始故障信号进行降噪并增强信号中微弱冲击成分,是进行该类部件早期故障诊断的关键<sup>[3-4]</sup>。

风机滚动轴承故障信号为非线性、非平稳信号,针对这一类信号,学者们提出了多种处理方法。何巍等<sup>[5]</sup>将改进小波降噪用于齿轮微弱故障提取。Yu等<sup>[6]</sup>将经验模态分解(empirical mode decomposition,简称EMD)与改进的局部Fisher判别分析相结合,开展了轴承的故障诊断。刘永强等<sup>[7]</sup>通过集合经验模态分解分解(ensemble empirical mode decomposition,简称EEMD)-分量重构-包络解调,实现了滚动轴承的早期故障诊断。杜冬梅等<sup>[8]</sup>提出了局部均值分解(local mean decomposition,简称LMD)与增强包络谱相结合的滚动轴承的故障诊断

方法。尽管上述各方法在滚动轴承故障诊断时取得了一定效果,但仍存在下列问题:①小波变换,难以根据实际信号实现小波基及分解层数的自适应选择;②EMD,EEMD,LMD等都属于递归模态分解,且缺乏严格的数学理论。针对上述非线性信号处理方法的不足,Dragomiretskiy等<sup>[9]</sup>提出了一种新的非递归式模态分解算法,即变分模态分解(VMD),可有效避免EMD等信号分解产生的模态混叠、端点效应等问题。此后,Liu等<sup>[10]</sup>将VMD与消除趋势波动分析结合,实现了信号降噪。

最小熵解卷积(minimum entropy deconvolution,简称MED)<sup>[11]</sup>通过保留信号的冲击成分,提取信号的故障特征。张龙等<sup>[12]</sup>将MED算法与谱峭度算法结合提取了滚动轴承微弱特征。为避免MED只能突出少数大的尖端脉冲,而导致其他冲击丢失的问题,Mcdonald等<sup>[13]</sup>提出了MCKD算法。MCKD通过解卷积运算突出被噪声淹没的连续冲击脉冲,提高原始信号的相关峭度值,非常适用于提取微弱故障信号的连续瞬态冲击。文献<sup>[14]</sup>先采用MCKD算法,再对解卷积后的信号进行VMD降噪,成功地诊断出轴承微弱故障。

<sup>\*</sup> 国家自然科学基金资助项目(51375013)

收稿日期:2018-05-05;修回日期:2018-08-05

需要指出的是,VMD算法和MCKD算法需要人为设置一些参数,且参数的取值对算法的影响非常大<sup>[15-16]</sup>。具体而言,VMD算法需要设置惩罚因子 $\alpha$ 和模态分解个数 $K$ ;MCKD需要提前设置滤波长度参数 $L$ 和解卷积周期 $T$ 。文献[17]采用试验方法确定VMD两个参数,但是该研究并未考虑 $\alpha$ 和 $K$ 的交互作用。文献[18]采用粒子群算法实现了MCKD参数 $L$ 和 $T$ 的自适应选择,但未给出解卷积周期 $T$ 的寻优范围。

为充分发挥VMD在降噪方面的优越性及MCKD能突出被噪声所掩盖的连续脉冲的优点,文中拟将这两种方法相结合,用于风机轴承微弱故障的诊断。为提高诊断效果,采用粒子群优化算法,以包络谱峰值因子作为适应度函数,对两种算法需要确定的参数进行全局寻优。以滚动轴承内圈微弱故障为例,采用PSO-VMD-MCKD算法先对仿真信号分析,然后搭建风机滚动轴承模拟实验台架,对实测信号进行诊断。在此基础上,证明PSO,VMD,MCKD结合的必要性,并对比PSO-VMD-MCKD方法与其他方法的诊断效果。

## 1 PSO-VMD-MCKD方法

### 1.1 VMD原理及算法流程

VMD是一种完全非递归模式的信号分解方法,通过迭代搜索变分模型中的最优解,将一个实际信号 $x$ 分解成 $K$ 个离散的模态 $u_k$ ,并且确定每个模态分量的中心频率 $\omega_k$ 和带宽。模型构造及求解步骤如下。

1) 由Hilbert变换计算每个模态 $u_k(t)$ 的解析信号,从而获得模态分量的单边频谱

$$\left(\delta(t) + \frac{j}{\pi t}\right) * u_k(t) \quad (1)$$

其中: $\delta(t)$ 为脉冲函数; $t$ 为时间; $j$ 为虚数单位;“\*”表示卷积。

2) 向单边频谱添加一个指数项 $e^{-j\omega_k t}$ 进行频率混合,将各模态的频谱调制到相应的基频带

$$\left[\left(\delta(t) + \frac{j}{\pi t}\right) * u_k(t)\right] e^{-j\omega_k t} \quad (2)$$

3) 计算解调信号的梯度,用其二范数平方,来估计各模态信号的带宽。所有分量相加等于原信号作为约束条件,约束变分模型描述如下

$$\begin{cases} \min_{\{u_k\}, \{\omega_k\}} \left\{ \sum_{k=1}^K \left\| \partial_t \left[ \left( \delta(t) + \frac{j}{\pi t} \right) * u_k(t) \right] e^{-j\omega_k t} \right\|_2^2 \right\} \\ \text{s.t.} \sum_{k=1}^K u_k = x \end{cases} \quad (3)$$

其中: $\{u_k\} = \{u_1, \dots, u_K\}$ ;  $\{\omega_k\} = \{\omega_1, \dots, \omega_K\}$ ;  $\partial_t(\cdot)$ 表示函数对 $t$ 求偏导。

4) 为求解式(3)的变分模型,引入拉格朗日乘子 $\lambda(t)$ 及二次惩罚因子 $\alpha$ ,将约束性变分问题变为非约束性变分问题。其中, $\lambda(t)$ 能够增强约束严格性, $\alpha$ 能够有效地降低高斯噪声干扰。扩展的拉格朗日表达式为

$$\begin{aligned} \mathcal{L}(\{u_k\}, \{\omega_k\}, \lambda) = & \alpha \sum_{k=1}^K \left\| \partial_t \left[ \left( \delta(t) + \frac{j}{\pi t} \right) * u_k(t) \right] e^{-j\omega_k t} \right\|_2^2 + \\ & \left\| x(t) - \sum_{k=1}^K u_k(t) \right\|_2^2 + \left\langle \lambda(t), x(t) - \sum_{k=1}^K u_k(t) \right\rangle \end{aligned} \quad (4)$$

5) 运用交替方向乘子算法(alternate direction method of multiplies,简称ADMM),不断迭代更新 $\{u_k^{n+1}\}, \{\omega_k^{n+1}\}, \lambda^{n+1}$ 寻求式(4)的“鞍点”。迭代方法为

$$u_k^{n+1} = \underset{u_k}{\operatorname{argmin}} \mathcal{L}(\{u_g^{n+1}\}, \{u_g^n\}, \{\omega_g^n\}, \lambda^n) \quad (5)$$

$$\omega_k^{n+1} = \underset{\omega_k}{\operatorname{argmin}} \mathcal{L}(\{u_g^{n+1}\}, \{u_g^n\}, \{\omega_g^{n+1}\}, \lambda^n) \quad (6)$$

$$\lambda^{n+1} = \lambda^n + \Gamma \left( x - \sum_{k=1}^K u_k^{n+1} \right) \quad (7)$$

$$\sum_{k=1}^K \|u_k^{n+1} - u_k^n\|_2^2 / \|u_k^n\|_2^2 < \varepsilon \quad (8)$$

其中: $n$ 为迭代次数; $g \in [1, K]$ ;  $\Gamma$ 为更新因子; $\varepsilon$ 为一个大于0的正数,代表精度。

式(8)为更新 $\{u_k^{n+1}\}, \{\omega_k^{n+1}\}$ 及 $\lambda^{n+1}$ 的收敛条件。

6) 利用Parseval/Plancherel傅里叶等距变换;对式(5)~(7)求解得

$$\hat{u}_k^{n+1}(\omega) = \frac{\hat{x}(\omega) - \sum_{g>k} \hat{u}_g^{n+1}(\omega) - \sum_{g<k} \hat{u}_g^{n+1}(\omega) + \frac{\hat{\lambda}^n(\omega)}{2}}{1 + 2\alpha(\omega - \omega_k^n)^2} \quad (9)$$

$$\omega_k^{n+1} = \frac{\int_0^\infty \omega |\hat{u}_k^{n+1}(\omega)|^2 d\omega}{\int_0^\infty |\hat{u}_k^{n+1}(\omega)|^2 d\omega} \quad (10)$$

$$\hat{\lambda}^{n+1}(\omega) \leftarrow \hat{\lambda}^n(\omega) + \Gamma \left( \hat{x}(\omega) - \sum_k \hat{u}_k^{n+1}(\omega) \right) \quad (11)$$

其中: $\hat{u}_k^{n+1}(\omega), \hat{x}(\omega), \hat{\lambda}^n(\omega)$ 分别为 $u_k^{n+1}, x(t), \lambda^n$ 所对应的傅里叶变换。

VMD算法是将各模态分量频域不断更新,然后通过傅里叶逆变换到时域。

综上所述,可制定VMD的具体实施流程如下:

- 1) 初始化  $\{u_k^1\}, \{\omega_k^1\}, \lambda^1, n=0$ ;
- 2)  $n=n+1$ , 开始整个算法的循环;
- 3)  $k=k+1$ , 直到  $k=K$ , 根据式(5), (6) 更新

$u_k, \omega_k$ ;

- 4) 根据式(7)更新  $\lambda$ ;

5) 根据式(8), 判断是否满足收敛条件, 如果满足收敛条件则停止迭代, 否则返回步骤 2。

## 1.2 MCKD 原理及算法流程

MCKD 算法实质是通过寻找一系列 FIR 滤波器  $f_l$ , 使得原始周期性冲击序列的相关峭度最大。MCKD 算法中, 周期冲击信号  $y_i (i=1, 2, \dots, N)$  的相关峭度定义为

$$CK_M(T) = \frac{\sum_{i=1}^N \left( \prod_{m=0}^M y_{i-mT} \right)^2}{\left( \sum_{i=1}^N y_i^2 \right)^{M+1}} \quad (12)$$

其中:  $T$  为冲击信号周期;  $M$  为移位数;  $m \in [0, M]$ ; 增加  $M$ , 可以增加算法序列脉冲数,  $M$  过大会影响精度, 文中选取  $M=7$ 。

若忽略噪声的影响, 则实际信号  $x_i$  为周期冲击信号  $y_i$  经过周围环境及路径传输的衰减效应所得。最大相关峭度解卷积就是寻找滤波器使实际信号  $x_i$  恢复  $y_i$ , 即

$$y = f' * x = \sum_{l=1}^L f'_l x_{i-l+1} \quad (13)$$

其中:  $y, x$  分别为  $y_i, x_i$  的向量形式;  $f' = [f'_1, \dots, f'_L]^T$ ;  $*$  为卷积;  $L$  为滤波器长度参数;  $l \in [0, L]$ 。

对实际信号进行滤波, 使得相关峭度最大

$$\max_{f'} CK_M(T) = \max_{f'} \frac{\sum_{i=1}^N \left( \prod_{m=0}^M y_{i-mT} \right)^2}{\left( \sum_{i=1}^N y_i^2 \right)^{M+1}} \quad (14)$$

求解式(14), 等价于求解下列方程

$$\frac{d}{df'_l} CK_M(T) = 0 \quad (l=1, 2, \dots, L) \quad (15)$$

由式(13)~(15)可求得滤波器的最终系数, 并表示为矩阵形式

$$f' = \frac{\|y\|^2}{2\beta^2} (X_0 X_0^T)^{-1} \sum_{m=0}^M X_{mT} \psi_m \quad (16)$$

$$\text{其中: } \beta = \begin{bmatrix} y_1 y_{1-T} \cdots y_{1-MT} \\ y_2 y_{2-T} \cdots y_{2-MT} \\ \vdots \\ y_N y_{N-T} \cdots y_{N-MT} \end{bmatrix};$$

$$X_r = \begin{bmatrix} x_{1-r} & x_{2-r} & x_{3-r} & \cdots & x_{N-r} \\ 0 & x_{1-r} & x_{2-r} & \cdots & x_{N-1-r} \\ 0 & 0 & x_{1-r} & \cdots & x_{N-2-r} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & 0 & \cdots & x_{N-L-r+1} \end{bmatrix};$$

$$(\psi_m = \begin{bmatrix} y_{1-mT}^{-1} (y_1^2 y_{1-T}^2 \cdots y_{1-MT}^2) \\ y_{2-mT}^{-1} (y_2^2 y_{2-T}^2 \cdots y_{1-MT}^2) \\ \vdots \\ y_{N-mT}^{-1} (y_N^2 y_{N-T}^2 \cdots y_{N-MT}^2) \end{bmatrix})^\circ$$

综上所述, 可制定 MCKD 算法实施流程如下:

- 1) 初始化解卷积周期  $T$ 、位移数  $M$  及滤波器长度  $L$  等参数;
- 2) 计算输入信号  $x$  的  $X_r, X_0^T, (X_0 X_0^T)^{-1}$ ;
- 3) 计算滤波后的输出信号  $y$ ;
- 4) 根据  $y$  计算  $\psi$  和  $\beta$ ;
- 5) 更新滤波器  $f'$  的系数;
- 6) 若滤波前、后信号的相关峭度值  $\Delta CK_M(T)$  小于阈值, 结束迭代, 否则重复步骤 3~5。

## 1.3 PSO 优化 VMD, MCKD 参数

本研究利用标准粒子群算法对 VMD, MCKD 算法中的参数进行优化。假设粒子  $o$  在一个  $D$  维空间进行搜索, 通过迭代更新寻找最优解; 每一次迭代中, 粒子的信息可用位置向量、速度向量来表示。

第  $o$  个粒子的位置表示为:  $s_o = (s_{o1}, s_{o2}, \dots, s_{oD})^T$ ; 速度表示为:  $v_o = (v_{o1}, v_{o2}, \dots, v_{oD})^T$ 。粒子可根据个体局部极值、种群全局极值来不断更新自己的两个信息, 更新公式为

$$v_{od}^{h+1} = \bar{\omega} v_{od}^h + c_1 \eta (P_{od}^h - s_{od}^h) + c_2 \eta (G_d^h - s_{od}^h) \quad (17)$$

$$s_{od}^{h+1} = s_{od}^h + v_{od}^{h+1} \quad (18)$$

其中:  $o=1, 2, \dots, O$ ;  $h$  为迭代次数;  $v_{od}^h$  为粒子  $o$  第  $h$  次迭代中  $d$  维的速度;  $\bar{\omega} \in [0, 1]$ , 为惯性权重;  $c_1$  和  $c_2$  为学习因子;  $\eta$  为介于区间  $[0, 1]$  的随机数;  $P_{od}^h$  为第  $h$  次迭代中粒子  $o$  在第  $d$  维的个体极值点的位置;  $s_{od}^h$  为第  $h$  次迭代中粒子  $o$  在  $d$  维的当前位置;  $G_d^h$  为第  $h$  次迭代中整个种群在  $d$  维的全局极值的位置。

粒子群算法中惯性权重  $\bar{\omega}$  按照凹函数变化的策略优于常数固定值<sup>[19]</sup>, 文中惯性权重  $\bar{\omega}$  按照凹函数变化。凹函数策略调整  $\bar{\omega}$  可以表述为

$$\bar{\omega} = (\bar{\omega}_{\max} - \bar{\omega}_{\min}) \left( \frac{h}{H} \right)^2 + (\bar{\omega}_{\min} - \bar{\omega}_{\max}) \frac{2h}{H} + \bar{\omega}_{\max} \quad (19)$$

其中:  $\bar{\omega}_{\max}$  为权重最大值;  $\bar{\omega}_{\min}$  为权重最小值;  $h$  为迭

代次数;  $H$  为最大迭代次数。

于是,式(17)变为

$$v_{od}^{h+1} = \left( (\bar{\omega}_{\max} - \bar{\omega}_{\min}) \left( \frac{h}{H} \right)^2 + (\bar{\omega}_{\min} - \bar{\omega}_{\max}) \frac{2h}{H} + \bar{\omega}_{\max} \right) v_{od}^h + c_1 \eta (P_{od}^h - s_{od}^h) + c_2 \eta (G_d^h - s_{od}^h) \quad (20)$$

使用粒子群算法进行优化寻优时,需确定一个适应度函数,整个粒子群是根据适应度的大小来评判最优解。文中采用文献[20]介绍的包络谱峰值因子(crest factor of envelope spectrum,简称 Ec),作为适应度函数。Ec 是一种无量纲指标,同时考虑了信号冲击成分的周期性和强度。假定信号包络谱幅值序列为  $X(z)$  ( $z=1, 2, \dots, Z$ ),则 Ec 可表达为

$$Ec = \frac{\max(X(z))}{\sqrt{\sum_z X(z)^2 / Z}} \quad (21)$$

其中: $X(z)$  为包络谱在  $[f_r, \gamma f_r]$  频率范围的幅值,  $f_r$  取值大于故障轴承所在轴的转频;  $f_r$  为传动系统最大轴承故障频率。

为充分提取周期冲击成分,且考虑轴承冲击成分会有衰减,  $\gamma$  取 4~8。Ec 越大,周期冲击特性越强,故障特征越明显。

PSO 优化 VMD, MCKD 的步骤如图 1 所示。

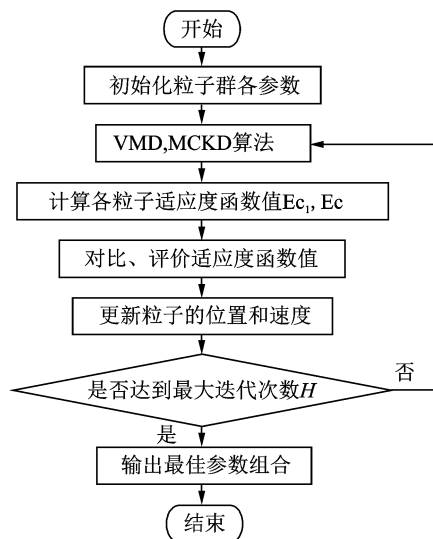


图 1 PSO 优化 VMD, MCKD 步骤

Fig.1 PSO optimization process for the VMD and MCKD

## 2 诊断流程

笔者采用 PSO-VMD-MCKD 方法用于强背景噪声的轴承微弱故障特征提取,具体诊断步骤如下。

1) 对 VMD 参数进行寻优,确定最佳影响参数

$[\alpha_0, K_0]$ 。参考文献[16]并结合实际,粒子群算法中设定的参数大小为:学习因子  $c_1 = c_2 = 2$ ;种群规模  $O=30$ ;  $H$  为最大迭代次数,  $H$  过大则会延长算法计算时间,  $H$  过小则可能导致在终止迭代时,算法仍未收敛,因此文中设定  $H=20$ ;最大权重  $\bar{\omega}_{\max} = 0.900$ ,最小权重  $\bar{\omega}_{\min} = 0.400$ ;粒子群算法对 VMD 参数组合  $[\alpha, K]$  进行寻优,  $\alpha$  的寻优范围为  $[100, 2000]$ ,  $K$  的寻优范围是  $[3, 10]$ 。

2) 对故障信号进行 VMD 分解,确定最优分量包络谱突出频率范围。设定 VMD 算法中的惩罚因子为  $\alpha_0$ ,分量个数为  $K_0$ 。VMD 分解后,计算各分量的包络谱峰值因子,选择 Ec 指标最大的分量为最优分量。对最优分量进行包络解调分析,包络谱中,包含幅值最大频线的频率带为突出频率范围,且频率带是以突出谱线为对称轴的对称区间。

3) 对最优分量进行 MCKD 参数  $[L, T]$  寻优,确定最佳影响参数  $[L_0, T_0]$ 。粒子群算法参数同步骤 1。  $L$  的寻优范围设置为  $[100, 1000]$ ,  $T$  的计算公式为  $T = f_s / f_i$ 。其中:  $f_s$  为采样频率;  $f_i$  为故障特征频率。当未知故障特征频率时,由步骤 2 的突出频率带,确定 MCKD 参数中  $T$  的寻优范围。频率带大小应适中,上边界最大取值略大于整个传动系统中理论轴承最大故障特征频率。

4) 对最优分量进行 MCKD 分析,再对解卷积后的信号进行包络解调。

5) 将轴承理论故障特征频率值与包络谱中峰值明显的谱线进行对照,诊断出故障类型,确定故障部位。

由上述诊断步骤, PSO-VMD-MCKD 方法流程如图 2 所示。

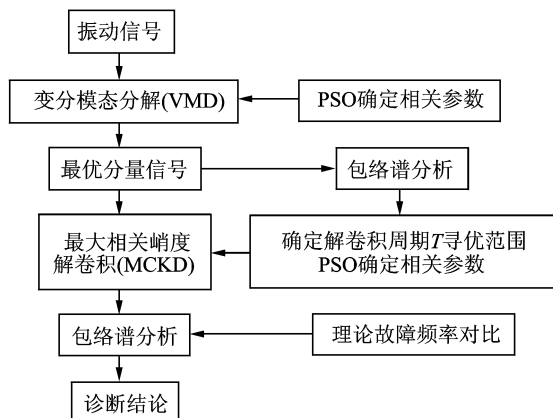


图 2 PSO-VMD-MCKD 方法流程图

Fig.2 The flow chart of the method

### 3 仿真信号分析


为验证文中所提方法正确性,利用滚动轴承故障模型<sup>[11]</sup>模拟风机轴承内圈故障产生的冲击信号,并添加强烈高斯白噪声来模拟实际工况风机被环境噪声所覆盖的微弱故障。仿真信号如下

$$\begin{cases} x(t) = y(t) + n(t) = \sum_{\kappa} A_{\kappa} h(t - \kappa T_1 - \tau_{\kappa}) + n(t) \\ A_{\kappa} = A_0 \sin(2\pi f_r t) + 1 \\ h(t) = \exp(-Ct) \sin(2\pi f_n t) \end{cases} \quad (22)$$

其中: $A_0=0.500$ ;转频 $f_r$ 为25 Hz;衰减系数 $C$ 为800;共振频率 $f_n$ 为4 000 Hz;内圈故障频率 $f_i=1/T_1=120$  Hz; $\tau_{\kappa}$ 为第 $\kappa$ 次冲击相对于周期 $T$ 的微小波动,随机波动服从0均值正态分布,标准差为转频的0.500%; $n(t)$ 为高斯白噪声成分,染噪信号的信噪比设为-16 dB;采样频率 $f_s$ 为12 800 Hz;分析点数为8 192点。


冲击信号及添加噪声后的仿真信号时域波形如图3(a,b)所示,其频谱及包络解调谱如图3(c,d)所示。图3(a)观察出明显的周期冲击;而图3(b)中的周期冲击信号则完全被噪声淹没;图3(c)中频率成分杂乱,很难找到故障信息;图3(d)中难以发现突出频率,无法辨别故障特征。图3(c,d)表明传统谱分析失效。

采用 PSO-VMD-MCKD 方法对仿真信号进行分析,先对 VMD 算法中的两个参数 $[\alpha, K]$ 进行寻优。由式(22)中的参数,设定优化 VMD 中的适应度函数求解的包络谱频率范围为 $[50, 800]$ 。图4(a)为局部最大包络谱峰值因子 $Ec_1$ 随种群进化迭代数变化的曲线,纵坐标 $Ec_1$ 为无量纲指标。PSO 算法优化 VMD 在第13代收敛,搜索到的局部最大包络谱峰值因子为4.848,最佳参数组合为 $[1\ 420, 9]$ 。根据寻优结果,设定 VMD 算法中的惩罚因子 $\alpha_0=1\ 420$ ,分量个数 $K_0=9$ ;对仿真信号进行 VMD 处理,得到9个分量。计算每个分量包络谱峰值因子,通过图4(b)各分量幅值图,可以比较出分量6为最优分量。对分量6进行包络谱分析,结果如图4(c)所示,可以观察到的突出谱线有:120,265 Hz,显然120 Hz突出谱线幅值最大,故认为120 Hz为最可能接近故障特征频率。在轴承故障信号包络谱中,出现故障频率 $f_i$ 及其倍频才能确保诊断方法准确有效,避免错诊。图中并未出现120 Hz倍频成分,无法确定120 Hz即为故障频率。




(a) 冲击信号

(a) Shock signal




(b) 仿真信号

(b) Simulated signal



(c) 仿真信号频谱

(c) Spectrum of the simulated signal



(d) 仿真信号的包络谱

(d) Envelope spectrum of the simulated signal



图3 仿真信号的波形及谱图

Fig.3 Time waveform and spectrum of the simulated signal


为凸显参数优化 VMD 的优越性,对仿真信号进行 EMD 分析,得到13个分量。分别计算各分量的 $Ec$ 指标,取 $Ec$ 指标最大者为最优分量,对其进行包络解调分析,结果见图5。

由图5可以看出,突出谱线的频率值均较低。对比图4(c),图5的突出频率范围并不包含故障特征频率。

为避免错诊,应做进一步分析。根据图4(c)幅值最大的突出谱线即120 Hz,选择包含120 Hz的频率带作为突出频率范围。频率带选择过大,会增加参数 $T$ 的寻优时间,降低计算效率;频率带选择过小,则有可能不包含故障特征频率。因此选取

(a)  $E_c$ 指标随迭代次数变化的关系曲线(a) Curve of  $E_c$  index with the number of iterations

(b) 各分量包络谱峰值因子幅值

(b) The amplitude of the  $E_c$  index for each mode

(c) 最优分量包络谱

(c) Envelope spectrum of optimal mode

图4 优化VMD分析结果

Fig.4 Analytical results of optimized VMD






图5 EMD 最优分量包络谱

Fig.5 The envelope spectrum of the optimal component of EMD


频率带 $[90, 150]$ 作为求解 $T$ 的频率范围,计算出MCKD优化参数 $T$ 的范围为 $[85, 142]$ ,再对MCKD参数组合 $[L, T]$ 进行全局寻优。图6(a)为优化MCKD算法的包络谱峰值因子值 $E_c$ 随种群进化迭代数变化的曲线,纵坐标 $E_c$ 为无量纲指标。从中可以观察到,粒子群优化算法在第16代收敛,其最优参数组合为 $[675, 105]$ 。因此,在MCKD算法中设定滤波器长度参数 $L=675$ ,解卷积周期 $T=105$ ,得到MCKD处理后的时域波形和包络谱如图6(b,c)所示。

(C) 2014-2015 China Academic Electronic Publishing House. All rights reserved. http://www.cnki.net

(a)  $E_c$ 指标随迭代次数变化的关系曲线(a) Curve of  $E_c$  index with the number of iterations

(b) MCKD处理后的时域波形

(b) Time domain waveform after MCKD processing



(c) MCKD处理后的包络谱

(c) Envelope spectrum after MCKD processing

图6 本方法分析仿真信号最终结果

Fig.6 The final result of simulated signal analyzed by the method

到。解卷积后的包络谱中故障特征频率 $f_i$ 及其2倍频、3倍频、...、8倍频的谱线均清晰可见,表明特征频率被准确提取,从而验证了本方法的正确性。

为验证文中PSO优化MCKD算法中自适应滤波所得结果的可靠性,更改MCKD两个最佳参数其中一个,如将滤波器长度参数 $L$ 由675改成605(按照寻优范围10%内改变),即设置 $[L, T]$ 为 $[605, 105]$ 。经过MCKD分析后,进行包络解调,结果如图7所示。

从图7中虽观测出故障特征频率 $f_i$ ,但其周围存在许多干扰谱线,且其倍频不够突出,故障特征不




图7 更改参数后的包络谱

Fig.7 The envelope spectrum after changed the param-



能够充分被提取,表明笔者使用粒子群算法优化 MCKD 结果可靠。

为验证笔者所提出的优化 VMD 算法和优化 MCKD 算法结合的必要性,对仿真信号不做优化 VMD 预处理,基于 PSO 优化 MCKD 对仿真信号进行分析。同图 6(c)设置解卷积周期  $T$  的寻优范围为  $[85, 142]$ ,使对比更加有说服力。PSO 算法得到最优的参数组合为  $L=555, T=92$ 。将最佳参数组合输入到 MCKD 算法中,仿真信号包络谱图见图 8。




图 8 直接优化 MCKD 包络谱

Fig. 8 The envelope spectrum of directly optimized MCKD

显然,图 8 中的突出频率成分并非对应故障频率及其倍频,表明直接优化 MCKD 算法可能在强背景噪声下难以提取轴承微弱故障,反向证明了笔者所提出的优化 VMD 和优化 MCKD 结合的必要性。

## 4 试验信号分析

采用美国 Spectra Quest 公司开发的风力发电模拟系统(wind turbine simulator, 简称 WTS)进行轴承内圈故障试验。如图 9 所示,试验台主要由电机、叶片、行星齿轮箱平行轴齿轮箱、以及发电机组成。内圈故障轴承型号为 ER-12K,主要承受径向载荷。电机提供的输入转速为 0.798 Hz,采样频率




图 9 WTS 试验台

Fig. 9 WTS Experiment Platform

$f_s$  为 12 800 Hz,采样点数为 8 192 点。

试验故障轴承的结构参数见表 1。可由下列公式计算轴承内圈故障频率系数,该系数与轴承所在轴的转频相乘即可得到理论内圈故障特征频率

$$f_{ip} = \frac{Z_n}{2} \left( 1 + \frac{\bar{d}}{D} \cos \theta \right) \quad (23)$$

其中: $f_{ip}$  为轴承内圈故障频率系数; $Z_n$  为滚动体个数; $\bar{d}$  为滚动体直径; $D$  为轴承节径; $\theta$  为接触角。

表 1 轴承结构参数

Tab.1 Structure parameters of rolling bearing

轴承型号	轴承节径/mm	滚动体直径/mm	滚动体个数	接触角/(°)
ER-12K	33.477	7.938	8	0

在该风机传动系统中,行星齿轮箱传动比为 4.571;平行轴齿轮箱第 1 级传动比为 2.683,第 2 级传动比为 1.210。根据表 1 的轴承结构参数,计算出故障频率系数为 4.950,理论轴承内圈故障频率  $f_i = 48.444$  Hz。为确定在优化算法中求解适应度函数的频率范围,计算出整个传动系统中轴的最大转速为 11.842 Hz,轴承理论最大故障频率为 57.816 Hz。向测点 1 采集的信号中添加 -4 dB 的高斯白噪声,作为文中分析的实验信号,以此来模拟该风机被噪声掩盖的微弱故障信号。

试验信号时域波形、频谱图如图 10(a,b)所示。时域波形中几乎观测不出任何冲击成分,而在频谱图中,也无规律可循。对信号进一步进行包络解调分析,如图 10(c)所示,也未发现突出频率成分。

用本方法对试验信号进行分析,先采用 PSO 对 VMD 算法中的两个参数  $[\alpha, K]$  进行寻优。取适应度函数求解频率范围为  $[15, 300]$ ,最后得到局部最大包络谱峰值因子  $E_{c1}$  为 3.439,最佳影响参数组合  $[\alpha_0, K_0]$  为  $[1\ 090, 10]$ 。根据搜索结果设定 VMD 算法中的惩罚因子为 1 090,分量个数为 10。

对试验信号进行 VMD 处理,得到 10 个分量,计算每个分量的  $E_c$  指标。通过图 11(a)比较包络谱峰值因子的大小,从而判断分量 9 为最优分量。对分量 9 进行包络分析,最优分量包络谱如图 11(b)所示。从中观测出在 45.330 Hz 有明显的突出谱线,其幅值较其他谱线都大,但因为其倍频不够明显突出,不能确定 45.330 Hz 为轴承故障频率。为了避免错诊,应做进一步分析。

选取频率带  $[30, 60]$  作为求解  $T$  的频率范围,从而计算出 MCKD 优化参数  $T$  的范围为  $[213, 427]$ 。最后得到最大幅值为 4.839,得到的最优参数

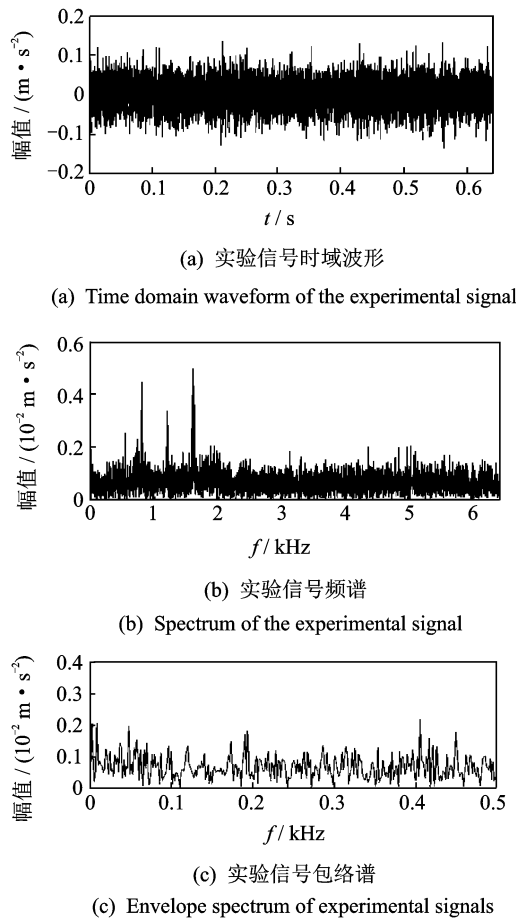


图10 实验信号的波形及谱图

Fig.10 Time waveform and spectrum of experimental signal

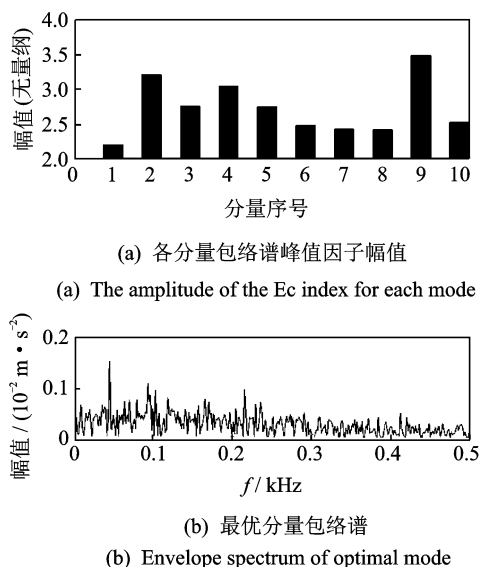


图11 优化VMD分析结果

Fig.11 The analytical results of optimized VMD

组合为[820, 267]。设置 MCKD 算法中滤波器长度参数  $L=820$ , 解卷积周期  $T=267$ , 得到最大相关峭度解卷积后实验信号的时域波形和包络谱如图 12(a, b) 所示。




图12 实验信号最终分析结果

Fig.12 The results of final analysis of experimental signals

图 12(a) 中, 信号冲击成分明显增多; 在图 12(b) 故障特征频率  $f_i$  及其倍频的谱线均清晰可见; 内圈故障特征信息被准确提取。

文献[12]采用 MED 算法结合谱峭度法实现了轴承微弱故障的提取; 采用文献[12]方法对试验信号进行分析, 并与 PSO-VMD-MCKD 方法诊断效果进行对比。文献[13]表明, 在 MCKD 算法中, 当  $T=0$ ,  $M=1$  时, MCKD 算法则退化为 MED 算法。MED 算法主要受滤波器长度这一个参数的影响, 为使对比结果更有说服力, 设置 MED 滤波长度与图 12(b) 相同, 即取滤波长度  $L$  为 820。图 13(a) 为采用 MED 算法后得到的包络谱图, 从中可以发现故障特征频率及其 2 倍频, 但周围杂频较多, 且幅值不够突出。

再用谱峭度法对滤波后信号进行分析, 谱峭度图见图 13(b), 纵坐标级数为无量纲单位。图中色块颜色的深浅, 代表了在不同滤波器参数  $[f_c, \Delta f]$  下滤波信号的谱峭度值, 右侧的颜色深度坐标即是谱峭度, 为无量纲指标。由图 13(b) 可知, 谱峭度图中色块颜色最深位于第 6.600 级 (白色椭圆虚线标记处), 对应滤波器中心  $f_c$  为 1 950 Hz, 带宽  $\Delta f$  为 100 Hz。设置带通滤波的范围是 1 900 ~ 2 000 Hz, 图 13(c) 为最终滤波包络谱。显然, 该图观测不出与故障频率相关的信息, 表明 MED 结合谱峭度法在强背景噪声下, 可能难以提取轴承微弱故障, 从而反向验证了文中所提优化 VMD 结合优化 MCKD 在强背景噪声的微弱故障提取的优越性和有效性。



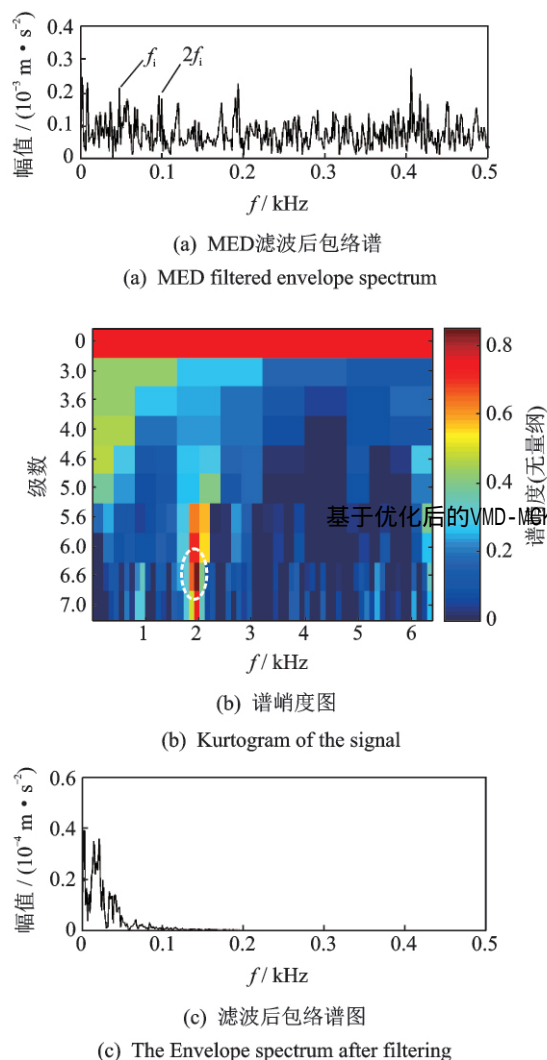


图13 MED结合谱峭度法分析结果

Fig.13 The results of MED combined with SK

## 5 结束语

在强背景噪声下,EMD方法难以有效地提取轴承微弱故障特征,而基于 PSO 优化的 VMD 能够有效抑制噪声成分,突出瞬态冲击。基于 PSO 优化的 MCKD 能够增强被噪声干扰的冲击成分,且能够避免人为选择参数导致的错误诊断结果。在 PSO 算法中,限定适应度函数求解范围,能够避免随机突出频率对两种寻优算法的影响。在强背景噪声下,仅采用优化 VMD 方法或直接采用优化 MCKD 都难以准确地提取出故障特征,而 PSO-VMD-MCKD 方法能够准确诊断出强背景噪声下的风机滚动轴承微弱故障。

## 参 考 文 献

- [1] WANG J, PENG Y, QIAO W, et al. Bearing fault diagnosis of direct-drive wind turbines using multiscale filtering spectrum[J]. IEEE Transactions on Industry Applications, 2017, 53(3): 3029-3038.

- [2] 赵洪山,刘辉海.基于性能改善深度置信网络的风电机组主轴承状态分析[J]. 电力自动化设备, 2018, 38(2): 44-49.

ZHAO Hongshan, LIU Huihai. Condition analysis of wind turbine main bearing based on deep belief network with improved performance[J]. Electric Power Automation Equipment, 2018, 38(2): 44-49. (in Chinese)

- [3] 吕中亮,汤宝平,周忆,等.基于网格搜索法优化最大相关峭度反卷积的滚动轴承早期故障诊断方法[J]. 振动与冲击, 2016, 35(15): 29-34.

LÜ Zhongliang, TANG Baoping, ZHOU Yi, et al. Rolling bearing early fault diagnosis based on maximum correlated kurtosis deconvolution optimized with grid search algorithm[J]. Journal of Vibration and Shock, 2016, 35(15): 29-34. (in Chinese)

- [4] LI J, ZHANG Y, XIE P. A new adaptive cascaded stochastic resonance method for impact features extraction in gear fault diagnosis [J]. Measurement, 2016, 91: 499-508.

- [5] 何巍,袁亮,章翔峰.改进小波去噪-Teager 算子的齿轮微弱故障提取方法[J]. 振动、测试与诊断, 2018, 38(1): 155-213.

HE Wei, YUAN Liang, ZHANG Xiangfeng. Weak fault diagnosis method of gearbox based on improved wavelet denoising-Teager energy operator[J]. Journal of Vibration, Measurement & Diagnosis, 2018, 38(1): 155-213. (in Chinese)

- [6] YU X, DONG F, DING E, et al. Rolling bearing fault diagnosis using modified LFDA and EMD with sensitive feature selection[J]. IEEE Access, 2018, 6: 3715-3730.


- [7] 刘永强,李翠省,廖英英.基于 EEMD 和自相关函数峰态系数的轴承故障诊断方法[J]. 振动与冲击, 2017, 36(2): 111-116.

LIU Yongqiang, LI Cuixing, LIAO Yingying. Fault diagnosis method for rolling bearings based on EEMD and autocorrelation function kurtosis [J]. Journal of Vibration and Shock, 2017, 36(2): 111-116. (in Chinese)

- [8] 杜冬梅,张昭,李红,等.基于 LMD 和增强包络谱的滚动轴承故障分析[J]. 振动、测试与诊断, 2017, 37(1): 92-96.

DU Dongmei, ZHANG Zhao, LI Hong, et al. Fault diagnosis for roller bearing based on local mean decomposition and enhanced envelope spectrum[J]. Journal

- of Vibration, Measurement & Diagnosis, 2017, 37(1): 92-96. (in Chinese)
- [9] DRAGOMIRETSKIY K, ZOZZO D. Variational mode decomposition[J]. IEEE Transactions on Signal Processing, 2014, 62(3): 531-544.
- [10] LIU Y, YANG G, LI M, et al. Variational mode decomposition denoising combined the detrended fluctuation analysis[J]. Signal Processing, 2016, 125: 349-364.
- [11] 王宏超, 陈进, 董广明. 基于最小熵解卷积与稀疏分解的滚动轴承微弱故障特征提取[J]. 机械工程学报, 2013, 49(1): 88-94.  
WANG Hongchao, CHEN Jin, DONG Guangming. Fault diagnosis method for rolling bearing's weak fault based on minimum entropy deconvolution and sparse decomposition[J]. Journal of Mechanical Engineering, 2013, 49(1): 88-94. (in Chinese)
- [12] 张龙, 胡俊峰, 熊国良. 基于 MED 和 SK 的滚动轴承循环冲击特征增强[J]. 振动、测试与诊断, 2017, 37(1): 97-101.  
ZHANG Long, HU Junfeng, XIONG Guoliang. Cyclic shock enhancement by the combination of minimum entropy deconvolution and spectral kurtosis[J]. Journal of Vibration, Measurement & Diagnosis, 2017, 37(1): 97-101. (in Chinese)
- [13] MCDONALD G L, ZHAO Q, ZUO M J. Maximum correlated kurtosis deconvolution and application on gear tooth chip fault detection [J]. Mechanical Systems & Signal Processing, 2012, 33(1): 237-255.
- [14] 夏均忠, 赵磊, 白云川, 等. 基于 MCKD 和 VMD 的滚动轴承微弱故障特征提取[J]. 振动与冲击, 2017, 36(20): 78-83.  
XIA Junzhong, ZHAO Lei, BAI Yunchuan, et al. Feature extraction for rolling element bearing weak fault based on MCKD and VMD[J]. Journal of Vibration and Shock, 2017, 36(20): 78-83. (in Chinese)
- [15] 唐贵基, 王晓龙. 参数优化变分模态分解方法在滚动轴承早期故障诊断中的应用[J]. 西安交通大学学报, 2015, 49(5): 73-81.  
TANG Guiji, WANG Xiaolong. Parameter optimized variational mode decomposition method with application to incipient fault diagnosis of rolling bearing[J]. Journal of Xi'an Jiaotong University, 2015, 49(5): 73-81. (in Chinese)
- [16] 陈昆弘, 刘小峰. 基于循环相关和 LPSO 算法的自适应 MCKD 方法的滚动轴承早期故障特征提取[J]. 振动与冲击, 2017, 36(22): 80-85.  
CHEN Kunhong, LIU Xiaofeng. Incipient fault diagnosis of rolling element bearing based on adaptive maximum correlated kurtosis deconvolution[J]. Journal of Vibration and Shock, 2017, 36(22): 80-85. (in Chinese)
- [17] 郑小霞, 周国旺, 任浩翰, 等. 基于变分模态分解和排列熵的滚动轴承故障诊断[J]. 振动与冲击, 2017, 36(22): 22-28.  
ZHENG Xiaoxia, ZHOU Guowang, REN Haohan, et al. A rolling bearing fault diagnosis method based on variational mode decomposition and permutation entropy[J]. Journal of Vibration and Shock, 2017, 36(22): 22-28. (in Chinese)
- [18] 唐贵基, 王晓龙. 自适应最大相关峭度解卷积方法及其在轴承早期故障诊断中的应用[J]. 中国电机工程学报, 2015, 35(6): 1436-1444.  
TANG Guiji, WANG Xiaolong. Adaptive maximum correlated kurtosis deconvolution method and its application on incipient fault diagnosis of bearing[J]. Proceedings of the CSEE, 2015, 35(6): 1436-1444. (in Chinese)
- [19] 陈贵敏, 贾建援, 韩琪. 粒子群优化算法的惯性权值策略研究[J]. 西安交通大学学报, 2006, 40(1): 53-56.  
CHEN Guimin, JIA Jianyuan, HAN Qi. Study on the strategy of decreasing inertia weight in particle swarm optimization algorithm[J]. Journal of Xi'an Jiaotong University, 2006, 40(1): 53-56. (in Chinese)
- [20] 张龙, 熊国良, 黄文艺. 复小波共振解调频带优化方法和新指标[J]. 机械工程学报, 2015, 51(3): 129-138.  
ZHANG Long, XIONG Guoliang, HUANG Wenyi. New procedure and index for the parameter optimization of complex wavelet based resonance demodulation [J]. Journal of Mechanical Engineering, 2015, 51(3): 129-138. (in Chinese)



第一作者简介: 张俊, 男, 1981 年 7 月生, 博士、教授、博士生导师, 主要研究方向为机械动力学、机械传动与机器人机构学。曾发表《Resultant vibration signal model based fault diagnosis of a single stage planetary gear train with an incipient tooth crack on the sun gear》《Renewable Energy》2018, Vol. 122 等论文。

E-mail: zhang\_jun@fzu.edu.cn

## Bearing Real-Time Condition Monitoring and Fault Feature Extraction Using SAX-LZC

WEI Xiang, LI Benwei

(Aeronautical foundation College, Naval Aeronautics and Astronautics University Yantai, 264001, China)

**Abstract** Aiming at the need for real-time monitoring of bearing vibration, the monitoring parameter which fused symbolic aggregation approximation and Lempel-ziv complexity is proposed from symbolic dynamical point of view. Using Logistic map and Duffing equations as objects, the accuracy of SAX-LZC for dynamic structural characterization is verified from theoretical perspective, and the anti-noise ability and computational efficiency are verified also. Based on this, a comprehensive comparison of SAX-LZC with dynamic parameters such as information entropy, sample entropy, and multi-segment Lempel-ziv complexity is performed. The weak early abnormality of the bearing is monitored and the faults characteristic of the bearing are extracted from the experimental perspective. Theoretical research results show that SAX-LZC has the advantages of accurate dynamic structural characterization, good anti-noise ability, and high computational efficiency. It overcomes the weak application of conventional dynamic parameters. The experimental results show that the SAX-LZC accurately monitors early weak anomalies, and has good distinguishing ability for different types of faults. It remedies the shortcomings of time and frequency domains' insufficient representation ability to characterize bearing weak abnormalities. Therefore, it is an effective parameter for real-time monitoring and fault feature extraction of bearing vibration.

**Keywords** bearing; vibration condition monitoring; fault feature extraction; symbolic aggregation approximation; Lempel-ziv complexity

## PSO-VMD-MCKD Based Fault Diagnosis for Incipient Damage in Wind Turbine Rolling Bearing

ZHANG Jun<sup>1</sup>, ZHANG Jianqun<sup>1</sup>, ZHONG Min<sup>1</sup>, ZHENG Jinde<sup>2</sup>, LI Xike<sup>1</sup>

(1. School of Mechanical Engineering and Automation, Fuzhou University Fuzhou, 350116, China)

(2. School of Mechanical Engineering, Anhui University of Technology Maanshan, 243032, China)

**Abstract** The incipient damage of wind turbine rolling bearings is very difficult to be detected, because the fault signals are nonlinear, nonstationary, and likely to be buried by strong background noise. In light of this problem, a comprehensive methodology that combines variational modal decomposition (VMD) and maximum correlated kurtosis deconvolution (MCKD) is presented. The parameters of VMD and MCKD are selected automatically by the particle swarm optimization algorithm (PSO). First, the optimal  $\alpha$  and  $K$  in VMD are calculated by PSO, and the most sensitive modal is selected according to the VMD decomposition of incipient fault signals. Then, the optimal  $L$  and  $T$  in MCKD algorithm are calculated by PSO so as to boost the fault shock in the modal. Finally, the incipient fault feature is extracted from the envelope demodulation of the faults. Simulation results as well as experimental tests both validate that the proposed method can adaptively enhance the weak fault component of rolling bearing, thus can effectively extract incipient fault features of rolling bearings from strong background noise.

**Keywords** fault diagnosis; rolling bearing; variational mode decomposition; maximum correlated kurtosis deconvolution; particle swarm optimization