

# 基于参数优化 VMD 和多尺度排列熵的齿轮故障诊断

谢棕, 张丽萍

(福州大学 机械工程及自动化学院 福建 福州 350108)

**摘 要:** 针对齿轮故障特征在单一尺度难以全面提取的问题, 提出一种基于参数优化的变分模态分解和多尺度排列熵的齿轮故障诊断方法。利用改进的蝙蝠算法对变分模态分解中的参数  $K$  和  $\alpha$  进行全局寻优, 以局部极小包络熵作为适应度值, 搜寻  $K$  和  $\alpha$  的最优组合。经 VMD 分解得到既定的若干 IMF 分量, 分别计算其相应的多尺度排列熵, 构建故障特征向量, 输入到极限学习机进行训练和识别, 进而实现齿轮的故障诊断。实验表明, 该方法具有非常好的分类性能, 故障诊断效果显著。

**关键词:** 变分模态分解; 多尺度排列熵; 改进蝙蝠算法; 极限学习机; 故障诊断

**中图分类号:** TH132.41      **文献标志码:** A      **文章编号:** 1671-5276(2021)06-0114-04

## Gear Fault Diagnosis Based on Parameter Optimization VMD and Multi-scale Permutation Entropy

XIE Zong, ZHANG Liping

(School of Mechanical Engineering and Automation, Fuzhou University, Fuzhou 350108, China)

**Abstract:** As to the difficulty in fully extracting gear fault features at a single scale, a parameter optimization-based variational mode decomposition and multi-scale permutation entropy gear fault diagnosis are proposed. The improved bat algorithm is used to optimize the parameters  $K$  and  $\alpha$  sums in the variational modal decomposition globally, and the local minimum envelope entropy is used as the fitness value to search for the optimal combination of  $K$  and  $\alpha$  sums. After VMD decomposition, a number of established IMF components are obtained, and the corresponding multi-scale permutation entropy is calculated respectively, and the fault feature vector is constructed, which is input to the extreme learning machine for training and identification, and the gear fault diagnosis is realized. The experiments show that the proposed method has very good classification performance and significant fault diagnosis effect.

**Keywords:** VMD; MPE; improved bat algorithm; ELM; fault diagnosis

## 0 引言

齿轮及齿轮箱作为机械设备常用的调节转速和传递转矩的旋转机械设备, 不仅能够传递较大的功率和载荷, 而且具有较好的可靠性<sup>[1]</sup>。但是在高精度的切削加工中, 当齿轮在变转速、变载荷等复杂工况下工作, 极易受到损伤、产生磨损、断齿等情况, 使得加工精度大打折扣。因此, 齿轮的状态监测和故障诊断变得尤为重要。

齿轮的故障信号多为非线性、非平稳信号。经验模态分解(EMD)和集合经验模态分解(EEMD)在分析非线性、非平稳信号时具有良好的优越性, 但是存在严重的端点效应和模态混叠问题<sup>[2]</sup>。基于此, DRAGOMIRETSKIY K<sup>[3]</sup>在2014年提出一种自适应、非递归模式的信号分解方法——变分模态分解(variational mode decomposition, VMD), 它很好地解决了EMD算法存在的问题, 并且具有更坚实的数学理论基础。但VMD算法在分解过程中会

同时受分解参数  $K$  和惩罚因子  $\alpha$  这两个参数的影响。因此, 如何快速、准确地确定这两个参数是研究的重点。刘长良等<sup>[4]</sup>提出一种观察中心频率的方法确定分解参数  $K$  值, 当开始出现中心频率相近时, 认为出现了过分解, 以此来确定  $K$  值, 但却忽略了惩罚因子  $\alpha$  对分解结果的影响。瞿红春等<sup>[5]</sup>利用手动寻优对 VMD 参数进行优化, 先假定  $\alpha$  不变, 不断寻优  $K$  值使得包络熵最小, 再将此  $K$  值设为定值, 不断寻优  $\alpha$  值使得包络熵最小, 得出分解参数  $K$  和惩罚因子  $\alpha$ 。但这样得出的  $K$  和  $\alpha$  并不是最优值, 且工作量巨大。基于以上分析, 本文提出以 IMF 分量局部包络熵最小为优化目标, 利用改进的蝙蝠算法优化 VMD 分解参数  $K$  和惩罚因子  $\alpha$ , 进而得到最优的分解参数, 通过计算  $K$  个 IMF 分量的多尺度排列熵(multiscale permutation entropy, MPE)构造故障特征向量, 输入到极限学习机(extreme learning machine, ELM)进行训练和识别, 进而实现齿轮的故障诊断。

基金项目: 福建省自然科学基金项目(2019J05024)

第一作者简介: 谢棕(1997—), 男, 江西吉安人, 硕士研究生, 研究方向为故障诊断。

# 1 参数优化 VMD

## 1.1 VMD 原理

VMD 分解是一种非递归模式的信号分解方法,通过迭代搜寻约束变分模型最优解,将输入信号  $f$  分解成  $k$  个离散的模态  $u_k(t)$ ,使得每个模态的估计带宽之和最小,约束条件为各模态之和等于输入信号  $f$ 。

构造相应的约束变分模型如下:

$$\begin{cases} \min_{\{u_k\}, \{\omega_k\}} \left\{ \sum_k \left\| \partial_t \left[ \left( \delta(t) + \frac{j}{\pi t} \right) * u_k(t) \right] e^{-j\omega_k t} \right\|^2 \right\} \\ \text{s.t.} \sum_k u_k = f \end{cases} \quad (1)$$

其中:  $\{u_k\} = \{u_1, \dots, u_k\}$  表示分解得到的  $k$  个模态函数;  $\{\omega_k\} = \{\omega_1, \dots, \omega_k\}$  表示各模态分量的中心频率<sup>[6]</sup>。

为求解式(1)的最优解,引入拉格朗日乘法算子  $\lambda(t)$  以及二次惩罚因子  $\alpha$ ,将约束性变分问题变为非约束性变分问题。 $\lambda(t)$  让约束条件保持严格性,  $\alpha$  能充分减少高斯噪声对信号的干扰:

$$L(\{u_k\}, \{\omega_k\}, \lambda) = \alpha \sum_k \left\| \partial_t \left[ \left( \delta(t) + \frac{j}{\pi t} \right) * u_k(t) \right] e^{-j\omega_k t} \right\|^2 + \left\| f(t) - \sum_k u_k(t) \right\|^2 + \langle \lambda(t), f(t) - \sum_k u_k(t) \rangle \quad (2)$$

利用交替方向乘子算法不断迭代更新各个模态及其中心频率<sup>[7]</sup>,寻求式(2)的靶点。具体实现算法如下( $n$  为迭代次数):

1) 初始化  $\{u_k^1\}$ 、 $\{\omega_k^1\}$ 、 $\lambda^1$  和  $n$ 。

2) 迭代  $k=1:K$  并更新各模态信号  $u_k$  和中心频率  $\omega_k$ ,  $i \in [1:K]$ 。

更新  $u_k$ :

$$\hat{u}_k^{n+1}(\omega) = \frac{\hat{f}(\omega) - \sum_{i < k} \hat{u}_i^{n+1}(\omega) - \sum_{i > k} \hat{u}_i^n(\omega) + \frac{\hat{\lambda}^n(\omega)}{2}}{1 + 2\alpha(\omega - \omega_k^n)^2} \quad (3)$$

更新  $\omega_k$ :

$$\omega_k^{n+1} = \frac{\int_0^\infty \omega |\hat{u}_k^{n+1}(\omega)|^2 d\omega}{\int_0^\infty |\hat{u}_k^{n+1}(\omega)|^2 d\omega} \quad (4)$$

3) 根据下式更新  $\lambda$ ,  $\Gamma$  为更新因子

$$\hat{\lambda}^{n+1}(\omega) = \hat{\lambda}^n(\omega) + \Gamma [\hat{f}(\omega) - \sum_k \hat{u}_k^{n+1}(\omega)] \quad (5)$$

4) 若满足下方收敛条件则停止迭代,否则重复 1)、2),  $\varepsilon$  为  $>0$  的正数。

$$\sum_k (\|u_k^{n+1} - u_k^n\|_2^2 / \|u_k^n\|_2^2) < \varepsilon \quad (6)$$

结束迭代,得到  $K$  个 IMF 分量。

## 1.2 改进蝙蝠算法

蝙蝠算法(bat algorithm, BA)是由英国学者 YANG X S<sup>[8]</sup> 在 2010 年提出的一种群智能优化算法。BA 算法把求解问题目标函数的适应度值度量成蝙蝠个体所处位置的优劣。最优解类比蝙蝠的猎物,脉冲响度和频率的变化在

一定程度上表明与最优解的靠近程度。

在 BA 算法中,搜索频率、位置和速度的更新公式如下:

$$f_i = f_{\min} + (f_{\max} - f_{\min}) \beta \quad (7)$$

$$v_i^{t+1} = v_i^t + (x_i^t - x^*) f_i \quad (8)$$

$$x_i^{t+1} = x_i^t + v_i^{t+1} \quad (9)$$

其中:  $f_i$ 、 $f_{\max}$ 、 $f_{\min}$  分别表示第  $i$  只蝙蝠当前时刻发出的声波频率以及声波频率的最大值与最小值;  $\beta \in [0, 1]$  的随机数;  $x^*$  表示当前最优位置。

在局部搜索中,如果一个蝙蝠选择了一个最优解,那么将在此最优解附近随机产生一个新解:

$$X_{\text{new}} = X_{\text{old}} + \varepsilon A^t \quad (10)$$

其中:  $X_{\text{old}}$  为从当前最优解中选择一个解;  $A^t$  为  $t$  时刻所有蝙蝠响度的平均值;  $\varepsilon$  是  $[-1, 1]$  的一个随机数。

蝙蝠脉冲的响度  $A_i$  和速率  $r_i$  通过下式计算:

$$A_i^{t+1} = \alpha A_i^t \quad (11)$$

$$r_i^{t+1} = r_i^0 (1 - e^{-\gamma}) \quad (12)$$

其中:  $\alpha$  和  $\gamma$  是常数,并且  $0 < \alpha < 1$ ,  $\gamma > 0$ 。响度  $A_i$  和速率  $r_i$  的持续迭代更新表明与最优解的靠近程度。

蝙蝠算法能够在算法运行的前期通过将全局优化转换到局部优化来实现算法的快速收敛,这同时也会导致该算法过早地处于停滞阶段。为改善这样的问题,本文在速度更新公式(8)中引入了线性递减惯性权重  $\omega(k)$  的概念:

$$v_i^{t+1} = \omega(k) v_i^t + (x_i^t - x^*) f_i \quad (13)$$

$$\omega(k) = w_{\max} (w_{\max} - w_{\min}) (T_{\max} - k) / T_{\max} \quad (14)$$

其中:  $\omega_{\max}$  为初始惯性权重;  $\omega_{\min}$  为迭代至最大次数时的惯性权重;  $k$  为当前迭代次数;  $T_{\max}$  为最大迭代次数。查阅相关文献知  $\omega_{\max} = 0.9$ ,  $\omega_{\min} = 0.4$  时算法性能最好<sup>[9]</sup>。迭代初期较大的初始惯性权重使算法保持了较强的全局搜索能力,而迭代后期较小的惯性权重有利于算法进行更精确的局部搜索。

## 1.3 VMD 参数优化

VMD 分解前,需要预先设定分量个数  $K$  和惩罚因子  $\alpha$  的值。 $K$  和  $\alpha$  的取值不同,会有不同的分解结果。 $K$  值过小,会造成模态混叠;  $K$  值过大,会产生虚假分量。 $\alpha$  值过小,各 IMF 分量的带宽越大;  $\alpha$  值过大,各 IMF 分量的带宽越小。因此,如何确定合适的  $K$  和  $\alpha$  的值是研究的关键所在。

利用蝙蝠算法对 VMD 进行参数优化时,需要选定一个适应度函数。本文采用 VMD 分解后的局部极小包络熵作为蝙蝠算法的适应度函数,搜寻最优的 VMD 参数组合。信号  $p_j$  的包络熵  $E_p$  可以表示成:

$$E_p = - \sum_{j=1}^N p_j \lg(p_j) \quad (15)$$

$$p_j = \frac{a(j)}{\sum_{j=1}^N a(j)} \quad (16)$$

$$a(j) = \sqrt{x^2(j) + \hat{x}^2(j)} \quad (17)$$

式中:  $p_j$  是  $a(j)$  的概率分布序列;  $a(j)$  为信号  $x(j)$  经过 Hilbert 解调后得到的包络信号。

改进 BA 算法优化 VMD 参数步骤如下:

步骤 1 BA 算法基本参数初始化。主要有种群大小  $s_{izepop}$ 、最大迭代次数  $\max g_{en}$ 、参数  $\alpha$  和  $K$  的搜索范围、最大脉冲响应度  $A_0$ 、最大脉冲速率  $r_0$ 、脉冲频率范围、音量的衰减系数  $\alpha$  以及搜索频率的增强系数  $\gamma$ 。

步骤 2 初始化种群,以局部极小包络熵作为适应度函数求出一组最优的  $\alpha$  和  $K$ 。

步骤 3 根据式(7)、式(13)、式(9)不断迭代更新种群的搜索脉冲频率、速度和位置。

步骤 4 生成均匀分布随机数  $r_{and}$ ,如果  $r_{and} > r_i$ ,则对当前最优解进行随机扰动,产生一个新的解。

步骤 5 如果计算出来的包络熵小于所得出的极小包络熵,对最优的  $\alpha$  和  $K$  以及最小的包络熵进行更新,然后按式(11)、式(12)对响度和频率进行更新。

步骤 6 重复步骤 3-步骤 5,直至达到最大迭代次数以及确定最小的包络熵值,得出最佳参数  $\alpha$  和  $K$ 。

## 2 多尺度排列熵

排列熵是由 BANDT C 等<sup>[10]</sup>提出的一种衡量一维时间序列复杂度的平均熵参数,常用来提取机械故障的特征。但齿轮及齿轮箱运转过程中的故障特征信息分布在多尺度中,仅用单一尺度的排列熵进行分析,会遗漏其余尺度上的故障特征信息。

针对排列熵的不足,COSTA M 等<sup>[11]</sup>提出了多尺度排列熵的概念。多尺度排列熵是在排列熵的基础上将时间序列进行多尺度粗粒化,然后计算不同尺度下粗粒化序列的排列熵,具体计算过程如下:

1) 假设有一段长度为  $N$  的时间序列  $X = \{x_i, i = 1, 2, \dots, N\}$  对其进行粗粒化处理,得到粗粒化序列  $y_j^{(s)}$ :

$$y_j^{(s)} = \frac{1}{s} \sum_{i=(j-1)s+1}^{js} x_i, j = 1, 2, \dots, [N/s] \quad (18)$$

式中:  $s$  为尺度因子;  $[N/s]$  表示取整。

2) 对  $y_j^{(s)}$  进行时间序列重构可得

$$Y_l = \{y_l^{(s)}, y_{l+\tau}^{(s)}, \dots, y_{l+(m-1)\tau}^{(s)}\} \quad (19)$$

式中:  $l$  表示第  $l$  个重构的分量;  $\tau$  表示延迟时间;  $m$  表示嵌入维数。

3) 将式(19)得到的重构时间序列按升序排列可得

$$S(g) = (j_1, j_2, \dots, j_m) \quad (20)$$

其中:  $g = 1, 2, \dots, k$  ( $k \leq m!$ )。  $S(g)$  共有  $m!$  种不同的排列方式,但是按升序排列的概率为  $m!$  中的一种。计算每一种符号序列出现的概率  $P_g = \{g = 1, 2, \dots, k\}$ ,  $\sum_{g=1}^k P_g = 1$ 。此时时间序列  $\{x(i), i = 1, 2, \dots, N\}$  按照 Shannon 熵的形式定义为

$$H_p(m) = - \sum_{g=1}^k P_g \ln P_g \quad (21)$$

4) 当  $P_g = 1/m!$  时,每种符号序列的概率都相等,此时时间序列的复杂程度最高,排列熵最大,为  $\ln m!$ 。为方便表示,通常会将  $H_p(m)$  进行归一化处理,即

$$H_p = H_p(m) / \ln(m!) \quad (22)$$

$H_p$  的取值范围为  $[0, 1]$ ,  $H_p$  的大小反映了时间序列

的复杂和随机程度。 $H_p$  越大,说明时间序列越随机,反之,说明时间序列越规则。

## 3 算法流程

本文提出基于参数优化 VMD 和多尺度排列熵的齿轮故障诊断方法,具体步骤如下:

1) 利用改进的蝙蝠算法优化 VMD 分解参数  $K$  和惩罚因子  $\alpha$ ,进而得到最优的分解参数,得到  $K$  个模态分量  $IMF_1, IMF_2, \dots, IMF_K$ 。

2) 计算被选模态分量的多尺度排列熵,选取合适尺度的排列熵值作为故障特征向量。

3) 将故障特征向量输入到已经训练好的极限学习机中进行训练和识别。

故障诊断流程如图 1 所示。

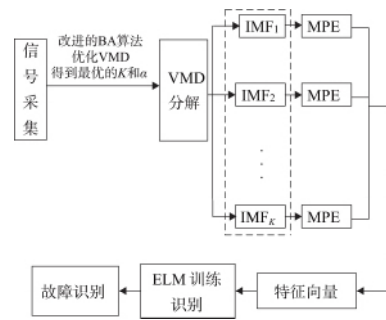


图 1 齿轮故障诊断流程

## 4 实验分析

### 4.1 实验说明

为了验证本文所提方法的有效性,在实验平台下(图 2)采集试验台减速箱齿轮不同状态下的实时振动信号。齿轮减速箱型号为 JZQ200,采样频率为 8 200 Hz。选择齿轮正常、不平衡、松动、错位、断齿、裂痕这 6 种不同状态的数据进行实验验证。



图 2 齿轮实验平台

### 4.2 故障特征提取

以减速箱齿轮出现裂痕为分析对象,本文在以下的实验选取的蝙蝠算法参数均为:  $s_{izepop} = 36$ , 参数  $\alpha$  和  $K$  的搜索范围  $l_{ow} = [1, 500]$ ,  $h_{igh} = [2, 500]$ , 速度  $v$  的范围为  $[-100, 100]$ ,  $A_0 = 0.5$ ,  $r_0 = 0.25$ , 脉冲频率范围  $[0, 1]$ ,

$\alpha=0.8, \gamma=0.5$ 。蝙蝠算法不同参数组合的优化如表 1 所示。

表 1 蝙蝠算法不同参数组合的优化

$S_{\text{izepop}}$	迭代次数	$(\alpha, K)$	最小包络熵
18	110	(2.387, 6)	5.542 4
18	100	(2.453, 6)	5.547 2
18	90	(1.975, 7)	5.553 2
36	80	(1.730, 7)	5.546 2
36	70	(2.453, 6)	5.547 2
36	60	(2.474, 6)	5.541 5
54	50	(1.716, 7)	5.545 3
54	40	(2.397, 6)	5.543 3
54	30	(1.660, 7)	5.543 7

图 3 为局部极小包络熵值随寻优迭代次数变化曲线, 优化结果如表 2 所示。




图 3 寻优迭代图

表 2 优化结果

迭代次数	$K$	$(\alpha, K)$	最小包络熵
60	6	(2.474, 6)	5.541 5

作为对比, 同时采用手动寻优的方法来求解最优的  $(K, \alpha)$  的值。VMD 参数设置如下: 初始化  $a_{\text{lpha}}=2.000$ ,  $t_{\text{au}}=0$ ,  $DC=0$ ,  $i_{\text{nit}}=1$ ,  $t_{\text{ol}}=1e-7$ 。

表 3 不同  $K$  值下的包络熵值

$K$ 值	包络熵值				
$K=3$	5.857 0	6.248 8	6.207 5	—	—
$K=4$	5.800 5	6.128 6	5.994 5	6.566 6	—
$K=5$	5.716 6	6.149 8	5.753 5	5.932 6	6.531 4
$K=6$	5.703 7	6.053 2	5.633 6	5.722 8	6.300 8
$K=7$	5.685 2	5.761 5	5.554 2	5.832 9	6.656 2
$K=8$	5.681 4	5.730 1	5.588 6	5.828 7	6.542 2

由于篇幅原因, 上述表格每个  $K$  值仅陈列 5 个极小包络熵值, 观察到最小的包络熵值仅为 5.554 2。对比蝙蝠

算法的迭代寻优结果, 通过手动寻优求得的最小包络熵值并不理想。

综合分析, 改进蝙蝠算法迭代寻优的最优参数  $K=6, \alpha=247.4$ 。选取裂痕齿轮一组数据中的 4 500 个样本点进行 VMD 分解, 得到 6 个 IMF 分量, 分解结果如图 4 所示。

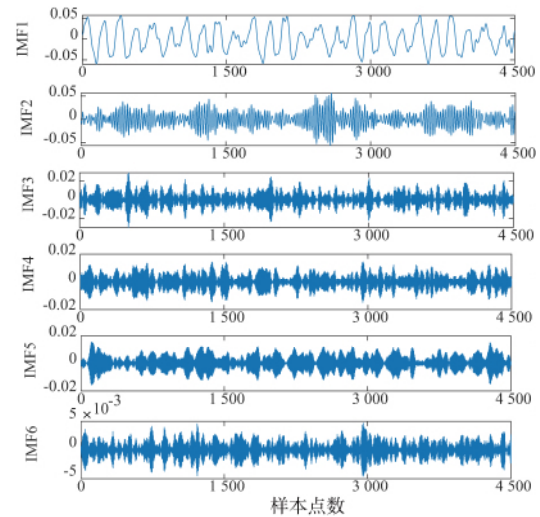


图 4 VMD 分解结果

$M_{\text{PE}}$  的计算需要设置嵌入维数  $m$ 、延迟时间  $\tau$  和尺度因子  $s$ 。其中维数  $m$  取值范围通常是 3~7,  $m$  取值太小, 算法的检测性能降低; 若  $m$  取值太大, 将无法反映时间序列的细微变化。延迟时间  $\tau$  对时间序列的计算影响较小, 尺度因子  $s$  最大值一般取 >10 即可。本文选取  $m=3, \tau=1, s=20$ 。

于是就能求出前面 VMD 分解后 6 个 IMF 分量的排列熵, 如图 5 所示。




图 5 裂痕齿轮各 IMF 分量的  $M_{\text{PE}}$  值

### 4.3 齿轮的故障诊断

对测得的正常、不平衡、松动、错位、断齿、裂痕这 6 种不同状态的数据, 每种数据取 50 组, 每组 4 500 个点。对这 50 组数据进行 VMD 分解后并计算模态分量的  $M_{\text{PE}}$  值, 6 个  $M_{\text{PE}}$  分量, 每个分量提取 20 尺度的因子, 所以每个样本就得到维度为 120 的特征。将故障特征向量输入到已经训练好的 ELM 中, 取前 40 组数据作为已知故障样本, 后 10 组数据作为待识别故障样本, 诊断情况如图 6 所示。

(下转第 128 页)

- [4] CAMPEAU – LECOURS A, FOUCAULT S, LALIBERTÉ T, et al. A cable-suspended intelligent crane assist device for the intuitive manipulation of large payloads [J]. IEEE/ASME Transactions on Mechatronics, 2016, 21(4): 2073-2084.
- [5] 高建秀. 助力机械手控制系统实验研究[D]. 哈尔滨: 哈尔滨工程大学, 2012.
- [6] 丁有爽, 肖曦. 伺服系统柔性负载建模方法研究[J]. 中国电机工程学报, 2016, 36(3): 818-827.
- [7] 王璨, 杨明, 徐殿国. 基于 PI 控制的双惯量弹性系统机械谐

振的抑制[J]. 电气传动, 2015, 45(1): 49-53.

- [8] 刘强, 尔联洁, 刘金琨. 摩擦非线性环节的特性、建模与控制补偿综述[J]. 系统工程与电子技术, 2002, 24(11): 45-52.
- [9] 丁千, 翟红梅. 机械系统摩擦动力学研究进展[J]. 力学进展, 2013, 43(1): 112-131.
- [10] 刘金琨. 先进 PID 控制 MATLAB 仿真[M]. 2 版. 北京: 电子工业出版社, 2004.

收稿日期: 2020-10-09

(上接第 117 页)

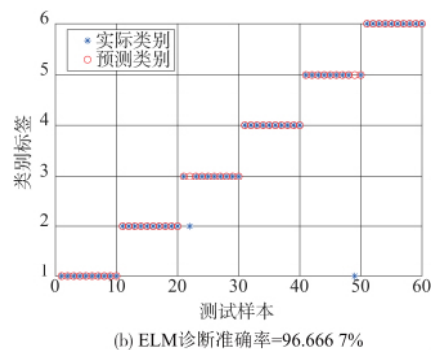
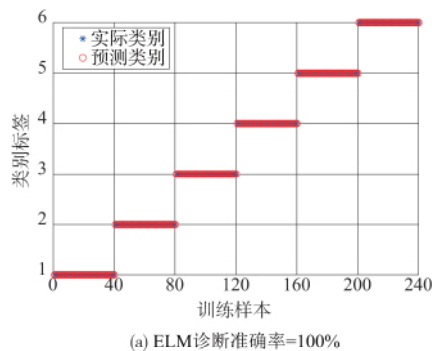


图 6 ELM 故障识别

图 6 中, 横坐标分别代表训练样本和测试样本, 纵坐标代表 6 种故障类别的标签。测试样本中的空心点代表预测类别。实心点代表实际类别。当测试的数据符合同类故障的标准时, 空心点和实心点会重合, 代表识别正确。本文测试集总的准确率达到 96.7%, 对于绝大多数的故障情况, 都能达到很好的识别效果。

## 5 结语

针对齿轮故障特征在单一尺度难以全面提取的问题, 提出一种基于参数优化的 VMD 和多尺度排列熵的齿轮故障诊断方法。相比较手动寻优, 该方法可以搜寻更优的

VMD 参数组合, 更有效地提取出不同故障状态下的信号特征参数。分析结果表明, 通过参数优化 VMD 和多尺度排列熵的齿轮故障诊断方法, 极大地提高了齿轮故障诊断的准确性。

参考文献:

- [1] 丁康, 李巍华, 朱小勇. 齿轮及齿轮箱故障诊断实用技术[M]. 北京: 机械工业出版社, 2005.
- [2] 卓仁雄, 肖金凤. 基于改进的集合经验模态分解的电动机滚动轴承故障诊断研究[J]. 机械制造与自动化, 2019, 48(1): 36-39.
- [3] DRAGOMIRETSKIY K, ZOISSO D. Variational mode decomposition [J]. IEEE Transactions on Signal Processing, 2014, 62(3): 531-544.
- [4] 刘长良, 武英杰, 甄成刚. 基于变分模态分解和模糊 C 均值聚类的滚动轴承故障诊断[J]. 中国电机工程学报, 2015, 35(13): 3358-3365.
- [5] 瞿红春, 许旺山, 郭龙飞, 等. 基于参数优化变分模态分解的滚动轴承微弱故障诊断研究[J]. 机床与液压, 2020, 48(9): 162-167, 180.
- [6] 张莹, 殷红, 彭珍瑞. 基于改进 SVD 及参数优化 VMD 的轴承故障诊断[J]. 噪声与振动控制, 2020, 40(1): 51-58.
- [7] 潘震, 黄国勇, 吴漫. 基于参数优化 VMD 和增强多尺度排列熵的单向阀故障诊断[J]. 振动与冲击, 2020, 39(15): 118-125.
- [8] YANG X S. A new metaheuristic bat-inspired algorithm [M] // Nature Inspired Cooperative Strategies for Optimization (NICSO 2010). Berlin, Heidelberg: Springer Berlin Heidelberg, 2010: 65-74.
- [9] 史峰, 王辉, 郁磊. MATLAB 智能算法 30 个案例分析[M]. 北京: 北京航空航天大学出版社, 2011.
- [10] BANDT C, POMPE B. Permutation entropy: a natural complexity measure for time series [J]. Physical Review Letters, 2002, 88(17): 174102.
- [11] COSTA M, GOLDBERGER A L, PENG C K. Multiscale entropy analysis of complex physiologic time series [J]. Physical Review Letters, 2002, 89(6): 068102.

收稿日期: 2020-11-02