

# 基于改进深度残差网络的旋转机械故障诊断

侯召国, 王华伟\*, 周良, 付强

(南京航空航天大学民航学院, 江苏 南京 211106)

**摘要:** 针对旋转机械工况复杂多变、有标签样本不足而导致的故障特征提取困难等问题,提出了一种用于旋转机械故障诊断的改进深度残差网络(improved deep residual network, IDRN)。首先,采集旋转机械一维振动信号进行数据预处理;然后,在深度残差网络的基础上引入了长短时记忆(long short-term memory, LSTM)网络,其中,LSTM网络可以有效捕捉故障的时序信息;在残差块中引入 Dropout 层提高了故障诊断的精度和收敛速度;最后在轴承与齿轮数据集上验证本文提出方法的有效性。实验结果表明,该方法在堆叠多层网络模型时,没有出现明显的网络退化现象,与当前广泛使用的几种诊断方法进行对比实验,表现出了较高的平均诊断精度和良好的适用性。

**关键词:** 故障诊断;改进深度残差网络;长短时记忆网络;Dropout 层

**中图分类号:** TH 17

**文献标志码:** A

**DOI:**10.12305/j.issn.1001-506X.2022.06.34

## Fault diagnosis of rotating machinery based on improved deep residual network

HOU Zhaoguo, WANG Huawei\*, ZHOU Liang, FU Qiang

(School of Civil Aviation, Nanjing University of Aeronautics and Astronautics, Nanjing 211106, China)

**Abstract:** An improved deep residual network (IDRN) for fault diagnosis of rotating machinery is proposed to solve the problems of fault feature extraction difficulty caused by complex and variable working conditions and insufficient samples of labels. Firstly, one-dimensional vibration signals of rotating machinery are collected for data preprocessing. Then, long short-term memory (LSTM) network is introduced on the basis of the deep residual network, in which the time-series information of faults could be captured effectively. The Dropout layer is introduced into the residual block to improve the accuracy and convergence speed of fault diagnosis. Finally, the validity of the proposed method is verified on the data sets of bearings and gears. Experimental results show that there is no obvious network degradation phenomenon when the proposed method is used to stack multi-layer network models. Compared with several widely used diagnostic methods, the proposed method shows higher average diagnostic accuracy and good applicability.

**Keywords:** fault diagnosis; improved deep residual network (IDRN); long short-term memory (LSTM) network; Dropout layer

## 0 引言

旋转机械是工业应用中的关键部件,已广泛应用于电机、直升机、航空发动机、水轮机和其他类型的复杂机械设备<sup>[1]</sup>。大型旋转机械设备工作环境极为恶劣,具有负载重、转速快、运行时间长等特点,容易出现各种故障,最终导致不必要的停机时间、经济损失甚至人员伤亡<sup>[1]</sup>。因此,及时

准确的故障诊断对于旋转机械系统设计、智能运维和安全可靠运行至关重要。传统上,旋转机械故障诊断主要包括3个阶段:数据采集、特征提取与选择、故障分类。当前旋转机械故障特征提取主要面临三大挑战:工况复杂且多变;振动信号具有极强的非线性;采集的数据样本存在不平衡性,体现在正常与故障样本的数量级不平衡。目前,传统的特征提取方法主要有小波变换(wavelet transform, WT)、

收稿日期:2021-07-15; 修回日期:2021-11-09; 网络优先出版日期:2022-01-24。

网络优先出版地址:https://kns.cnki.net/kcms/detail/11.2422.TN.20220124.0943.002.html

基金项目:国家自然科学基金和民航联合研究基金(U1833110)资助课题

\* 通讯作者。

引用格式:侯召国,王华伟,周良,等.基于改进深度残差网络的旋转机械故障诊断[J].系统工程与电子技术,2022,44(6):2051-2059.

**Reference format:** HOU Z G, WANG H W, ZHOU L, et al. Fault diagnosis of rotating machinery based on improved deep residual network[J]. Systems Engineering and Electronics, 2022, 44(6): 2051-2059.

经验模态分解(empirical mode decomposition, EMD)和集成经验模态分解(ensemble empirical mode decomposition, EEMD)等<sup>[2]</sup>。传统的特征提取与故障分类方法对于人工特征工程和专家知识的依赖较为严重。特别是,随着工业大数据时代的到来和传感器技术的发展,传统的特征提取与故障分类方法已经无法满足海量数据的诊断需求。在此背景下,智能故障诊断开始发展与推广,智能故障诊断是指将人工神经网络、支持向量机和深度神经网络等机器学习理论应用于机器故障诊断<sup>[3]</sup>。然而,基于人工神经网络、支持向量机等传统的机器学习智能诊断方法,由于网络结构较浅,限制了其对复杂故障特征的提取能力。近年来,深度自动编码器、深度卷积神经网络等深度神经网络被广泛用于构建端到端智能诊断模型,减少了对人工劳动和专家知识的依赖,极大地推动了智能故障诊断的发展<sup>[3]</sup>。由于能够直接从原始数据或低层次特征数据中挖掘代表性信息,以及强大的多模式分解能力,基于深度学习的智能诊断引起了越来越多的国内外学者的关注<sup>[4]</sup>。

Shao 等<sup>[5]</sup>提出了一种基于压缩感知的改进卷积深度信念网络方法,大大提升了模型的特征提取能力和泛化性能。Li 等<sup>[6]</sup>提出了一种基于残差连接自适应一维可分离卷积的混合工况齿轮点蚀故障诊断方法,并验证了其良好的诊断性能。Zhang 等<sup>[7]</sup>通过突出小波系数的本质频带和卷积通道的故障特征,提出了一种基于混合注意力改进残差网络的风电齿轮箱故障诊断方法,并在传动系统诊断模拟器仿真数据集和风电场实测数据上验证了该方法的有效性。Hoang 等<sup>[8]</sup>提出了一种基于深层卷积神经网络的轴承故障诊断方法,并验证了其较高的诊断精度和强大的抗噪能力。Yu 等<sup>[9]</sup>提出基于一维残差卷积自动编码器的齿轮箱故障诊断特征学习方法,在行星齿轮箱数据集上表现出良好的信号去噪和特征提取性能。Mao 等<sup>[10]</sup>提出了一种融合多种故障类型判别信息的深度自动编码器方法,并用于轴承故障诊断。Lu 等<sup>[11]</sup>提出了一种基于分层卷积神经网络健康状态分类的滚动轴承智能故障诊断方法,并验证了其在滚动轴承故障分类中的有效性。Jia 等<sup>[12]</sup>提出了一种新的深度神经网络智能诊断方法,并在轴承和行星齿轮箱数据集上验证了其良好的性能。针对现代机械设备复杂多样、信号源多、类型差异大、耦合性强、动力学建模困难、非线性强以及不确定性干扰强等问题,仍需要故障诊断理论进一步深入研究<sup>[13]</sup>。当前的智能诊断模型在融入工业实际需求与模型动态优化更新方面还存在很大不足,实现智能故障诊断真正落地还有很长的路要走。因此,随着机械设备向着更加复杂化和智能化的方向发展,在更好地满足工业实际需求与融入工业实际应用方面,必将为当前的智能诊断模型的性能改进提出更加严峻的挑战。面向未来工业实际,亟需更加精准且高效的智能故障诊断方法。

深度残差网络(deep residual network, DRN)是为了解决卷积神经网络的梯度消失现象而提出的一种深层神经网络,不仅保留了卷积神经网络强大的故障特征提取能力,而且有效缓解了网络退化现象。为了进一步改善深度残差网络的特征提取能力和收敛速度,本文提出了一种改进深度

残差网络(improved DRN, IDRN)。在深度残差网络中引入长短时记忆(long short-term memory, LSTM)网络可以最大限度地考虑到故障的时序信息,在残差块中加入 Dropout 层可以有效缓解过拟合并提升诊断效率,通过改进深度残差网络可以实现端到端的故障诊断,通过与当前广泛使用的几种网络模型的对比实验,验证了该方法的有效性和可行性。

## 1 深度残差网络原理

针对卷积神经网络随着层的堆叠容易出现梯度消失的问题,He 等<sup>[14]</sup>首次提出了深度残差网络,并将其用于图像识别任务,表现出了较高的分类精度。深度残差网络由多个带有跳跃连接线的残差块构成,残差思想的引入大大缓解了深层神经网络的梯度消失问题。其中残差块的结构如图 1 所示。




图 1 残差块结构图

Fig. 1 Structure diagram of residual block

残差块包含两种映射:一种是恒等映射;另一种是残差映射。假设要求的最优解为  $H(X)=X$ , 残差映射是指映射  $H(X)$  和  $X$  的残差值,用  $F(X)$  表示,即  $F(X)=H(X)-X$ 。当  $F(X)$  无限接近于 0 时,网络达到最佳状态,继续加深网络深度,网络也将一直处于最优状态<sup>[15]</sup>。当残差块的输入为  $X_n$  时,可得计算后的输出<sup>[15]</sup>为

$$X_{n+1} = f(X_n + F(X_n, W_n)) \quad (1)$$

式中: $F(\cdot)$  为残差映射; $W_n$  为相应的权重参数; $f(\cdot)$  为激活函数。由图 1 可知,不同残差块之间可能存在维度不匹配的情况,此时只需要对恒等映射  $X_n$  做一个线性变换  $W_s$ <sup>[15]</sup> 即可:

$$X_{n+1} = f(W_s X_n + F(X_n, W_n)) \quad (2)$$

式中: $W_s$  为权重参数。

残差结构具有两个结构优势:第一,网络前向传播时浅层的特征可以在深层得以重用;第二,网络反向传播时深层的梯度可以直接传回浅层。因此,带有快捷连接的残差块可以在网络的输入与输出之间有较大的重构误差时,直接通过快捷连接将误差信息反馈给前面的网络层,这种结构设计不仅提升了模型训练速度,而且有效缓解了网络退化问题。

## 2 基于 IDRN 的故障诊断模型

### 2.1 Dropout 层工作原理

Dropout 是 Hinton 等<sup>[16]</sup>于 2012 年提出的处理过拟合

问题的方法,常用于深度网络的优化中,其中 Dropout 前的深度前馈网络至 Dropout 后的深度前馈网络的原理过程如图 2 所示,其中虚线圆表示被删除的神经元,与其连接的边也被删除了。




图 2 Dropout 层示意图

Fig. 2 Schematic diagram of Dropout layer

Dropout 层的工作过程如下:首先,随机“丢弃”网络中的一部分隐藏层神经元,构造新的隐藏层,同时保持输入输出神经元不变,并将小批量训练输入样本通过新构造的隐藏层进行前向传播;然后,根据返回的损失函数结果进行反向传播。通过优化算法更新未隐藏的神经元参数,最后恢复“丢弃”的神经元,并重复 Dropout 过程直至训练完成<sup>[17]</sup>。

经过添加 Dropout 层,网络的计算公式可以表示为

$$\begin{cases} r_j^{(l)} \sim \text{Bernoulli}(p) \\ \tilde{y}^{(l)} = r^{(l)} \cdot y^{(l)} \\ z_i^{(l+1)} = \omega_i^{(l+1)} \cdot \tilde{y}^{(l)} + b_i^{(l+1)} \\ y_i^{(l+1)} = f(z_i^{(l+1)}) \end{cases} \quad (3)$$

式中:  $r_j^{(l)}$  为随机系数;  $y^{(l)}$  为隐层神经元;  $\tilde{y}^{(l)}$  为经过 Dropout 后的神经元;  $z_i^{(l+1)}$  为  $l+1$  层待激活神经元;  $y_i^{(l+1)}$  为  $l+1$  层输出神经元;  $f(\cdot)$  为激活函数;  $\omega_i^{(l+1)}$  和  $b_i^{(l+1)}$  分别为  $l+1$  层的权重和偏置。通过添加 Dropout 层,可以减少中间特征的数量,从而降低冗余并减少神经元之间复杂的共适应关系,增加每层各个特征之间的正交性,避免出现过拟合现象<sup>[16]</sup>。

## 2.2 改进残差块

为了避免网络在层数较深时,出现过拟合的现象,对残差块的结构进行了改进。其中标准的残差块结构如图 1 所示,改进的残差块结构如图 3 所示。




图 3 改进残差块结构图

Fig. 3 Structure diagram of improved residual block

图 1 中,残差块仅仅包含卷积层和批量标准化层,在网络堆叠过多的层时很容易出现过拟合现象。为了缓解残差块的过拟合现象<sup>[18]</sup>,在残差块中引入了丢弃层,其结构如图 3 所示。丢弃层可以舍弃网络的一些随机单元和冗余单元,使网络在提取主要特征信息的同时简化计算量,而且也有效缓解了网络的退化现象。因此,丢弃层的这一特性特别适用于处理冗余信息较多的旋转机械振动信号。

## 2.3 改进残差块与 LSTM 网络的融合

### 2.3.1 CNN 基本原理

卷积神经网络(convolutional neural network, CNN)具有强大的特征提取能力,它包含卷积层、激活层、池化层、批量标准化层、全连接层和分类层,其中分类层由多层感知机组成<sup>[19]</sup>。

卷积层进行深层特征提取,其中卷积过程<sup>[19]</sup>可以描述如下:

$$y_i^{l+1}(j) = K_i^l \cdot x^l(j) + b_i^l \quad (4)$$

式中:  $K_i^l$  表示  $l$  层中第  $i$  个滤波器的权重;  $b_i^l$  表示  $l$  层中第  $i$  个滤波器的偏差;  $x^l(j)$  表示  $l$  层中的第  $j$  个局部区域;  $y_i^{l+1}(j)$  表示  $l+1$  层帧  $i$  中的第  $j$  个神经元的输入。

池化层通常连接在卷积层之后,它利用下采样操作减小了特征和网络参数的空间大小,其中最大池化操作<sup>[19]</sup>可以描述如下:

$$P_i^{l+1}(j) = \max_{(j-1)W+1 \leq t \leq jW} \{q_i^l(t)\} \quad (5)$$

式中:  $q_i^l(t)$  表示  $l$  层  $i$  帧的第  $t$  个神经元的值;  $t \in [(j-1)W+1, jW]$ ;  $W$  是池化区域的宽度;  $P_i^{l+1}(j)$  是池化操作的  $l+1$  层中神经元的对应值。

### 2.3.2 LSTM 基本原理

LSTM 是循环神经网络(recurrent neural networks, RNN)的变体,其经过结构的改进,有效缓解了 RNN 的梯度问题。LSTM 的结构主要包括遗忘门、输入门和输出门<sup>[20]</sup>。

LSTM 的遗忘门决定信息的通过量,其计算过程<sup>[20]</sup>如下:

$$f_t = \sigma(\omega_{L1} \cdot [h_{t-1}, x_t] + b_{L1}) \quad (6)$$

式中:  $\sigma$  是 sigmoid 函数;  $\omega_{L1}$  和  $b_{L1}$  分别是权重和偏置;  $h_{t-1}$  是前一个单元的输出;  $x_t$  是当前输入。

LSTM 的输入门决定了新信息能否被细胞单元记忆,其计算过程<sup>[20]</sup>如下:

$$i_t = \sigma(\omega_{L2} \cdot [h_{t-1}, x_t] + b_{L2}) \quad (7)$$

$$\tilde{C}_t = \tanh(\omega_{L3} \cdot [h_{t-1}, x_t] + b_{L3}) \quad (8)$$

$$C_t = f_t \cdot C_{t-1} + i_t \cdot \tilde{C}_t \quad (9)$$

式中:  $\omega_{L2}$ 、 $\omega_{L3}$  和  $b_{L2}$ 、 $b_{L3}$  分别是输入门、记忆门单元的权重和偏置;  $\tanh$  为激活函数;  $f_t$ 、 $i_t$  分别为遗忘门和输入门的输出;  $C_t$  是记忆单元的输出;  $C_{t-1}$  为前一个记忆单元的输出;  $\tilde{C}_t$  是激活函数  $\tanh$  的输出。

LSTM 单元的最终输出  $h_t$  由输出门的输出  $o_t$  与记忆单元输出  $C_t$  决定,具体计算<sup>[20]</sup>如下:

$$o_t = \sigma(\omega_{L4} \cdot [h_{t-1}, x_t] + b_{L4}) \quad (10)$$

$$h_t = o_t \cdot \tanh(C_t) \quad (11)$$

式中:  $\omega_{L4}$ 、 $b_{L4}$  分别是输出门的权重和偏置。

### 2.3.3 IDRN 模型

考虑到不同模型具有各自的优势,模型融合可以优势互补、取长补短。CNN 具有强大的特征提取能力,可以提取更

深层次的故障特征,能够捕捉故障发生的属性信息<sup>[21]</sup>。LSTM 具备长短时记忆的能力,能够捕捉故障发生的时序信息<sup>[22]</sup>。因此,为了最大程度地保留振动信号的时序特征<sup>[22]</sup>,本文设计了融合改进残差块和 LSTM 层的 IDRN 作为旋转机械故障诊断模型,不仅可以直接处理原始机械信号,而且在提取故障属性信息的同时也可以将故障发生的时序信息融入到模型之中。IDRN 结构如图 4 所示,包括两个初始卷积层、一个池化层、一个 LSTM 网络层和 3 个改进残差块,然后经过卷积层、全局平均池化层、展开层、全连接层和分类层进行故障分类。以初始卷积层为例描述参数,(Conv1D,32,3)表示模型是一维卷积神经网络,滤波器尺寸为 32,卷积核大小为 3;(MaxPooling,3)表示最大池化操作,池化块尺寸为 3;(LSTM,32)表示模型是 LSTM 网络,神经元个数为 32;(Dropout,0.25)表示丢弃层,丢弃率为 0.25;(Dense,64)表示全连接层,神经元个数为 64;Flatten 表示展开层;ReLU 表示整流后的线性单元激活函数;Softmax 表示分类层激活函数。LSTM 层被设计用来进行时序特征提取,多层残差块被设计用来进行深层故障特征提取,全局平均池化层被设计为处理所学习的特征,其将每个特征图视为一个区域来执行池化操作,并且其输出大小等于特征图的数量<sup>[23]</sup>。分类层中的神经元个数与故障类别个数相同。

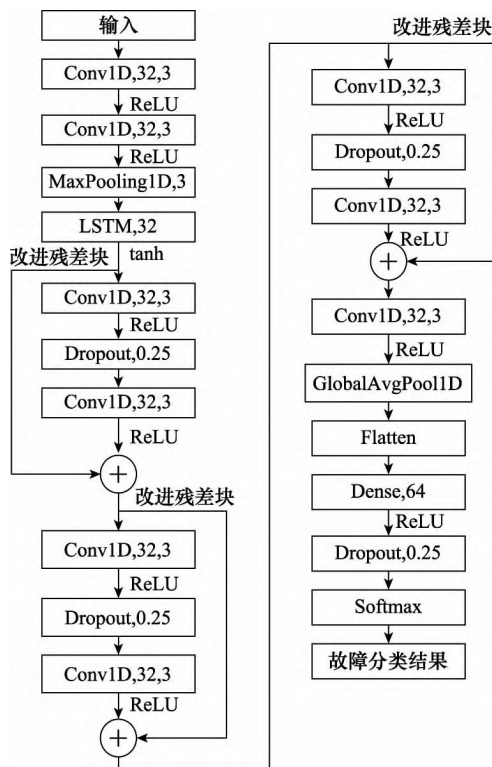


图 4 IDRN 结构图

Fig. 4 Structure diagram of IDRN

## 2.4 IDRN 故障诊断流程

针对旋转机械工况复杂多变、振动信号具有极强的非线性和有标签样本不足而导致的故障特征提取困难等问题,本文提出了一种用于旋转机械故障诊断的 IDRN。基于 IDRN

的旋转机械故障诊断流程如图 5 所示。通过对滚动轴承和齿轮箱振动信号进行分析,发现其中存在大量的噪声和冗余信息。因此,在数据处理阶段,首先需要进行数据采样和数据标准化处理,然后划分训练集、验证集和测试集的比例,最后对数据标签进行 one-hot 编码处理。在模型训练阶段,首先初始化网络参数,然后将预处理之后的训练集数据输入到融合 LSTM 层和 Dropout 层的 IDRN 进行训练,并利用验证集进行参数调整,训练完成之后可以得到故障诊断模型。在故障诊断阶段,将测试数据输入到故障诊断模型之中,输出故障诊断结果,完成故障诊断流程。

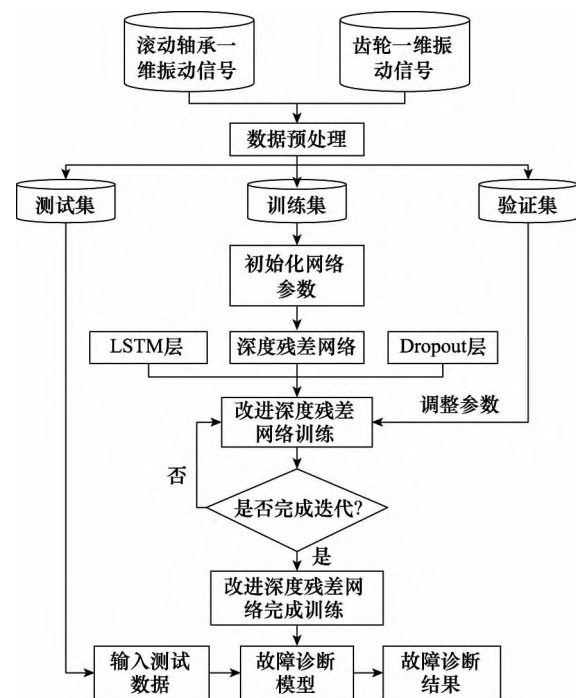


图 5 IDRN 故障诊断流程图

Fig. 5 Fault diagnosis flow chart of IDRN

## 3 实验验证与结果分析

### 3.1 实验数据与参数设置

滚动轴承与齿轮都是旋转机械的关键部件,其运行状态直接关系到旋转机械的安全可靠运行。因此,为了测试该故障诊断方法的性能并验证其有效性,在滚动轴承单工况、变工况和齿轮箱三个数据集上进行了实验。此外,还进行了对比实验,以比较现有方法的分类精度。

#### 3.1.1 滚动轴承实验数据描述

滚动轴承实验利用文献[24]中的凯斯西储大学轴承数据进行验证。该数据采样频率设置为 12 kHz 和 48 kHz,采用电火花技术来加工轴承故障。轴承故障分为内圈故障、外圈故障和滚珠故障。每种故障类型包括 7 mils、14 mils 和 21 mils 3 种故障直径。电机负荷包括 0 HP、1 HP、2 HP 和 3 HP 4 种状态;电机转速包括 1 797 rpm、1 772 rpm、1 750 rpm 和 1 730 rpm 4 种状态。

### 3.1.2 齿轮实验数据描述

齿轮实验利用文献[25]中东南大学齿轮箱数据集进行验证,该数据是从东南大学齿轮箱实验平台驱动系统动力学模拟器中收集的。在转速系统负载设置为 20 Hz—0 V 或 30 Hz—2 V 的情况下,该平台研究了两种不同工作条件下的多种故障模式。

### 3.1.3 实验数据设置

滚动轴承单工况实验数据组成如表 1 所示,其中故障

标号 N 为正常样本,F1~F5 为故障位置不同的 5 种故障样本。单工况的轴承故障诊断实验中故障直径、电机负荷和电机转速都是保持同一条件,不能很好地展示模型在变工况下的诊断性能,为了验证模型的泛化能力,又进一步设置了变工况下轴承故障诊断实验,针对故障直径、电机负荷和电机转速都不同的故障类型进行识别。其中变工况轴承数据包括 1 种正常样本 N'和 3 种不同类型的故障样本 F1'~F3',其组成如表 2 所示。

表 1 单工况轴承故障数据组成  
Table 1 Composition of bearing fault data under single working condition

故障标号	故障直径/(")	电机负荷/HP	电机转速/rpm	故障位置	样本长度	训练/验证/测试
N	无	0	1 797	无	2 048	700/200/100
F1	0.021	0	1 797	内圈	2 048	700/200/100
F2	0.021	0	1 797	滚珠	2 048	700/200/100
F3	0.021	0	1 797	外圈 6 点钟	2 048	700/200/100
F4	0.021	0	1 797	外圈 3 点钟	2 048	700/200/100
F5	0.021	0	1 797	外圈 12 点钟	2 048	700/200/100

表 2 变工况轴承故障数据组成  
Table 2 Composition of bearing fault data under variable working conditions

故障标号	故障直径/(")	电机负荷/HP	电机转速/rpm	故障位置	样本长度	训练/验证/测试
N'	无	0	1 797	无	2 048	700/200/100
F1'	0.007	1	1 772	内圈	2 048	700/200/100
F2'	0.014	2	1 750	滚珠	2 048	700/200/100
F3'	0.021	3	1 730	外圈 6 点钟	2 048	700/200/100

为了验证模型对多种旋转机械的故障诊断性能,进而在工业应用领域进一步推广,又设置了齿轮箱故障诊断实验。齿轮故障诊断中选用同一电机负荷下的 5 种运行状态进行实验,其中 H 代表健康状态,G1~G4 代表 4 种不同类型的故障状态,其组成如表 3 所示。

表 3 齿轮故障数据组成  
Table 3 Composition of gear fault data

故障标号	故障类型	电机负荷	样本长度	训练/验证/测试
H	无	20 Hz—0 V	2 048	700/200/100
G1	剥落	20 Hz—0 V	2 048	700/200/100
G2	断齿	20 Hz—0 V	2 048	700/200/100
G3	裂纹	20 Hz—0 V	2 048	700/200/100
G4	磨损	20 Hz—0 V	2 048	700/200/100

### 3.1.4 实验参数设置

实验设置训练批次大小为 128、周期大小为 20、样本长度为 2 048,其中每种故障类型采集 1 000 个样本,训练集、验证集和测试集的比率为 0.7、0.2 和 0.1,如表 1、表 2 和表 3 所示。以轴承单工况故障诊断为例,IDRN 的模型参数如表 4 所示,以改进残差块 1 为例,(32,3)表示滤波器尺寸为 32、卷积核大小为 3。实验中,学习率设置为 0.001,损失函数采用交叉熵损失函数,优化器采用 Adam,分类层激活函数采用 Softmax 分类函数。

表 4 IDRN 模型参数  
Table 4 Parameters of IDRN

模型结构	模型参数	激活函数	输入大小	输出大小
输入层	—	—	(None,2 048,1)	(None,2 048,1)
卷积层	(32,3)	ReLU	(None,2 048,1)	(None,2 046,32)
卷积层	(32,3)	ReLU	(None,2 046,32)	(None,2 044,32)
最大池化层	3	—	(None,2 044,32)	(None,681,32)
LSTM 网络层	32	Tanh	(None,681,32)	(None,681,32)
改进残差块 1	(32,3)	ReLU	(None,681,32)	(None,681,32)
改进残差块 2	(32,3)	ReLU	(None,681,32)	(None,681,32)
改进残差块 3	(32,3)	ReLU	(None,681,32)	(None,681,32)
卷积层	(32,3)	ReLU	(None,681,32)	(None,679,32)
全局平均池化层	—	—	(None,679,32)	(None,32)
全连接层	64	ReLU	(None,32)	(None,64)
丢弃层	0.25	—	(None,64)	(None,64)
分类层	6	Softmax	(None,64)	(None,6)

## 3.2 实验结果分析

### 3.2.1 实验模型评价

为了显示模型在测试集中对各个故障类型的详细识别效果<sup>[26]</sup>,引入了多分类混淆矩阵对轴承单工况和变工况以及齿轮箱故障诊断的实验结果进行更加精准全面的分析。



多分类混淆矩阵详细展示了所有故障类型的分类结果,既包含正确分类信息,也包含错误分类信息。混淆矩阵的纵轴代表分类的实际标签,横轴代表预测标签。因此,混淆矩阵主对角线位置上的值代表每种故障类型正确分类的比例,而非主对角线位置上的值代表一种故障类型被误分类为其他故障类型的比例。颜色条显示从 0 到 1 的值和颜色之间的相关性。其中轴承单工况和变工况的以及齿轮箱的诊断模型测试结果混淆矩阵分别如图 6、图 7 和图 8 所示。




图 6 单工况轴承混淆矩阵

Fig. 6 Confusion matrix of single working condition bearing




图 7 变工况轴承混淆矩阵

Fig. 7 Confusion matrix of variable working condition bearing

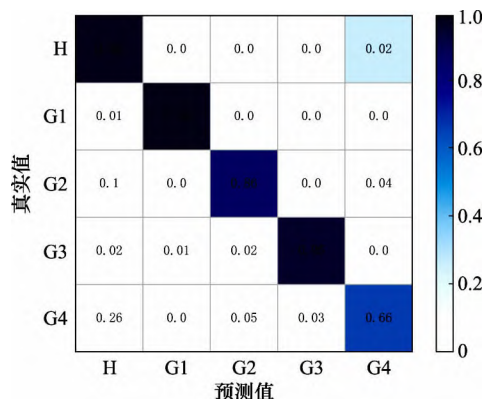


图 8 齿轮混淆矩阵

Fig. 8 Confusion matrix of gear

由图 6~图 8 可知,模型对轴承单工况和变工况的每一类故障样本都没有出现误分类的情况,但在齿轮箱故障诊断中大部分样本标注正确<sup>[27]</sup>,除了故障类型 G4 准确率为 66% 之外,其余故障类型分类准确率都在 85% 以上,说明了本文所提出模型在轴承故障诊断中表现出了比齿轮箱故障诊断更高的精度。这可能是由于齿轮箱故障特征微弱或不同故障类型之间的故障特征较为相似。

### 3.2.2 实验结果可视化

为了验证该方法自适应挖掘故障特征的能力,引入了流形学习中的 t 分布随机近邻嵌入 (t-distributed stochastic neighbor embedding, t-SNE) 算法对模型隐藏层提取的高维特征进行降维可视化分析<sup>[28]</sup>。其中轴承单工况和变工况以及齿轮箱的隐藏层输出特征 t-SNE 可视化结果分别如图 9~图 11 所示。由图 9~图 11 可知,该模型具有强大的特征提取能力,在轴承故障诊断中,类间的样本被完美地分离,类内的样本被完美地聚类<sup>[29]</sup>,在齿轮箱故障诊断中,除了 G4、G2 和 H 3 种故障类型之间略微有些重叠之外,其余相同故障类型之间可以很好地聚类,不同故障类型之间可以很好地分离。结果表明,该方法能够自适应地挖掘旋转机械在不同工况下的故障特征。




图 9 单工况轴承隐藏层 t-SNE 可视化

Fig. 9 t-SNE visualization of single working condition bearing hidden layer




图 10 变工况轴承隐藏层 t-SNE 可视化

Fig. 10 t-SNE visualization of variable working condition bearing hidden layer




图 11 齿轮隐藏层 t-SNE 可视化

Fig. 11 t-SNE visualization of gear hidden layer

### 3.2.3 对比实验结果分析

为了更加全面地验证本文所提出模型的性能,分别与反

向传播神经网络(back propagation neural network, BPNN)、多层感知机(multilayer perception, MLP)、堆叠自编码器(stacked auto-encoder, SAE)、CNN、RNN、DRN 等当前广泛使用的故障诊断模型进行了对比实验。以单工况实验为例,各对比实验模型的参数设置如表 5 所示。各对比实验模型诊断精度如表 6 所示,表 6 中 IDRN(本文所提方法)是本文所设计的 IDRN 模型,针对 3 个故障诊断实验的测试集及测试集平均中精度最高的值都进行了加粗表示,各诊断模型在 3 个实验的测试将重复 5 次,5 次测试样本的平均诊断精度作为各诊断模型在 3 个实验的测试集诊断精度,为了使对比实验更有说服力,同时避免偶然误差,再取 3 个实验测试集的平均诊断精度<sup>[30]</sup>作为各模型最终诊断结果对算法性能进行评价。由表 6 可知,IDRN 模型在轴承单工况和变工况以及齿轮箱下的测试集故障诊断精度及测试集平均故障诊断精度都达到了最高,从而验证了本文所提方法的有效性。

表 5 对比模型训练参数

Table 5 Comparison of model training parameters

模型	单工况参数设置
BPNN	网络结构为[32,6],训练周期为 20,学习率为 0.001,优化器采用随机梯度下降
MLP	网络结构为[64,32,16,6],训练周期为 20,学习率为 0.001,优化器为 Adam
SAE	网络结构为[64,32,16,10,16,32,64,6],训练周期为 20,学习率为 0.001,优化器为 Adam
CNN	网络包含 3 个卷积层,每个卷积层滤波器尺寸分别为[16,32,64],卷积核大小分别为[64,3,3],池化步长为 2,训练周期为 20,学习率为 0.001,优化器为 Adam
RNN	网络结构为[32,32,16,32,6],训练周期为 20,学习率为 0.001,优化器为 Adam
DRN	网络结构包含 3 个残差块,每个残差块包含 2 个卷积层和 1 个 Dropout 层,每个卷积层滤波器尺寸为 32,卷积核大小为 3,训练周期为 20,学习率为 0.001,优化器为 Adam

表 6 模型对比实验精度

Table 6 Experimental accuracy of model comparison

%

模型	轴承单工况数据			轴承变工况数据			齿轮数据			
	训练集	验证集	测试集	训练集	验证集	测试集	训练集	验证集	测试集	测试集平均
BPNN	43.76	41.75	38.16	38.14	30.00	33.00	50.34	38.30	37.00	36.05
MLP	97.21	95.69	96.33	97.61	93.50	94.24	81.89	42.00	40.59	77.05
SAE	97.77	95.92	95.66	96.34	94.50	95.24	79.69	55.70	56.99	82.63
CNN	98.40	97.17	96.60	98.90	98.45	98.23	98.31	87.00	87.59	94.14
RNN	96.00	94.15	93.33	95.00	93.23	94.15	95.43	84.44	85.69	91.05
DRN	98.60	98.25	97.75	98.90	98.54	98.36	97.69	90.50	89.39	95.16
IDRN(本文所提方法)	99.95	99.90	<b>99.80</b>	99.86	99.75	<b>99.69</b>	96.46	91.30	<b>91.00</b>	<b>96.83</b>

## 4 结 论

本文针对旋转机械工况复杂多变、振动信号具有极强的非线性以及有标签样本不足而导致的故障特征提取困难等问题,提出了一种用于旋转机械故障诊断的 IDRN,主要得到了以下结论。

(1) 将该模型在轴承与齿轮箱数据集上进行了验证,在轴承单工况、变工况及齿轮箱 3 个实验中的测试集平均诊断精度达到了 96.83%,高于当前广泛使用的其他诊断模型。

(2) IDRN 在旋转机械智能故障诊断实验中,展示了强大的自适应挖掘故障特征的能力和稳定的识别性能。

(3) LSTM 具有长短时记忆的能力,能够捕捉故障发生的时序信息,对于时序型振动信号,可以获得更加丰富的特征表示。

(4) 残差块中引入 Dropout 层可以丢弃网络中的一些冗余信息,防止网络过拟合,提升诊断效率。

为了提升模型的诊断性能,并进一步推广到工业实际应用中,应该充分考虑各模型的优势,实现多种模型之间的相互融合与协调,充分发挥多模型融合的优势。

## 参考文献

- [1] WU X Y, ZHANG Y, CHENG C M, et al. A hybrid classification autoencoder for semi-supervised fault diagnosis in rotating machinery [J]. *Mechanical Systems and Signal Processing*, 2021, 149: 107327.
- [2] GUO J C, ZHEN D, LI H Y, et al. Fault feature extraction for rolling element bearing diagnosis based on a multi-stage noise reduction method[J]. *Measurement*, 2019, 139: 226–235.
- [3] LEI Y G, YANG B, JIANG X W, et al. Applications of machine learning to machine fault diagnosis: a review and roadmap[J]. *Mechanical Systems and Signal Processing*, 2020, 138: 106587.
- [4] 邵海东, 张笑阳, 程军圣, 等. 基于提升深度迁移自动编码器的轴承智能故障诊断[J]. *机械工程学报*, 2020, 56(9): 84–90.
- [5] SHAO H D, ZHANG X Y, CHENG J S, et al. Intelligent fault diagnosis of bearings based on lifting depth migration autoencoder[J]. *Journal of Mechanical Engineering*, 2020, 56(9): 84–90.
- [6] SHAO H D, JIANG H K, ZHANG H Z, et al. Rolling bearing fault feature learning using improved convolutional deep belief network with compressed sensing[J]. *Mechanical Systems and Signal Processing*, 2018, 100: 743–765.
- [7] LI X Y, LI J L, ZHAO C Y, et al. Gear pitting fault diagnosis with mixed operating conditions based on adaptive 1D separable convolution with residual connection[J]. *Mechanical Systems and Signal Processing*, 2020, 142: 106740.
- [8] ZHANG K, TANG B P, DENG L, et al. A hybrid attention improved ResNet based fault diagnosis method of wind turbines gearbox[J]. *Measurement*, 2021, 179: 109491.
- [9] HOANG D T, KANG H J. Rolling element bearing fault diagnosis using convolutional neural network and vibration image[J]. *Cognitive Systems Research*, 2019, 53: 42–50.
- [10] YU J B, ZHOU X K. One-dimensional residual convolutional autoencoder based feature learning for gearbox fault diagnosis[J]. *IEEE Trans. on Industrial Informatics*, 2020, 16(10): 6347–6358.
- [11] MAO W T, FENG W S, LIU Y M, et al. A new deep auto-encoder method with fusing discriminant information for bearing fault diagnosis[J]. *Mechanical Systems and Signal Processing*, 2021, 150: 107233.
- [12] LU C, WANG Z Y, ZHOU B. Intelligent fault diagnosis of rolling bearing using hierarchical convolutional network based health state classification[J]. *Advanced Engineering Informatics*, 2017, 32: 139–151.
- [13] JIA F, LEI Y G, LIN J, et al. Deep neural networks: a promising tool for fault characteristic mining and intelligent diagnosis of rotating machinery with massive data[J]. *Mechanical Systems and Signal Processing*, 2016, 72/73: 303–315.
- [14] 陈国梁, 岳夏, 周超, 等. 机械故障诊断技术机遇与挑战[J]. *机电工程技术*, 2020, 49(10): 1–4.
- [15] CHEN G L, YUE X, ZHOU C, et al. Opportunity and challenge to the development of mechanical fault diagnosis technology[J]. *Mechanical & Electrical Engineering Technology*, 2020, 49(10): 1–4.
- [16] HE K M, ZHANG X Y, REN S Q, et al. Deep residual learning for image recognition[C]//*Proc. of the IEEE Computer Vision and Pattern Recognition*, 2016: 770–778.
- [17] 田强, 贾小宁. 基于深度残差神经网络的车标识别[J]. *吉林大学学报*, 2021, 59(2): 319–324.
- [18] TIAN Q, JIA X N. Vehicle sign recognition based on deep residual neural network[J]. *Journal of Jilin University*, 2021, 59(2): 319–324.
- [19] HINTON G, SRIVASTAVA N, KRIZHEVSKY A, et al. Improving neural networks by preventing co-adaptation of feature detectors[J]. *Computer Science*, 2012, 3(4): 212–223.
- [20] SRIVASTAVA N, HINTON G, KRIZHEVSKY A, et al. Dropout: a simple way to prevent neural networks from overfitting[J]. *Journal of Machine Learning Research*, 2014, 15(1): 1929–1958.
- [21] CHEN L T, XU G H, TAO T F, et al. Deep residual network for identifying bearing fault location and fault severity concurrently[J]. *IEEE Access*, 2020, 8: 168026–168035.
- [22] ZHANG W, PENG G L, LI C H, et al. A new deep learning model for fault diagnosis with good anti-noise and domain adaptation ability on raw vibration signals[J]. *Sensors*, 2017, 17: 425.
- [23] 陈保家, 陈学力, 沈保明, 等. CNN-LSTM深度神经网络在滚动轴承故障诊断中的应用[J]. *西安交通大学学报*, 2021, 55(6): 28–36.
- [24] CHEN B J, CHEN X L, SHEN B M, et al. Application of CNN-LSTM deep neural network in rolling bearing fault diagnosis[J]. *Journal of Xi'an Jiaotong University*, 2021, 55(6): 28–36.
- [25] 张强, 黄挺, 陆效农, 等. 基于CNN-LSTM深度学习方法及多属性时序数据的故障诊断方法. 中国, 201811472378.6[P]. 2018–12–04.
- [26] ZHANG Q, HUANG T, LU X N, et al. Fault diagnosis method based on CNN-LSTM deep learning method and multi-attribute time-series data. China, 201811472378.6[P]. 2018–12–04.
- [27] WANG Y M, CHENG L. A combination of residual and long-short-term memory networks for bearing fault diagnosis based on time-series model analysis[J]. *Measurement Science and Technology*, 2021, 32: 015904.
- [28] JIAO J Y, ZHAO M, LIN J, et al. Residual joint adaptation adversarial network for intelligent transfer fault diagnosis[J]. *Mechanical Systems and Signal Processing*, 2020, 145: 106962.
- [29] CHEN Z Y, MAURICIO A, LI W H, et al. A deep learning method for bearing fault diagnosis based on cyclic spectral coherence and convolutional neural networks[J]. *Mechanical Systems and Signal Processing*, 2020, 140: 106683.
- [30] SHAO S Y, MCALEER S, YAN R Q, et al. Highly accurate machine fault diagnosis using deep transfer learning[J]. *IEEE Trans. on Industrial Informatics*, 2019, 15(4): 2446–2455.
- [31] LI X, LI X, MA H. Deep representation clustering-based fault diagnosis method with unsupervised data applied to rotating machinery[J]. *Mechanical Systems and Signal Processing*, 2020, 143: 106825.
- [32] XIANG Z, ZHANG X N, ZHANG W W, et al. Fault diagnosis



- sis of rolling bearing under fluctuating speed and variable load based on TCO spectrum and stacking auto-encoder[J]. Measurement, 2019, 138: 162–174.
- [28] JIANG W, ZHOU J Z, LIU H, et al. A multi-step progressive fault diagnosis method for rolling element bearing based on energy entropy theory and hybrid ensemble auto-encoder[J]. ISA Transactions, 2019, 87: 235–250.
- [29] ZHOU Q, LI Y B, TIAN Y, et al. A novel method based on nonlinear auto-regression neural network and convolutional neural network for imbalanced fault diagnosis of rotating machinery[J]. Measurement, 2020, 161: 107880.
- [30] MENG Z, ZHAN X Y, LI J, et al. An enhancement denoising autoencoder for rolling bearing fault diagnosis[J]. Measurement, 2018, 130: 448–454.

## 作者简介

侯召国(1996—),男,硕士研究生,主要研究方向为故障诊断、航空器健康管理。

王华伟(1974—),女,教授,博士研究生导师,博士,主要研究方向为民航安全工程、民航维修工程、可靠性工程。

周良(1996—),男,硕士研究生,主要研究方向为故障诊断、民机健康监测。

付强(1990—),男,博士研究生,主要研究方向为状态监测、民航安全风险评估。