

信息与控制

Information and Control

ISSN 1002-0411, CN 21-1138/TP

《信息与控制》网络首发论文

题目: 基于 SSA 优化变分模态分解和混合核极限学习机的短期风电功率预测
作者: 王瑞, 徐新超, 逯静
DOI: 10.13976/j.cnki.xk.2023.2281
收稿日期: 2022-04-26
网络首发日期: 2022-11-02
引用格式: 王瑞, 徐新超, 逯静. 基于 SSA 优化变分模态分解和混合核极限学习机的短期风电功率预测[J/OL]. 信息与控制.
<https://doi.org/10.13976/j.cnki.xk.2023.2281>



网络首发: 在编辑部工作流程中, 稿件从录用到出版要经历录用定稿、排版定稿、整期汇编定稿等阶段。录用定稿指内容已经确定, 且通过同行评议、主编终审同意刊用的稿件。排版定稿指录用定稿按照期刊特定版式 (包括网络呈现版式) 排版后的稿件, 可暂不确定出版年、卷、期和页码。整期汇编定稿指出版年、卷、期、页码均已确定的印刷或数字出版的整期汇编稿件。录用定稿网络首发稿件内容必须符合《出版管理条例》和《期刊出版管理规定》的有关规定; 学术研究成果具有创新性、科学性和先进性, 符合编辑部对刊文的录用要求, 不存在学术不端行为及其他侵权行为; 稿件内容应基本符合国家有关书刊编辑、出版的技术标准, 正确使用和统一规范语言文字、符号、数字、外文字母、法定计量单位及地图标注等。为确保录用定稿网络首发的严肃性, 录用定稿一经发布, 不得修改论文题目、作者、机构名称和学术内容, 只可基于编辑规范进行少量文字的修改。

出版确认: 纸质期刊编辑部通过与《中国学术期刊 (光盘版)》电子杂志社有限公司签约, 在《中国学术期刊 (网络版)》出版传播平台上创办与纸质期刊内容一致的网络版, 以单篇或整期出版形式, 在印刷出版之前刊发论文的录用定稿、排版定稿、整期汇编定稿。因为《中国学术期刊 (网络版)》是国家新闻出版广电总局批准的网络连续型出版物 (ISSN 2096-4188, CN 11-6037/Z), 所以签约期刊的网络版上网络首发论文视为正式出版。

基于 SSA 优化变分模态分解和混合核极限学习机的短期风电功率预测

王瑞, 徐新超, 逯静

河南理工大学计算机科学与技术学院, 河南 焦作 454000

基金项目: 河南省科技攻关项目(222102210120)

通信作者: 逯静, lujing@hpu.edu.cn

收稿/录用/修回: 2022-04-26/2022-08-09/

DOI: 10.13976/j.cnki.xk.2023.2281

摘要

为提高风电功率的预测精度, 提出了一种变分模态分解(variational mode decomposition, VMD)和混合核极限学习机(hybrid kernel extreme learning machine, HKELM)相结合的短期风电功率预测方法。针对 VMD 和 HKELM 参数难调问题, 以及实现两算法参数的自适应选择, 采用麻雀搜索算法(sparrow search algorithm, SSA)对两种算法中的关键参数进行优化。首先, 基于 3 种信号分解指标设计 SSA 优化 VMD 的适应度函数, 对 VMD 关键参数进行寻优, 利用优化后的 VMD 将风电功率分解为一组平稳子分量。然后, 结合径向基核函数与多项式核函数优点组成混合核函数, 对各分量结合气象特征分别建立兼顾学习与泛化能力的 HKELM 预测模型, 并使用 SSA 对模型参数进行寻优, 以充分发挥模型性能。最后, 将各分量预测值叠加, 得到最终预测结果。以中国内蒙古某风电场实际数据进行仿真实验, 结果表明, 该方法相比于其他预测方法具有更高的预测精度。

关键词

短期风电功率预测
麻雀搜索算法
变分模态分解
混合核函数
核极限学习机

中图分类号: TP391.9

文献标识码: A

Short-term Wind Power Prediction Based on SSA Optimized Variational Mode Decomposition and Hybrid Kernel Extreme Learning Machine

WANG Rui, XU Xinchao, LU Jing

School of Computer Science and Technology, Henan Polytechnic University, Jiaozuo 454000, China

Abstract

In order to improve the prediction accuracy of wind power, a short-term wind power prediction method combining variational mode decomposition (VMD) and hybrid kernel extreme learning machine (HKELM) is proposed. To address the problem of difficult parameters tuning of VMD and HKELM, and to achieve adaptive selection of the parameters of the two algorithms, the sparrow search algorithm (SSA) is used to optimize the key parameters in the two algorithms. Firstly, the SSA is designed to optimize the fitness function of the VMD based on three signal decomposition indexes, and the key parameters of the VMD are searched for,

Keywords

short-term wind power prediction;
sparrow search algorithm;
variational mode decomposition;
hybrid kernel function;

and the optimized VMD is used to decompose the wind power into a set of smooth subcomponents. Then, a hybrid kernel function is formed by combining the advantages of radial basis kernel function and polynomial kernel function, and a HKELM prediction model with learning and generalization capabilities is built for each component combined with meteorological features, and SSA is used to optimize the model parameters to fully utilize the model performance. Finally, the predicted values of each component are superimposed to obtain the final prediction results. Simulation experiments are conducted with actual data from a wind farm in Inner Mongolia, China, and the results show that the method has higher prediction accuracy than other prediction methods.

0 引言

随着中国提出力争到 2030 年和 2060 年前分别实现“碳达峰”和“碳中和”双碳目标推进^[1], 大力推动新能源技术发展已然是必然选择, 风电作为绿色清洁能源之一, 发展迅猛。然而风电出力易受气象特征及设备运行等多种因素影响, 使得发电功率具有强随机性和非平稳性, 并网时会对电力系统的安全稳定造成巨大影响。因此, 为提升风电的消纳能力, 维护电力系统安全稳定, 准确有效的风电功率预测显得尤为重要^[2]。

目前, 常用的风电功率预测方法主要包括物理法和统计法两大类^[3]。物理法通常需要考虑数值天气预报(numerical weather prediction, NWP)数据信息^[4]、风电场地形地貌信息^[5]、风电机组信息^[6], 通过求解复杂的偏微分方程组进行预测。统计法主要通过算法学习建立影响因素与风电功率间的非线性联系, 然后结合 NWP 数据和实测数据进行预测。统计法不仅包括持续法^[7]、自回归差分移动平均^[8]等时间序列法; 支持向量回归(support vector regression, SVR)^[9]、随机森林^[10]等传统机器学习方法; 还包括长短期记忆网络^[11-12]、门控循环单元^[13-14]、反向传播(back propagation, BP)网络^[15]和极限学习机(extreme learning machine, ELM)^[16]等深度学习算法。但由于风电功率波动性强、非平稳性高的特点, 使得单一预测算法并不能充分学习功率与特征影响因素间的非线性关系。不少学者通过使用一些信号处理方法, 对功率分解后再进行建模预测, 为提高风电功率预测精度奠定了数据基础。文[17]采用集成经验模态分解(ensemble empirical mode decomposition, EEMD)与改进核极限学习机(kernel extreme learning machine, KELM)的预测模型, 提高了预测精度, 并且 EEMD 缓解了经验模态

分解^[18]的模态混叠, 但其残留噪声也会削弱数据序列中的有效信息影响预测精度。文[19]提出了一种自适应噪声完整集成经验模态分解加模糊熵重构及核极限学习机的预测方法, 该分解方法很好地解决了模态混叠及残留噪声的影响, 取得了较好的预测精度, 但该分解方法也会由于集合平均时产生误差而影响精度。文[20]通过将 VMD 分解后的分量, 划分为 3 种趋势分量, 再分别进行预测, 减少了建模数量, 提高了模型的预测效率和精度。VMD 虽有效克服了经验模态分解的缺点, 但模态数量及一些关键参数仍需手动设置, 自适应性较差, 且手动调参具有较大的分解随机性。基于此, 文[21]提出了一种基于最优 VMD 及改进深度极限学习机的风电功率预测模型, 通过观察中心频率的方法确定模态数 K , 有效避免了 VMD 的过分解及欠分解, 且优化的深度极限学习机模型有效提高了预测精度。文[22]提出了一种基于自适应变分模态分解的风功率组合预测方法, 通过使用一种结合了排列熵的信号随机性检测方法, 确定了 VMD 的 K 值。两种方法都仅对模态数量 K 作了选取, 惩罚因子 α 值仍然通过人工经验方式选取, 但 α 值对 VMD 分解的影响也尤为重要。文[23]提出了一种基于优化算法寻优 VMD 关键参数及小波核极限学习机的风电功率多步预测方法, 通过将各分量排列熵加权设计适应度函数, 在提高 VMD 分解自适应的同时对最优解求解提供了有效判别。在众多预测算法中, 核极限学习机以其训练速度快, 学习能力强, 无需设定隐含层节点数, 训练结果稳定等特点, 得到了广泛应用。但采用单一核函数的核极限学习机, 往往难以兼顾学习精度和泛化能力, 同时也难以适应风电功率这种多数据特征样本^[24]。

基于上述, 本文提出了一种基于 SSA 优化 VMD-HKELM 的短期风电功率预测方法。首先, 使用 SSA 优化 VMD(optimized VMD, OVMD)将风

电功率分解为一组平稳子分量，基于排列熵、Pearson相关系数和VMD迭代代数构建综合指标，作为SSA优化VMD参数的适应度函数，以实现VMD对风电功率的自适应分解。然后，使用混合核函数代替单一核函数，对各分量结合气象特征分别建立兼顾学习与泛化能力的HKELM预测模型，同时利用SSA对模型参数寻优。最后，叠加各分量的预测值，得到最终预测值。与多种方法进行实验对比，结果表明本文方法具有更好的预测精度与泛化性。

1 方法与理论

1.1 变分模态分解

VMD在检测分解非线性、非平稳信号方面具有良好的性能。可将风电功率信号 $f(t)$ ，分解为不同的本征模态函数(intrinsic mode function, IMF)分量 u_k ，及对应中心频率 ω_k ，其分解可概括为变分问题的构建和求解过程，步骤如下：

1)对每个 u_k 通过希尔伯特变换得到单边频谱及解析信号，将解析信号及其预估中心频率 $e^{-j\omega_k t}$ 项混合，把频谱变换到基带上，利用高斯平滑估算已解调信号的带宽，并构建变分约束问题如下：

$$\begin{cases} \min_{\{u_k\}, \{\omega_k\}} \left\{ \sum_k \left\| \partial(t) \left[\left(\delta(t) + \frac{j}{\pi t} \right) * u_k(t) \right] e^{-j\omega_k t} \right\|_2^2 \right\} \\ \text{s.t. } \sum u_k = f(t) \end{cases} \quad (1)$$

2)使用拉格朗日算子 $\lambda(t)$ 和二次惩罚因子 α ，将变分约束问题转变为非约束问题，求解变分问题最优解：

$$\begin{aligned} L(\{u_k\}, \{\omega_k\}, \lambda) = & \alpha \sum_k \left\| \partial(t) \left[\left(\delta(t) + \frac{j}{\pi t} \right) * u_k(t) \right] e^{-j\omega_k t} \right\|_2^2 + \\ & \left\| f(t) - \sum_k u_k \right\|_2^2 + \left\langle \lambda(t), f(t) - \sum_k u_k \right\rangle \end{aligned} \quad (2)$$

3)通过交替方向乘子法实现对 u_k 及 ω_k 的交替更新，完成VMD分解。

$$\hat{u}_k^{n+1}(\omega) = \frac{\hat{f}(\omega) - \sum_{i \neq k} \hat{u}_i(\omega) + \frac{\hat{\lambda}(\omega)}{2}}{1 + 2\alpha(\omega - \omega_k)^2} \quad (3)$$

$$\omega_k^{n+1} = \frac{\int_0^\infty \omega |\hat{u}_k^{n+1}(\omega)|^2 d\omega}{\int_0^\infty |\hat{u}_k^{n+1}(\omega)|^2 d\omega} \quad (4)$$

式中： n 为迭代次数； $\hat{f}(\omega)$ 、 $\hat{u}_i(\omega)$ 、 $\hat{\lambda}(\omega)$ 、 $\hat{u}_k^{n+1}(\omega)$

分别代表 $f(t)$ 、 $u(t)$ 、 $\lambda(t)$ 、 $u_k^{n+1}(t)$ 的傅里叶变换。

1.2 麻雀搜索算法

SSA算法是2020年由Xue等^[25]受麻雀捕食行为启发而提出的一种新型群智能优化算法，麻雀种群按其职能行为可划分为发现者和追随者。

发现者是种群中适应度较好的个体，负责搜索食物源，同时为追随者提供食物源的位置，一般占10%~20%，位置更新公式如下：

$$X_{ij}^{t+1} = \begin{cases} X_{ij}^t \cdot \exp\left(\frac{-i}{\alpha \cdot M}\right), & R_2 < ST \\ X_{ij}^t + Q \cdot L, & R_2 \geq ST \end{cases} \quad (5)$$

式中： t 表示当前迭代次数， X_{ij}^t 表示第 i 个麻雀在第 j 维的位置， M 表示最大迭代次数， $\alpha \in (0,1]$ 的随机数， Q 为服从正态的随机数， $R_2 \in [0,1]$ 和 $ST \in [0.5,1]$ 分别为预警值和安全值， L 为值均为1的 $1 \times j$ 矩阵。

剩余个体为紧跟发现者进行觅食行为的追随者，位置更新公式如下：

$$X_{ij}^{t+1} = \begin{cases} Q \cdot \exp\left(\frac{X_{wj}^t - X_{ij}^t}{i^2}\right), & i > \frac{n}{2} \\ X_{pj}^{t+1} + |X_{ij}^t - X_{pj}^{t+1}| \cdot A^+ \cdot L, & \text{other} \end{cases} \quad (6)$$

式中： X_{pj}^{t+1} 表示 $t+1$ 次迭代最优位置， X_{wj}^t 表示 t 次迭代全局最差位置， A 为值为-1或1的 $1 \times j$ 矩阵，且 $A^+ = A^T(AA^T)^{-1}$ 。

同时，每代会随机分配10%~20%的警戒者，巡查监控觅食区域，当遇到危险时会发出报警信号，并迅速向安全地点转移，从而避免被捕食，位置更新公式如下：

$$X_{ij}^{t+1} = \begin{cases} X_{bj}^t + \beta(X_{ij}^t - X_{bj}^t), & f_i \leq f_g \\ X_{ij}^t + k \cdot \left(\frac{X_{ij}^t - X_{wj}^t}{(f_i - f_w) + \xi} \right), & f_i \leq f_g \end{cases} \quad (7)$$

式中： X_{bj}^t 表示全局最佳位置， β 是步长控制参数， $k \in [-1,1]$ 的均匀随机数， ξ 是极小实数， f_g 和 f_w 分别表示当前麻雀最好和最差适应度值。

1.3 SSA优化VMD

为降低风电功率的非平稳性，采用VMD对功率信号进行分解。VMD分解前需要对各种参数进行手动设置，其中模态数 K 及惩罚因子 α 对分解结果影响较大，设置不当会严重影响分解结果，其余参数通常设置为默认值。当模态数 K 设置过大时会过分解，产生频率混叠， K 设置过小又会欠

分解,导致信息缺失。 α 值设置不当也会影响信号的提取结果,对信号的重构结果影响较大。鉴于 K 和 α 两参数难以确定,且人工设置随机性大,本文使用 SSA 对 VMD 的 $[K, \alpha]$ 进行寻优。

优化算法寻优前适应度函数的构造也尤为重要。排列熵值的大小可表示时间序列信号 X_i 的随机程度,分解产生的各 IMF 分量熵值越小表明序列越规律,反之表明序列越复杂,随机性越大。

设一组长度为 N 的时间序列为 $u(1), u(2), \dots, u(N)$, 设置 m 和 L 值后对其重构,重构后的各子序列 X_i 表示如下:

$$X_i = [u(i), u(i+L), \dots, u(i+(m-1)L)] \quad (8)$$

式中: m 表示嵌入维度, L 表示延迟时间。

对每个 X_i 内部进行递增排序有:

$$u(i+(j_1-1)L) \leq \dots \leq u(i+(j_m-1)L) \quad (9)$$

其中, 每一个 X_i 被映射到一个符号序列 $S(K) = (j_1, j_2, \dots, j_m)$ 中, $K \in (1, m!)$ 。将所有的符号序列表示为概率分布 P_1, P_2, \dots, P_K 的形式, 计算 Shannon 熵, 则 $u(1), u(2), \dots, u(N)$ 的排列熵为

$$H_{PE}(m) = - \sum_{j=1}^K P_j \ln P_j \quad (10)$$

为方便表示, 将排列熵值进行归一化。

$$H_{PE}(m) = \frac{H_{PE}(m)}{\ln(m!)} \quad (11)$$

Pearson 相关系数可以衡量两种信号序列之间的相关程度, 其值范围在 $[-1, 1]$ 内, 值越大表明两信号的相关性越强, 因此可用 Pearson 相关系数作为衡量原始风功率信号与重构信号偏差的一种指标, 其公式如下:

$$P = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_{i=1}^n (x_i - \bar{x})^2 \sum_{i=1}^n (y_i - \bar{y})^2}} \quad (12)$$

式中: x_i 和 y_i 分别表示原始风电功率信号和重构信号, \bar{x} 和 \bar{y} 分别为对应的均值。

VMD 分解的输出变量 ω 指示了被估计模态的中心频率, 能反映各 IMF 分量的中心频率特征。其结果值与 ω 结果矩阵中 VMD 的收敛迭代代数直接相关, 迭代代数越少表明信号分解收敛越快, 各分量的频率特征越明显。因此将其作为适应度函数评估指标之一。

本文综合 3 种 VMD 分解的相关指标组成综合

评价指标构造适应度函数, 以更准确地寻找 VMD 分解中稳定性及规律性最好的分量。本文构建的综合评价指标适应度函数 f 公式如下:

$$O_{inter} = \text{length}(\omega) \quad (13)$$

$$f = \min \left[\frac{H_{PE}}{P} \times \lg(O_{inter}) \right] \quad (14)$$

式中: O_{inter} 表示 VMD 的收敛迭代代数, $\lg(O_{inter})$ 表示取迭代数的对数值。

以 f 作为 SSA 优化 VMD 的适应度函数, 对参数 $[K, \alpha]$ 进行寻优, 优化流程步骤如下:

- 1) 初始化参数组合 $[K, \alpha]$ 及其范围, 初始化麻雀种群参数, 将综合适应度指标作为适应度函数。
- 2) 计算当前各麻雀适应度大小, 找出最优最差适应度值, 及对应位置。
- 3) 一次迭代后对各麻雀适应度重新计算, 并更新麻雀个体位置信息。根据麻雀当前状态, 对整个麻雀种群的最优最差适应度值和位置进行更新。
- 4) 判断是否满足最大迭代, 若满足, 则输出最佳麻雀个体 $[K, \alpha]$, 否则返回 2) 继续迭代。
- 5) 由 SSA 优化后的参数组合 $[K, \alpha]$, 对功率信号进行 VMD 分解。

优化流程图如图 1 所示。

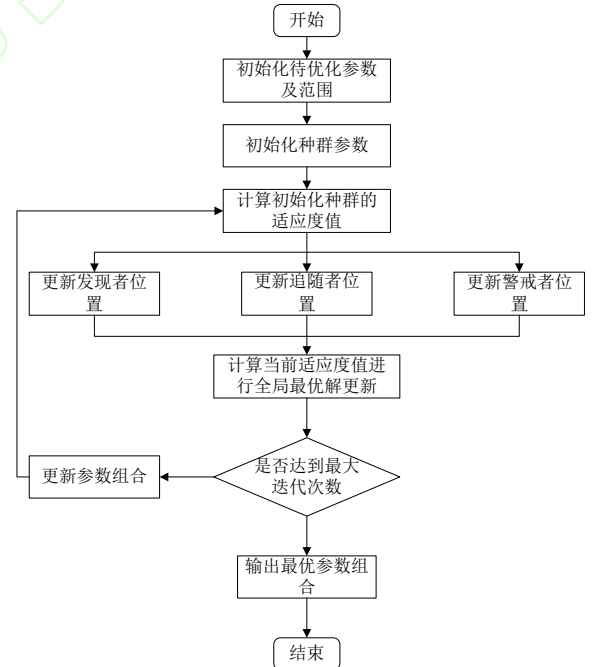


图 1 SSA 优化 VMD 流程图

Fig.1 Flow chart of SSA optimized VMD

1.4 混合核极限学习机

核极限学习机 KELM 模型是在极限学习机 ELM 模型基础上的一种改进, 通过引入核函数映射代替隐含层输入输出之间的随机映射关系, 在保

留 ELM 良好预测性能的同时, 因其无需给定隐含层节点数, 从而避免了人工设置节点数使训练结果随机性大的问题, 具有更好的稳健性。KELM 通过将低维空间中的非线性不可分数据转化为线性可分数据, 有效提高了 ELM 的鲁棒性及泛化能力, 更擅长解决回归预测问题。核极限学习机的模型结构图如图 2 所示。

对于给定的输入样本, KELM 的预测输出为

$$f(x) = \begin{bmatrix} K(x, x_1) \\ \vdots \\ K(x, x_n) \end{bmatrix} \left(K_{\text{ELM}} + \frac{I}{C} \right)^{-1} T \quad (15)$$

式中: C 是正则化系数, I 和 T 分别是对角矩阵和目标向量矩阵, $K(x, x_i)$ 是核函数, K_{ELM} 是核矩阵。

核矩阵 K_{ELM} 定义如下:

$$K_{\text{ELM}} = HH^T, K_{\text{ELM}_{i,j}} = h(x_i)h(x_j) = K(x_i, x_j) \quad (16)$$

式中: HH^T 表示 ELM 中的随机矩阵, 在 KELM 中将由核矩阵 K_{ELM} 代替。




图 2 核极限学习机模型结构图

Fig.2 The structure of the kernel extreme learning machine model

核函数选择不同, 模型的预测性能也存在较大差异, 采用单一核函数的 KELM 通常也难以适应风电功率这样的多特征样本。核函数包含多种类型, 其中径向基函数(radial basis function, RBF)为典型的局部型核函数, 学习能力强泛化能力弱; 多项式(polynomial, Poly)核为典型的全局型核函数, 学习能力较弱泛化能力强。为进一步提升核极限学习机的学习和泛化性能, 本文结合 RBF 和 Poly 核函数的优点, 组成混合核函数构造混合核极限学习机 HKELM 预测模型^[26-27], 从而更好地学习风电功率与特征因素之间的非线性关系。混合核函数的计算公式如下:

$$K_{\text{RBF}}(x, x_i) = \exp\left(-\frac{\|x - x_i\|^2}{\sigma^2}\right) \quad (17)$$

$$K_{\text{Poly}}(x, x_i) = (x, x_i + \mu)^v \quad (18)$$

$$K_{\text{HK}}(x, x_i) = \lambda K_{\text{RBF}} + (1 - \lambda) K_{\text{Poly}} \quad (19)$$

式中: σ 为 RBF 核的核参数, μ 和 v 为 Poly 核的核参数, λ 为两核间的权重系数, $\lambda \in (0, 1)$ 。

从混合核函数的计算公式及核极限学习机输出形式可知, HKELM 模型中参数较多, 参数设置对模型的精度也影响较大。为避免人工选择参数效率低, 且回归精度难以最优的缺点, 利用 SSA 对 HKELM 模型的正则化系数、混合核函数的核参数以及权重进行寻优。即优化目标 $G = [C, \sigma, \mu, v, \lambda]$, 其优化流程步骤与 SSA 优化 VMD 类似, 这里本文不再赘述。

2 基于 OVMD-SSA-HKELM 的短期风电功率预测

风电功率具有较强的波动性及非平稳性, 因此为提升可预测性, 本文设计一个综合评价指标作为 SSA 优化 VMD 的适应度函数, 将风电功率分解为一组相对平稳的 IMF 分量。对各分量划分训练集和测试集, 在训练集上训练各分量的 HKELM 预测模型, 并使用 SSA 对模型参数进行优化。在测试集上将气象特征因素输入预测模型进行预测, 得到各 IMF 分量预测值, 叠加各分量的预测值, 得到最终预测值, 并验证所建模型性能。本文构建了基于 OVMD-SSA-HKELM 的短期风电功率预测模型, 模型流程图如图 3 所示:

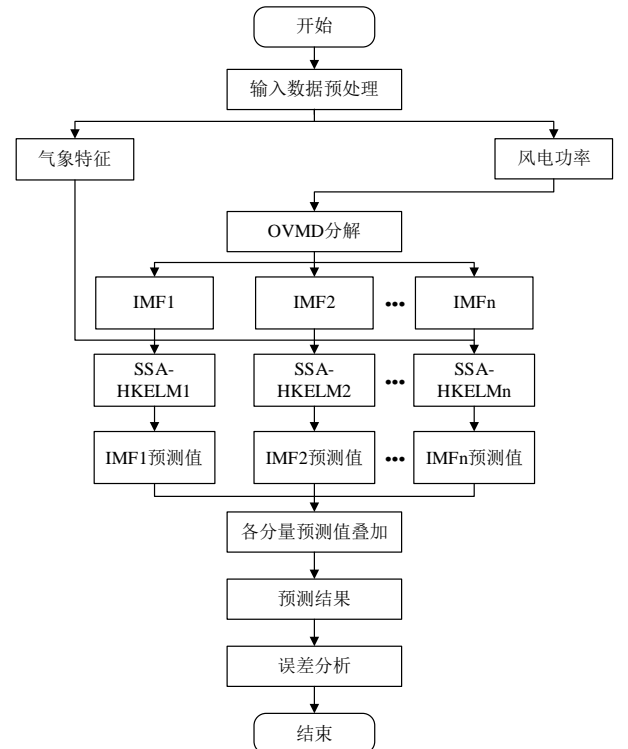


图3 OVMD-SSA-HKELM模型流程图

Fig.3 Flow chart of OVMD-SSA-HKELM model

具体流程步骤如下所示：

1)对输入数据进行预处理并划分数据集，利用SSA优化后的VMD将原始功率数据分解为一组平稳IMF分量。

2)在训练集上训练各IMF分量的HKELM预测模型，并使用SSA对模型参数寻优。

3)将各分量测试集输入量输入已训练好的SSA-HKELM模型，得到各IMF分量预测值。

4)叠加各分量预测值，得到最终预测结果值。

5)对预测结果进行误差分析，分析模型性能。

2.1 数据预处理及初始化

1)将原始风电功率数据带入SSA优化后的VMD模型分解，将分解后各分量与气象特征的风速、风向数据组成若干输入数据向量。

$$X:(x_1, x_2, \dots, x_k, \dots, x_K) \quad (20)$$

$$x_k = [P_k \quad WS \quad WD] \quad (21)$$

式中： $1 < k < K$ ， P_k 表示分解后的第 k 个风电功率分量。 WS 表示风速， WD 表示风向。

2)由于本文为多变量进行预测，不同变量之间的量纲各有不同，为减轻量纲对模型训练及预测结果的影响，对数据根据式(22)进行标准化处理。标准化公式如下所示：

$$x^* = \frac{x - \mu}{\sigma} \quad (22)$$

式中： x^* 表示标准化后的数据； x 表示实际值； μ 和 σ 分别表示每一列样本数据的均值和方差。为方便后续误差评价指标的计算与分析，对预测结果反归一化，使功率数据返回原来的量级。

2.2 评价指标

为验证本文所提方法性能，使用均方根误差(root mean square error, RMSE)、平均绝对误差(mean absolute error, MAE)、平均绝对百分比误差(mean absolute percentage error, MAPE)三个误差指标对模型预测效果进行评估，其公式如下：

$$X_{RMSE} = \sqrt{\frac{1}{N} \sum_{i=1}^N (\hat{y}(i) - y(i))^2} \quad (23)$$

$$X_{MAE} = \frac{1}{N} \sum_{i=1}^N |\hat{y}(i) - y(i)| \quad (24)$$

$$X_{MAPE} = \frac{1}{N} \sum_{i=1}^N \left| \frac{\hat{y}(i) - y(i)}{y(i)} \right| \times 100\% \quad (25)$$

式中： N 代表样本个数； $\hat{y}(i)$ 和 $y(i)$ 分别代表第 i

个风功率样本的预测值和真实值。

3 算例分析

为验证本文所提方法的有效性，采用中国内蒙古某风电场2020年1月份实际发电功率数据与气象数据作为实验数据，数据采样间隔15min。选取1月1日~1月30日共2880个数据样本作为训练集，1月31日的96个数据样本作为测试集。

3.1 VMD分解结果及SSA优化性能分析

风电功率序列具有波动性及非平稳性，为提升预测精度，采用VMD将原始功率序列分解。考虑VMD分解时模态数 K 及惩罚因子 α 难以人为确定，而SSA算法相比其他传统的智能优化算法有着较好的寻优精度和收敛速度，且稳定性更好^[28-29]，因此采用SSA对参数 $[K, \alpha]$ 寻优。同时为验证SSA优化性能，将SSA分别与遗传算法(genetic algorithm, GA)、布谷鸟搜索算法(cuckoo search algorithm, CSA)、鲸鱼优化算法(whale optimization algorithm, WOA)进行对比。实验中设置各优化算法的种群数量均为20，迭代次数为30，寻优范围 $K \in [3, 12]$ ， $\alpha \in [100, 2500]$ ，适应度迭代曲线及寻优结果如图4和表1所示。




图4 适应度迭代曲线

Fig.4 Fitness iteration curve

表1 VMD寻优结果

Tab.1 Optimization results of VMD

	分解参数		分解结果
	模态数	惩罚因子	综合指标值
GA-VMD	7	1698	2.466
WOA-VMD	6	2396	2.414
CSA-VMD	6	2159	2.405
SSA-VMD	5	1683	2.389

从图4可以看出，GA在迭代时适应度极不稳定，且算法收敛较慢，寻优能力最差；WOA相较于GA寻优精度得到了较大提升，但算法在迭代后

期并未完全收敛，收敛速度最慢；CSA 虽然相对收敛较快，但与 SSA 相比适应度值仍较高；SSA 在第 8 次迭代时就已完成收敛，具有更快的收敛速度，且适应度值更低，寻优能力更强。相比于另外三种优化算法，SSA 的这些优势主要得益于麻雀种群间分工明确，相互之间协同性强，以及侦查预警机制在种群中的警戒监察作用，且在迭代过程中能将种群中的所有因素考虑在内，使种群中的麻雀向全局最优值移动，迅速在最优值附近收敛。因此，在 4 种算法中 SSA 寻优能力最佳。从表 1 也可以发现，SSA-VMD 取得了最优的综合指标值，算法寻优精度最高，因此采用 SSA 寻优后的参数进行风电功率分解，分解结果图如图 5 所示。




图5 VMD分解结果
Fig.5 Decomposition results of VMD

3.2 预测结果分析

为验证本文所提方法的有效性，与相关单一及组合模型进行对比，对比实验基准模型信息描述如表 2 所示。

表2 对比实验基准模型

Tab.2 Comparison of experimental benchmark models

模型	描述
SVR ^[9]	支持向量回归模型
BP ^[15]	反向传播神经网络模型
ELM ^[16]	极限学习机模型
KELM ^[19]	核极限学习机模型
HKELM ^[26]	混合核极限学习机模型
OVMD-KELM ^[23]	SSA 优化 VMD 功率分解 +KELM 模型
OVMD-HKELM ^[22]	SSA 优化 VMD 功率分解 +HKELM 模型

EEMD-SSA-HKELM ^[17]	EEMD 功率分解+SSA 优化 HKELM 模型
CVMD-SSA-HKELM ^[27]	CSA 优化 VMD 功率分解 +SSA 优化 HKELM 模型
OVMD-SSA-HKELM	SSA 优化 VMD 功率分解 +SSA 优化 HKELM 模型

其中 SVR 采用径向基 RBF 核函数，*gamma* 取 0.01；BP 神经元个数取 64，激活函数为 tanh；ELM 采用双隐含层，神经元个数分别 64 和 30，激活函数为 tanh；KELM 采用 RBF 核函数，正则化系数 $C=10$ ，核参数 $\sigma=1$ ；HKELM 为 RBF 和 Poly 混合核函数，权重系数 $\lambda=0.5$ ，正则化系数 $C=10$ ，混合核参数 σ ， μ ， ν 均为 1。组合方法 OVMD-KELM 和 OVMD-HKELM 中的 KELM 和 HKELM 模型采用与单一 KELM 和 HKELM 模型相同的初始化参数设置，除此之外，各组合方法中 VMD 和 HKELM 的参数均由优化算法寻优所得。各单一模型预测结果如图 6 所示，误差指标如表 3 所示。

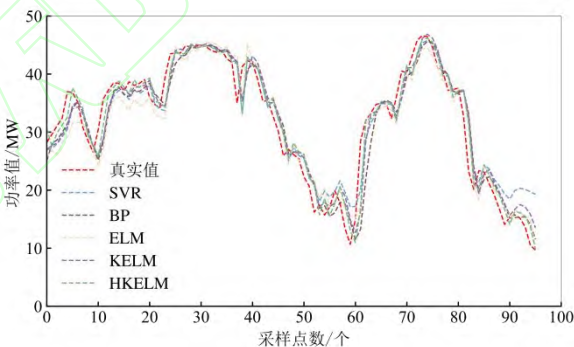


图6 各单一模型预测结果

Fig.6 Prediction results of each single model

从图6可看出，各单一模型虽能预测出真实值的变化趋势，但在波动剧烈及尖峰的样本点处仍有不小的拟合误差，其中HKELM模型预测偏差相对较小，具有更好的预测精度。从表3也可以发现 HKELM模型相比于KELM三种误差指标分别提升了9.83%，13.91%和13.77%。表明相比于采用单一核函数的KELM模型，采用混合核函数的HKELM模型具有更好的学习能力，更适合处理风电功率这种波动性较强的数据。

表3 单一模型的误差指标值

Tab.3 Error index values of a single model

预测模型	RMSE/MW	MAE/MW	MAPE/%
SVR	3.4699	2.6154	8.0074
BP	3.4622	2.4926	7.8594
ELM	3.3969	2.5840	8.2053

KELM	3.0385	2.2401	6.9529
HKELM	2.7398	1.9284	5.9958

本文方法与各组合方法的预测结果如图 7 所示，误差指标如表 4 所示。

结合图6图7可以看出，相比于单一模型，加入分解策略后的各组合方法的预测结果更贴近真实值，其中本文所提方法的拟合效果更好，在尖峰及

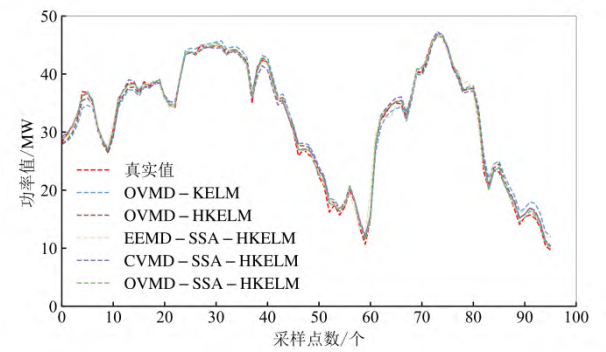


图7 各组合模型预测结果

Fig.7 Prediction results of each combination model
功率波动处具有更小的预测误差。从表4也可以发现，对功率分解后再进行预测，采用混合核函数的HKELM模型相比于KELM三种误差指标也分别提升了38.04%，40.13%和39.71%。进一步表明了混合核极限学习机模型具有更好的学习及泛化能力，预测精度更高。为进一步提高预测精度，本文方法使用SSA对各分量HKELM的相关超参数进行寻优，相比于未寻优的OVMD-HKELM模型三种误差指标分别提升了36.95%，33.48%和37.27%。表明通过优化算法对相关超参数寻优，有效克服了手动设置参数随机性大且难以发挥模型性能的限制。SSA优化的适应度变化图如图8所示，从图8可以看出，各分量优化时的收敛速度逐渐减低，分量1在迭代15次时已完成收敛，分量4和分量5均在迭代60次后才开始收敛，这主要由于相比于分量4分量5这样的高频分量，分量1的规律性更好，波动性更小，更有利于预测。


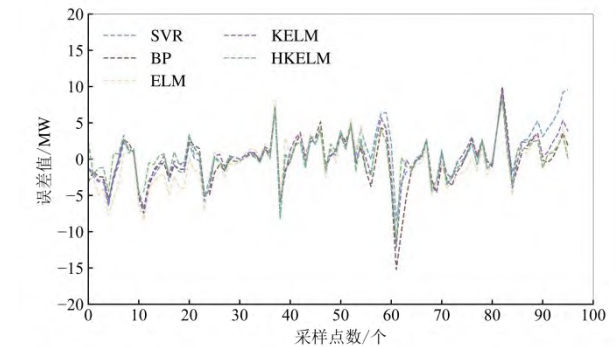


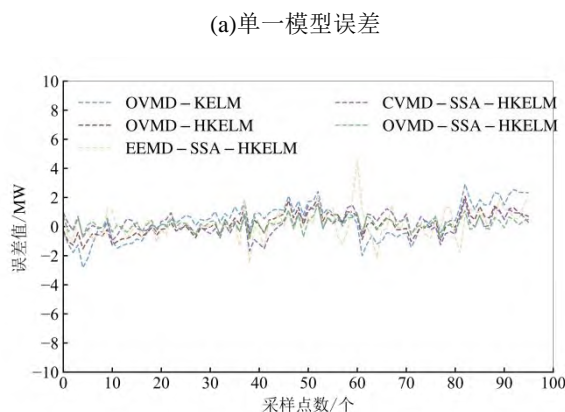
图8 各分量的适应度变化图

Fig.8 The fitness change diagram of each component
从表4还可以发现，相比于采用EEMD分解的EEMD-SSA-HKELM模型，本文方法的三种误差指标分别提升了51.67%，46.81%和46.78%。表明VMD可有效克服EEMD残留噪声的影响，使模型更易学习各分量与特征间的联系。相比于CVMD-SSA-HKELM模型，本文方法的三种误差指标分别提升了32.45%，31.12和31.57%。表明SSA优化VMD分解后的各分量更具稳定性和规律性，与原始序列的差别更小，可预测性更好。综合来看，本文所提方法具有更高的预测精度，模型的适应性更好。

表4 组合模型的误差指标值
Tab.4 Error index values of combined model

预测模型	RMSE /MW	MAE /MW	MAPE /%
OVMD-KELM	1.2563	1.0436	3.2255
OVMD-HKELM	0.7784	0.6248	1.9447
EEMD-SSA-HKELM	1.0155	0.7374	2.2920
CVMD-SSA-HKELM	0.7266	0.5694	1.7826
OVMD-SSA-HKELM	0.4908	0.3922	1.2199





(a)单一模型误差

(b)组合模型误差
图9 单一及组合模型误差值对比图
Fig.9 Comparison of error values of single and combined models

图9为各单一及组合模型的误差对比图,从图9可以直观看出,单一模型的误差值波动更大,误差最大达到15MW左右,具有较大的误差,表明单一模型并不能满足风电功率这种波动性较强数据的预测精度需求。各组合模型相比于单一模型的误差波动及误差值更小,预测性能有了较大提升,其中本文所提方法的预测误差更接近于0值,进一步表明本文方法的预测精度更好。

3.3 其他实验分析

为进一步验证本文所提方法的准确性与泛化性,选取内蒙古某风电场8月份以及与内蒙古风电场经纬度不同的宁夏某风电场1月份实际数据进行验证。与之前实验中所用内蒙古1月份数据相比,两数据分别由于季节差异和地理位置的不同,相关气象特征尤其是风速情况各有差异,其中宁夏1月份数据也由于场站风机信息的差异,具有更高的额定出力功率。两数据的采样时间间隔均为15min,均选取前30天2880个样本点用于训练,最后一天96个样本点进行测试。各模型8月及1月预测结果如图10和图11所示,误差指标如表5所示。

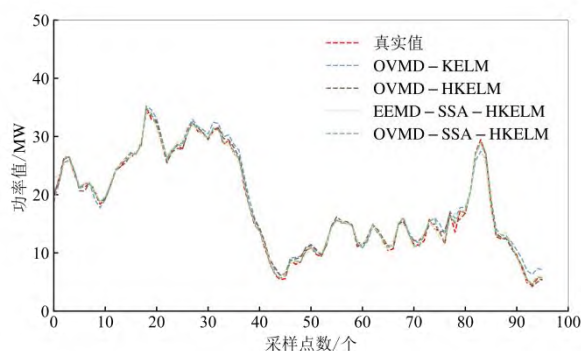


图10 各模型8月预测结果

Fig.10 Prediction results of each model in August

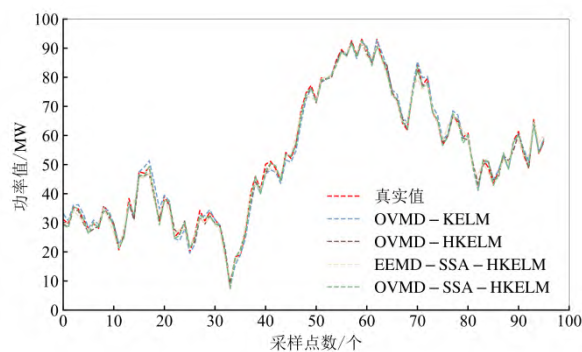


图11 各模型1月预测结果

Fig.11 Prediction results of each model in January

从图10可以看出,在最后的几个样本点处,OVMD-KELM模型预测值与真实值之间出现了较大偏差,而本文方法的预测值相比其他方法则更贴近真实值,且在功率急速升降的样本点处本文方法仍具有更好的拟合效果。从图11也可以看出,相比于内蒙古8月份数据,所选宁夏1月份数据测试样本点的波动性更大,在功率波动较快的10~26样本点及80~96样本点处,本文方法预测值相比其他方法与真实值的吻合度更高,整体的拟合效果也更好。综合两图可以看出,本文方法在8月和1月两数据中预测结果的拟合效果相比于其他方法均最好,模型具有较好的适应性。从表5也可以发现在8月和1月数据中,本文方法的MAPE值分别达到1.7052%和1.4942%,均保持在2%以内,且在几种模型中均具有最高的精度,进一步证明了本文方法具有较好的准确性与泛化性。

表5 各模型的误差指标值

Tab.5 Error index values of each model

数据	预测模型	RMSE /MW	MAE /MW	MAPE /%
8月	OVMD-KELM	0.9376	0.6517	4.0372
	OVMD-HKELM	0.6306	0.4923	2.6705
	EEMD-SSA-HKELM	0.8096	0.5817	3.1740
	OVMD-SSA-HKELM	0.4047	0.3130	1.7052
1月	OVMD-KELM	1.7295	1.3883	2.6652
	OVMD-HKELM	1.3378	1.0896	2.1109
	EEMD-SSA-HKELM	1.9367	1.5486	2.9978
	OVMD-SSA-HKELM	0.9196	0.7710	1.4942

4 结论

针对风电功率的波动性及非平稳性,本文提出一种基于SSA优化VMD-HKELM的短期风电功率预测方法,通过仿真实验对比得出如下结论:

1)综合排列熵、Pearson相关系数及VMD迭代

代数三种指标设计一种 SSA 优化 VMD 的适应度函数, 在提高 VMD 分解自适应性的同时, 实现了对分解量平稳性及规律性更为精准有效的判别, 克服了 VMD 参数难调、手动设置参数随机性大的问题, 为最大化提高风电功率预测精度奠定了基础。

2) 结合全局性 Poly 核与局部性 RBF 核函数的优点, 构建 HKELM 预测模型, 有效提高了预测模型的学习与泛化能力。引入收敛速度与寻优能力较强的 SSA 对 HKELM 模型的参数进行优化, 解决了 HKELM 模型参数多、人工选取难度大的问题, 大大提高了预测精度。

3) 通过与多种单一及组合方法对比, 仿真实验表明, 本文所提方法的预测精度更高且泛化性能更好。值得注意的是, 在设定好 SSA 算法基础参数后, 本文方法无需再手动调节参数, 有效避免了手动调参的繁琐性及随机性, 具有较强的自适应性及智能性。

风电功率出力受影响因素较多, 因此后续研究将考虑加入更多特征影响因素, 同时开展四季等更大范围的预测。

参考文献

- [1] 袁铁江, 曹继雷. 计及风电-负荷不确定性的风氢低碳能源系统容量优化配置[J]. 高电压技术, 2022, 48(6): 2037-2044.
- [2] Yuan T J, Cao J L. Capacity optimization allocation of wind hydrogen low-carbon energy system considering wind power-load uncertainty[J]. High Voltage Engineering, 2022, 48(6): 2037-2044.
- [3] Liu H, Chen C, Lv X, et al. Deterministic wind energy forecasting: A review of intelligent predictors and auxiliary methods[J]. Energy Conversion and Management, 2019, 195(1): 328-345.
- [4] 唐新姿, 顾能伟, 黄轩晴, 等. 风电功率短期预测技术研究进展[J]. 机械工程学报, 2022, 58(12): 213-236.
- [5] Tang X Z, Gu N W, Huang X Q, et al. Progress on short term wind power forecasting technology[J]. Journal of Mechanical Engineering, 2022, 58(12): 213-236.
- [6] 宋家康, 彭勇刚, 蔡宏达, 等. 考虑多位置 NWP 和非典型特征的短期风电功率预测研究[J]. 电网技术, 2018, 42(10): 3234-3242.
- [7] Song J K, Peng Y G, Cai H D, et al. Research of short-term wind power forecasting considering multi-location NWP and uncanonical feature[J]. Power System Technology, 2018, 42(10): 3234-3242.
- [8] 余沅, 董存, 王铮, 等. 考虑山东近海不同风能天气特征的风电功率区间预测模型[J]. 电网技术, 2020, 44(4): 1238-1247.
- [9] Yu F, Dong C, Wang Z, et al. Wind power interval forecasting model considering different wind energy weather characteristics in Shandong offshore areas[J]. Power System Technology, 2020, 44(4): 1238-1247.
- [10] 杨茂, 周宜. 计及风电场状态的风电功率超短期预测[J]. 中国电机工程学报, 2019, 39(5): 1259-1268.
- [11] Yang M, Zhou Y. Ultra-short-term prediction of wind power considering wind farm status[J]. Proceedings of the CSEE, 2019, 39(5): 1259-1268.
- [12] Lu P, Ye L, Pei M, et al. Coordinated control strategy for active power of wind power cluster based on model, Predictive Control[J]. Proceedings of the CSEE, 2021, 41(17): 5887-5899.
- [13] Korprasertsak N, Leephakpreeda T. Robust short-term prediction of wind power generation under uncertainty via statistical interpretation of multiple forecasting models[J]. Energy, 2019, 180: 387-397.
- [14] 赵倩, 黄景涛. 基于 EMD-SA-SVR 的超短期风电功率预测研究[J]. 电力系统保护与控制, 2020, 48(4): 89-96.
- [15] Zhao Q, Huang J T. On unra-short-term wind power prediction based on EMD-SA-SVR[J]. Power System Protection and Control, 2020, 48(4): 89-96.
- [16] 刘兴, 王艳, 纪志成. 基于随机森林的风电功率短期预测方法[J]. 系统仿真学报, 2021, 33(11): 2606-2614.
- [17] Liu X, Wang Y, Ji Z C. Short-term wind power prediction method based on random forest[J]. Journal of System Simulation, 2021, 33(11): 2606-2614.
- [18] 张群, 唐振浩, 王恭, 等. 基于长短期记忆网络的超短期风功率预测模型[J]. 太阳能学报, 2021, 42(10): 275-281.
- [19] Zhang Q, Tang Z H, Wang G, et al. Ultra-short-term wind power prediction model based on long and short term memory network[J]. ActaEnergiae Solaris Sinica, 2021, 42(10): 275-281.
- [20] Shahid F, Zameer A, Muneeb M. A novel genetic LSTM model for wind power forecast[J]. Energy, 2021, 223: 120069.
- [21] 王雨城, 曾宪文, 高桂革. 基于 GRU 网络的风功率短期预测模型[J]. 仪表技术, 2020(1): 9-12, 39.
- [22] Wang Y C, Zeng X W, Gao G G. Short-term forecast model of wind power based on GRU network[J]. Instrument Technology, 2020(1): 9-12, 39.
- [23] Niu Z W, Yu Z Y, Tang W H, et al. Wind power forecasting using attention-based gated recurrent unit network[J]. Energy, 2020, 196: 117081.
- [24] 李国庆, 刘钊, 金国彬, 等. 基于随机分布式嵌入框架及 BP 神经网络的超短期电力负荷预测[J]. 电网技术, 2020, 44(2): 437-445.
- [25] Li G Q, Liu Z, Jin G B, et al. Ultra-short-term power load forecasting based on randomly distributive embedded framework and BP neural network[J]. Power System Technology, 2020, 44(2): 437-445.
- [26] 刘栋, 魏霞, 王维庆, 等. 基于 SSA-ELM 的短期风电功率预测[J]. 智慧电力, 2021, 49(6): 53-59, 123.
- [27] Liu D, Wei X, Wang W Q, et al. Short-term wind power prediction based on SSA-ELM[J]. Smart Power, 2021, 49(6): 53-59, 123.
- [28] 杨锡运, 康宁, 杨雨薇, 等. 基于 EEMD 的 SOA-KELM 风电功率概率性短期区间预测[J]. 动力工程学报, 2019, 39(11): 926-933, 952.
- [29] Yang X Y, Kang N, Yang Y W, et al. Probabilistic short-term interval forecast of wind power based on EEMD and SOA-KELM model[J]. Chinese Journal of Power Engineering, 2019, 39(11): 926-933, 952.
- [30] Naik J, Satapathy P, Dash P K. Short-term wind speed and wind power prediction using hybrid empirical mode decomposition and kernel ridge regression[J]. Applied Soft Computing, 2018, 70: 1167-1188.
- [31] 李军, 李大超. 基于 CEEMDAN-FE-KELM 方法的短期风电功率预测[J]. 信息与控制, 2016, 45(2): 135-141.
- [32] Li J, Li D C. Short-term wind power forecasting based on CEEMDAN-FE-KELM method[J]. Information and Control, 2016, 45(2): 135-141.
- [33] 王瑞, 陈泽坤, 逯静. 基于 VMD 和 IBA-LSSVM 的短期风电功率预测[J]. 河海大学学报(自然科学版), 2021, 49(6): 575-582.
- [34] Wang R, Chen Z K, Lu J. Short-term prediction of wind power based on VMD and IBA-LSSVM[J]. Journal of Hohai

- University(Natural Science), 2021, 49(6): 575-582.
- [21] 曾亮, 雷舒敏, 王珊珊, 等. 基于OVMD-SSA-DELM-GM模型的超短期风电功率预测方法[J]. 电网技术, 2021, 45(12): 4701-4712.
- Zeng L, Lei S M, Wang S S, et al. Ultra-short-term wind power prediction based on OVMD-SSA-DELM-GM model[J]. Power System Technology, 2021, 45(12): 4701-4712.
- [22] 鹿凯, 石开明, 贾欢, 等. 基于自适应变分模态分解的组合模型风电功率预测[J/OL]. 电源学报. (2021-11-23)[2022-05-14]. <https://kns.cnki.net/kcms/detail/12.1420.TM.20211122.1634.006.html>.
- Lu K, Shi K M, Jia H, et al. wind power prediction of combined model based on variational modal decomposition[J/OL]. Journal of Power Supply. (2021-11-23)[2022-05-14]. <https://kns.cnki.net/kcms/detail/12.1420.TM.20211122.1634.006.html>.
- [23] 李青, 张新燕, 马天娇, 等. 基于ECBO-VMD-WKELM的风电功率超短期多步预测[J]. 电网技术, 2021, 45(8): 3070-3080.
- Li Q, Zhang X Y, Ma T J, et al. Multi-step ahead ultra-short term forecasting of wind power based on ECBO-VMD-WKELM[J]. Power System Technology, 2021, 45(8): 3070-3080.
- [24] 林涛, 蔡睿琪, 张丽, 等. 基于IBA-KELM的风电功率区间预测方法[J]. 可再生能源, 2018, 36(7): 1092-1097.
- Lin T, Cai R Q, Zhang L, et al. Prediction intervals forecasts of wind power based on IBA-KELM[J]. Renewable Energy Resources, 2018, 36(7): 1092-1097.
- [25] Xue J, Shen B. A novel swarm intelligence optimization approach: sparrow search algorithm[J]. Systems Science & Control Engineering An Open Access Journal, 2020, 8(1): 22-34.
- [26] 李可军, 徐延顺, 魏本刚, 等. 基于 PSO-HKELM 的变压器顶层油温预测模型[J]. 高电压技术, 2018, 44(8): 2501-2508.
- Li K J, Xu Y S, Wei B G, et al. Prediction model for top oil temperature of transformer based on hybrid kernel extreme learning machine trained and optimized by particle swarm optimization[J]. High Voltage Engineering, 2018, 44(8): 2501-2508.
- [27] 郭建帅, 崔双喜, 郭建斌, 等. 基于 VMD-SSA-HKELM 的超短期负荷预测[J]. 国外电子测量技术, 2022, 41(6): 105-111.
- Guo J S, Cui S X, Guo J B, et al. Ultra-short-term load prediction based on VMD-SSA-HKELM[J]. Foreign Electronic Measurement Technology, 2022, 41(6): 105-111.
- [28] 李雅丽, 王淑琴, 陈倩茹, 等. 若干新型群智能优化算法的对比研究[J]. 计算机工程与应用, 2020, 56(22): 1-12.
- Li Y L, Wang S Q, Chen Q R, et al. Comparative study of several new swarm intelligence optimization algorithms[J]. Computer Engineering and Applications, 2020, 56(22): 1-12.
- [29] 张九龙, 王晓峰, 芦磊, 等. 若干新型智能优化算法对比分析研究[J]. 计算机科学与探索, 2022, 16(1): 88-105.
- Zhang J L, Wang X F, Lu L, et al. Analysis and research of several new intelligent optimization algorithms[J]. Computer Science and Exploration, 2022, 16(1): 88-105.

作者简介

王瑞 (1977-), 男, 硕士, 副教授, 硕士生导师。研究领域为电力系统分析, 智能信息处理, 人工智能。

徐新超 (1998-), 男, 硕士生。研究领域为电力系统负荷预测。

逯静 (1980-), 女, 硕士, 副教授。研究领域为深度学习, 物联网技术。