



控制与决策

Control and Decision

ISSN 1001-0920, CN 21-1124/TP

《控制与决策》网络首发论文

题目: 基于多维特征评价的风机齿轮箱早期故障诊断
作者: 郭方洪, 林凯, 窦云飞, 吴祥, 俞立
DOI: 10.13195/j.kzyjc.2022.1388
收稿日期: 2022-08-02
网络首发日期: 2023-02-08
引用格式: 郭方洪, 林凯, 窦云飞, 吴祥, 俞立. 基于多维特征评价的风机齿轮箱早期故障诊断[J/OL]. 控制与决策. <https://doi.org/10.13195/j.kzyjc.2022.1388>



网络首发: 在编辑部工作流程中, 稿件从录用到出版要经历录用定稿、排版定稿、整期汇编定稿等阶段。录用定稿指内容已经确定, 且通过同行评议、主编终审同意刊用的稿件。排版定稿指录用定稿按照期刊特定版式(包括网络呈现版式)排版后的稿件, 可暂不确定出版年、卷、期和页码。整期汇编定稿指出版年、卷、期、页码均已确定的印刷或数字出版的整期汇编稿件。录用定稿网络首发稿件内容必须符合《出版管理条例》和《期刊出版管理规定》的有关规定; 学术研究成果具有创新性、科学性和先进性, 符合编辑部对刊文的录用要求, 不存在学术不端行为及其他侵权行为; 稿件内容应基本符合国家有关书刊编辑、出版的技术标准, 正确使用和统一规范语言文字、符号、数字、外文字母、法定计量单位及地图标注等。为确保录用定稿网络首发的严肃性, 录用定稿一经发布, 不得修改论文题目、作者、机构名称和学术内容, 只可基于编辑规范进行少量文字的修改。

出版确认: 纸质期刊编辑部通过与《中国学术期刊(光盘版)》电子杂志社有限公司签约, 在《中国学术期刊(网络版)》出版传播平台上创办与纸质期刊内容一致的网络版, 以单篇或整期出版形式, 在印刷出版之前刊发论文的录用定稿、排版定稿、整期汇编定稿。因为《中国学术期刊(网络版)》是国家新闻出版广电总局批准的网络连续型出版物(ISSN 2096-4188, CN 11-6037/Z), 所以签约期刊的网络版上网络首发论文视为正式出版。

基于多维特征评价的风机齿轮箱早期故障诊断

郭方洪¹, 林 凯¹, 窦云飞¹, 吴 祥^{1†}, 俞 立¹

(1. 浙江工业大学 信息工程学院, 杭州 310014)

摘 要: 为了及时有效地诊断风机齿轮箱早期微弱故障, 针对齿轮箱微弱故障信号非线性、非平稳、低幅值、低信噪比的特点, 本文提出了一种基于多维特征评价的风机齿轮箱早期故障诊断方法. 首先, 利用变分模态分解将原始振动信号分解为多个固有模态分量, 并构建“信息熵—峭度—包络谱峭度”多维特征评价模型, 结合熵权法筛选关键特征分量以重构信号. 其次, 运用改进的小波阈值法降低噪声干扰对重构信号的影响, 得到显著的故障冲击特征. 再者, 使用宽度学习系统进行状态识别, 并利用 L_{21} 正则化技术进一步提高其网络结构的稀疏性. 最后, 通过对风机齿轮箱实测数据进行特征分析与传统方法进行对比实验, 表明了本方法的有效性和优越性.

关键词: 风机齿轮箱; 故障诊断; 变分模态分解; 小波阈值降噪; 宽度学习; L_{21} 范数

中图分类号: TM315

文献标志码: A

DOI: 10.13195/j.kzyjc.2022.1388

引用格式: 郭方洪, 林凯, 窦云飞, 等. 基于多维特征评价的风机齿轮箱早期故障诊断 [J]. 控制与决策.

Incipient fault diagnosis for wind turbine gearbox based on multidimensional feature evaluation

GUO Fang-hong¹, LIN Kai¹, DOU Yun-fei¹, WU Xiang^{1†}, YU Li¹

(1. College of Information Engineering, Zhejiang University of Technology, Hangzhou 310014, China)

Abstract: In order to timely and effectively diagnose the incipient weak faults of wind turbine gearbox, a fault diagnosis method for wind turbine gearbox is proposed, which deals with the nonlinear, nonstationary, low amplitude and low SNR vibration signals. Firstly, the original vibration signal is decomposed into multiple intrinsic mode functions by using the optimal variational mode decomposition. Meanwhile, a new “information entropy-kurtosis-envelop spectrum kurtosis” multidimensional feature evaluation model is constructed, which is combined with entropy weight method to screen key intrinsic mode functions to reconstruct the signal. Then an improved wavelet threshold method is designed to perform secondary noise reduction, and the obvious fault shock characteristics are obtained. Finally, broad learning system is used for fault classification, and the L_{21} regularization technology is used to improve the sparsity of network structure. By analyzing the measured data of wind turbine gearbox and comparing with traditional methods, it is shown that this method is effective and has good performance on incipient fault diagnosis.

Keywords: wind turbine gearbox; fault diagnosis; variational mode decomposition; wavelet threshold denoising; broad learning system; L_{21} norm

0 引 言

风电的快速发展对我国能源结构转型起到了重要的战略支撑作用^[1], 风电机组的运维需求也随之迅速增长, 其中故障率高、可及性差、运维成本高等问题给风电机组全生命周期健康管理带来了巨大挑战. 齿轮箱是风电机组内部故障率最高的核心部件^[2], 及早发现齿轮箱故障并调整运维计划, 能有效提高风电机组运行的安全性和经济性. 然而, 当风机齿轮箱故障处于早期阶段时, 其动力学响应较弱, 故障信号容易淹没在较强的背景噪声中, 导致故障检出率较

低. 因此, 针对风机齿轮箱早期故障诊断, 如何有效地提取微弱故障特征并进行准确的故障状态识别是研究的关键难点和重点方向.

风机齿轮箱早期故障信号具有非线性、非平稳、低幅值、低信噪比等特点^[3], 使得故障特征具有较强的隐蔽性, 特征提取难度较大, 因此实现诊断的关键是从故障信号中提取出高质量的特征信息^[4]. 针对故障信号特征提取, 经验模态分解^[5]、集合经验模态分解^[6]和局部均值分解^[7]等信号分解算法被相继提出. 然而, 上述算法均受限于递归模式分解框架, 将

收稿日期: 2022-08-02; 录用日期: 2023-01-20.

[†]通讯作者. E-mail: xiangwu@zjut.edu.cn.

其应用于复杂信号分析时将存在模态混叠和端点效应等问题,降噪的同时也损伤了早期故障特征信号.为解决此问题,文献[8]提出一种自适应、完全非递归的变分模态分解 (variational mode decomposition, VMD) 算法,该算法具有严格的数学模型,克服了端点效应和模态混叠问题.VMD 将故障信号分解为若干个固有模态分量 (intrinsic mode function, IMF),采用评价指标分析 IMF 是筛选早期故障特征的关键^[9].文献[10]使用 VMD 将柱塞泵振动信号分解为 7 个中心频率相互独立的 IMF,并使用“峭度”指标从中筛选表征早期故障特征的关键 IMF.文献[11]针对滚动轴承故障诊断,同样采用 VMD 算法分析故障信号,基于“峭度”指标筛选关键 IMF.然而,现有大部分研究中通过单维指标“峭度”在筛选关键 IMF 时极易造成重要特征信息遗漏并产生误判^[12],如文献[13]中将“峭度”作为筛选轴承故障关键 IMF 的唯一指标时,未获得显著故障特征.此外,由于风机运行环境恶劣,分析关键 IMF 发现其仍存在较大背景噪声,信号降噪效果将决定故障特征提取的精度.因此,研究在噪声影响下的 IMF 多维评估与精细化筛选,对增强特征分量的故障表征能力进而提高风机齿轮箱早期故障诊断准确率具有积极意义.

在故障状态识别方面,基于深度学习的方法表现优异,在故障诊断领域得到广泛应用.文献[14]将齿轮箱故障信号进行时频变换,进而将得到的频域图像作为深度卷积神经网络的输入来训练模型,具有较高的故障诊断准确率.文献[15]利用深度置信网络的复杂映射表征能力实现齿轮故障识别.深度学习网络具有强大的学习能力和广泛的适用范围,但其涉及大量的超参数且网络结构复杂,对计算资源需求高.然而,现有风机系统硬件有限的计算资源无法满足实际需求.同时,齿轮箱早期微弱故障极有可能在短时间内突变至较大幅值,基于深度学习的方法时效性无法得到保证.因此,从神经网络计算复杂度和实时性综合考虑,选择轻量级网络用于风机齿轮箱早期故障诊断具有现实意义.文献[16]利用轻量级网络极限学习机在较短时间内完成了行星齿轮故障的精确诊断.文献[17]提出一种轻量级的宽度学习系统 (broad learning system, BLS),文献[18-19]通过对 BLS 的深入研究证明其在学习速度、泛化性能等方面表现优异.尽管 BLS 已在诸多领域得到成功应用^[20-22],但鲜有研究讨论其网络结构稀疏问题.标准 BLS 在目标函数中引入 L_2 范数,利用岭回归算法求得输出权重.然而岭回归倾向于保持

原有的网络节点,当样本数据具有较高维度时,网络结构变得非常复杂^[23],增加了算力消耗.因此,提高宽度学习网络结构的稀疏性可进一步提升训练效率.

综上所述,为了有效地对风机齿轮箱早期故障进行精确诊断,本文提出一种基于多维特征评价的风机齿轮箱早期故障诊断方法.该方法首先利用 VMD 对实测振动信号进行最优模态分解得到数个 IMF;针对现有 IMF 评价机制片面导致重要信息遗漏的现象,建立了“信息熵—峭度—包络谱峭度”多维特征评价模型,从三个不同维度全面评估各 IMF,结合熵权法^[24]筛选关键 IMF 以重构信号.同时针对重构信号中仍存在噪声干扰的现象,运用改进的小波阈值降噪法^[25](wavelet threshold denoising, WTD)对重构信号进行二次降噪,改进后的 WTD 能在降噪的同时最大程度保留早期故障信号的微小细节特征.最后,将标准 BLS 中的 L_2 范数替换为 L_{21} 范数,基于 L_{21} 范数的 BLS(L_{21} -BLS)网络结构更为紧凑,可高效完成风机齿轮箱状态识别.通过对真实风电机组运行数据进行实验分析表明,所提方法适用于风机齿轮箱早期故障诊断.本文主要贡献如下:

(1) 提出一种早期故障特征精细化提取策略.该策略联合 VMD 与改进 WTD 对故障早期微弱信号进行组合分析,并将故障信号的不确定性、脉冲性和循环平稳性指标纳入评价体系,从多维度评估筛选特征,强化特征分量的故障表征能力.

(2) 设计一种基于 L_{21} 范数正则化的 BLS: L_{21} -BLS,其可剔除网络中的冗余节点,具有结构轻量、计算资源依赖度低等优点.应用于风机齿轮箱早期故障诊断时具有较高的准确率和较强的实时性,为实际工程中的故障诊断算法选择提供新思路.

1 相关理论基础

在给出本文所提方法之前,本节先对后续需要用到的核心技术及其基本原理进行简单介绍.

1.1 变分模态分解

VMD 是一种基于维纳滤波的自适应信号处理方法,将原始信号分解成有限数量个不同频段的 IMF^[8].VMD 算法的核心是构建和求解变分问题.构造变分问题如下:

$$\begin{cases} \min_{\{u_k\}, \{\omega_k\}} \left\{ \sum_k \left\| \partial_t \left[\delta(t) + \frac{j}{\pi t} \right] * u_k(t) \right\|_2^2 \right\}; \\ \text{s.t. } \sum_{k=1}^K u_k = f(t). \end{cases} \quad (1)$$

式中: K 表示固有模态分量个数; $\{u_k\}$ 、 $\{\omega_k\}$ 分别表示第 k 个分量及其中心频率; ∂_t 表示解调信号梯度; $\delta(t)$ 表示狄拉克函数; $*$ 表示卷积运算符; $f(t)$ 表示

原始信号.

为了求解上述约束变分问题的最优解, 引入惩罚因子 α_1 和 Lagrange 乘子 λ_1 , 将其变为非约束变分问题. 增广 Lagrange 表达式为:

$$\begin{aligned} \mathcal{L}(\{u_k\}, \{\omega_k\}, \lambda_1) = & \alpha_1 \sum_k \left\| \partial_t \left[\left(\delta(t) + \frac{j}{\pi t} \right) * u_k(t) \right] e^{-j\omega_k t} \right\|_2^2 + \\ & \left\| f(t) - \sum_k u_k(t) \right\|_2^2 + \left\langle \lambda_1(t), f(t) - \sum_k u_k(t) \right\rangle. \end{aligned} \quad (2)$$

利用交替方向乘子法^[26] 寻找式 (2) 的“鞍点”并求解最小值, 获得最优解. 最优解即为固有模态分量 $\{u_i\}$ 及各自的中心频率 $\{\omega_i\}$.

1.2 宽度学习系统

BLS 是在随机向量函数链接神经网络 (Random Vector Functional-Link Neural Network, RVFLNN) 基础上发展的一种轻量化的扁平神经网络结构^[27]. 通过对 RVFLNN 中的隐藏层进行运算得到增强层, 增强层与原有的输入层并列为同一层, 而输出层节点直接与所有映射的输入层特征节点和增强层节点相连, 便形成如图 1 所示“扁平”化的网络结构. 由于减少了隐藏层, 使得层间反向求导和迭代更新所花费的时间大大减少, 提高了网络运行效率.

利用含 n 个特征节点和 m 个增强节点的 BLS 进行状态识别时, 先将待分类数据样本 $\mathbf{X} \in \mathbb{R}^{N \times M}$ 作为输入, 经过线性映射得到特征节点, 第 i 个特征节点 F_i 记为:

$$F_i = \Phi(\mathbf{X}\mathbf{W}_{e_i} + \beta_{e_i}), i = 1, 2, \dots, n. \quad (3)$$

式中: Φ 表示特征节点的激活函数; \mathbf{W}_{e_i} 和 β_{e_i} 分别表示随机初始化的输入权重和偏置.

记 n 个特征节点组合为 $\mathbf{F}^n = [F_1, F_2, \dots, F_n]$, 特征节点经过非线性函数变换得到增强节点, 第 j 组增强节点 E_j 记为:

$$E_j = \xi(\mathbf{F}^n \mathbf{W}_{h_j} + \beta_{h_j}), j = 1, 2, \dots, m. \quad (4)$$

式中: ξ 表示增强节点的激活函数; \mathbf{W}_{h_j} 和 β_{h_j} 分别表示增强节点的连接权重和偏置.

类似地, 定义 m 个增强节点组合为 $\mathbf{E}^m = [E_1, E_2, \dots, E_m]$, 则 BLS 模型可表示为:

$$\mathbf{Y} = \mathbf{A}\mathbf{W}. \quad (5)$$

式中: $\mathbf{A} = [\mathbf{F}^n | \mathbf{E}^m]$; \mathbf{W} 表示 BLS 的权重, 可通过最小化目标公式求解, 即

$$\arg \min_{\mathbf{W}} \{ \|\mathbf{Y} - \mathbf{A}\mathbf{W}\|_2^2 + \eta \|\mathbf{W}\|_2^2 \}. \quad (6)$$

根据式 (6), 得到输出权重

$$\mathbf{W} = (\eta \mathbf{I} + \mathbf{A}^T \mathbf{A})^{-1} \mathbf{A}^T \mathbf{Y}. \quad (7)$$

式中: η 为正则化参数; \mathbf{I} 为单位矩阵.




图1 BLS模型图

2 风机齿轮箱早期故障诊断方法

从振动信号中分离并识别微弱异常信号分量是风机齿轮箱早期故障诊断的关键. 针对风机齿轮箱早期故障信号, 本节将提出改进 VMD-WTD 联合特征提取策略, 可有效分离出微弱的异常信号分量. 同时为满足风机运行过程中对故障诊断准确率和时效性的要求, 本节提出在计算资源有限的设备上采用轻量级的 L_{21} -BLS 进行高效故障状态识别. 综上, 本文提出的风机齿轮箱早期故障诊断系统框架如图 2 所示.

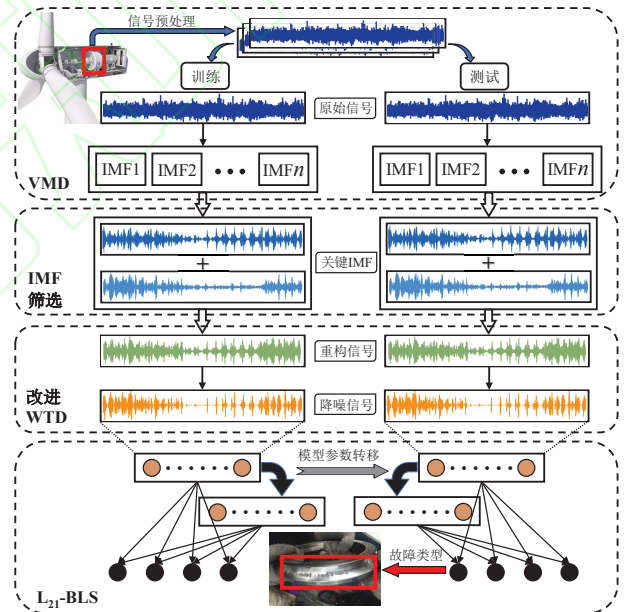


图2 风机齿轮箱早期故障诊断系统框架图

2.1 早期故障特征精细化提取策略

针对风机齿轮箱早期故障信号非线性、非平稳、低幅值、低信噪比的特点, 提出并使用一种联合降噪策略提取微弱故障特征. 首先, 利用基于多维特征评价模型的 VMD 分解原始信号并筛选出表征早期故障特征的关键 IMF. 其次, 运用改进 WTD 对故障信号进行二次降噪, 进一步凸显故障特征.

原始信号经 VMD 后得到多个不同频段的 IMF, 但部分不包含故障特征信息的 IMF 在后期处理时将导致数据量倍增, 极易造成误诊断, 因此需要从中筛选出关键 IMF. 分析风机齿轮箱故障可知, 当齿轮发

生故障时,其故障表面会与其他元件发生周期性撞击,产生周期性均匀脉冲,由此可知风机齿轮箱故障信号有两大关键特征:脉冲性和循环平稳性.然而,现有研究中通常只考虑故障的脉冲性,即通过单维指标“峭度”^[28]来评估故障信号,忽略了循环平稳性,造成重要故障特征信息遗漏.为了更加全面地对各IMF进行评估,本文使用“包络谱峭度”^[29]来表征故障信号的循环平稳性,并引入信号的不确定性评价指标——信息熵^[30]来评估信号的无序程度,构建了“信息熵—峭度—包络谱峭度”多维特征评价模型.上述三个评价指标在数值计算上无相关性,为了进一步确定各指标的重要程度,运用熵权法对上述指标进行加权排序.熵权法的具体步骤如下:

step 1: 指标标准化.将指标分为 I、II 两类,根据定义将信息熵划为 I 类指标(信息熵越小,IMF 越能表征原始信号的特征),将峭度、包络谱峭度划为 II 类指标(峭度、包络谱峭度越大,IMF 越能表征原始信号的特征).设共有 n 个 IMF,记第 i 个 IMF 的信息熵、峭度、包络谱峭度值分别为 u_{i1}, u_{i2}, u_{i3} ,对 I 类指标进行标准化

$$l_{i1} = \frac{\max(u_{11}, u_{21}, \dots, u_{n1}) - u_{i1}}{\max(u_{11}, u_{21}, \dots, u_{n1}) - \min(u_{11}, u_{21}, \dots, u_{n1})}. \quad (8)$$

对 II 类指标进行标准化

$$l_{i2} = \frac{u_{i2} - \min(u_{12}, u_{22}, \dots, u_{n2})}{\max(u_{12}, u_{22}, \dots, u_{n2}) - \min(u_{12}, u_{22}, \dots, u_{n2})}. \quad (9)$$

$$l_{i3} = \frac{u_{i3} - \min(u_{13}, u_{23}, \dots, u_{n3})}{\max(u_{13}, u_{23}, \dots, u_{n3}) - \min(u_{13}, u_{23}, \dots, u_{n3})}. \quad (10)$$

step 2: 计算指标熵权.以“信息熵”指标为例,其熵值为

$$H_1 = -\frac{1}{\ln n} \sum_{i=1}^n v_{i1} \ln v_{i1}. \quad (11)$$

式中: $v_{i1} = \frac{l_{i1}}{\sum_{i=1}^n l_{i1}}$.同理可得“峭度”、“包络谱峭度”指标的熵值 H_2 、 H_3 .

则“信息熵”指标的熵权为

$$s_1 = \frac{1 - H_1}{3 - \sum_{i=1}^3 H_i}. \quad (12)$$

同理可得“峭度”、“包络谱峭度”指标的熵权 s_2 、 s_3 .

step 3: 筛选关键 IMF.根据 3 个指标的值及其熵权,利用线性加权和法求得第 i 个 IMF 的评价系数 L_i 为

$$L_i = s_1 \cdot u_{i1} + s_2 \cdot u_{i2} + s_3 \cdot u_{i3} \quad (13)$$

选取评价系数较大的 2 个 IMF 作为故障关键 IMF 以重组信号.

此外,由于风机运行环境恶劣,经重构的信号中仍存在较多噪声干扰,为进一步凸显早期微弱故障特征,本文使用改进 WTD 实现二次降噪以提高信号信噪比.改进 WTD 在充分研究传统 WTD 中硬阈值函数^[31]和软阈值函数^[32]特点的基础上,提出一种如图 3 所示的改进阈值函数,其数学模型为

$$f(\mu) = \begin{cases} \mu - \frac{\theta^2}{\mu} \cdot e^{-a \cdot |\mu - \theta|}, & |\mu| \geq \theta; \\ 0, & |\mu| < \theta. \end{cases} \quad (14)$$

式中: $f(\mu)$ 表示估计小波系数; μ 表示原始小波系数; θ 表示阈值; $a \in \mathbb{R}^+$ 表示调节因子.改进阈值函数是以 $f(\mu) = \mu$ 为渐近线的连续函数并可通过调节因子 a 来控制函数的逼近速度.若 a 值较小,改进阈值函数将以较慢的速度逼近 $f(\mu) = \mu$,使得降噪信号更光滑;增大 a 值则可加快逼近速度,避免降噪信号过于平缓光滑而丢失大量原始信息.因此只要适当调整 a 的大小即可获得更好的降噪效果.可见,改进阈值函数不仅在处理不同信号时具备更强的适应性,而且物理意义明显,其克服了硬阈值函数在阈值处不连续,软阈值函数存在恒定偏差等缺点.




图 3 3 种阈值函数坐标对比图

2.2 基于 L_{21} 范数正则化的宽度学习系统

在本节中,将介绍本文所提出的 L_{21} -BLS,并利用交替方向乘子法给出其优化求解过程.

标准 BLS 的输入权重是随机选取的,权重的生成独立于样本数据^[17].一般情况下,为保证 BLS 的函数拟合及泛化能力,其神经元数目被设置得非常大.然而,此时网络结构往往是冗余的,部分多余的神经元导致了网络算力需求大、耗时长、存储所占空间大,不利于模型在实际场景中的应用.为此,本文提出利用 L_{21} 范数替换标准 BLS 中的 L_2 范数.对于权重矩阵 \mathbf{W} ,将第 i 行记为 \mathbf{w}^i ,第 j 行记为 \mathbf{w}_j ,则其 L_{21} 范数定义为

$$\|\mathbf{W}\|_{2,1} = \sum_{i=1}^n \sqrt{\sum_{j=1}^m (\mathbf{w}_j^i)^2} = \sum_{i=1}^n \|\mathbf{w}^i\|_2 \quad (15)$$

式中: $\|\cdot\|_{2,1}$ 表示 L_{21} 范数, $\|\cdot\|_2$ 表示 L_2 范数. L_{21} 范数实则为矩阵所有行向量的 L_2 范数之和.在最小化问题中, L_{21} 范数将矩阵内不相关的权值缩减至 0,

实现结构化稀疏, 而 L_2 范数不具备此功能. 因此, 采用基于 L_{21} 正则化^[33] 的稀疏表示方法来选择最优神经元, 既保证了原系统的性能, 又精简了系统结构. L_{21} -BLS 优化目标函数:

$$\arg \min_W \{ \|Y - AW\|_2^2 + \eta \|W\|_{21} \}. \quad (16)$$

式 (16) 可等价于:

$$\begin{cases} \arg \min_{G, W} \{ \|Y - AW\|_2^2 + \eta \|G\|_{21} \}; \\ \text{s.t. } G = W. \end{cases} \quad (17)$$

将式 (17) 转化为增广 Lagrange 形式:

$$\mathcal{L}(W, G, \lambda_2) = \|Y - AW\|_2^2 + \eta \|G\|_{21} + \frac{\alpha_2}{2} \|G - W\|_2^2 + \lambda_2^T (G - W). \quad (18)$$

式中: α_2 为惩罚因子; λ_2 为 Lagrange 乘子.

交替方向乘子法由以下求解步骤组成:

(1) 求解 W : 可由以下公式求解:

$$\arg \min_W \left\{ \|Y - AW\|_2^2 + \frac{\alpha_2}{2} \|M - W\|_2^2 \right\}. \quad (19)$$

式中: $M = G + \frac{\lambda_2}{\alpha_2}$. 则可求得 W :

$$W = (\alpha_2 I + 2A^T A)^{-1} (\alpha_2 M + 2A^T Y). \quad (20)$$

(2) 求解 G : 可由以下公式求解:

$$\arg \min_G \left\{ \eta \|G\|_{21} + \frac{\alpha_2}{2} \|N - G\|_2^2 \right\}. \quad (21)$$

式中: $N = W - \frac{D}{\alpha_2}$, 则可求得 G :

$$G = (\eta \Gamma + \alpha_2 I)^{-1} \rho N. \quad (22)$$

式中: $\Gamma = \text{diag} \left(\frac{1}{\|G^s\|_2} \right) W$; G^s 为 G 第 s 行构成的向量.

(3) λ_2 在每次迭代中通过以下公式更新:

$$\lambda_2' = \lambda_2 + \alpha_2 (G - W). \quad (23)$$

2.3 风机齿轮箱早期故障诊断流程

本文所提出的基于 VMD、多维特征评价模型、改进 WTD 和 L_{21} -BLS 的风机齿轮箱早期故障诊断方法流程如图 4 所示.

故障诊断方法具体步骤如下.

step 1: 利用振动传感器采集风机齿轮箱早期故障的振动信号并预处理.

step 2: 使用 VMD 将振动信号分解为多个 IMF.

step 3: 构建“信息熵—峭度—包络谱峭度”多维特征评价模型, 分别计算各 IMF 的信息熵^[27]、峭度^[25]和包络谱峭度^[26]的值.

step 4: 运用熵权法确定 3 个评价指标的权重, 计算各 IMF 的评价系数, 筛选关键 IMF.

step 5: 利用改进 WTD 对重构信号降噪.

step 6: 输入训练样本训练 L_{21} -BLS 网络, 得到风

机齿轮箱故障诊断模型.

step 7: 用测试样本验证所提方法的有效性, 根据诊断结果分析验证该方法的有效性和时效性.

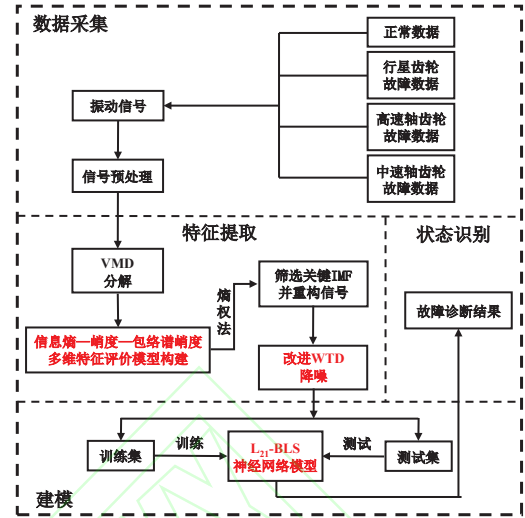


图 4 风机齿轮箱故障诊断方法流程图

3 实验分析

3.1 实验条件

本文实验硬件环境为 2.4GHz 11th Intel Core i5 CPU、16GB 4267MHz LPDDR4 内存; 软件环境为 Windows10 系统、python3.

实验采用某并网风电场的风机齿轮箱振动数据来验证所提方法的有效性. 风机变速恒频, 电机的额定输出功率为 1500kW, 工作运行转速为 1700-1800r/min, 信号采样频率为 5120Hz. 采集到的数据由风电场技术人员标定初始标签, 根据该风电场的多年故障记录, 按照发生故障部位的不同可将风机齿轮箱工作状态分为 4 类, 即行星齿轮故障、中速轴故障、高速轴故障和正常状态. 图 5 分别为风机齿轮箱内 3 种齿轮发生早期轻微故障和正常状态时的原始振动信号, 由于故障信号微弱以及噪声干扰, 从图中很难发现周期性脉冲特征. 进一步整理数据得到 4 种工作状态各 150 个样本, 单个样本长度为 1024.




图 5 4 种工作状态的振动信号

3.2 特征分析

首先使用 VMD 对原始振动信号进行分解, 本文使用文献 [34] 所提方法确定 VMD 参数, 并对每种工

态各寻优 10 次求其平均值, 获取最优参数组合如表 1 所示.

表 1 最优参数组合

数据类型	模态数 K	惩罚因子 α
正常 (0)	6	2983
行星齿轮故障 (1)	5	2450
高速轴齿轮故障 (2)	4	3790
中速轴齿轮故障 (3)	6	3465

以行星齿轮故障信号为例,VMD 取模态个数 K 为 5, 惩罚因子 α 为 2450, 判断精度 ε 和噪声容限 τ 对分解结果影响较小, 取默认值 $\varepsilon = 1 \times 10^{-7}, \tau = 0$. 图 6 为行星齿轮故障信号经 VMD 后的各 IMF 时域图, 图 7 为各 IMF 的频域图. 由图可知各 IMF 中心频率相互独立, 能有效避免模态混叠问题.




图 6 IMF 分量时域图

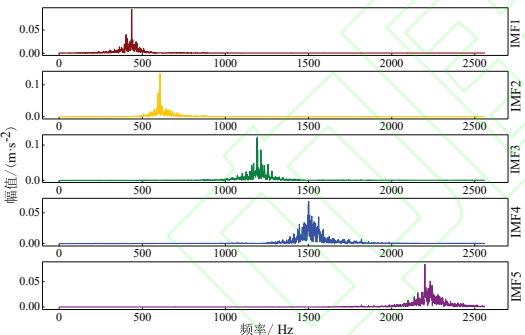


图 7 IMF 分量频域图

表 2 IMF 分量信息熵、峭度与包络谱峭度值

模态分量	信息熵	峭度	包络谱峭度
IMF1	5.1994	2.6354	3.2464
IMF2	4.7601	3.0748	2.6083
IMF3	3.8867	3.9669	3.9703
IMF4	3.9225	3.8426	4.9499
IMF5	4.1033	5.8271	6.9774

为了从分解得到的 5 个 IMF 中提取包含最多风机齿轮箱状态信息的 2 个关键 IMF, 使用“信息熵—峭度—包络谱峭度”多维特征评价模型评估所有 IMF. 首先, 分别计算得到每个 IMF 的信息熵、峭度与包络谱峭度的值如表 2 所示. 其次, 运用熵权法求得 3 个评价指标的权重, 由表 3 可知“峭度”和“包

络谱峭度”指标较“信息熵”指标对早期故障信号更敏感.

表 3 综合评价模型的指标权重

指标	权重
信息熵	0.25187
峭度	0.37769
包络谱峭度	0.37044

根据上述信息, 加权得到各 IMF 的评价系数如图 8 所示. 可知 IMF4 与 IMF5 中包含了较丰富的故障信息, 将 IMF4 与 IMF5 作为关键分量重构信号, 得到的重构信号如图 9(a) 所示. 若采用传统单维指标“峭度”作为关键分量的筛选原则, 则是将 IMF3 与 IMF5 进行重构, 得到了如图 9(b) 所示的重构信号. 对比发现图 9(a) 中重构信号呈现出更高幅值、周期性规律更强的冲击脉冲, 故障特征更为明显. 进一步定量分析两种重构信号, 结果如表 4 所示, 图 9(a) 中重构信号的峭度值、综合评价系数与信噪比 SNR 均高于图 9(b) 中重构信号, 表明图 9(a) 中重构信号包含更丰富的故障信息, 有利于齿轮箱工作状态识别. 因此本文提出的基于多维特征评价模型的 VMD 方法对微弱故障信息的敏感度较高, 适用于早期故障特征提取.




图 8 各 IMF 的评价系数




图 9 2 种重构信号对比图

表 4 2 种重构信号参数对比

重构信号	峭度	综合评价系数	SNR
本文所提方法下的重构信号	4.4010	6.6722	9.8280
传统方法下的重构信号	4.1776	6.2960	8.7800

图 9(a) 重构信号中已观察到故障冲击特征, 但整体仍存在噪声干扰. 进一步, 基于文献 [35] 所提阈值与本文所提改进阈值函数 $f(\mu)$ 对重构信号进行

小波阈值降噪处理, 处理时选择 Haar 小波基函数、4 层分解, 经过多次试验设定调节因子 $\alpha = 0.04$. 同时为证明本文所提改进 WTD 方法的优越性, 分别使用硬阈值和软阈值函数进行降噪效果对比, 结果如图 10 所示. 从图中可以看到硬阈值降噪方法对重构信号中的上升沿、下降沿等突变部分保留得较好, 但整体还存在噪声, 信号不够光滑. 软阈值降噪后的信号整体过于光滑, 部分突变保留不完整, 存在失真现象. 用改进阈值降噪方法处理后, 信号中突变部分保留较完整, 噪声也得到有效抑制. 采用信噪比 SNR 和均方根误差 RMSE 作为评价指标来定量分析不同方法的降噪效果, 结果如表 5 所示. 重构信号经本文所提方法降噪后 SNR 提高了 56.42%, 同时对比软、硬阈值函数, 经本文所提方法处理后的重构信号信噪比高、均方根误差小, 降噪效果更好.




图 10 不同阈值函数降噪效果对比图

表 5 不同降噪策略效果指标对比

降噪方式	SNR	RMSE
VMD	9.828	0.289
VMD+ 硬阈值	14.410	0.171
VMD+ 软阈值	12.437	0.214
VMD+ 改进阈值	15.373	0.153

经本文所提方法处理后的行星齿轮故障重构信号包络谱如图 11 所示, 从图中可以看到转动频率 28.5Hz, 故障频率 89.3Hz 及其 2 倍频、3 倍频等, 说明已成功提取故障特征信息.




图 11 重构信号包络谱

3.3 诊断结果

为了验证基于多维特征评价模型的 VMD 与改进 WTD 联合提取风机齿轮箱早期故障特征的有效性, 本节设计了消融实验. 首先, 分别对经不同特征提取策略处理后的数据进行划分, 每组随机选取 80%

作为训练样本, 剩余 20% 为测试样本, 并对数据标签进行 One-Hot 编码, 以便更新模型参数. 其次, 使用 L_{21} -BLS 对每组样本各进行 10 次故障诊断. 根据第 2.2 节所述, 预先对 L_{21} -BLS 设置足够大的初始网络结构: 特征节点数 $n = 20 \times 30$, 增强节点数 $m = 200$.

消融实验结果如表 6 所示, 原始数据经联合特征提取策略处理后在 L_{21} -BLS 模型上的平均分类准确率提升了 33.63%, 同时对比单独使用 VMD 或 WTD 的情况, 分类准确率均有不同程度的提升, 实验结果说明本文所提风机齿轮箱早期故障特征提取策略可有效提升诊断准确率.

表 6 L_{21} -BLS 在不同特征提取策略下的准确率对比

特征提取策略	最高准确率/%	最低准确率/%	平均准确率/%
原始信号	65.83	59.17	61.67
VMD	87.50	83.33	86.11
WTD	84.17	78.33	81.50
VMD+WTD	98.30	93.33	95.30

为了进一步验证 L_{21} -BLS 对风机齿轮箱故障的分类效果, 将 L_{21} -BLS 与标准 BLS 以及机械故障诊断领域应用最广泛的 BP 神经网络、SVM 和深度神经网络 DBN 作对比. 其中, 标准 BLS 与 L_{21} -BLS 的超参数设置与初始网络结构均相同. 每种分类算法使用经联合特征提取策略处理后的特征数据分别进行 10 次实验, 诊断结果如表 7 所示. 根据结果可知, L_{21} -BLS 在计算资源有限的设备上用最短的时间获得了最高的故障诊断准确率, 准确率较常用的 BP、SVM 算法分别提升了 6.63%、7.79%, 且在诊断耗时上优势明显. 与深度学习算法 DBN 相比, L_{21} -BLS 在准确率小幅提升的情况下, 训练耗时节省了约 90%, 训练耗时的缩短, 有助于降低对计算机硬件的性能要求. 此外, L_{21} -BLS 的最高、最低及平均准确率均优于标准 BLS. 但值得注意的是, L_{21} -BLS 的平均训练耗时比标准 BLS 长 2.68%, 这是由于在建模过程中, L_{21} 范数的求解复杂度略高于标准 BLS 中的 L_2 范数, 因此 L_{21} -BLS 在该阶段的耗时略长. 但在测试阶段, 由于 L_{21} -BLS 网络结构更加稀疏, 其测试耗时比标准 BLS 缩短了 45.15%. 若将 L_{21} -BLS 应用于处理风机齿轮箱的全时段海量运行数据时, 其诊断效率优势将进一步凸显.

综上所述, L_{21} -BLS 具有更优的性能, 其主要原因有: 1) 引入 L_{21} 范数有效避免了过拟合, 提高了模型泛化能力; 2) L_{21} -BLS 剔除了部分无关或低相关性的网络节点, 使得网络结构更紧凑, 占用更少计算资源.

表 7 5 种故障分类算法的故障检测结果

分类算法	最高准确率/%	最低准确率/%	平均准确率/%	平均训练耗时/s	平均测试耗时/s	平均总耗时/s
BP	90.83	84.17	88.67	181.00	11.20	192.20
SVM	90.00	85.83	87.51	131.37	9.04	140.41
DBN	95.83	92.50	94.33	224.33	2.77	227.10
BLS	96.67	90.83	94.54	19.43	3.92	23.35
L ₂₁ -BLS	98.30	93.33	95.30	19.95	2.15	22.10

4 结论

针对风机齿轮箱早期微弱故障诊断问题, 本文提出了一种轻量级的基于多维特征评价的风机齿轮箱早期故障诊断方法, 为风机齿轮箱全生命周期健康管理提供新思路. 主要贡献有: 1) 根据风机齿轮箱振动信号的特点, 设计了基于多维特征评价模型的VMD与改进WTD联合特征提取策略, 成功提取到齿轮箱早期微弱故障特征; 2) 结合工程实际, 权衡网络结构与诊断精度的关系, 将标准BLS目标函数中的L₂范数替换为L₂₁范数, 得到一个紧凑的网络结构. 本文选取了真实风电场齿轮箱运行数据, 在计算资源有限的设备上使用所提方法进行性能测试. 实验结果表明, 该方法对早期故障诊断具有适用性和优越性, 可用于风机齿轮箱的预测性维保.

参考文献 (References)

[1] 刘吉臻, 马利飞, 王庆华, 等. 海上风电支撑我国能源转型发展的思考 [J]. 中国工程科学, 2021, 23(1): 149-159.
(Liu J Z, Ma L F, Wang Q H, et al. Offshore Wind Power Supports China's Energy Transition[J]. Strategic Study of CAE, 2021, 23(1): 149-159.)

[2] Peng H D, Chen X Q, Ren M, et al. Intelligent Fault Diagnosis Technology and System for Wind Turbines[J]. Power System and Clean Energy, 2011, 27(2): 61-66.

[3] 文成林, 吕菲亚, 包哲静, 等. 基于数据驱动的微小故障诊断方法综述 [J]. 自动化学报, 2016, 42(9): 1285-1299.
(Wen C L, Lü F Y, Bao Z J, Liu M Q. A Review of Data Driven-based Incipient Fault Diagnosis[J]. Acta Automatica Sinica, 2016, 42(9): 1285-1299.)

[4] Li W, Zhu Z C, Jiang F, et al. Fault diagnosis of rotating machinery with a novel statistical feature extraction and evaluation method[J]. Mechanical Systems and Signal Processing, 2015, 50-51: 414-426.

[5] 张雯, 吴志彬, 徐玖平. 基于 EMD-PSO-LSSVM 的碳排放分解集成预测方法 [J]. 控制与决策, 2022, 37(7): 1837-1846.
(Zhang W, Wu Z B, Xu J P. A decomposition-integration forecasting method of carbon emission based on EMD-PSO-LSSVM[J]. Control and Decision, 2022, 37(7): 1837-1846.)

[6] Zhong T, Qu J F, Fang X Y, et al. The intermittent fault

diagnosis of analog circuits based on EEMD-DBN[J]. Neurocomputing, 2021, 436: 74-91.

[7] Sun Y H, Yu J B. Fault feature extraction of rolling bearings using local mean decomposition-based enhanced sparse coding shrinkage[J]. Journal of King Saud University-Engineering Sciences, 2022, 34(1): 17-22.

[8] Dragomiretskiy K, Zosso D. Variational mode decomposition[J]. IEEE Transactions on Signal Processing, 2013, 62(3): 531-544.

[9] Viswanath A, Jose K J, Krishnan N, et al. Spike Detection of Disturbed Power Signal Using VMD[J]. Procedia Computer Science, 2015, 46: 1087-1094.

[10] 程珩, 励文艳, 权龙, 等. 基于 VMD-MDE 和 ELM 的柱塞泵微弱故障诊断 [J]. 振动. 测试与诊断, 2020, 40(4): 635-642.
(Chen H, Li W Y, Quan L, et al. Weak Fault Diagnosis of Axial Piston Pump Based on VMD-MDE and ELM[J]. Journal of Vibration, Measurement & Diagnosis, 2020, 40(4): 635-642.)

[11] 任学平, 李攀, 孙百祎, 等. 基于改进 vmd 的滚动轴承故障诊断 [J]. 机械设计与制造, 2020, 1: 188-191.
(Ren X P, Li P, Sun B Y, et al. Rolling Bearing Fault Diagnosis Based on Improved VMD[J]. Machinery Design & Manufacture, 2020, 1: 188-191.)

[12] Tan S, Wang A M, Shi H B, et al. Rolling Bearing Incipient Fault Detection via Optimized VMD Using Mode Mutual Information[J]. International Journal of Control, Automation and Systems, 2022, 20: 1305-1315.

[13] Kumar A, Zhou Y Q, Xiang J W. Optimization of VMD using kernel-based mutual information for the extraction of weak features to detect bearing defects[J]. Measurement, 2021, 168: 108402.

[14] Jing L Y, Zhao M, Li P, et al. A convolutional neural network based feature learning and fault diagnosis method for the condition monitoring of gearbox[J]. Measurement, 2017, 111: 1-10.

[15] 段礼祥, 赵剑平, 曲海涛, 等. 基于深度置信网络的齿轮箱智能诊断方法 [J]. 科学技术与工程, 2020, 20(27): 11099-11104.
(Duan L X, Zhao J P, Qu H T, et al. Gearbox Intelligent Diagnosis Method Based on Deep Belief Network[J]. Science Technology and Engineering, 2020, 20(27): 11099-11104.)

[16] 张宁, 魏秀业, 徐晋宏. 基于 LMD 样本熵与 ELM 的行星齿轮箱故障诊断 [J]. 机械传动, 2020, 44(4): 152-157.

- (Zhang N, Wei X Y, Xu J H. Planetary Gearbox Fault Diagnosis based on LMD Sample Entropy and ELM[J]. Journal of Mechanical Transmission, 2020, 44(4): 152-157.)
- [17] Chen C L P, Liu Z. Broad Learning System: An Effective and Efficient Incremental Learning System Without the Need for Deep Architecture[J]. IEEE Transactions on Neural Networks & Learning Systems, 2018, 29(99): 10-24.
- [18] Wang B, Zhao Y, Chen C L P. Hybrid transfer learning and broad learning system for wearing mask detection in the covid-19 era[J]. IEEE Transactions on Instrumentation and Measurement, 2021, 70: 1-12.
- [19] 徐鹏飞, 王敏, 刘金平, 等. 基于数据分布特性的代价敏感宽度学习系统 [J]. 控制与决策, 2021, 36(7): 1686-1692.
(Xu P F, Wang M, Liu J P, et al. Data distribution-based cost-sensitive broad learning system[J]. Control and Decision, 2021, 36(7): 1686-1692.)
- [20] 王晶, 姚邹静, 赵春晖. 基于红外图像时空特征的电力设备故障诊断 [J]. 控制工程, 2021, 28(8): 1683-1690.
(Wang J, Yao Z J, Zhao C H. A Fault Diagnosis Method for Power Equipment Based on Spatiotemporal Features of Infrared Images[J]. Control Engineering of China, 2021, 28(8): 1683-1690.)
- [21] Mou M, Zhao X Q. Gated Broad Learning System Based on Deep Cascaded for Soft Sensor Modeling of Industrial Process[J]. IEEE Transactions on Instrumentation and Measurement, 2022, 71: 1-11.
- [22] Liu H Y, Zhang H L, Guo L, et al. Privacy-Preserving cloud-Aided broad learning system[J]. Computers & Security, 2022, 112: 102503.
- [23] 褚菲, 苏嘉铭, 梁涛, 等. 基于 lasso 和 elastic net 的宽度学习系统网络结构稀疏方法 [J]. 控制理论与应用, 2020, 37(12): 2543-2550.
(Chu F, Su J M, Liang T, et al. Sparsity method for network structure of broad learning system based on lasso and elastic net[J]. Control Theory & Applications, 2020, 37(12): 2543-2550.)
- [24] Li Y J, Zhang Q, Wang L Z, et al. Regional environmental efficiency in China: An empirical analysis based on entropy weight method and non-parametric models[J]. Journal of Cleaner Production, 2020, 276: 124147.
- [25] Kumar A, Tomar H, Mehla V K, et al. Stationary wavelet transform based ECG signal denoising method[J]. ISA Transactions, 2013, 114(24): 251-262.
- [26] Euhanna G, Andre T, Iman S, et al. Optimal Parameter Selection for the Alternating Direction Method of Multipliers (ADMM): Quadratic Problems[J]. IEEE Transactions on Automatic Control, 2015, 60(3): 644-658.
- [27] Chu F, Liang T, Chen C L P, et al. Weighted Broad Learning System and Its Application in Nonlinear Industrial Process Modeling[J]. IEEE Transactions on Neural Networks and Learning Systems, 2020, 31(8): 3017-3031.
- [28] 胡爱军, 马万里, 唐贵基. 基于集成经验模态分解和峭度准则的滚动轴承故障特征提取方法 [J]. 中国电机工程学报, 2012, 32(11): 106-111.
(Hu A J, Ma W L, Tang G J. Rolling Bearing Fault Feature Extraction Method Based on Ensemble Empirical Mode Decomposition and Kurtosis Criterion[J]. Proceedings of the CSEE, 2012, 32(11): 106-111.)
- [29] 聂周, 李迎春, 王森, 等. 小波降噪与快速包络谱峭度相结合的轴承组件故障诊断技术 [J]. 飞控与探测, 2021, 4(2): 96-102.
(Nie Z, Li Y C, Wang S, et al. Fault Diagnosis Technology of Bearing Assembly Based on Wavelet Denoising and Fast Envelope Kurtogram[J]. Flight Control & Detection, 2021, 4(2): 96-102.)
- [30] Shannon C E. A mathematical theory of communication[J]. The Bell System Technical Journal, 1948, 27(3): 379-423.
- [31] Donoho D L. De-noising by soft-thresholding[J]. IEEE Transactions on Information Theory, 2002, 52(3): 613-627.
- [32] Chen G A, Li Q Y, Li D Q, et al. Main frequency band of blast vibration signal based on wavelet packet transform[J]. Applied Mathematical Modelling, 2019, 74: 569-585.
- [33] Ren C X, Dai D Q, Yan H. Robust classification using L_{21} -norm based regression model[J]. Pattern Recognition, 2012, 45(7): 2708-2718.
- [34] 刘建昌, 权贺, 于霞, 等. 基于参数优化 VMD 和样本熵的滚动轴承故障诊断 [J]. 自动化学报, 2022, 48(3): 808-819.
(Liu J C, Quan H, Yu X, et al. Rolling bearing fault diagnosis based on parameter optimization VMD and sample entropy[J]. Acta Automatica Sinica, 2022, 48(3): 808-819.)
- [35] 苏小会, 王钦钦, 王贵鸿. 基于改进小波阈值算法的遥测数据去噪研究 [J]. 科学技术与工程, 2019, 19(22): 254-258.
(Su X H, Wang Q Q, Wang G H. Denoising of Telemetry Data Based on Improved Wavelet Threshold Algorithm[J]. Science Technology and Engineering, 2019, 19(22): 254-258.)

作者简介

郭方洪 (1988—), 男, 副教授, 博士, 硕士生导师, 从事工业故障诊断、智能电网的研究, E-mail: fhguo@zjut.edu.cn;
林凯 (1997—), 男, 硕士研究生, 从事工业故障诊断的研究, E-mail: lin_kyle@163.com;
窦云飞 (1999—), 男, 硕士研究生, 从事工业故障诊断的研究, E-mail: yfdou@foxmail.com;
吴祥 (1990—), 男, 副研究员, 博士, 从事数据分析、网络化运动控制的研究, E-mail: xiangwu@zjut.edu.cn;
俞立 (1961—), 男, 教授, 博士, 博士生导师, 从事数据分析、控制理论的研究, E-mail: lyu@zjut.edu.cn.