

机电工程

Journal of Mechanical & Electrical Engineering

ISSN 1001-4551, CN 33-1088/TH

《机电工程》网络首发论文

题目: 基于 CCGAN 和 ResNet34 的滚动轴承故障诊断方法
作者: 骆耀谱, 王衍学, 李孟
网络首发日期: 2023-01-06
引用格式: 骆耀谱, 王衍学, 李孟. 基于 CCGAN 和 ResNet34 的滚动轴承故障诊断方法 [J/OL]. 机电工程.
<https://kns.cnki.net/kcms/detail//33.1088.TH.20230106.1327.003.html>



网络首发: 在编辑部工作流程中, 稿件从录用到出版要经历录用定稿、排版定稿、整期汇编定稿等阶段。录用定稿指内容已经确定, 且通过同行评议、主编终审同意刊用的稿件。排版定稿指录用定稿按照期刊特定版式 (包括网络呈现版式) 排版后的稿件, 可暂不确定出版年、卷、期和页码。整期汇编定稿指出版年、卷、期、页码均已确定的印刷或数字出版的整期汇编稿件。录用定稿网络首发稿件内容必须符合《出版管理条例》和《期刊出版管理规定》的有关规定; 学术研究成果具有创新性、科学性和先进性, 符合编辑部对刊文的录用要求, 不存在学术不端行为及其他侵权行为; 稿件内容应基本符合国家有关书刊编辑、出版的技术标准, 正确使用和统一规范语言文字、符号、数字、外文字母、法定计量单位及地图标注等。为确保录用定稿网络首发的严肃性, 录用定稿一经发布, 不得修改论文题目、作者、机构名称和学术内容, 只可基于编辑规范进行少量文字的修改。

出版确认: 纸质期刊编辑部通过与《中国学术期刊 (光盘版)》电子杂志社有限公司签约, 在《中国学术期刊 (网络版)》出版传播平台上创办与纸质期刊内容一致的网络版, 以单篇或整期出版形式, 在印刷出版之前刊发论文的录用定稿、排版定稿、整期汇编定稿。因为《中国学术期刊 (网络版)》是国家新闻出版广电总局批准的网络连续型出版物 (ISSN 2096-4188, CN 11-6037/Z), 所以签约期刊的网络版上网络首发论文视为正式出版。

基于CCGAN和ResNet34的滚动轴承故障诊断方法*

骆耀谱¹，王衍学^{1,2*}，李孟¹

(1. 北京建筑大学 机电与车辆工程学院，北京 102616; 2. 北京建筑大学 城市轨道交通服役性能保障北京市重点实验室，北京 100044)

摘要：在实际的工业过程中，由于滚动轴承故障数据的小样本或样本分布不平衡很常见，导致许多算法难以准确地识别不同故障。针对这一问题，提出了一种基于条件卷积生成对抗网络(CCGAN)和ResNet34的深度神经网络故障诊断方法。首先，采集了滚动轴承振动信号数据，并将振动信号转换为灰度图像，并增强了其数据特征；然后，采用CCGAN网络学习了原始小样本数据的特征，扩展了小样本不平衡数据集；最后，在滚动轴承振动信号的数据扩充和特征增强的基础上，采用ResNet34深度网络进行了一维振动信号的小样本不平衡故障诊断和分类。研究表明：随着小样本不平衡数据集逐步扩展到多维平衡数据集，该方法在不同数据集中故障诊断的准确性均得到了有效提高，在分类精度上达到了99.5%；诊断证明了其特征提取能力优于典型的机器学习和深度学习网络，从而验证了该方法在小样本不平衡故障诊断中的优势。

关键词：小样本故障诊断；数据扩充；深度学习；生成对抗网络；残差结构；条件卷积生成对抗网络；改进的特征提取并增强方法

中图分类号：TH133.33

文献标识码：A

Rolling bearing fault diagnosis method based on CCGAN and ResNet34

LUO Yao-pu¹，WANG Yan-xue^{1,2}，LI Meng¹

(1. School of Mechanical-Electronic and Vehicle Engineering, Beijing University of Civil Engineering and Architecture, Beijing 102616, China; 2. Beijing Key Laboratory of Performance Guarantee on Urban Rail Transit Vehicles, Beijing University of Civil Engineering and Architecture, Beijing 100044, China)

Abstract: Aiming at the problem that it is difficult for many algorithms to accurately identify different faults due to the small sample unbalanced rolling bearing data collected in the industrial process, a deep neural network fault diagnosis method based on the conditional convolution generates adversarial networks (CCGAN) and ResNet34 was proposed. Firstly, the vibration signal data of the rolling bearing were collected, and the vibration signal was converted into gray image and the data characteristics were enhanced. Then, the CCGAN network was used to learn the features of the original small sample data and expand the small sample unbalanced data set. Finally, on the basis of data expansion and feature enhancement of vibration signals of rolling bearings, ResNet34 deep network was used to diagnose and classify the small sample unbalance fault of one-dimensional vibration signals. The experimental results show that with the gradual expansion of the small sample unbalanced data set to the multi-dimensional balanced data set, the accuracy of the proposed method in different data sets has been effectively improved, and the classification accuracy has reached 99.5%, which proves that the feature extraction capability of the proposed method is superior to the typical machine learning and deep learning neural network, thus verifying the advantages of the method in the small sample unbalanced fault diagnosis.

Key words: small sample fault diagnosis; data expansion; deep learning; generating adversarial networks; residual structure; conditional convolution generates adversarial networks (CCGAN); improved feature extraction enhancements (IFEE) method

0 引言

滚动轴承在旋转机械中扮演着重要角色, 它的健康状况直接影响到整个机械系统的运行状态。由于其运行在高温、高转速、高负载等工况下, 且运行时各个元器件表面接触挤压会产生相互作用, 因此其工作过程中容易出现各种故障。轴承一旦出现故障, 轻则会导致整个机械系统崩溃, 重则会引发机毁人亡等重大事故, 造成巨大损失。因此, 对滚动轴承故障检测方法的速度、效率和精确性等都有着越来越高的要求, 实现快速、准确地滚动轴承故障诊断具有重大意义。

在对机械设备进行故障诊断过程中, 由于振动信号的采集相对比较简单, 且容易从时域图判断故障的类型, 因此, 可通过对其进行分析的基础上, 从而判断出轴承的具体故障。在机械故障诊断技术的发展过程中, 基于信号处理的方法^[1]和基于数据驱动的方法是更为典型的两类方法。

基于信号处理的方法是利用先进的信号去噪和滤波技术, 从而发现机械设备的故障特征。何正嘉等人^[2]提出了一种基于局部均值分解的瞬时频率求解、时频分析的故障诊断方法, 并采用此方法成功提取出了齿轮箱局部故障信息; 但该方法针对不同工况下提取的故障频率不够精确。张锁峰等人^[3]提出了一种基于变分模态分解(variational mode decomposition, VMD)的调制强度分布的齿轮故障诊断方法, 并取得了一定的成果; 但该方法所需预设的参数过多, 不同参数设置会导致诊断结果的误差较大。项伟等人^[4]提出了一种自适应集合经验模态分解(ensemble empirical mode decomposition, EEMD)结合快速峭度图的故障诊断方法, 并取得了一定的成果; 但该方法计算冗余、占用计算资源大。

作为数据驱动方法的典型代表, 机器学习在故障诊断领域有广泛的应用。程晓卿等人^[5]针对轴承振动信号的非线性、非平稳性特征, 提出了一种基于EEMD和优化支持向量机的轴承故障诊断方法, 并取得了一定的成果; 但该方法模型泛化能力低, 需借助EEMD来提取故障特征。李红月等人^[6]提出了一种改进天鹰优化算法优化支持向量机(support vector machines, SVM)的电机滚动轴承故障诊断方法, 该方法寻优时间效果好; 但该方法容易陷入局部最小值, 计算量大且收敛速度较慢。王进花等人^[7]提出了一种基于振动信号的多特征互补融合并结合随机森林(random forest, RF)的故障诊断方法, 并取得了一定的成果; 但该方法需收集滚动轴承的电流信号和振动信号, 且电流信号容易受到复杂工况的影响, 使得工作量加大。

作为机器学习的分支, 近几年来, 深度学习在机械故障诊断领域也有一定的成果。周兴康等人^[8]提出了一种一维残差卷积自编码器模型, 将其成功应用于振

动信号的无监督学习及故障特征提取; 但该方法需要大数量样本, 当采集到的数据量不足时, 其诊断的准确性不高。CHEN Jun-gan等人^[9]提出了一种有效的可调输入尺寸通用自适应卷积神经网络(convolution neural network, CNN)的轴承故障诊断方法, 并取得了一定的效果; 但其泛化性和准确性依赖于使用大量的标签数据来训练网络避免过拟合。董绍江等人^[10]提出了一种基于多层降噪技术及改进卷积神经网络的轴承故障诊断方法, 并取得了一定的效果; 但该方法运用了奇异值分解和经验模态分解(empirical mode decomposition, EMD)处理原始信号, 步骤过于复杂, 并加大了工作总量。HUANG Ting等人^[11]提出了一种基于卷积神经网络和长短期记忆网络相结合的滑动窗处理的故障诊断方法, 并取得了一定的成果; 但其泛化性还有待验证, 且削弱了故障诊断的可靠性。ZHANG Ya-hui等人^[12]提出了一种基于递归神经网络和多层感知器的旋转机械故障诊断方法, 该方法具有较高的分类精度; 但方法的准确性仍受限于有限的数据库。

采用上述方法基本都能对滚动轴承故障进行诊断分析。但随着网络深度的扩大, 梯度消失问题愈加明显, 造成模型难以训练。此外, 在实际的工业过程中, 故障数据的小样本或样本分布不平衡很常见, 由于小样本的类别容易被大量样本的类别所忽略, 难以准确地把握特征来识别不同的故障, 导致分类精度较低。

因此, 笔者提出一种基于CCGAN和ResNet34的滚动轴承故障智能诊断方法。

首先, 将振动信号转化成灰度图, 并通过均值和中值通道增加数据特征; 然后, 进行数据样本扩充, 将笔者提出的ResNet34模型与典型的机器学习模型、深度学习模型进行比较; 最后, 在数据扩充和特征增强的基础上, 结合ResNet34模型, 进行小样本不平衡故障诊断分类。

1 理论基础

1.1 IFEE

对于传统的数据驱动方法来说, 数据预处理至关重要。大部分预处理方法是人工提取数据特征, 例如EMD、VMD、EEMD等, 这些方法通常耗时, 且需要专业知识。为此, 笔者采用一种改进的特征提取并增强(improved feature extraction enhancements, IFEE)方法。

振动信号转换灰度图方法如图1所示。

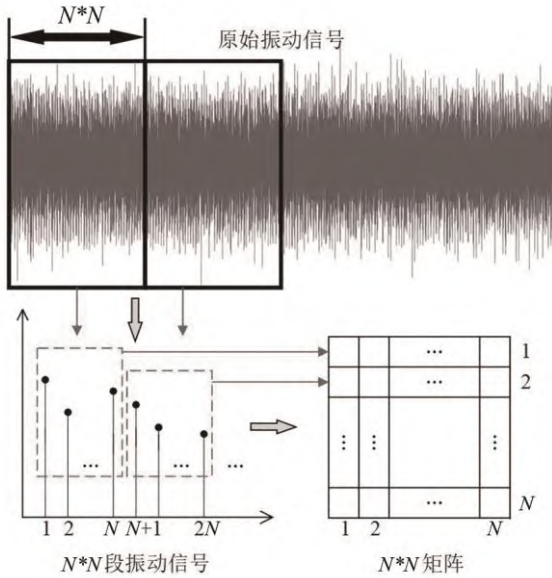


图 1 振动信号转换灰度图方法

首先，笔者将一维原始振动信号转换为二维灰度图像，提取振动信号的局部特征。由于单通道灰度图作为样本输入，提取特征不太明显，因此，需要使用均值和中值通道增强原始信号的数据特征，以此来提高精度。

(1) 为了获得 M 个 $N*N$ 大小的图像，从原始信号中获取 M 个长度为 $N*N$ 的段振动信号。把每个段振动信号样本的幅值归一化，幅值范围从0到255，这是灰度图像的重要像素强度范围，如下式所示^[13]：

$$output = 255 * \frac{input - \min(input)}{\max(input) - \min(input)} \quad (1)$$

式中： $input$ —原始段振动信号； $output$ —赋值归一化后段振动信号。

(2) 对每一个 $N*N$ 的段振动信号构造 $N*N$ 矩阵，并将其转换为 $N*N$ 单通道灰度图(N 值分别表示图像的行和列， N 的值一般根据原始信号的容量来取)。然而，该方法的计算复杂度与 N 的值成正比，因此，优选较小的 N 值，但也不能太小，以免丢失最重要的特征。

笔者分别选取32、64、96、112和128进行了实验和对比。振动信号转化为灰度图像如图2所示。




图 2 振动信号转化为灰度图像

在原始信号获得 M 个段振动信号过程中，为了每次获得更多样化的样本信息，笔者提出了一种随机取值分割方法，如图3所示。




图 3 随机取值分割方法

笔者设置了随机生成数作为段振动信号的分割间隔。通过该方法让每次的实验样本数据都不相同，避免了实验的偶然性；

(3) 为了生成均值和中值的新通道，将1个长度为9的滑动窗口作为滤波器，从头到尾扫描每个一维振动信号。在采样信号数据的首尾均补充4个“0”，滤波器每次移动长度为1，从而得到与原始数据相同数量的数据点。滤波器在完成数据遍历后，生成了1个与原通道形状大小相同的新通道。

笔者将新通道与原通道结合，形成3通道灰度图作为诊断模型的新输入，3通道灰度图如图4所示。




图 4 3 通道灰度图

在 3 通道灰度图中，原信道是原始振动信号，第 1 个附加信道是应用均值滤波器来生成的均值信道，第 2 个附加信道是应用中值滤波器来生成的中值信道。

1.2 CCGAN

常规生成对抗网络^[14](generate adversarial networks, GAN)通常包括两个网络，即生成器 G 和鉴别器 D ，这两个网络通过相互竞争交替训练。

GAN的主要目的是通过将真实的样本和 G 生成的样本输入到 D 中，让 D 无法判断出是真实样本还是通过噪声生成的样本；训练 G 并学习生成真实的数据分布，同时训练 D 来判断生成样本或人工样本。

因此，实验的目的是 G 和 D 同时训练：调整 G 的参数使 $\log(1-D(G(z)))$ 最小化，并调整 D 的参数使 $\log D(x)$ 最小化。最大化 D 和最小化 G 的损失函数如下：

$$\min_G \max_D V(D, G) = E_{x \sim p_r} [\log D(x)] + E_{z \sim p_z} [\log(1 - D(G(z)))] \quad (2)$$

式中： E —期望； P_r —真实样本 x 的概率分布； P_z —随机噪声 z 的先验分布，如高斯分布等。

深度卷积生成对抗网络^[15] (deep convolution generate adversarial networks, DCGAN)是GAN的一个变体, DCGAN就是将CNN和原始的GAN结合到一起, 生成器网络 G 和鉴别器网络 D 都运用到了深度卷积神经网络。

DCGAN的卷积生成器结构如图5所示。




图 5 DCGAN 的卷积生成器结构

将卷积神经网络应用到GAN生成对抗网络的模型中, 从而代替全连接层, DCGAN提高了基础GAN的稳定性和生成结果质量。

笔者采用的是条件卷积生成对抗网络CCGAN, CCGAN是常规DCGAN的一种条件模型, 它的条件是生成器和鉴别器的附加类别标签 y , CCGAN如图6所示。

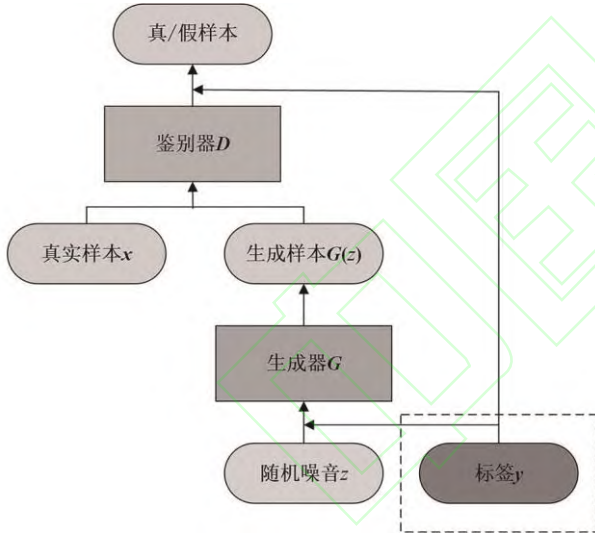


图 6 CCGAN

在生成器 G 中, 类标签 y 与随机输入噪声组合成一个联合表示作为输入, 将真实样本 x 和类标签 y 作为鉴别器中判别函数的输入, 从而训练其能生成含有给定类标签数据特征的数据。

最大化 D 和最小化 G 的损失函数如下:

$$\min_G \max_D V(D, G) = E_{x \sim P_r} [\log D(\frac{x}{y})] + E_{z \sim P_z} [\log(1 - D(G(\frac{z}{y})))] \quad (3)$$

式中: E —期望; y —一类标签; P_r —真实样本 x 的概率分布; P_z —随机噪声 z 的先验分布, 如高斯分布等。

1.3 ResNet

ResNet^[16]是一种网络结构超深的深度学习方法, 它的基本组件是残差结构(residual structure, RS)。

一个残差结构由2个卷积层、2个批量归一化层(BatchNorm2d, BN)、2个ReLU激活层和一个恒等捷径组成。恒等捷径是使ResNet优于一般卷积网络的部分。

在一般的卷积网络中, 交叉熵误差的梯度是逐层反向传播的。通过使用恒等捷径, 梯度可以有效地流向靠近输入层较早的层, 从而更有效地更新参数, 同时通过计算残差来解决由层数过高产生的退化问题。

ResNet网络共有5种不同的深度, 分别是18、34、50、101和152。ResNet网络每隔几层便减少输出特征图的宽度, 其目的是为了减少深层网络的计算量; 增加输出特征图的通道数, 其目的是为了便于将不同的样本特征整合为判别特征。

此处笔者选取的是ResNet34深度网络, ResNet34的整体架构如图7所示。

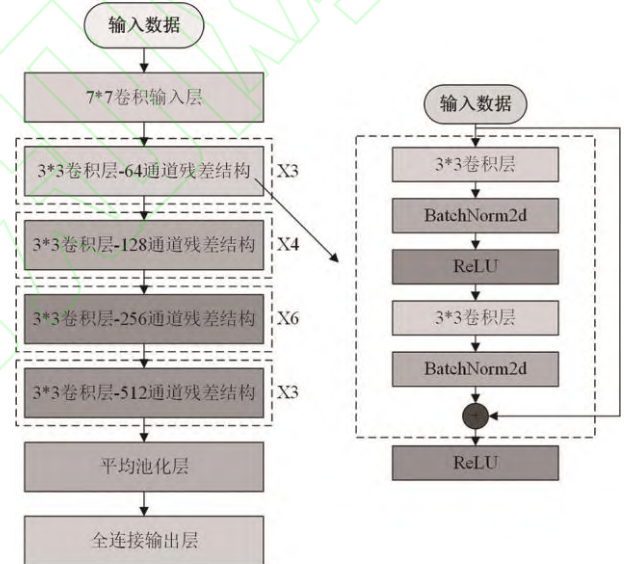


图 7 ResNet34 的整体架构

该网络由一个卷积输入层、多个残差结构、一个池化层、一个全连接输出层组成。

这是笔者进行故障诊断的模型框架基体。

2 故障诊断模型

在上述各理论的基础上, 笔者提出了一种基于CCGAN和ResNet34的滚动轴承故障智能诊断模型。

故障诊断模型的框架如图8所示。

故障诊断的具体流程如下:

(1) 对滚动轴承振动信号进行处理, 将其转换成 $N*N$ 的灰度图样本;

(2) 将灰度图样本输入到CCGAN模型当中, 训练CCGAN模型, 并生成可用的生成样本;

(3) 将灰度图样本和生成样本整合成增强样本集, 经过IFEE方法处理, 然后将其输入到ResNet34模

型当中;

(4) 通过交叉熵损失函数与故障类型建立对应关系, 从而实现滚动轴承的故障分类。

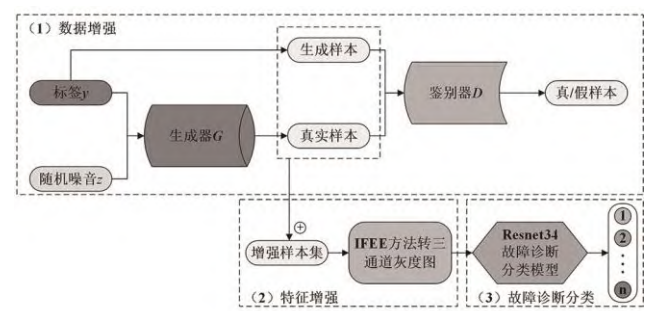


图 8 故障诊断模型框架

3 实验及结果分析

3.1 实验设置

3.1.1 数据集

此处所有实验数据是来自机械故障预防技术学会 (machinery failure prevention technology, MFPT) 轴承故障数据集、渥太华大学时变转速条件下的轴承故障数据集和实验室数据集。

3个数据集如表1所示。

表 1 3 个数据集

MFPT小样本不平衡数据集		渥太华大学小样本数据集		实验室小样本数据集	
故障类型	数量	故障类型	数量	故障类型	数量
健康	105	健康	100	健康	100
3个外圈故障	105	内圈缺陷	100	内圈缺陷	100
7个外圈故障	105	外圈缺陷	100	外圈缺陷	100
7个内圈故障	205	球缺陷故障	100	滚动体缺陷故障	100
		组合缺陷故障	100	复合缺陷故障	100

表 1 中, MFPT 数据集由 4 组轴承振动数据组成, 包括一个健康状态 (Baseline)、3 个外圈故障 (ThreeOR)、7 个外圈故障 (SevenOR) 以及 7 个内圈故障 (SevenIR), 其中, 振动信号的采样频率为 48.828 kHz, 采样时间为 3 s。笔者从原始数据中随机抽取 520 个数据样本, 形成了小样本不平衡数据集;

渥太华大学数据集包括健康、内圈缺陷故障、外圈缺陷故障、球缺陷故障以及内圈、外圈和滚动体组合缺陷故障, 其中, 振动信号的采样频率为 200 kHz, 采样时间为 10 s。笔者从原始数据中随机抽取 500 个数据样本, 形成了小样本数据集;

此外, 此处还使用了实验室自测数据集。实验室数据集是在 5 种不同转速条件下从不同健康状况轴承

中收集的振动信号, 共有 25 个数据集。包括健康、内圈缺陷故障、外圈缺陷故障、滚动体缺陷故障以及内圈、外圈和滚动体复合缺陷故障, 其中, 振动信号的采样频率为 25.6 kHz, 采样时间为 12.8 s。笔者选取了在 10 Hz 变频下 5 种不同状况数据, 从原始数据中随机抽取 500 个数据样本, 形成了小样本数据集。

实验室机械故障综合模拟实验平台如图 9 所示。




图 9 实验平台

实验台转速由变速控制器控制, 有缺陷的滚动轴承安装在驱动电机附近, 再通过压电式加速度传感器采集振动信号。

3.1.2 模型参数设置

笔者使用基于 Windows 10 的深度学习框架 pytorch 进行了实验。

深度学习平台的基本信息如下: 显卡版本为 NVIDIA GTX 1650, CPU 为 i7-10700F@2.90GHz, Python 版本为 3.8.12, pytorch 版本为 1.9.0。模型参数默认 batch_size 为 32, epochs 为 100。所有结果都是独立运行 10 次获得的。设置训练数据占整个数据集的比例为 0.7, 所有分类精度是使用相应测试数据集得到的结果。

3.1.3 对比模型

笔者选择常用的典型机器学习方法, 即随机森林 [17]、支持向量机 [18]、深度学习方法一维卷积神经网络 [19-20] (one-dimensional convolutional neural network, 1DCNN) 与上述的 ResNet34 方法进行模型故障分类准确性的对比。

3.2 结果分析

首先, 将一维振动信号分别应用到典型的机器学习方法 RF、SVM、深度学习方法 1DCNN 和笔者提出的 ResNet34 网络当中, 分别对其做故障诊断分类, 不同方法在 3 种数据集上的诊断准确率如表 2 所示。

表 2 不同方法在 3 种数据集上的诊断准确率(%)

	MFPT小样本不平衡数据集		渥太华大学小样本数据集		实验室小样本数据集	
	32*32	64*64	32*32	64*64	32*32	64*64
RF	0.563	0.625	0.447	0.570	0.374	0.437
SVM	0.585	0.676	0.473	0.603	0.393	0.453

1DCNN	0.614	0.713	0.507	0.647	0.427	0.507
ResNet34	0.775	0.825	0.642	0.824	0.553	0.693

从表2中数据可以明显看出：**ResNet34**网络诊断准确率均优于其他3种方法，但其准确率还有待提升。

因此，按照上述*N*的取值，笔者将3个数据集原始不同样本状态下，在3种数据集上的诊断准确率如表3所示。

表3 不同样本状态下在3种数据集上的诊断准确率(%)

样本 状态	MFPT小样本		渥太华大学		实验室	
	不平衡数据集		小样本数据集		小样本数据集	
	单通道准确率	3通道准确率	单通道准确率	3通道准确率	单通道准确率	3通道准确率
32*32	0.775	0.844	0.642	0.687	0.553	0.579
64*64	0.825	0.921	0.824	0.853	0.693	0.718
96*96	0.919	0.983	0.952	0.971	0.772	0.811
112*112	0.841	0.862	0.871	0.916	0.818	0.837
128*128	0.893	0.926	0.975	0.982	0.795	0.814

从表3中数据可以明显看出：随着通道数量的增加，数据的特征得以增强，平均诊断准确率在5种状态下均得到了很好的提升。

笔者选择每个数据集在5种状态中准确率表现最好的样本状态，分别在MFPT小样本不平衡数据集中，将96*96的原始样本数量偏少的Baseline、ThreeOR和SevenOR样本输入到CCGAN模型，训练生成每种类别各100个生成样本，再将520个原始样本和300个生成样本一起输入到ResNet34诊断模型当中；

在渥太华大学小样本数据集中，将128*128的原始样本输入到CCGAN模型，训练生成每种类别各100个生成样本，再将500个原始样本和500个生成样本一起输入到ResNet34诊断模型当中；

在实验室小样本数据集中，将112*112的原始样本输入到CCGAN模型，训练生成每种类别各100个生成样本，再将500个原始样本和500个生成样本一起输入到ResNet34诊断模型当中。

引入CCGAN后，在3种数据集上的诊断准确率如表4所示。

信号分别形成32×32、64×64、96×96、112×112、128×128这5种样本状态，在这5种状态下分别运用单通道灰度图与结合了均值和中值通道的3通道灰度图作为ResNet34诊断模型的输入。

表 4 引入CCGAN后在3种数据集上的诊断准确率(%)

	MFPT数据集	渥太华大学数据集	实验室数据集
	96*96	128*128	112*112
原始准确率	0.983	0.982	0.833
CCGAN准确率	0.995	0.995	0.874

从表4中数据可以看出：在引入CCGAN模型后，准确率又得到了进一步提升，其中，在MFPT和渥太华大学数据集中非常接近1，表明CCGAN方法性能较好，能够生成有用的人工样本，其数据增强功能对整体模型故障诊断分类具有很好的作用，一定程度上提高了分类精度。

为进一步量化故障诊断模型的分类能力，在MFPT数据集96*96样本状态单通道输入、3通道输入和增强样本集输入下，笔者得到ResNet34网络模型诊断结果的混淆矩阵，如图10所示。




图 10 模型诊断结果的混淆矩阵

图10为混淆矩阵中行和列分别代表预测标签和真实标签，混淆矩阵中的数字表示每种情况下正确或错

误预测的数量占比。

图10结果表明,随着IFEE方法和CCGAN方法的引入,其分类精度得到逐步提升。

此外,为了更加直观地展示模型的分类效果,在

渥太华大学数据集128×128样本状态单通道输入、3通道输入和增强样本集输入下,笔者得到ResNet34网络模型分类结果的特征可视化,如图11所示。

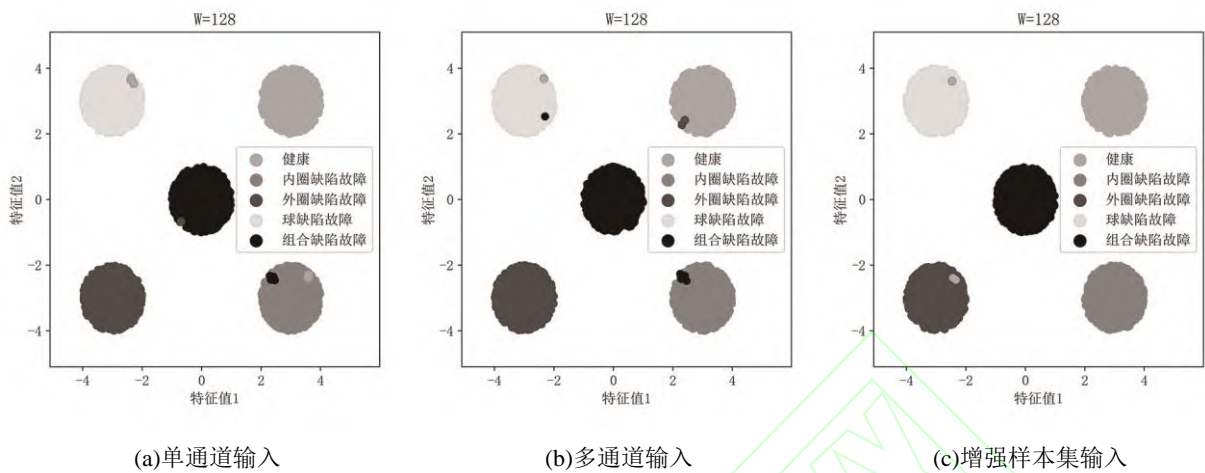


图 11 模型分类结果的特征可视化

由图11可以看出:随着IFEE方法和CCGAN方法的引入,相同标签的特征数据在二维空间上具有较好的相似性,能够更加容易地区分出不同的故障数据类型,从而验证了ResNet34网络模型的强大特征提取能力。

4 结束语

笔者提出了一个新的深度神经网络模型,即基于CCGAN和ResNet34的滚动轴承故障诊断模型,采用该诊断模型,有效地解决了机械故障诊断领域中遇到的小样本或不平衡样本的问题;并且在多种数据集上,对该算法模型的有效性进行了验证。

研究结论如下:

(1)采用IFEE方法将滚动轴承一维振动信号转换成灰度图像,保留了时间序列数据之间的相关信息,同时增加中值和均值通道,提升了振动信号的关键特征,有效提高了诊断模型的性能;

(2)采用CCGAN网络进行数据样本扩充,能从少量样本中学习,并有效地生成与真实样本高度相似的数据。相较于其他算法,该算法不需要大量标签数据,因此,在小样本不平衡故障诊断中具有一定的实用价值;

(3)通过ResNet34深度网络对灰度图像进行故障分类,提升了特征信息利用率,其残差结构加快了梯度的反向传播,避免了梯度消失。该方法的特征提取能力优于典型机器学习方法RF、SVM和深度学习方法1DCNN,可将其应用于滚动轴承小样本故障诊断中。

笔者后续的研究方向是希望采用迁移学习方法,探究更多实际工况下滚动轴承振动信号数据的特征

分布及其数据规律,最终对滚动轴承进行精准的故障诊断。

参考文献(References):

- [1] 陈是扞,彭志科,周 鹏.信号分解及其在机械故障诊断中的应用研究综述[J].机械工程学报,2020,56(17):91-107.
- [2] 王衍学,何正嘉,瞿艳阳,等.基于LMD的时频分析方法及其机械故障诊断应用研究[J].振动与冲击,2012,31(9):9-12.
- [3] 张锁峰,王衍学,何水龙,等.基于VMD的调制谱强度分布在齿轮故障诊断中的应用研究[J].机械强度,2019,41(2):267-274.
- [4] 项 伟,李如玉,王 慧,等.基于自适应EEMD与Fast Kurtogram的齿轮箱故障诊断[J].机械强度,2022,44(5):1024-1031.
- [5] 姚德臣,杨建伟,程晓卿,等.基于多尺度本征模态排列熵和SA-SVM的轴承故障诊断研究[J].机械工程学报,2018,54(9):168-176.
- [6] 李红月,高英杰,朱文昌. IAO优化SVM的电机滚动轴承故障诊断[J].电子测量技术,2022,45(10):126-132.
- [7] 王进花,周德义,曹 洁,等.基于多特征融合与RF的球磨机滚动轴承故障诊断[J/OL].北京航空航天大学学报,2022:1-19. DOI:10.13700/j.bh.1001-5965.2022.0069.
- [8] 周兴康,余建波.基于深度一维残差卷积自编码网络的齿轮箱故障诊断[J].机械工程学报,2020,56(7):96-108.

- [9] CHEN Jun-gan, JIANG J, GUO Xin-nian, et al. An efficient CNN with tunable input-size for bearing fault diagnosis[J]. **International Journal of Computational Intelligence Systems**, 2021, 14(1): 625-634.
- [10] 董绍江, 裴雪武, 吴文亮, 等. 基于多层降噪技术及改进卷积神经网络的滚动轴承故障诊断方法[J]. **机械工程学报**, 2021, 57 (1) : 148-156.
- [11] HUANG Ting, ZHANG Qiang, TANG Xiao-an, et al. A novel fault diagnosis method based on CNN and LSTM and its application in fault diagnosis for complex systems[J]. **Artificial Intelligence Review**, 2021(5): 1-27.
- [12] ZHANG Ya-hui, ZHOU Tao-tao, HUANG Xu-feng, et al. Fault diagnosis of rotating machinery based on recurrent neural networks[J]. **Measurement**, 2021, 171(1): 108774-108781.
- [13] DO V T, CHONG U P. Signal model-based fault detection and diagnosis for induction motors using features of vibration signal in two-dimension domain[J]. **Journal of Mechanical Engineering**, 2011, 57(9): 655-666.
- [14] GOODFELLOW I J, POUGET-ABADIE J, MIRZA M, et al. Generative adversarial nets[C]// **Neural Information Processing Systems**. Long Beach: MIT Press, 2014: 1-9.
- [15] RADFORD A, METZ L, CHINTALA S. Unsupervised Representation Learning with Deep Convolutional Generative Adversarial Networks[C]// **ICLR2016**. San Juan:[s.n.], 2016: 1-16.
- [16] HE Kai-ming, ZHANG Xiang-yu, REN Shao-qing, et al. Deep residual learning for image recognition[C]// 2016 IEEE Conference on Computer Vision and Pattern Recognition. Las Vegas :IEEE, 2016:1-12.
- [17] 王梓杰, 周新志, 宁 芊. 基于PCA和随机森林的故障趋势预测方法研究[J]. **计算机测量与控制**, 2018, 26 (2) : 21-26.
- [18] 武 兵, 林 健, 熊晓燕. 基于支持向量回归的多参数设备故障预测方法[J]. **振动. 测试与诊断**, 2012, 32 (5) : 791-795.
- [19] ZHANG Wei, PENG Gao-liang, LI Chuan-hao, et al. A new deep learning model for fault diagnosis with good anti-noise and domain adaptation ability on raw vibration signals[J]. **Sensors**, 2017, 17(2): 425-445.
- [20] ZHANG Wei, LI Chuan-hao, PENG Gao-liang, et al. A deep convolutional neural network with new training methods for bearing fault diagnosis under noisy environment and different working load[J]. **Mechanical Systems and Signal Processing**, 2018, 100(1): 439-453.
- 【编辑：李辉】