



机电工程
Journal of Mechanical & Electrical Engineering
ISSN 1001-4551, CN 33-1088/TH

《机电工程》网络首发论文

题目：基于 ResNet-ELM 和迁移学习的风机齿轮箱故障诊断方法研究
作者：孙晔，张泽明，刘晓悦
收稿日期：2022-08-09
网络首发日期：2023-02-13
引用格式：孙晔，张泽明，刘晓悦. 基于 ResNet-ELM 和迁移学习的风机齿轮箱故障诊断方法研究[J/OL]. 机电工程.
<https://kns.cnki.net/kcms/detail//33.1088.th.20230210.1728.006.html>



网络首发：在编辑部工作流程中，稿件从录用到出版要经历录用定稿、排版定稿、整期汇编定稿等阶段。录用定稿指内容已经确定，且通过同行评议、主编终审同意刊用的稿件。排版定稿指录用定稿按照期刊特定版式（包括网络呈现版式）排版后的稿件，可暂不确定出版年、卷、期和页码。整期汇编定稿指出版年、卷、期、页码均已确定的印刷或数字出版的整期汇编稿件。录用定稿网络首发稿件内容必须符合《出版管理条例》和《期刊出版管理规定》的有关规定；学术研究成果具有创新性、科学性和先进性，符合编辑部对刊文的录用要求，不存在学术不端行为及其他侵权行为；稿件内容应基本符合国家有关书刊编辑、出版的技术标准，正确使用和统一规范语言文字、符号、数字、外文字母、法定计量单位及地图标注等。为确保录用定稿网络首发的严肃性，录用定稿一经发布，不得修改论文题目、作者、机构名称和学术内容，只可基于编辑规范进行少量文字的修改。

出版确认：纸质期刊编辑部通过与《中国学术期刊（光盘版）》电子杂志社有限公司签约，在《中国学术期刊（网络版）》出版传播平台上创办与纸质期刊内容一致的网络版，以单篇或整期出版形式，在印刷出版之前刊发论文的录用定稿、排版定稿、整期汇编定稿。因为《中国学术期刊（网络版）》是国家新闻出版广电总局批准的网络连续型出版物（ISSN 2096-4188，CN 11-6037/Z），所以签约期刊的网络版上网络首发论文视为正式出版。

基于 ResNet-ELM 和迁移学习的风机齿轮箱故障 诊断方法研究*

孙晔¹, 张泽明², 刘晓悦^{2*}

(1. 中国信息通信研究院, 北京 100083; 2. 华北理工大学 电气工程学院, 河北 唐山 063210)

摘要：在变工况以及混合故障情况下，采用传统的方法对风力发电机齿轮箱进行故障诊断时，存在诊断效果不佳、泛化能力差等问题，为此，提出了一种基于深度残差网络(ResNet)-极限学习机(ELM)和迁移学习(TL)的风力发电机齿轮箱故障诊断方法(TL-RN-ELM)。首先，分别介绍了连续小波变换(CWT)、卷积神经网络(CNN)、深度残差网络(ResNet)、迁移学习(TL)、极限学习机(ELM)的原理；然后，基于上述原理，建立了 TL-RN-ELM 的风力发电机齿轮箱故障诊断模型（流程）；最后，使用轴承数据集和齿轮箱数据集对上述方法进行了实验验证，即从美国凯斯西储大学（CWRU）轴承数据集和东南大学（SEU）齿轮箱数据集中进行了数据采集和处理，利用 CWT 将原始一维振动信号转换成了二维小波时频图像，使用 CWRU 轴承数据集对搭建的 ResNet18 模型进行了训练，生成了预训练模型；将预训练模型中的数据迁移至 SEU 齿轮箱数据集，微调了模块，提取了特征，并将其输入到 ELM 分类器，然后将分类结果与其他三类模型进行了对比分析。实验结果表明：对于从轴承到轴承、轴承到齿轮以及混合故障的小样本迁移故障诊断，TL-RN-ELM 的平均准确率可达 98.79%；与其他方法相比，该方法的平均准确率提升了 4.73%~9.6%，研究结果表明：该方法具有良好的诊断效果和泛化能力。

关键词：齿轮传动；迁移学习；深度残差网络；极限学习机；卷积神经网络；连续小波变换；模型预训练；模型迁移；小波时频图

中图分类号：TH132.41；TM315

文献标识码：A

Fault diagnosis method of wind turbine gearbox based on ResNet-ELM and transfer learning

SUN Ye¹, ZHANG Ze-ming², LIU Xiao-yue²

(1. China Academy of Information and Communications, Beijing 100083, China; 2. School of Electrical Engineering, North China University of Science and Technology, Tangshan 063210, China)

Abstract: Aiming at the problems that the traditional fault diagnosis methods had poor diagnosis effect and poor generalization ability in the wind turbine gearbox under variable operating conditions and mixed fault conditions, a wind turbine gearbox fault diagnosis method (TL-RN-ELM) based on deep residual network (ResNet)-extreme learning machine (ELM) and transfer learning (TL) was proposed. Firstly, the principles of continuous wavelet transform (CWT), convolutional neural network (CNN), ResNet, TL and ELM were introduced. Then, the TL-RN-ELM fault diagnosis model of wind turbine gearbox was established. Finally, the bearing data set and gearbox data set were used to validate the proposed method. Data acquisition and processing were carried out from the CWRU bearing data set and the SEU gearbox data set. The original one-dimensional vibration signal was converted into two-dimensional wavelet time-frequency image using CWT, and the ResNet18 model was trained using CWRU bearing data set to generate a pre-training model. Migrate the data in the pre-training model to the SEU gearbox dataset, fine-tune the module, features were extracted and input them into the ELM classifier, and then the classification results were compared with the other three types of models. The experiment results show that the average accuracy of TL-RN-ELM can reach 98.79% for small sample migration fault diagnosis from bearing to bearing, bearing to gear and mixed fault. Compared with other methods, the average accuracy rate is increased by 4.73%~9.6%. The research results show that this method has good diagnostic effect and generalization ability.

收稿日期：2022-08-09

基金项目：国家自然科学基金资助项目（61803154）；河北省自然科学基金资助项目（E2019209492）

作者简介：孙晔（1990-），女，北京人，研究员，主要从事机械设备大数据分析处理方面的研究。E-mail: sunye2017@126.com

通信联系人：刘晓悦，女，博士，教授，硕士生导师。E-mail: xiaopi135@163.com

Key words: gear transmission; transfer learning(TL); deep residual network (ResNet); extreme learning machine (ELM); convolutional neural network (CNN); continuous wavelet transform (CWT); model pre-training; model drift; wavelet time-frequency diagram

0 引言

近几十年来, 风力发电技术已经在世界范围内得到了广泛应用。

风力发电机(wind turbine, WT)能否正常运行, 直接影响了风电场的发电效率以及经济效益^[1]。齿轮箱作为 WT 传动系统的关键部件, 长期工作在重载、阵风、粉尘腐蚀等恶劣条件下, 是导致 WT 故障的主要原因之一。由于其故障停机时间长、维护成本高, 因此, 对齿轮箱进行快速诊断和定位故障具有总要意义^[2]。

目前, WT 齿轮箱的故障诊断主要是基于数据驱动的方法, 其不依赖于精确的物理模型和丰富的信号处理经验, 已经成为故障诊断领域的研究热点^[3]。LEI Ya-guo 等人^[4]综述了传统机器学习(traditional machine learning, TML)理论在机器故障中的应用, 主要有基于专家系统的方法、基于人工神经网络的方法、基于支持向量机(support vector machine, SVM)的方法。

其中, TML 方法的一般流程是数据采集、信号处理、特征提取、特征选择、健康状态识别^[5]。虽然, 传统的机器学习已经简化了人类劳动, 将人工智能带入了机器故障诊断中, 并取得了一些成就; 但是它的非线性特征提取能力较弱, 特征提取和选择过于依赖人工经验, 无法满足工业应用的需求。

近年来, 随着深度学习的快速发展, 其在图像分类、目标检测和自然语言处理等领域的应用取得了显著的成就^[6-8], 也为 WT 齿轮箱的故障诊断提供了一种新的方案。它不需要丰富的工程实践经验进行手动特征提取和过滤故障特征, 且具有强大的非线性自动特征提取能力。

HUANG Da-jian 等人^[9]提出了一种基于小波包分解和卷积神经网络(CNN)的 WT 齿轮箱智能故障诊断方法, 该方法能够自适应地提取齿轮箱振动信号的多尺度特征, 并对故障进行有效分类。WANG Jin-gang 等人^[10]提出了一种基于多传感器频谱图与改进 CNN 融合的风机齿轮箱故障诊断方法, 解决了单一频谱图的输入不能充分表达齿轮箱故障特征的问题, 并通过实验证明了该齿轮箱故障

诊断方法的有效性。XU Zi-fei 等人^[11]提出了一种将 CNN 和变分模态分解相结合的 WT 轴承故障诊断方法, 基于该故障诊断方法, 采用端到端的方式, 在没有人工干预的情况下, 对不同环境和状态下滚动轴承进行了有效诊断, 解决了在实际工业应用中由于工作条件和数据差异性导致故障诊断方法性能不佳的问题。CHENG Yi-wei 等人^[12]采用连续小波变换(continuous wavelet transform, CWT)方式, 将振动信号转换成了二维度时频图, 使之能更好地显示信号中所包含的时频信息; 将其输入到局部二元 CNN 中, 可自适应地捕捉图像特征, 实现了对旋转机械故障进行自动诊断的目的。CHEN Zhu-yuan 等人^[13]提出了一种集成 CNN 和极限学习机(extreme learning machine, ELM)的新型故障诊断方法, 并构建了具有方池化架构的 CNN, 以提取故障特征; 该方法不需要额外的训练和微调, 降低了计算成本。最后使用 ELM 进行了分类, 证明了 ELM 强大的分类性能。

在此基础上, 为了解决在实际应用中无法获得足够的有故障信息标记的历史数据, 以及训练和测试数据的概率分布不同等问题, 一些学者将迁移学习(TL)引入到了机械设备的故障诊断中^[14]。迁移学习任务由两个数据集组成, 一个来自源域, 另一个来自目标域。目标域中的数据与源域中的数据分布不同, 但包含相关的知识。可以利用从源域中学习到的公共知识来解决目标域的相关任务^[15]。

SHAO Si-yu 等人^[16]利用 TL 进行了高精度机器的故障诊断, 将原始传感器数据通过 CWT 转换为图像, 接着使用在 ImageNet 数据集上训练好的 VGG-16 预训练网络, 以提取其低级特征, 利用微调神经网络结构来提取高级特征, 并通过 3 个主要机械数据集证明了该方法的有效性和泛化性。LI Yan-ting 等人^[17]提出了一种基于参数 TL 和卷积自编码器的小尺度 WT 故障诊断方法, 该方法可以将类似 WT 的知识转移到目标 WT, 并通过实验对比, 证明了该方法在小尺度数据的 WT 故障诊断中具有优势。GUO Jian-wen 等人^[18]提出了一种生成 TL 的 WT 齿轮箱故障诊断方法, 先建立一个域鉴别器, 区分数据是来自源域还是目标域, 再通过特征提

取器和分类器得到目标与分类模型；与其他域自适应算法相比,该方法不仅精度更高,且收敛速度更快。WEN Long 等人^[19]通过结合 TL,将应用在 ImageNet 上训练的 ResNet-50 作为特征提取器,进行了故障诊断,通过实验证明,该方法优于其他 TL 模型和传统方法。

综合以上研究,笔者提出一种基于 ResNet-ELM 和 TL 的 WT 齿轮箱故障诊断方法(TL-RN-ELM)。

首先,笔者利用 CWT,将时域信号转换成小波时频图像,获得原始信号的预处理表示;然后,使用美国凯斯西储大学(CWRU)的轴承数据集,训练搭建的 ResNet18 网络,生成预训练模型,再将预训练模型迁移到东南大学(SEU)的齿轮箱数据集中,进行跨设备以及不同工况的小样本迁移故障诊断(其中,在源域中,对预训练模型进行参数微调;在目标域中,冻结模型的部分卷积层作为特征提取器);最后,使用 ELM 分类器进行故障的分类识别。

1 基本原理

1.1 连续小波变换

小波变换是一种强大的信号处理算法,在故障诊断中得到了广泛的应用^[20]。连续小波变换(CWT)是小波变换的一种,其可以通过以下卷积运算实现^[21]:

$$cwt(a,b) = \frac{1}{\sqrt{a}} \int_{-\infty}^{+\infty} x(t) \varphi^* \left(\frac{t-b}{a} \right) dt \quad (1)$$

式中: a —尺度参数; b —平移参数; $x(t)$ —原始时域信号; φ —小波函数; φ^* — φ 的复共轭。

经 CWT 得到的小波时频图代表了时频和频域的联合分布信息,直观地反映了信号的频率分量与时间的关系。

1.2 卷积神经网络

CNN 是一种有监督的前馈深度学习网络,由卷积层、池化层和全连接层组成^[22]。

其具体结构如图 1 所示。




图 1 CNN 结构图

图 1 中,卷积层和池化层的作用分别是提取数据特征、防止过拟合,二者间隔分布;全连接层整合提取的深度特征,并输出结果。

CNN 对非线性等复杂信号具有强大的处理能力,在故障诊断等许多领域都取得了出色的成果。

1.3 深度残差网络

ResNet使用残差块来解决普通CNN中存在的退化和梯度消失问题。残差块不仅加深了网络的深度,还提高了网络的性能。并且,ResNet网络在ImageNet^[23]分类竞赛中取得了良好的成绩。

ResNet中的残差块将输入和输出相加来实现残差目的。残差函数的公式如下:

$$y = F(x, W) + x \quad (2)$$

式中: x —残差块的输入; W —权重; y —残差块的输出。

残差块的具体结构如图2所示。




图 2 残差块结构图

ResNet网络由若干个残差块组成的,残差块中卷积层的卷积核大小各不相同。由ResNet残差网络提取特征放入全连接层,再进行图像分类,通常使用SoftMax函数来进行分类。

笔者所使用的ResNet18结构参数如图3所示(它是由残差块堆叠而成的,其中,“ \times ”前面的数字代表残差块的个数)。

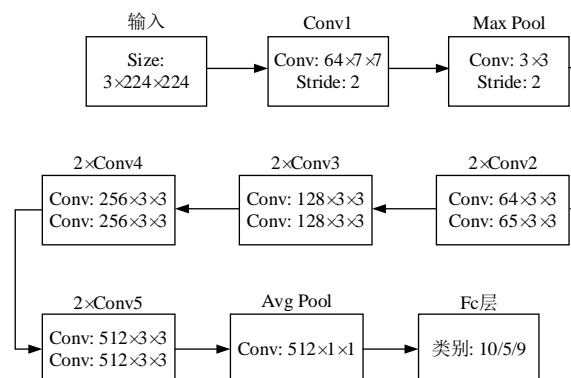


图3 ResNet18结构图

1.4 迁移学习简介

TL描述如下:

设定源域 $D_s = \{(xSi, ySi)\}$, 其中, $xSi \in X_s$ 是一个数据样本, $ySi \in Y_s$ 是其对应的标签;

目标域 $D_t = \{(xTi)\}$, 其中, $xTi \in X_t$ 是一个数据样本, D_s 和 D_t 分别由概率分布 $P_s(X)$ 和 $P_t(X)$ 得出, 且由于域偏差, $P_s(X) \neq P_t(X)$ 。在不同的域中使用相同的标签空间, 即 $Y_t = Y_s$ 。

在故障诊断中, 迁移学习的目标是利用在 D_s 域中学习到的知识, 改进 D_t 域的概率预测函数。

1.5 极限学习机原理

ELM是由 HUANG Gao 等人^[24]构建的一种只有一个隐藏层的前馈神经网络, 其泛化性能优于传统的神经网络模型, 只需要设置隐藏层神经元的数量, 而不需要调整其他参数, 就可以在训练过程中得到唯一最优解。

ELM的构如图4所示。

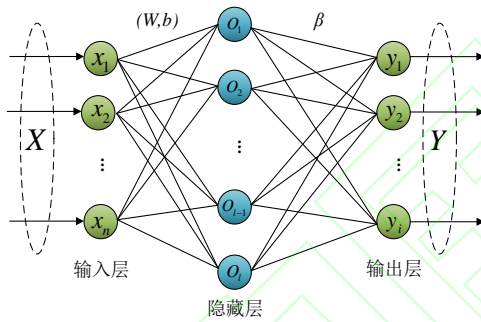


图4 ELM结构图

ELM的具体流程如下:

对于输入样本 X , 隐藏层节点数为 l 的 ELM 网络结构, 其输出函数 Y 可表示为:

$$Y = \sum_i^l \beta_i g(WX_j + b), \quad j = 1, 2, \dots, N \quad (3)$$

式中: W —输入权值, 即输入层与隐藏层之间的连接权值; β —输出权值, 即隐藏层与输出层之间的连接权值; b —隐藏层的阈值; $g(x)$ —激活函数。

训练神经网络使误差最小, 即输出与期望输出之间的误差接近于0, 误差可计算为:

$$\|Y - T\| = 0 \quad (4)$$

并将上述两个公式组合, 得到:

$$\sum_i^l \beta_i g(WX_j + b) = T, \quad j = 1, 2, \dots, N \quad (5)$$

将上述表达式简化为:

$$H\beta = T' \quad (6)$$

式中: H —隐藏层节点的输出矩阵; T' —预期输出。

于是就有:

$$\|H(\hat{W}, \hat{b})\hat{\beta} - T'\| = \min_{W, b, \beta} \|H(W, B)\beta - T'\| \quad (7)$$

隐藏层与输出层之间的连接权值 β 是通过求解上述方程的最小二乘解得到的, 即:

$$\hat{\beta} = H^+ T' \quad (8)$$

式中: H^+ — H 的 Moore-Penrose 广义逆矩阵。

2 基于 TL-RN-ELM 的诊断模型 (流程)

此处, 笔者提出一种基于 ResNet-ELM 和 TL 的风机齿轮箱故障诊断方法(TL-RN-ELM)。

TL-RN-ELM 模型整体流程示意图如图5所示。

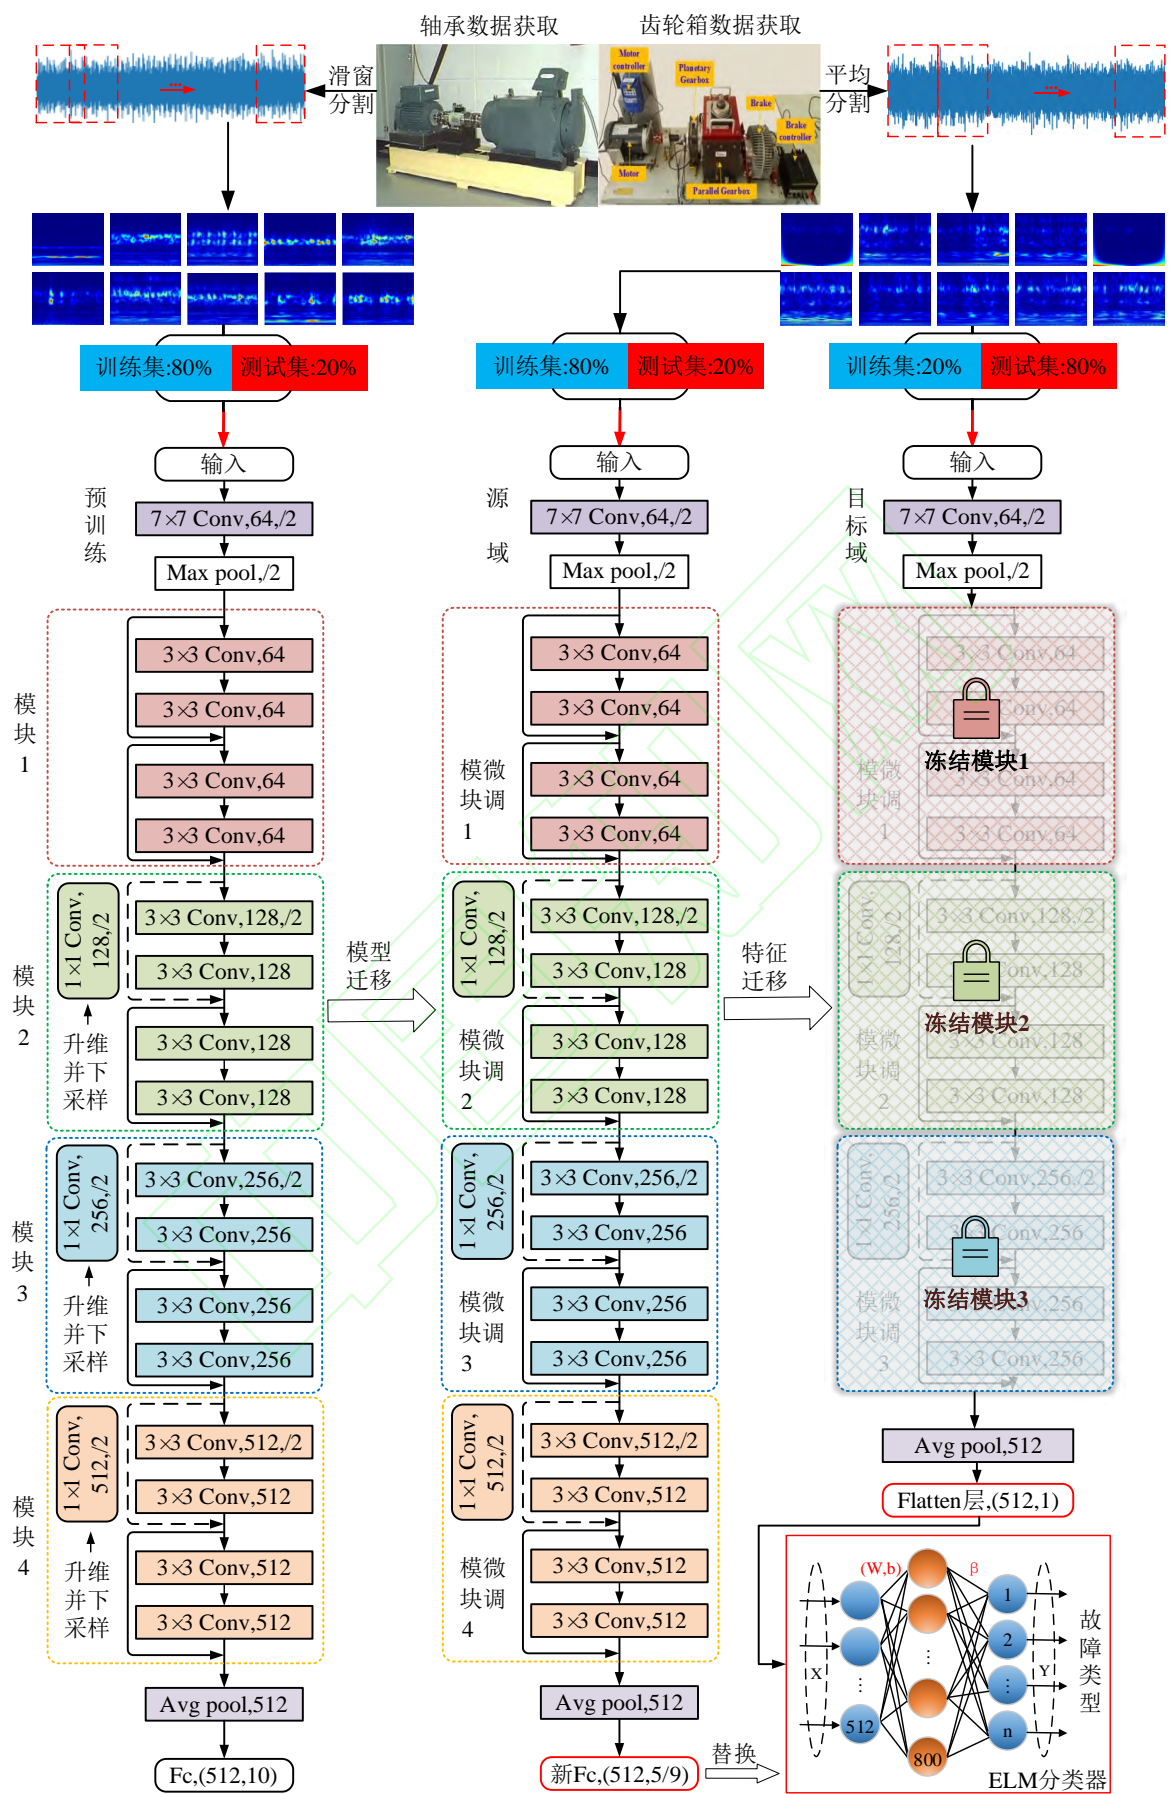


图 5 TL-RN-ELM 模型整体流程示意图

其具体流程如下：

(1) 数据采集与预处理。收集传感器采集的轴承齿轮箱数据，生成时域图并进行数据分割，对于数据不足的，采用滑动窗口采样的分割方式进行数据增强；对于数据充足的，采用平均采样的方式进行分割；

(2) 生成小波时频图。使用 CWT 将预处理后的信号转换成大小为 $224 \times 224 \times 3$ 的二维小波时频图（选用 Morlet 小波为母小波），并添加标签，然后按比例将其划分为训练集和测试集；

(3) 生成预训练模型。使用典型的轴承数据集生成的小波时频图，训练所搭建的 ResNet18 模型，得到理想的分类结果，并加以保存，将其作为预训练模型；

(4) 模型迁移与应用。首先，将预训练模型迁移至齿轮箱数据集中，进行应用；其次，在源域中，使用某一工况下的数据，对预训练模型的模块 1~4 进行参数微调，得到新的适合源域输出个数的全连接层，再进行分类；在目标域中，冻结模块 3 及以上的部分作为特征提取器，提取不同工况下少量数据样本的高级特征表示，并将其输入 ELM 进行分类，从而实现不同工况下对小样本进行故障诊断的目的。

3 实验验证与结果分析

由于 WT 真实运行数据难以获取，为验证基于 TL-RN-ELM 的 WT 齿轮箱故障诊断方法的有效性，笔者使用美国凯斯西储大学(CWRU)提供的轴承数据集和东南大学(SEU)提供的齿轮箱数据集进行实验验证。

计算机硬件环境配置为：64 位 Window10 操作系统，CPU 为 i7-11800H@ 2.30 GHz，GPU 为 Nvidia GeForce RTX 3050。程序运行环境为 python3.7，深度学习框架的搭建为 Pytorch。

模型参数设置如表 1 所示。

表 1 模型参数设置

参数名称	参数值
批次大小	32
Epoch 次数	50
学习速率	0.000 1
优化器	Adam
损失函数	交叉熵损失函数

3.1 数据采集与处理

CWRU 轴承数据中心^[25]提供的 CWRU 数据集是智能故障诊断最著名的开源数据集之一，已经被大量故障诊断类研究所使用。

CWRU 轴承实验装置平台如图 6 所示。




图 6 CWRU 轴承实验装置平台

笔者使用 CWRU 轴承数据中，采样频率为 12 kHz、功率为 0 的驱动端轴承故障数据。

10 种轴承状态及样本分布情况如表 2 所示。

表 2 CWRU 轴承数据集样本分布情况

标签	故障类型	故障大小/mm	训练样本	测试样本
0	NA	0	400×1 024	100×1 024
1	BF	0.177 8	400×1 024	100×1 024
2	IF	0.177 8	400×1 024	100×1 024
3	OF	0.177 8	400×1 024	100×1 024
4	BF	0.355 6	400×1 024	100×1 024
5	IF	0.355 6	400×1 024	100×1 024
6	OF	0.355 6	400×1 024	100×1 024
7	BF	0.533 4	400×1 024	100×1 024
8	IF	0.533 4	400×1 024	100×1 024
9	OF	0.533 4	400×1 024	100×1 024

表 2 中，共包含 1 个正常轴承(normal, NA)和 3 种故障类型，有内圈故障(inner fault, IF)、外圈故障(outer fault, OF)和滚动体故障(ball fault, BF)，根据故障状态的不同，可分为 1 种健康状态和 9 种故障状态，共 10 类。

为了获取足够的样本数据对 ResNet18 模型进行训练，笔者采用滑动窗口方式对 CRWU 数据进行了分割。

滑动窗口分割采样示意图，即分割具体过程如图 7 所示。




图 7 滑动窗口分割采样示意图

每种状态共有 1 200 00 个数据点，每个样本长度为 1 024 个采样点，以 238 个点为步长滑动窗口，共获取 500 个样本。10 种状态共 5 000 个样本，并将其以 8:2 的比例，划分为训练集和测试集。

SEU 提供的齿轮箱数据集^[16]由两个子数据集组成，包括轴承数据集和齿轮数据集。这两个子数据集都是从传动系统动力学模拟器(drivetrain dynamic simulator, DDS)中收集的。

SEU 齿轮箱实验装置平台如图 8 所示。




图 8 SEU 齿轮箱实验装置平台

该数据集共收集了 8 个通道。

笔者使用来自通道 2 的数据，每个子数据集包含 5 个条件：1 个健康状态和 4 个故障状态。

SEU 齿轮箱数据集样本具体分布情况如表 3 所示。

表 3 SEU 齿轮箱数据集样本分布情况

故障部位	故障类型	训练样本		测试样本	
		源域	目标域	源域	目标域
齿轮	健康	800	40	200	160
	裂纹	800	40	200	160
	缺齿	800	40	200	160
	齿根磨损	800	40	200	160
	齿面磨损	800	40	200	160

轴承	健康	800	40	200	160
	内圈故障	800	40	200	160
	外圈故障	800	40	200	160
	滚珠故障	800	40	200	160
	内外圈联合故障	800	40	200	160

在收集数据时，笔者将转速-系统负荷分别设置为 20 Hz-0 V 和 30 Hz-2 V；将这两种工作条件视为不同的任务，轴承子数据集设置为任务 A 和任务 B、齿轮子数据集设置为任务 C 和任务 D。

为验证 TL-RN-ELM 方法在处理混合故障时的性能，笔者将轴承故障和齿轮故障组合为 4 种轴承故障和 1 种健康状态、4 种齿轮故障的 9 类混合故障数据集，设置为任务 E 和任务 F。

SEU 齿轮箱数据集 6 种迁移学习设置如表 4 所示。

表 4 SEU 齿轮箱数据集迁移任务设置

任务	故障部位	转速-系统负荷
A	轴承	20 Hz-0 V
B		30 Hz-2 V
C	齿轮	20 Hz-0 V
D		30 Hz-2 V
E	轴承+齿轮	20 Hz-0 V
F		30 Hz-2 V

在源域中，每种状态共使用 1 024 000 个点，平均分割成 1 000 个样本，每个样本 1 024 个采样点，轴承和齿轮单独故障分别获得 5 000 个样本，混合故障获得 9 000 个样本；

在目标域中，使用少量数据样本，每种状态选用 2 048 00 个点，平均分割成 200 个样本，每个样本 1 024 个采样点，轴承和齿轮单独故障分别获得 1 000 个样本，混合故障共获得 1 800 个样本。

为了更好地验证在实际应用环境下 TL-RN-ELM 的小样本迁移故障诊断效能，笔者将目标域样本以 2:8 的比例划分为训练集和测试集。

3.2 小波时频图获取

SEU 数据集在 10 种不同状态下的原始信号样本如图 9 所示。

经 CWT 得到对应的小波时频图如图 10 所示。

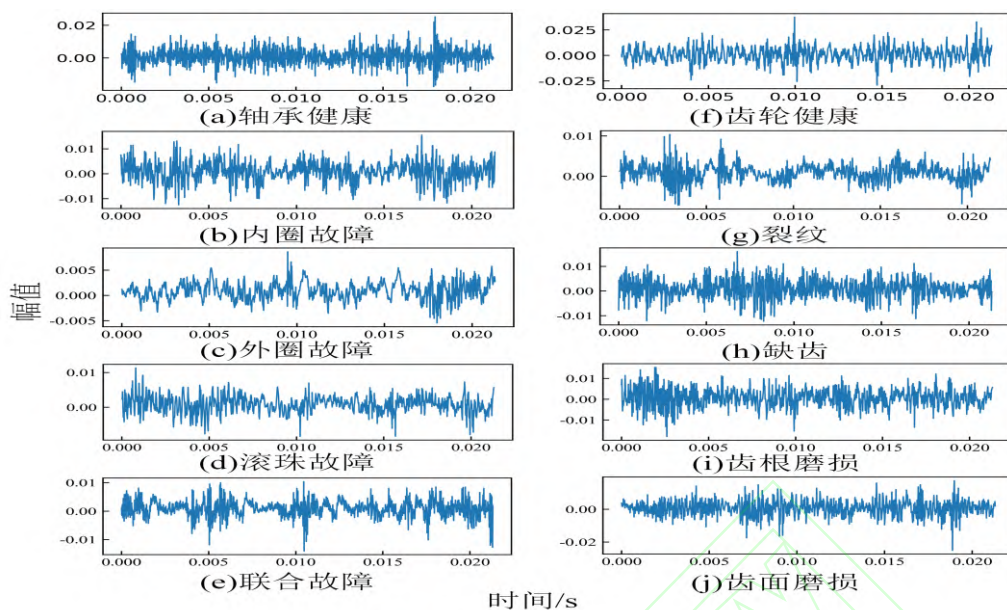


图 9 SEU 齿轮箱原始信号样本

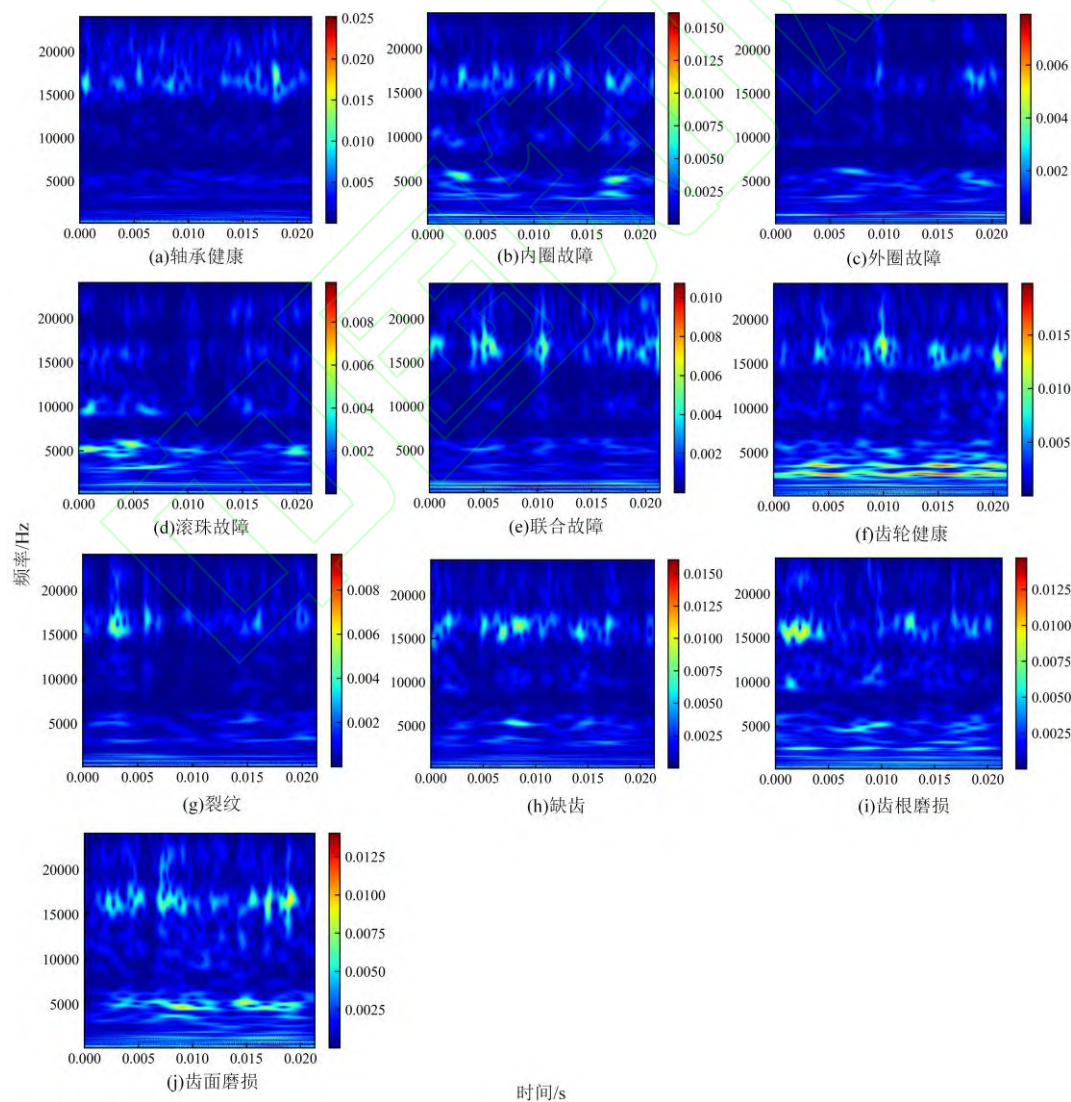


图 10 SEU 齿轮箱原始信号对应的小波时频图

由图（9，10）可以看出：不同状态下的时频分布特征有所不同，与单纯的时域或频域信息相比，小波时频图所包含的状态变化特征更加明显。

3.3 预训练模型生成

笔者使用表 1 所示的 CWRU 轴承数据集，对 ResNet18 模型进行预训练，得到的准确率如图 11 所示。




图 11 ResNet18 预训练模型分类精度

由图 11 可知：仅经过 5 次迭代，测试集的准确率就达到了 98.6%，且最终实现了 10 种状态的完全分类目的。

ResNet18 预训练模型测试集混淆矩阵的具体细节如图 12 所示。

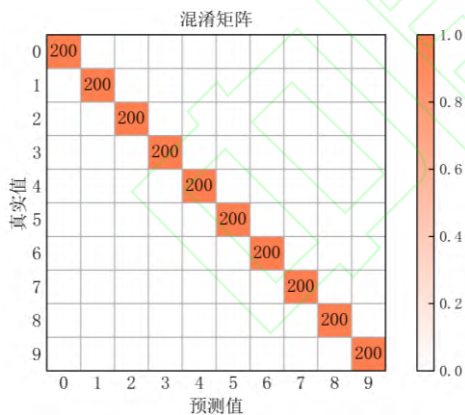


图 12 ResNet18 预训练模型测试集混淆矩阵

由图 12 可以确定：预训练模型取得了很好的

分类效果。

3.4 模型迁移与应用

笔者将经 CWRU 轴承数据集预训练的 ResNet18 模型迁移至 SEU 齿轮箱数据集，分别进行了 $A \rightarrow B$ 、 $B \rightarrow A$ 、 $C \rightarrow D$ 、 $D \rightarrow C$ 、 $E \rightarrow F$ 、 $F \rightarrow E$ 共 6 种不同工况的迁移任务。

为确保实验结果的准确性，所有迁移任务均重复了 10 次实验，并计算了平均值。

测试结果如图 13 所示。




图 13 6 个迁移任务的测试集分类精度

由图 13 可知：在源域中，笔者将预训练模型的所有模块进行微调，并重新建立输出个数为 5 和 9 的全连接层，进行了分类，测试结果均达到了 99% 以上；

在目标域中，去掉源域中模块 4 及以后的部分，将剩余部分冻结，提取其特征，并将其输入 ELM 分类器，在处理 5 个分类和 9 个分类任务时，ELM 隐藏层神经元个数分别设置为 1 300 和 2 500。

结果表明：在齿轮箱的小样本数据下，使用 ELM 作为分类器取得了很好的效果。特别是在任务 $C \rightarrow D$ 和任务 $D \rightarrow C$ 中，故障分类平均准确率达到了 99.25%，除了任务 $E \rightarrow F$ 的平均准确率为 97.78% 外，其余 3 个分类任务的平均准确率均在 98% 以上。

6 个迁移任务单次分类的具体结果如图 14 所示。

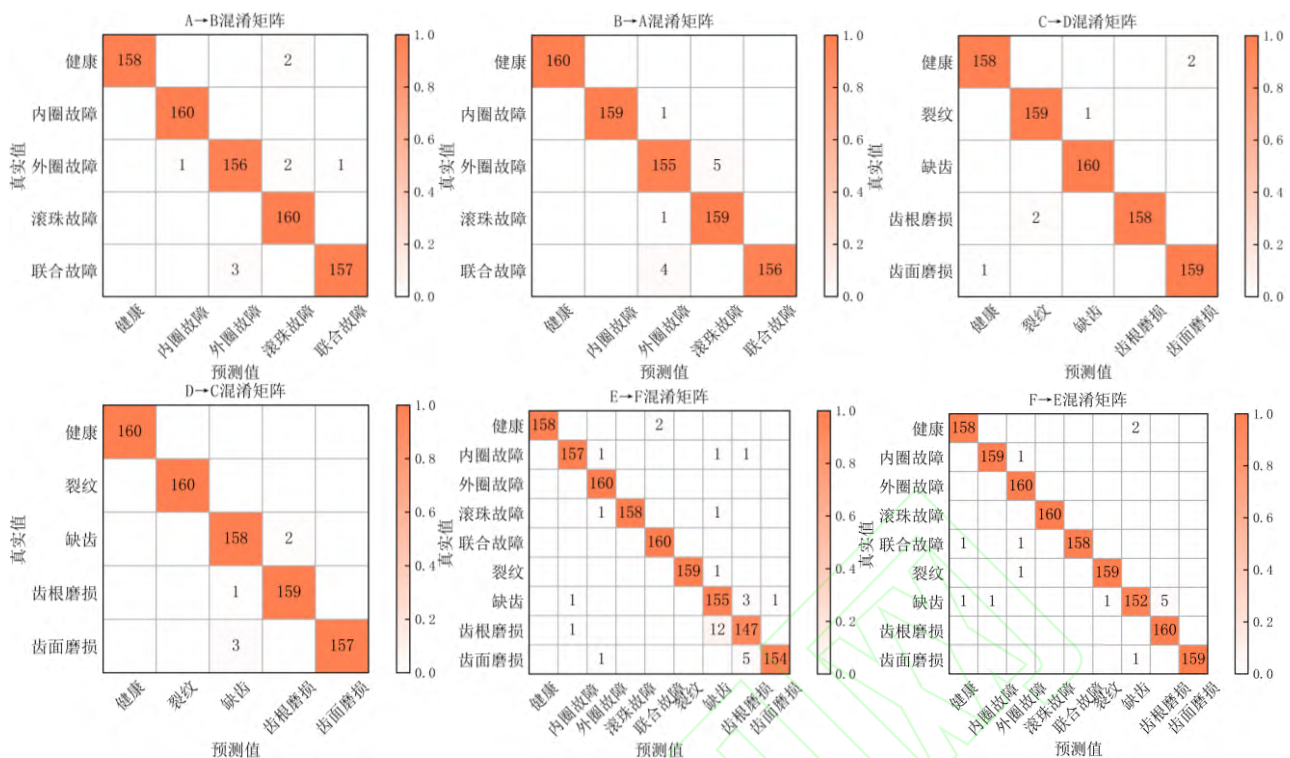


图 14 6 个迁移任务的混淆矩阵图

由图 14 可知：在任务 C→D 的 800 个故障测试样本中，仅有 6 个样本被错误分类；在任务 D→C 中，有 2 个缺齿故障被错分到了齿根磨损故障，有 1 个齿根磨损故障被错分到了缺齿故障，有 3 个齿面磨损故障被错分到了缺齿故障，其余 2 种状态实现了完全分类目的；

其余任务的故障分类结果相对较差一些，但也均完成了某种故障状态的完全分类任务，这说明 TL-RN-ELM 方法具有良好的诊断效果和泛化能力。

3.5 实验结果对比分析

为了验证 TL-RN-ELM 方法的优越性，笔者建立了 3 种模型，进行了 6 种迁移任务：(1)在目标域中不去掉模块 4 等结构下直接使用 ELM 分类；(2)使用 SoftMax 分类；(3)使用 SVM 分类。

笔者将采用上述模型所得结果与采用 TL-RN-ELM 方法所得的结果进行了比较，结果对比情况如表 5 所示。

表 5 实验结果对比

任务	ELM/%	SoftMax/%	SVM /%	TL-RN-ELM /%
A→B	95.8	94.5	91.6	98.88
B→A	96.6	94.6	90.8	98.63
C→D	94.2	92.5	91.9	99.25
D→C	92.9	95.5	90.6	99.25
E→F	88.75	84.6	81.02	97.78

F→E	96.13	95.8	89.22	98.96
平均	94.06	92.92	89.19	98.79

模型分类结果对比的雷达图如图 15 所示。




图 15 模型分类结果对比雷达图

由表 5 和图 15 可以看出：在各项迁移任务中，采用 TL-RN-ELM 方法都取得了更好的诊断效果，且平均准确率达到 98.79%；与其他三种方法相比，平均准确率提升了 4.73%~9.6%；

对比结果表明：目标域所冻结的卷积模块可

以很好地作为特征提取器,提取齿轮箱的故障特征,且 ELM 分类器与其他分类方法相比,具有更佳的性能。

4 结束语

笔者提出了一种基于 ResNet-ELM 和 TL 的风机齿轮箱故障诊断方法 TL-RN-ELM。

首先,笔者将原始振动信号转换成小波时频图像,构造了数据集样本;然后,搭建了基于 ResNet18 和 ELM 的风机齿轮箱迁移学习故障诊断模型,并使用 CWRU 轴承数据集对模型进行了训练,生成预训练模型;最后,在源域中,使用 SEU 齿轮箱数据集(某一工况下的样本),对模型进行了微调;在目标域中,使用不同工况下的样本,进行了从轴承到轴承、轴承到齿轮以及混合故障的小样本迁移故障诊断。

研究结论如下:

(1)在不同设备数据集、不同工况及混合故障下,采用基于 TL-RN-ELM 的风机齿轮箱故障诊断模型取得了比较优异的结果,证明该模型具有良好的诊断效果和泛化能力;

(2)在目标域中,仅使用少量的数据样本对预训练模型进行微调就可以达到很高的诊断结果,平均准确率达到 98.79%,证明该模型可以很好地完成风电装备小样本数据下的准确故障诊断任务;

(3)经过微调后,ResNet18 的部分卷积层可以作为特征提取器,具有很强的故障特征提取能力;同时,与 SoftMax 和 SVM 相比,ELM 分类器具有更强的分类性能,其平均准确率提高了 4.73%~9.6%。

在该研究内容的基础上,后续笔者将针对使用更少样本进行模型训练方面的研究,以便建立更加快速的风机迁移学习故障诊断模型,并且进一步提高模型在更加复杂情况下的故障诊断准确率。

参考文献(References):

[1] GU H, LIU W Y, GAO Q W, et al. A review on wind turbines gearbox fault diagnosis methods[J]. **Journal of Vibroengineering**, 2021, 23(1): 26-43.

[2] WANG Tian-yang, HAN Qin-kai, CHU Fu-lei, et al. Vibration based condition monitoring and fault diagnosis of wind turbine planetary gearbox: a review[J]. **Mechanical**

Systems and Signal Processing, 2019, 126 (7) : 662-685.

[3] 曾军,陈艳峰,杨苹,等.大型风力发电机组故障诊断综述[J]. **电网技术**, 2018, 42(3): 849-860.

[4] LEI Ya-guo, YANG Bin, JIANG Xin-wei, et al. Applications of machine learning to machine fault diagnosis: a review and roadmap[J]. **Mechanical Systems and Signal Processing**, 2020, 138 (4) : 106587.

[5] 王宏伟,孙文磊,张小栋,等.基于优化VMD复合多尺度散布熵及LSTM的风力发电机齿轮箱故障诊断方法研究[J]. **太阳能学报**, 2022, 43(4): 288-295.

[6] 武海彬,卜明龙,刘圆圆,等.基于SDP图像与VGG网络的旋转机械转子故障诊断研究[J]. **机电工程**, 2020, 37(9): 1069-1074.

[7] 李兰,奚舒舒,张才宝,等.基于DSSD模型的机械加工件表面缺陷检测研究[J]. **机电工程**, 2021, 38(2): 234-238, 255.

[8] 贾骏,杨强,付慧,等.基于电力设备大数据的预训练语言模型构建和文本语义分析[J/OL]. **中国电机工程学报**: 1-10[2023-02-06].
<http://kns.cnki.net/kcms/detail/11.2107.TM.20220616.1409.005.html>.

[9] HUANG Da-jian, ZHANG Wen-an, GUO Fang-hong, et al. Wavelet packet decomposition-based multiscale CNN for fault diagnosis of wind turbine gearbox[J]. **IEEE Transactions on Cybernetics**, 2021, 53 (1) : 443-453.

[10] WANG Jin-gang, LIU Ya, TIAN Tian. Fault Diagnosis Method of Wind Turbine Gearbox Based on Fusion Multi-Spectrogram and Improved CNN Neural Network[C]//2022 5th International Conference on Energy, Electrical and Power Engineering (CEEPE). IEEE, 2022: 513-517.

[11] XU Zi-fei, LI Chun, YANG Yang. Fault diagnosis of rolling bearing of wind turbines based on the variational mode decomposition and deep convolutional neural networks[J]. **Applied Soft Computing**, 2020, 95 (10) : 106515.

[12] CHENG Yi-wei, LIN Man-xi, WU Jun, et al. Intelligent fault diagnosis of rotating machinery based on continuous wavelet transform-local binary convolutional neural network[J]. **Knowledge-Based Systems**, 2021, 216 (1) : 106796.

[13] CHEN Zhu-yun, GRYLLIAS K, LI Wei-hua. Mechanical fault diagnosis using convolutional neural networks and extreme learning machine[J]. **Mechanical systems and**

signal processing, 2019, 133 (11) : 106272.

- [14] MAO Wen-tao, LIU Ya-min, DING Ling, et al. A new structured domain adversarial neural network for transfer fault diagnosis of rolling bearings under different working conditions[J]. **IEEE Transactions on Instrumentation and Measurement**, 2020, 70 (12) : 1-13.
- [15] CHEN Zhu-yun, GRYLLIAS K, LI Wei-hua. Intelligent fault diagnosis for rotary machinery using transferable convolutional neural network[J]. **IEEE Transactions on Industrial Informatics**, 2019, 16(1): 339-349.
- [16] SHAO Si-yu, MCALEER S, YAN Ru-qiang, et al. Highly accurate machine fault diagnosis using deep transfer learning[J]. **IEEE Transactions on Industrial Informatics**, 2018, 15(4): 2446-2455.
- [17] LI Yan-ting, JIANG Wen-bo, ZHANG Guang-yao, et al. Wind turbine fault diagnosis based on transfer learning and convolutional autoencoder with small-scale data[J]. **Renewable Energy**, 2021, 171 (3) : 103-115.
- [18] GUO Jian-wen, WU Jia-peng, ZHANG Shao-hui, et al. Generative transfer learning for intelligent fault diagnosis of the wind turbine gearbox[J]. **Sensors**, 2020, 20(5): 1361.
- [19] WEN Long, LI Xin-yu, GAO Liang. A transfer convolutional neural network for fault diagnosis based on ResNet-50[J]. **Neural Computing and Applications**, 2020, 32(10): 6111-6124.
- [20] YAN Ru-qiang, GAO R X, CHEN Xue-feng. Wavelets for fault diagnosis of rotary machines: a review with applications[J]. **Signal processing**, 2014, 96 (3) : 1-15.
- [21] RIOUL O, VETTERLI M. Wavelets and signal processing[J]. **IEEE signal processing magazine**, 1991, 8(4): 14-38.
- [22] RAWAT W, WANG Zeng-hui. Deep convolutional neural networks for image classification: A comprehensive review[J]. **Neural computation**, 2017, 29(9): 2352-2449.
- [23] HE Kai-ming, ZHANG Xiang-yu, REN Shao-qing, et al. Deep Residual Learning for Image Recognition[C]// Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. 2016: 770-778.
- [24] HUANG Gao, HUANG Guang-bin, SONG Shi-ji, et al. Trends in extreme learning machines: A review[J]. **Neural Networks**, 2015, 61 (1) : 32-48.
- [25] Case Western Reserve University. (Aug. 2020). Case Western Reserve University (CWRU) Bearing Data Center. [Online]. Available: <https://csegroups.case.edu/bearing-data-center/pages/download-data-file/>.

作者简介：孙晔（1990-），女，北京市人，研究员，主要从事大数据分析处理方面的研究。E-mail: sunye2017@126.com。

联系地址：北京市海淀区学院路40号。

手机：15033912510

通信联系人：刘晓悦（1965-），女，河北省唐山市人，博士，教授，硕士生导师，主要从事检测与控制技术及智能装置方面的研究。E-mail: xiaopi135@163.com。

手机：15613857816