

# 基于 ResNet 和领域自适应的轴承故障诊断研究

杨冰如<sup>1</sup>, 李 奇<sup>1</sup>, 陈 良<sup>1</sup>, 沈长青<sup>2</sup>, 朱忠奎<sup>2</sup>

(1. 苏州大学 机电工程学院, 江苏 苏州 215131; 2. 苏州大学 轨道交通学院, 江苏 苏州 215131)

**摘要:** 轴承故障诊断在实际工业场景中意义重大。基于信号处理方法和机器学习方法, 往往非常依赖先验知识, 难以保证特征提取的有效性, 深度学习方法要求训练集和测试集满足同一分布, 这在工业现场难以满足, 使得模型性能大幅下降。提出一种基于多层领域自适应的故障诊断方法, 能够实现多种类、多尺寸的轴承故障诊断。首先, 采用预训练好的 ResNet18 (Residual Network) 作为特征提取器, 并对每个残差块提取的特征计算 MK-MMD (Multiple Kernel-Maximum Mean Discrepancy) 距离, 通过同时匹配高层和低层特征以有效匹配边缘分布差异。其次, 每个残差块提取的特征都进入与之匹配的分类器中, 通过 Softmax 层计算的预测概率分布, 并转化为伪标签, 缩小条件分布差异。最后, 引入 Adam 优化器, 对整体模型参数进行优化, 加快模型训练, 提高模型收敛速度。实验结果表明, 所提出的方法能够有效提取可迁移特征, 在负载变化的场景下达到了较高的诊断精度, 并具有一定的泛化能力。

**关键词:** 机械故障诊断; 轴承; 领域自适应; 迁移学习

**中图分类号:** TH133.3    **文献标志码:** A    **文章编号:** 1000-8829(2021)12-0031-09

**doi:** 10.19708/j.ckjs.2021.02.204

## Bearing Fault Diagnosis Based on ResNet and Domain Adaptation

YANG Bing-ru<sup>1</sup>, LI Qi<sup>1</sup>, CHEN Liang<sup>1</sup>, SHEN Chang-qing<sup>2</sup>, ZHU Zhong-kui<sup>2</sup>

(1. School of Mechanical and Electrical Engineering, Soochow University, Suzhou 215131, China;

2. School of Rail Transportation, Soochow University, Suzhou 215131, China)

**Abstract:** Bearing fault diagnosis is of great significance in practical industrial scenarios. Methods based on signal processing and machine learning often rely heavily on prior knowledge, and it is difficult to guarantee the effectiveness of feature extraction. Deep learning methods require the training set and test set to meet the same distribution, which is difficult to meet in industrial sites, greatly reduces model performance. A fault diagnosis method based on multi-layer domain adaptation is proposed, which can realize various types and degrees of bearing fault diagnosis. Firstly, pre-trained ResNet18 (Residual Network) is used as a feature extractor, and the MK-MMD (Multiple Kernel-Maximum Mean Discrepancy) distance is calculated for the features extracted from each residual block. In this way, high-level and low-level features are simultaneously matched to effectively match the marginal distribution differences. Secondly, the features extracted by each residual block are entered into a matching classifier, and the predicted probability distribution calculated by the Softmax layer is converted into pseudo labels to reduce the conditional distribution differences. Finally, the Adam optimizer is introduced to optimize the overall model parameters, speed up model training, and improve model convergence speed. The experimental results show that the proposed method can effectively extract transferable features, achieve high diagnostic accuracy under load changing scenarios, and have a certain generalization ability.

收稿日期: 2020-08-26

基金项目: 国家自然科学基金项目(51875375, 51875376)

引用格式: 杨冰如, 李奇, 陈良, 等. 基于 ResNet 和领域自适应的轴承故障诊断研究[J]. 测控技术, 2021, 40(12): 31-39.

YANG B R, LI Q, CHEN L, et al. Bearing Fault Diagnosis Based on ResNet and Domain Adaptation[J]. Measurement & Control Technology, 2021, 40(12): 31-39.

**Key words:** mechanical fault diagnosis; bearing; domain adaptation; transfer learning

旋转机械是实际工业现场的重要部件之一,通常需要在恶劣的情况下长时间运转,很容易磨损滚动轴承等零部件,不可避免会形成故障<sup>[1]</sup>。而机械设备一旦发生故障,会导致大量的经济损失,严重时甚至会发生人身事故,因此可靠准确的轴承故障诊断方法的研究越来越重要,它能够对旋转机械的健康状态进行监测与诊断,从而保障机械设备的正常运行,降低故障风险。随着智能制造模式的发展,对工业过程中的故障检测提出了更高的要求<sup>[2]</sup>。

轴承振动信号是能为检测机械设备状态提供信息的高精度指标<sup>[3]</sup>,因此大多数传统的基于信号处理的故障诊断方法都是从原始振动信号中提取故障信息,如经验模态分解(Empirical Mode Decomposition, EMD)<sup>[4]</sup>、小波包变换(Wavelet Packet Transform, WPT)<sup>[5]</sup>和其他时频域信号处理方法。Yu等<sup>[6]</sup>采用经验模态分解方法,根据固有模态函数计算振动信号的原始统计特征,再结合特征降维方法,实现了轴承的故障诊断。Wang等<sup>[7]</sup>将小波包变换和稀疏编码相结合,提出了一种有监督的基于稀疏小波变换的轴承故障检测方法。小波包变换可以检测到轴承信号发生的故障。基于结构化字典的稀疏编码可以找到信号的鲁棒表示,同时集成类别信息。基于信号处理的方法要求分析人员具有一定的先验知识的储备,包括机械方面的专业知识和数学基础,才能保证较好的信号处理效果<sup>[8]</sup>。

在实际运行过程中的设备状况会受到很多因素的影响,十分复杂,采用基于信号处理的诊断方法效果不明显,因此研究人员引入了机器学习模型来弥补这一不足。Zhang等<sup>[9]</sup>将经验模态分解和支持向量机(Support Vector Machines, SVM)相结合,揭示了振动信号多尺度内在特征。Mao等<sup>[10]</sup>针对故障数据比正常数据少得多的数据不平衡问题,提出了一种基于极限学习机的故障诊断在线时序预测方法。但机器学习诊断模型的性能也往往受到手工提取特征的限制,当数据结构复杂时,难以提取到有效特征。

随着深度学习(Deep Learning)<sup>[11]</sup>的发展,其自动特征提取的能力在故障诊断领域中有着良好的应用前景。Zhang等<sup>[12]</sup>提出了一种使用稀疏自动编码器(Sparse Auto Encoder, SAE)的新标签生成方法,它能够从训练样本中构造一个分布,并识别那些不属于已知类别的样本。Dong等<sup>[13]</sup>将无监督卷积神经网络(Convolutional Neural Networks, CNN)和深度信念网络(Deep Belief Network, DBN)相结合,提出了随机卷积深度信念网络,通过加入无监督成分,提高了模型的泛化能力。Shao等<sup>[14]</sup>利用生成对抗网络(Generative

Adversarial Network, GAN)学习机械传感器信号并生成真实的带标签的合成信号,并将生成的信号作为扩展数据用于故障诊断。

然而,深度学习模型需要满足训练集和测试集服从同一分布的假设,并且需要大量有标签数据才能训练一个足够好的模型,这两个条件在实际工业现场都是难以满足的。机械设备在运行过程中会受到温度、负载、运行时间等因素的影响,导致采集的数据分布有差异,此时训练好的深度学习模型的诊断效果会大打折扣。并且为数据打标签是个耗时耗力的工作,很难收集到大量有标签的数据去训练模型。因此将迁移学习(Transfer Learning)模型用于机械故障诊断是近年来新兴起但发展较为迅速的一个研究方向,其目标在于能够将从源域学习到的知识用于解决目标域中新的相关的任务<sup>[15-16]</sup>。Wen等<sup>[17]</sup>提出了一种深度迁移学习网络,采用了一个无标签的第三数据集来辅助分类,能够在一定程度上提高分类效果。Zhang等<sup>[18]</sup>提出了域自适应卷积神经网络,将源域和目标域分别输入到各自的特征提取器中,使源域和目标域的实例样本在映射后具有相似的分布,实现了不同工作条件下的轴承故障诊断。Guo等<sup>[19]</sup>提出了深度卷积迁移学习网络,包括状态识别和域自适应两个模块,通过最大化域识别误差和最小化概率分布距离,使一维卷积神经网络更容易学习域不变特征。Li等<sup>[20]</sup>通过人工生成用于领域自适应的伪样本,能够在机器故障条件下的测试数据不能用于训练时提供可靠的跨领域诊断结果。

综上所述,基于信号处理的方法和机器学习方法都非常依赖先验知识的储备,深度学习模型需要满足的假设在实际工业现场难以满足,而目前大多数的迁移学习模型仅匹配一种分布差异,边缘分布差异或是条件分布差异,并且在匹配特征分布时,有些学者认为高层特征的可迁移性显著下降<sup>[21]</sup>,而有些学者则认为低层特征更导致了领域分布差异<sup>[22]</sup>。针对上述问题,本文采用经过预训练的深度残差网络(Residual Network, ResNet)作为特征提取器,对4个残差块提取的源域和目标域特征计算最大均值差异(Maximum Mean Discrepancy, MMD)以匹配边缘分布,通过为目标域数据打伪标签匹配条件分布差异。经实验证明,在变工况的场景下,该模型能在提高诊断精度的同时,对轴承故障进行定性、定量诊断。

## 1 理论背景

### 1.1 领域自适应

迁移学习是目前受到众多研究人员广泛关注的一

个研究方向,并已在图像识别<sup>[23]</sup>、语音识别<sup>[24]</sup>、文本识别<sup>[25]</sup>等领域成功应用。领域自适应(Domain Adaptation)可以看作是迁移学习中的一种特定的设置<sup>[26]</sup>。

假设给定一个源域  $D_s = \{(x_i^s, y_i^s)\}_{i=1}^{n_s}$ , 其中包含  $n_s$  个有标签的样本, 相应的学习任务为  $T_s$ ; 一个目标域  $D_t = \{(x_j^t)\}_{j=1}^{n_t}$ , 包含  $n_t$  个无标签的样本, 相应的学习任务为  $T_t$ ;  $D_s \neq D_t$  或  $T_s \neq T_t$ 。领域自适应的目标是在训练过程中充分利用来自  $D_s$  和  $D_t$  的信息, 使学习过程自适应<sup>[27]</sup>, 提取可迁移的特征, 找到一个目标预测函数  $f(\cdot)$ , 能够在  $D_t$  上取得良好的效果。

领域  $D$  中包含样本空间  $X$  和样本的边缘分布  $P(X)$ , 可以表示为  $D = \{X, P(X)\}$ , 即  $D_s \neq D_t$  意味着  $X_s \neq X_t$  或(和)  $P_s(X) \neq P_t(X)$ 。

任务  $T$  包含标签空间  $Y$  和目标预测函数  $f(\cdot)$ , 可以表示为  $T = \{Y, f(\cdot)\}$ , 从概率的观点来看,  $f(\cdot)$  也可以表示为条件分布  $P(Y|X)$ , 即  $T_s \neq T_t$  意味着  $Y_s \neq Y_t$  或(和)  $P_s(Y|X) \neq P_t(Y|X)$ 。

当  $D_s$  和  $D_t$  差距较大时, 如图 1(a) 所示, 此时  $D_t$  中每一类的中心和  $D_s$  中的相距较远, 匹配边缘分布更为重要。而当边缘分布比较接近时, 如图 1(b) 所示, 此时  $D_t$  中每一类的中心和  $D_s$  中的差距较小, 则更应该关注匹配条件分布差异。在实际工业场景中,  $D_s$  和  $D_t$  的边缘分布和条件分布往往都会有差异, 对领域自适应产生不同的影响, 因此在本文中同时匹配边缘分布和条件分布, 如图 1(c) 所示。




图 1 边缘分布和条件分布对领域自适应的不同影响

## 1.2 深度残差网络

在 2015 年提出的深度残差网络(ResNet)<sup>[28]</sup>取得了当年 ImageNet 数据集<sup>[29]</sup>的分类比赛冠军。它解决了当深度网络层数增加时, 网络准确率出现饱和甚至下降的问题, 并且具有很强的特征提取能力。考虑到数据集的规模, 采用 ResNet18 作为特征提取器, 网络包含 4 个残差块, 每个残差块的内部结构如图 2 所示, 具体网络结构参数如表 1 所示。Conv 代表一个卷积层(Convolutional Layer), BN 代表批标准化(Batch Normalization), ReLU 代表线性修正单元(Rectified Linear Unit), 是一种激活函数, FC 代表全连接层(Fully Connected Layer)。

malization), ReLU 代表线性修正单元(Rectified Linear Unit), 是一种激活函数, FC 代表全连接层(Fully Connected Layer)。




图 2 残差块内部结构

表 1 ResNet18 网络参数

名称	输出尺寸	通道数 × 内核尺寸
输入	3 × 224 × 224	—
Conv1	64 × 112 × 112	64 × 7 × 7, 步长为 2
BN, ReLU	64 × 112 × 112	—
Max pool	64 × 56 × 56	64 × 3 × 3, 步长为 2
第 1 块: Conv2_x	256 × 56 × 56	$\begin{bmatrix} 64 \times 3 \times 3 \\ 64 \times 3 \times 3 \end{bmatrix} \times 2$
第 2 块: Conv3_x	512 × 28 × 28	$\begin{bmatrix} 128 \times 3 \times 3 \\ 128 \times 3 \times 3 \end{bmatrix} \times 2$
第 3 块: Conv4_x	1024 × 14 × 14	$\begin{bmatrix} 256 \times 3 \times 3 \\ 256 \times 3 \times 3 \end{bmatrix} \times 2$
第 4 块: Conv5_x	2048 × 7 × 7	$\begin{bmatrix} 512 \times 3 \times 3 \\ 512 \times 3 \times 3 \end{bmatrix} \times 2$
ReLU	2048 × 7 × 7	—
Average pool	2048 × 1	2048 × 7 × 7
FC, Softmax	1000	—

原始结构的 ResNet18 在图像识别领域取得了巨大的成功, 但在本文中, 仅将 ResNet18 作为特征提取器, 并且结合轴承信号的特性, 对其进行一些改动。首先, 为了匹配轴承信号维度, 将 Conv1 的内核尺寸改为 3 × 3; 其次为了尽可能保留状态信息, 去掉 Max pool 层; 最后不需要 ResNet18 的分类功能, 去掉 FC 层和 Softmax 层。修改后的具体网络参数如表 2 所示。

## 1.3 最大均值差异(MMD)

为了寻找合适的  $f(\cdot)$ , 需要缩小  $D_s$  和  $D_t$  间的分布差异  $d(X_s, X_t)$ , 许多迁移学习方法中都采用 MMD<sup>[30]</sup>来衡量边缘分布差异。

$$MMD_k(U, V) = \|E_U[\varphi(x^s)] - E_V[\varphi(x^t)]\|_{H_k}^2 \quad (1)$$



表 2 修改后的 ResNet18 网络参数

名称	输出尺寸	通道数 × 内核尺寸
输入	$3 \times 224 \times 224$	—
Conv1	$64 \times 112 \times 112$	$64 \times 3 \times 3$ , 步长为 2
BN, ReLU	$64 \times 112 \times 112$	—
第 1 块: Conv2_x	$256 \times 56 \times 56$	$\begin{bmatrix} 64 \times 3 \times 3 \\ 64 \times 3 \times 3 \end{bmatrix} \times 2$
第 2 块: Conv3_x	$512 \times 28 \times 28$	$\begin{bmatrix} 128 \times 3 \times 3 \\ 128 \times 3 \times 3 \end{bmatrix} \times 2$
第 3 块: Conv4_x	$1024 \times 14 \times 14$	$\begin{bmatrix} 256 \times 3 \times 3 \\ 256 \times 3 \times 3 \end{bmatrix} \times 2$
第 4 块: Conv5_x	$2048 \times 7 \times 7$	$\begin{bmatrix} 512 \times 3 \times 3 \\ 512 \times 3 \times 3 \end{bmatrix} \times 2$
ReLU	$2048 \times 7 \times 7$	—
Average pool	$2048 \times 1$	$2048 \times 7 \times 7$

式中,  $U$  和  $V$  为两种分布样本;  $H_k$  为再生核希尔伯特空间 (Reproducing Kernel Hilbert Space, RKHS),  $k$  为内核。内核的选择对于 MMD 有着重要的影响, 因为不

同的核可能会在不同的 RKHSs 中嵌入概率分布<sup>[31]</sup>, 并且有研究表明与单一内核相比, 采用多核 MMD (Multiple Kernel-Maximum Mean Discrepancy, MK-MMD) 能够极大地提高自适应的效率<sup>[32]</sup>, 因此在本文中使用了多个内核的混合。

$$k(x^s, x^t) = \sum_{i=1}^G k_{\theta_i}(x^s, x^t) \quad (2)$$

式中,  $G$  为内核数量;  $k_{\theta_i}$  为带宽为  $\theta_i$  的高斯核 (Gaussian kernel)。在本文中, 使用了带宽分别为 4, 8, 16, 32 和 64 的 5 个高斯核的混合。

## 2 基于多层领域自适应的故障诊断

### 2.1 模型设计

针对变工况场景下的轴承故障诊断问题, 所设计的模型结构如图 3 所示。

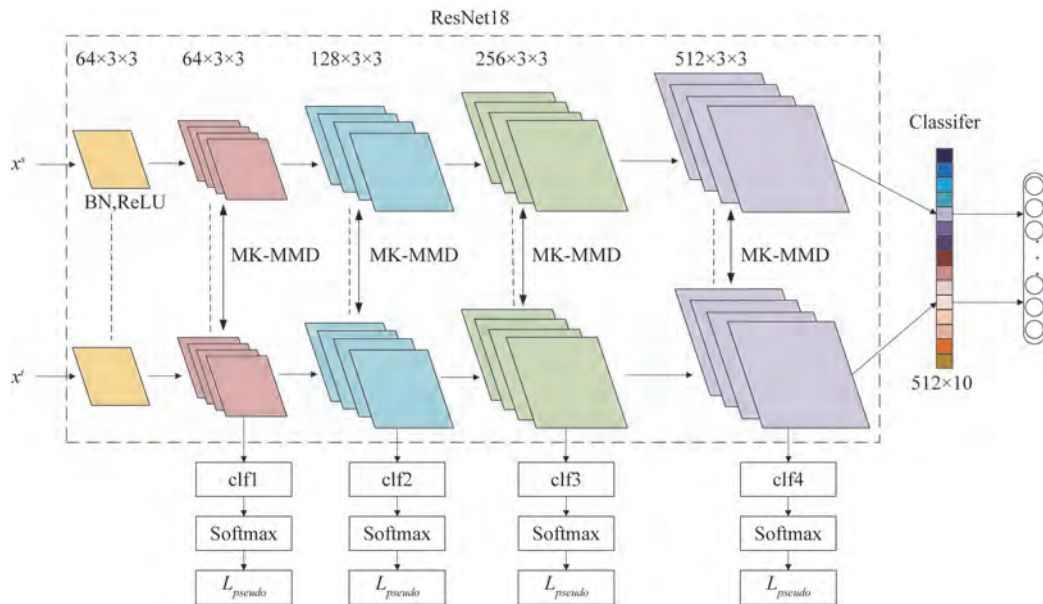


图 3 整体网络结构

首先, 如 1.2 节所述, 采用改进过的 ResNet18 作为特征提取器。来自  $D_s$  和  $D_t$  的数据进入同一个预训练好的特征提取器。为了能够提取到有效的可迁移特征, 需要充分减小两个域之间的特征分布差异, 因此采用 1.3 节中介绍的 MK-MMD 作为优化目标。虽然 MMD 距离已经在迁移学习方法中被广泛使用, 但大多数研究只是最小化网络最后一层的分布差异, 然而两个域之间的域偏移不仅仅会出现在最高层, 因此只最小化单个层间的差异不能有效地匹配  $D_s$  和  $D_t$  间的偏差。在本文中, 通过对每一个残差块提取的特征都计算 MK-MMD 距离进行多层适配, 即对多个残差块层进行领域自适应, 以匹配边缘分布差异。MK-MMD 的损失可定义为

$$L_{MMD} = \sum_{l \in N^l} \sum_{k \in K} MMD_k(U^l, V^l) \quad (3)$$

式中,  $N^l$  为计算 MK-MMD 的层数;  $K$  为高斯核的个数;  $U^l$  和  $V^l$  分别为第  $l$  个残差块提取的  $D_s$  和  $D_t$  的分布;  $MMD_k(U^l, V^l)$  为通过式 (2) 计算的 MK-MMD 距离,  $k$  为内核。

在两个工况不同的域中, 故障诊断的任务是相同的, 即分类的类别是相同的。由于  $D_s$  的标签是已知的, 可以最小化训练样本的分类误差, 采用交叉熵作为优化目标:

$$L_{clf} = -\frac{1}{M} \sum_{m=1}^M \tilde{y} \ln y \quad (4)$$

式中,  $M$  为样本数量;  $y$  为真实标签;  $\tilde{y}$  为分类器输出的标签。

通过多层领域适配,可以减小可迁移特征的分布差异,匹配边缘分布,但是  $D_i$  的无标签数据无法运用到训练中,因此引入伪标签来解决这个问题,匹配条件分布差异。伪标签的生成可以分为两步:标签的概率预测和伪标签转化<sup>[33]</sup>。在所提模型中,每个残差块后都有一个与之匹配的分类器(FC 层),经过分类器和 Softmax 层给出的标签的预测概率分布计算式为

$$\hat{y}_i = [P(y_i = 1 | x) \cdots P(y_i = C | x)]^T$$

$$P(y_i = c | x) = \frac{e^{W_c \cdot x}}{\sum_{c=1}^C e^{W_c \cdot x}} \quad (5)$$

式中,  $y_i$  为第  $i$  个样本;  $C$  为总的类别数;  $W$  为相应类别的权重。伪标签的转换可表示为

$$\hat{y}_i = [\hat{y}_j \cdots \hat{y}_j]$$

$$\hat{y}_j = \begin{cases} 1, & j = \arg\max_j \hat{y}_i \\ 0, & \text{otherwise} \end{cases} \quad (6)$$

式中,  $\hat{y}_i$  为第  $i$  个样本的伪标签,随着训练过程中不断优化,伪标签的准确性会逐渐提高,使得类间的条件分布距离减小。每个残差块的伪标签损失函数可通过交叉熵计算:

$$L_{\text{pseudo}} = -\frac{1}{N} \sum_{n=1}^N \hat{y} \ln \hat{y} \quad (7)$$

总的伪标签损失函数可计算如下:

$$L_p = \sum_{l \in N^l} L_{\text{pseudo}}(\hat{y}^l, \hat{y}^l) \quad (8)$$

由此可得,整体模型的损失函数可表示为

$$L_{\text{total}} = L_{\text{clf}} + \lambda_1 L_{\text{MMD}} + \lambda_2 L_p \quad (9)$$

式中,  $\lambda_1$  和  $\lambda_2$  为权衡系数。

## 2.2 诊断流程

所提出的故障诊断模型的整体流程图如图 4 所示。

首先,从实验台上采集原始振动信号,对数据进行预处理,每个样本取 2048 个采样点经过快速傅里叶变换(Fast Fourier Transform, FFT)后转化为频域信号,由于经过 FFT 变换后的信号是对称的,所以取变换后频域信号的前 1024 个点作为模型的输入。将数据划分为有标签的源域数据集和无标签的目标域数据集,并进一步划分为训练集和测试集。另外,为了加速模型训练的进程,使用源域数据对 ResNet18 进行预训练,保存效果最好的网络参数,在训练模型时直接读取。

其次,在模型训练阶段, batch 的大小设为 64,即每次从源域和目标域数据中各取 64 个样本输入到模型中进行训练。通过预训练好的 ResNet18 提取可迁移特征,减小源域和目标域的分布差异。在网络的顶层,应用 FC 层作为分类器,利用模型学习到的可迁移

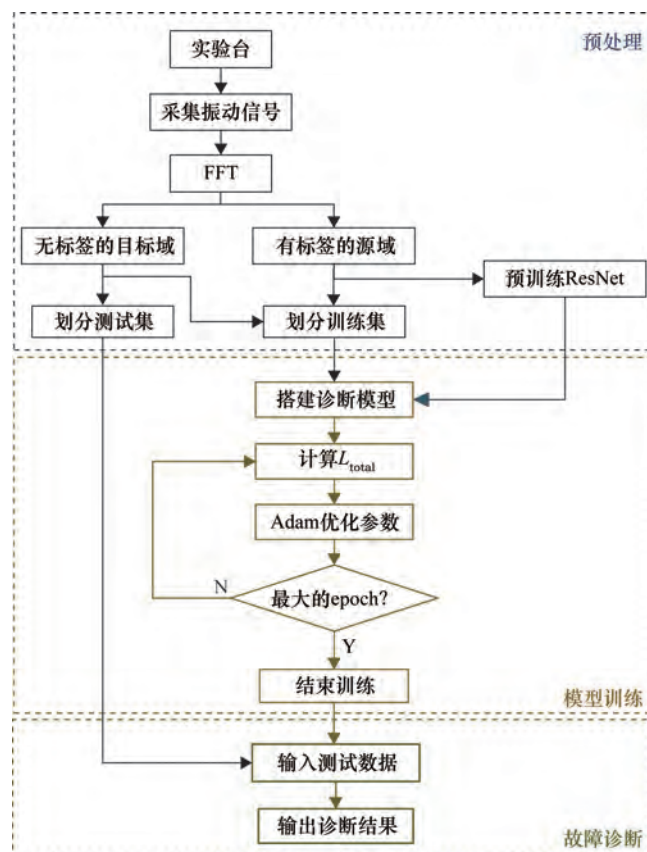


图 4 故障诊断流程图

特征,对轴承健康状态进行分类。引入 Adam 算法<sup>[34]</sup>对整体模型参数进行优化,加快模型收敛。

最后,当模型训练结束后,将目标域的测试集样本输入到模型中评估模型的能力,输出最终的故障诊断结果。

## 3 实验对比

### 3.1 数据集描述

研究轴承故障诊断方法需要使用真实、有效的轴承故障数据,以保障开展的实验和所验证研究方法的有效性和科学性。本文采用的是实验室自制轴承故障试验平台,如图 5 所示。该平台由驱动电机、梅花联轴器、健康轴承、测试轴承、测力器、加速度传感器和 NIPXle-1082 数据采集系统等装置组成,测试轴承型号为 6205-2RS SKF。在不同负载情况下试验台中的加速度传感器负责采集轴承的振动信号。

该实验平台在采样频率为 10 kHz 和不同的电机负载(0 kN, 1 kN, 2 kN, 3 kN)情况下进行了故障模拟实验,采集到了不同工况下不同故障类型和不同故障尺寸的轴承振动信号数据,轴承健康状态包括正常状态(Normal)、内圈故障(Inner Race Fault, IF)、外圈故障(Outer Race Fault, OF)和滚动体故障(Ball Fault, BF)4 种,轴承故障尺寸包括 0.3 mm, 0.4 mm 和 0.5 mm。




图5 滚动轴承振动数据采集试验平台

实验采用了4种不同电机负载的轴承故障数据。每种负载下包含了4种故障类型和3种故障尺寸,共10种健康状态,每种状态包括320个训练样本和160个测试样本,具体信息如表3所示。

表3 数据集设置

故障类型	故障尺寸/mm	训练样本数	测试样本数	标签	缩写
Normal	—	320	160	0	NO
IF	0.3	320	160	1	IF03
	0.4	320	160	2	IF04
	0.5	320	160	3	IF05
BF	0.3	320	160	4	BF03
	0.4	320	160	5	BF04
	0.5	320	160	6	BF05
OF	0.3	320	160	7	OF03
	0.4	320	160	8	OF04
	0.5	320	160	9	OF05

### 3.2 实验结果与对比分析

#### 3.2.1 不同参数设置的对比

不同的参数设置会对实验结果产生不同程度的影响。在实验中,学习率设置为0.0001, $\lambda_1$ 和 $\lambda_2$ 分别为1和0.1。首先,为了验证多层领域自适应的效果,设

计了仅匹配第一个残差块的特征和仅匹配最高层特征的两组对比实验。其次,为了验证MMD距离多个内核的效果,将仅使用一个带宽为4的内核作为一组对比。另外,为了验证频域信号作为输入的优势,将直接输入时域信号作为对比。具体的对比实验结果如表4所示。其中,迁移方向指不同负载间的迁移,如0-1是指负载为0 kN的数据作为源域,迁移到负载为1 kN的目标域。用 $MK(1,2,3,4,fc,p)$ 表示本文所提出的方法,MK代表多个内核,SK代表单个内核,数字代表特征匹配的残差块层,fc代表分类器,p代表伪标签。当只匹配单层的时候,只计算该层的MK-MMD距离和伪标签。 $T-MK(1,2,3,4,fc,p)$ 代表用时域信号作为输入,其余实验都采用经过FFT处理的频域信号作为输入。

由表4可以看出,所提模型在所有的设置中获得了最高的平均准确率,能够达到99%。通过第1组和第2组的对比可以看出,低层特征和高层特征都会导致一定程度的域偏移,只匹配高层的特征比只匹配低层的特征能获得更好的准确率,说明高层特征所导致的分布差异更为严重,并且当源域和目标域分布差异比较大的时候,如0 kN和3 kN之间的迁移,多层特征匹配的优势比较明显。通过第3组实验设置的对比可以看出,单个MMD核也可以取得不错的效果,但当两个域之间分布差异较大时,所提出的模型依然可以取得较大的提升,证明了多个内核混合的效果较好。第4组对比的设置中去掉了伪标签,从结果中可以看出,伪标签在一定程度上能够提升分类的效果。直接输入时域信号的对比结果表明,输入经过FFT处理的频域信号能够取得更高的诊断精度。

图6展示了不同参数设置的实验结果雷达图,从图中可以更直观地看出所提模型在所有参数设置中取得了整体的最好效果。

表4 不同参数实验对比结果

迁移方向	$MK(1,fc,p)/\%$	$MK(4,fc,p)/\%$	$SK(1,2,3,4,fc,p)/\%$	$MK(1,2,3,4,fc)/\%$	$T-MK(1,2,3,4,fc,p)/\%$	$MK(1,2,3,4,fc,p)/\%$
0-1	97.94	95.74	98.44	98.52	96.46	98.69
0-2	87.52	94.21	91.87	99.51	98.38	99.67
0-3	87.08	97.70	90.19	99.47	91.71	99.77
1-0	98.69	98.55	99.25	98.99	96.89	99.06
1-2	96.54	97.21	95.48	99.26	98.73	99.34
1-3	94.39	98.80	98.19	99.25	93.00	99.52
2-0	94.55	96.84	93.35	99.25	94.35	99.24
2-1	97.28	98.57	98.60	98.58	94.95	98.51
2-3	96.16	99.60	98.10	99.64	97.55	99.59
3-0	83.69	93.19	85.89	97.79	88.52	97.81
3-1	92.07	94.94	95.45	97.83	91.68	97.97
3-2	93.08	97.07	92.83	98.57	93.36	98.79
平均值	93.25	96.87	94.80	98.89	94.63	99.00






图6 不同参数实验对比雷达图

3.2.2 不同方法的对比

为了展示所提模型的效果,分别将其与迁移成分分析(Transfer Component Analysis,TCA)<sup>[26]</sup>、联合分布适配(Joint Distribution Adaptation,JDA)<sup>[35]</sup>、CORAL(Correlation Alignment)<sup>[36]</sup>和作为预训练模型的 ResNet18 相比较,对比实验结果如表 5 所示。

表 5 不同方法的实验对比结果

迁移方向	TCA/%	JDA/%	CORAL/%	ResNet18/%	MK(1,2,3,4,fc,p)/%
0-1	96.19	96.22	97.22	97.37	98.69
0-2	97.00	97.19	91.91	85.19	99.67
0-3	84.63	93.43	82.34	80.19	99.77
1-0	96.47	96.69	97.84	98.69	99.06
1-2	97.50	97.03	98.13	95.06	99.34
1-3	93.19	94.84	94.41	91.31	99.52
2-0	95.81	96.41	97.53	88.06	99.24
2-1	96.44	96.69	96.78	92.56	98.51
2-3	95.53	95.47	95.09	87.81	99.59
3-0	89.93	89.90	88.78	84.81	97.81
3-1	89.09	89.19	89.19	89.50	97.97
3-2	90.94	91.13	91.44	81.12	98.79
平均值	93.56	94.52	93.39	89.31	99.00

前 3 种方法为传统的迁移学习方法,当源域和目标域分布差异比较小的时候,如 0 kN 和 1 kN 间相互迁移时,3 种方法都能取得不错的效果。而当两个域之间分布差异较大时,迁移效果则会有明显下降,这说明工况变化的程度会影响数据分布的变化程度和所提取特征的泛化能力。而作为预训练模型的 ResNet18,

体现出了特征提取能力,而由于不具备迁移的能力,在不进行领域自适应的情况下难以直接对目标域进行诊断。

图 7 展示了不同方法的实验对比雷达图,可以看出,所提模型在 12 组迁移任务中都获得了最高的准确率,有较好的泛化能力。




图 7 不同方法实验对比雷达图

为了进一步确认所提模型是否提取到了可迁移特征,引入 t-SNE<sup>[37]</sup>对各个方法提取的特征进行降维可视化,结果如图 8 所示,展示的是 0 kN 为源域,3 kN 为目标域的迁移任务。可以看出,使用迁移学习的方法都能够在一定程度上匹配特征的分布差异,但是效果有限。相比之下,所提模型能够清晰地提取到可迁移特征,减小两个域之间的域偏移,将在源域学习到的知识有效地运用到了目标域中,实现高精度的故障诊断。

4 结束语

针对变工况场景下的轴承故障诊断问题,提出了基于多层领域自适应的故障诊断模型,可以有效提取到可迁移性特征,对轴承进行定性、定量的故障诊断。首先,采用预训练好的 ResNet18 作为特征提取器,并对每个残差块提取的特征都计算 MK-MMD 距离,匹配边缘分布差异。其次,将每个残差块提取的特征输入与之匹配的分类器中,再通过 Softmax 层计算预测概率分布,并转化为伪标签,匹配条件分布差异。最后,引入 Adam 优化器,对整体模型参数进行优化,加快模型训练,提高模型收敛速度。通过 12 组迁移任务的实验表明,本文所提出的方法通过同时匹配高层和低层

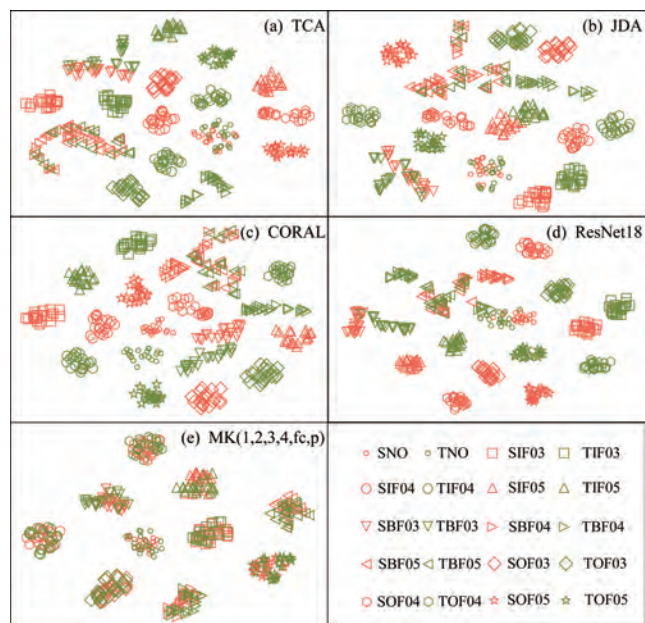


图 8 特征可视化

特征,能够有效减小域偏移,运用从源域数据集中学习到的知识对目标域数据进行有效的故障诊断,达到了较高的精度,并具有一定的泛化能力。

#### 参考文献:

- [1] 王建国,范业锐,张文兴,等.改进差分滤波器在轴承故障诊断中的应用研究[J].振动与冲击,2019,38(13):81-86.
- WANG J G, FAN Y R, ZHANG W X, et al. Application of improved difference filter in bearing fault diagnosis [J]. Journal of Vibration and Shock, 2019, 38(13): 81-86 (in Chinese).
- [2] 耿晓强,唐向红,陆见光.基于云加端的电机轴承故障诊断应用研究[J].振动与冲击,2019,38(9):223-230.
- GENG X Q, TANG X H, LU J G. Application of motor bearing fault diagnosis based on cloud and terminal [J]. Journal of Vibration and Shock, 2019, 38(9): 223-230 (in Chinese).
- [3] HOANG T D, KANG H J. Rolling element bearing fault diagnosis using convolutional neural network and vibration image [J]. Cognitive Systems Research, 2019, 53: 42-50.
- [4] PARK S, KIM S, CHOI J H. Gear fault diagnosis using transmission error and ensemble empirical mode decomposition [J]. Mechanical Systems and Signal Processing, 2018, 108: 262-275.
- [5] YAN R Q, GAO R X, CHEN X F. Wavelets for fault diagnosis of rotary machines: a review with applications [J]. Signal Processing, 2014, 96: 1-15.
- [6] YU X A, DONG F, DING E J, et al. Rolling bearing fault diagnosis using modified LFDA and EMD with sensitive feature selection [J]. IEEE Access, 2018, 6: 3715-3730.
- [7] WANG C, GAN M, ZHU C A. A supervised sparsity-based wavelet feature for bearing fault diagnosis [J]. Journal of Intelligent Manufacturing, 2019, 30(1): 229-239.
- [8] SHEN C Q, WANG D, KONG F R, et al. Fault diagnosis of rotating machinery based on the statistical parameters of wavelet packet paving and a generic support vector regressive classifier [J]. Measurement, 2013, 46(4): 1551-1564.
- [9] ZHANG X Y, LIANG Y T, ZHOU J Z, et al. A novel bearing fault diagnosis model integrated permutation entropy, ensemble empirical mode decomposition and optimized SVM [J]. Measurement, 2015, 69: 164-179.
- [10] MAO W T, HE L, YAN Y J, et al. Online sequential prediction of bearings imbalanced fault diagnosis by extreme learning machine [J]. Mechanical Systems and Signal Processing, 2017, 83: 450-473.
- [11] HINTON G E, SALAKHUTDINOV R R. Reducing the dimensionality of data with neural networks [J]. Science, 2006, 313(5786): 504-507.
- [12] ZHANG S H, WANG M, LI W H, et al. Deep learning with emerging new labels for fault diagnosis [J]. IEEE Access, 2019, 7: 6279-6287.
- [13] DONG S Z, ZHANG Z F, WEN G, et al. Design and application of unsupervised convolutional neural networks integrated with deep belief networks for mechanical fault diagnosis [C]//2017 Prognostics and System Health Management Conference (PHM-Harbin). 2017: 1-7.
- [14] SHAO S Y, WANG P, YAN R Q. Generative adversarial networks for data augmentation in machine fault diagnosis [J]. Computers in Industry, 2019, 106: 85-93.
- [15] TAN C Q, SUN F C, KONG T, et al. A survey on deep transfer learning [M]//Artificial Neural Networks and Machine Learning - ICANN 2018. Cham: Springer International Publishing, 2018: 270-279.
- [16] BEN-DAVID S, BLITZER J, CRAMMER K, et al. A theory of learning from different domains [J]. Machine Learning, 2010, 79(1/2): 151-175.
- [17] WEN L, GAO L A, LI X Y. A new deep transfer learning based on sparse auto-encoder for fault diagnosis [J]. IEEE Transactions on Systems, Man, and Cybernetics: Systems, 2019, 49(1): 136-144.
- [18] ZHANG B, LI W, LI X L, et al. Intelligent fault diagnosis under varying working conditions based on domain adaptive convolutional neural networks [J]. IEEE Access, 2018, 6: 66367-66384.
- [19] GUO L A, LEI Y G, XING S B, et al. Deep convolutional transfer learning network: a new method for intelligent fault diagnosis of machines with unlabeled data [J]. IEEE Transactions on Industrial Electronics, 2019, 66(9): 7316-7325.
- [20] LI X A, ZHANG W, DING Q A. Cross-domain fault diagnosis of rolling element bearings using deep generative neural networks [J]. IEEE Transactions on Industrial Electronics,



- 2019,66(7):5525–5534.
- [21] YOSINSKI J, CLUNE J, BENGIO Y, et al. How transferable are features in deep neural networks? [C]//Advances in Neural Information Processing Systems. 2014:3320–3328.
- [22] ALJUNDI R, TUYTELAARS T. Lightweight unsupervised domain adaptation by convolutional filter reconstruction [C]//Computer Vision—ECCV 2016 Workshops. 2016:508–515. DOI:10.1007/978-3-319-49409-8\_43.
- [23] ZHANG L, ZUO W M, ZHANG D. LSDT: latent sparse domain transfer learning for visual adaptation [J]. IEEE Transactions on Image Processing, 2016, 25(3):1177–1191.
- [24] DENG J, XU X Z, ZHANG Z X, et al. Universum autoencoder-based domain adaptation for speech emotion recognition [J]. IEEE Signal Processing Letters, 2017, 24(4):500–504.
- [25] LI W, DUAN L X, XU D, et al. Learning with augmented features for supervised and semi-supervised heterogeneous domain adaptation [J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2014, 36(6):1134–1148.
- [26] PAN S J, TSANG I W, KWOK J T, et al. Domain adaptation via transfer component analysis [J]. IEEE Transactions on Neural Networks, 2011, 22(2):199–210.
- [27] LONG M S, WANG J M, DING G G, et al. Adaptation regularization: a general framework for transfer learning [J]. IEEE Transactions on Knowledge and Data Engineering, 2014, 26(5):1076–1089.
- [28] HE K M, ZHANG X Y, REN S Q, et al. Deep residual learning for image recognition [C]//2016 IEEE Conference on Computer Vision and Pattern Recognition. 2016:770–778.
- [29] DENG J, DONG W, SOCHER R, et al. ImageNet: a large-scale hierarchical image database [C]//2009 IEEE Conference on Computer Vision and Pattern Recognition. 2009:248–255.
- [30] SEJDINOVIC D, SRIPERUMBUDUR B, GRETTON A, et al. Equivalence of distance-based and RKHS-based statistics in hypothesis testing [J]. The Annals of Statistics, 2013, 41(5):2263–2291. DOI:10.1214/13-aos1140.
- [31] LI X A, ZHANG W, DING Q A, et al. Multi-Layer domain adaptation method for rolling bearing fault diagnosis [J]. Signal Processing, 2019, 157:180–197.
- [32] LONG M S, CAO Y, WANG J M, et al. Learning transferable features with deep adaptation networks [C]//Proceedings of 32nd International Conference on Machine Learning. 2015, 37:97–105.
- [33] YANG B, LEI Y G, JIA F, et al. An intelligent fault diagnosis approach based on transfer learning from laboratory bearings to locomotive bearings [J]. Mechanical Systems and Signal Processing, 2019, 122:692–706.
- [34] KINGMA D, BA J. Adam: a method for stochastic optimization [J]. arXiv, Preprint, arXiv:1412.6980, 2014.
- [35] LONG M S, WANG J M, DING G G, et al. Transfer feature learning with joint distribution adaptation [C]//2013 IEEE International Conference on Computer Vision. 2013:2200–2207.
- [36] WANG X X, HE H B, LI L S. A hierarchical deep domain adaptation approach for fault diagnosis of power plant thermal system [J]. IEEE Transactions on Industrial Informatics, 2019, 15(9):5139–5148.
- [37] VAN DER MAATEN L, HINTON G. Visualizing data using t-SNE [J]. Journal of Machine Learning Research, 2008, 9:2579–2625.

□

## 征稿启事

《测控技术》于1982年创刊,月刊,国内外公开发行,是由中国航空工业集团有限公司主管,北京长城航空测控技术研究所主办的学术期刊。《测控技术》为中国科技核心期刊,被中国核心期刊(遴选)数据库、中国学术期刊综合评价数据库、中国期刊全文数据库、中文科技期刊数据库、中国学术期刊(光盘版)全文收录期刊、中国科技期刊文摘数据库英文版入库期刊、日本科学技术振兴机构数据库(JST)等收录。

关注测控技术热点,崇尚科研创新,倡导科学严谨,注重学术质量。

**栏目全新改版,诚邀您投稿!**

常设栏目:

《综述》《智能感知与仪器仪表》  
《数据采集与处理》《试验与测试》  
《计算机与控制系统》

不定期栏目:

《大家论坛》《模式识别(先进算法)与人工智能》  
《机器人技术与应用》《网络技术与应用》  
《虚拟现实技术》《飞行器控制》  
《兵器科学技术与运用》《理论专栏》

联系电话:010-65667497,65665486,65665345

通信地址:北京亦庄经济技术开发区经海二路29号院9号楼

投稿网址:www.mct.com.cn

邮政编码:101111