

# 基于 SimAM 模块与 ResNet34 网络的 混合缺陷检测模型<sup>\*</sup>

朱传军<sup>1</sup>, 刘荣光<sup>1</sup>, 成佳闻<sup>2</sup>, 梁泽启<sup>1</sup>, 王林琳<sup>1</sup>

( 1 湖北工业大学机械工程学院, 武汉 430068;

2 华中科技大学数字制造装备与技术国家重点实验室, 武汉 430074)

**摘要:** 针对现表面缺陷检测方法准确率低、需要进行复杂的特征设计、特征泛化性不强、参数多和识别速度慢等问题, 在残差网络卷积模块之后采用自适应全局平均池化, 有效降低了分类器的特征维度, 减少了信息冗余。将无参注意力机制模块 SimAM 与 ResNet34 网络相结合用于缺陷检测, 并对不同组合结构进行研究, 提出 ResNet34\_s\_e 和 ResNet34\_m 这 2 种混合网络模型, 该 2 种混合网络模型均不增加原始网络参数量。在东北大学钢铁缺陷标准数据集上进行实验, 对数据集使用镜像、翻转等数据增广策略, 防止模型过拟合。通过对比发现, ResNet34\_s\_e 混合网络模型能够有效加快训练过程中误差的下降趋势, 提升分类准确率。最后在武汉某制造车间采集的冲压件缺陷数据集上验证该混合网络模型的泛化性能。测试集正确率由 88.34 % 提高到了 89.19 %, 有效提升了车间冲压件缺陷检测准确率。

**关键词:** 缺陷识别; 残差网络; 数据增广; SimAM 模块

中图分类号: TG245; TP183; TP391.41 文献标志码: A 文章编号: 1671-3133( 2023) 02-0001-09

DOI: 10.16731/j.cnki.1671-3133.2023.02.001

## Hybrid defect detection model based on SimAM module and ResNet34 network

ZHU Chuanjun<sup>1</sup>, LIU Rongguang<sup>1</sup>, CHENG Jiawen<sup>2</sup>, LIANG Zeqi<sup>1</sup>, WANG Linlin<sup>1</sup>

( 1 School of Mechanical Engineering, Hubei University of Technology, Wuhan 430068, China;

2 State Key Laboratory of Digital Manufacturing Equipment and Technology, Huazhong University of  
Science and Technology, Wuhan 430074, China)

**Abstract:** Aiming at the problems of low accuracy, the need for complex feature design, weak feature generalization, many parameters and slow recognition speed of the current surface defect detection method, adaptive global averaging pooling was adopted after the convolutional module of the residual network, which effectively reduced the characteristic dimension of the classifier and information redundancy. The SimAM non-parameter attention mechanism module was combined with the ResNet34 network for defect detection, and different combination structures were studied, and two hybrid models of ResNet34\_s\_e and ResNet34\_m were proposed, and neither of these hybrid models increased the amount of original network parameters. Experiments were conducted on the steel defect standard dataset of Northeastern University, and data augmentation strategies such as mirroring and flipping were used to prevent the model from overfitting. Through comparison, it is found that the ResNet34\_s\_e hybrid model can effectively accelerate the error reduction and improve the classification accuracy. Finally, the generalization performance of the hybrid model is verified on the data set of stamping parts defects collected in a manufacturing workshop in Wuhan. The accuracy rate of the test set is increased from 88.34 % to 89.19 %, which effectively improves the accuracy of defect detection of stamping parts in the workshop.

**Keywords:** defect recognition; residual network; data enhancement; SimAM module

<sup>\*</sup> 国家自然科学基金国际(地区)合作与交流项目(51861165202); 广东省重点领域研发计划项目(2019B090921001); 湖北工业大学博士科研启动基金项目(BSQD2019010)

## 0 引言

表面缺陷是一个至关重要的问题,据世界质量管理协会报道,超过85%的缺陷发生在表面上,影响最终产品的外观和物理性能。产品表面缺陷通常是指由于物理、化学性质改变或者材料分布不均匀而造成的局部异常。传统的表面缺陷识别依赖人工完成,主观因素较强,检测效率不高,且存在易疲劳、稳定性差等问题,而在当前生产过程中,高速、多样以及实现自动化才是车间追求的目标<sup>[1]</sup>。

随着大数据、物联网等技术的发展,基于机器视觉的表面缺陷识别技术在学术界开始得到广泛关注<sup>[2]</sup>。这种缺陷识别方法利用图像采集技术收集缺陷图像,并通过机器学习算法给出相应的缺陷类别。与人工识别相比,这种缺陷识别方法不但成本低,而且正确率高。

传统的机器学习模型有以贝叶斯定理为基础的贝叶斯分类器(Bayes classifier)<sup>[3]</sup>,该算法较为简单,易于理解;有支持向量机(Support Vector Machine, SVM)<sup>[4]</sup>,其作为经典的二分类算法,核心思想是找到正确划分训练集且距离最大的分离超平面;还有来源于生物学启发的人工神经网络(Artificial Neural Network, ANN)<sup>[5]</sup>,该模型对人工智能的发展起到至关重要的作用。这些模型在解决相关问题上确实能够取得良好的效果,但提取设计特征过程复杂,不利于广泛应用。

随着深度学习技术的发展以及其在图像识别领域所取得的巨大成功<sup>[6-7]</sup>,深度学习算法对表面缺陷的准确识别逐渐受到广泛关注。PARK等人<sup>[1]</sup>提出卷积神经网络(Convolutional Neural Networks, CNN)模型在缺陷图像上具有强大的识别能力。MASCI等人<sup>[8]</sup>在CNN模型中应用最大池化层,实现了钢铁表面缺陷数据集的准确识别。GAO等人<sup>[9]</sup>提出了一种半监督的CNN模型,通过引入伪标记机制,使得无标记样本可以有效参与模型训练,从而降低样本标记成本,加速模型部署。何星辰等人<sup>[10]</sup>提出一种抗年龄干扰的人脸识别方法,从而克服了年龄干扰的问题。仰梓淮等人<sup>[11]</sup>提出四叉树分裂与支持向量机相结合的电路板缺陷检测方法,既保证了精度又实现了良好的定位效果。HUANG等人<sup>[12]</sup>提出一种改进的注意力机制模块和隐马尔可夫模型(Hidden Markov Model, HMM)相结合的自动睡眠分类模型,提高了模型的分类精度。

卷积神经网络在分类任务中超过了传统机器学

习算法,可以实现端到端的自动化特征提取,从而有效避免复杂的特征设计和选择过程。在梯度下降和反向传播策略下,完成图像分类和缺陷检测任务。从CNN模型本身来讲,现有方法大多只是对模型做一些简单的调整,识别准确率仍有进一步提升的空间。与普通的图像识别问题相比,缺陷识别问题由于图像更加复杂,缺陷主体与背景之间区分度较低,导致模型更难训练。

本文围绕2种缺陷数据集对残差网络模型展开深入研究。将无参注意力机制模块SimAM与残差网络相结合,并进行相关实验,验证了ResNet34\_s\_e混合网络模型对缺陷识别效果的提升,从而实现工件表面缺陷的准确识别,为产品质量提供了可靠地保障,同时有力地促进了车间自动化加工过程。

## 1 模型方法与原理

### 1.1 残差网络

ResNet网络架构由HE等人<sup>[13]</sup>提出,该网络架构通过不断堆叠残差模块构成。在不断加深神经网络的同时,网络可以进行更加复杂的特征提取,理论上在分类和检测任务上可以取得更高的准确率。但深层的网络模型也变得更加复杂,不一定能带来分类准确率的提升,也会出现网络退化。ResNet网络架构通过在残差块中加入快速通道来克服网络退化现象。通过这种结构保证了算法的最优解“至少不会变差”。ResNet网络架构解决了深层的卷积神经网络无法训练的问题<sup>[14]</sup>,该网络架构在堆叠层数的同时不会增加模型的复杂度。残差块使得很深层的网络更加容易训练,不管网络有多深,有跨层数据通路连接的存在,其始终能够包含小型网络,因为跳转连接的存在,所以会先将下层的小型网络训练好,再去训练更深层的网络,甚至可以训练1000层的网络,通过层间的残余连接更快地向前传播。残差网络可以在不学习整个输出的情况下学习以前的网络输出,所以ResNet也称为剩余网络。在图像分类方面,ResNet也优于其他神经网络。由于浅层网络提取特征能力有限,更深层的网络迭代速度也会变慢,不利于快速检测,因此本文选择34层网络架构进行研究。

ResNet34网络架构如图1所示,该架构由33个卷积层(Conv)和1个全连接层(FC)构成。输入图像首先经过第一个卷积层,卷积核大小为 $7 \times 7$ ,卷积核个数为64,步长为2,卷积的填充为3,然后进行最大池化(pool),池化核大小为 $3 \times 3$ ,步长为2。从第2个卷积

层开始有连续几个相同的残差模块单元,这些单元的通道数一样,将几个拥有多个残差模块单元的结构称为 layer。ResNet34 共有 4 个 layer,其中:layer1 含有 3 个残差模块,同时没有使用卷积进行下采样,每个残差模块都是由卷积核大小为  $3 \times 3$ 、步长为 1、填充为 1 且卷积核个数为 64 的卷积构成;layer2 含有 4 个残差模块;layer3 含有 6 个残差模块;layer4 含有 3 个残差模块。图 1 中,实线连接的部分表示输入的通道数与输出的通道数是相同的,通过残差连接可以直接相加,layer2、layer3、layer4 与 layer1 的区别在于第一个残差模块进行了下采样,即图 1 中的虚线箭头残差结构,残差模块的第一个卷积层(Conv1)进行了步长为 2、填

充为 1 且卷积核大小为  $3 \times 3$  的卷积,同时把通道数目增加为原来的 2 倍;残差模块的第 2 个卷积层(Conv2)进行了步长为 1、填充为 1 且卷积核大小为  $3 \times 3$  的卷积,通道数目保持不变。为了使残差旁路部分能和卷积层 Conv1、Conv2 的输出结果相匹配,下采样层使用的是卷积核大小为  $1 \times 1$ 、卷积步长为 2 的卷积,同时使通道变成原来的 2 倍。layer2、layer3 和 layer4 从第 2 个残差模块到最后一个残差模块没有进行下采样。layer1~layer4 之后对输出的张量进行全局平均池化(Avg pool),输出 512 维的张量。最后进行全连接层(FC)的转换,输出类别的分类,使用 Softmax 函数输出每个分类的概率。




图 1 ResNet34 网络架构

## 1.2 SimAM 模块

注意力机制模块 SimAM( 简称为 SimAM 模块)<sup>[15]</sup> 是一种简单且非常有效的轻量型注意力模块,与以往提出的通道注意力机制、空间注意力有所不同,SimAM 模块由于没有额外的参数,加入网络不会增加网络的复杂度,是一种用特征图推导出的 3D 注意力机制。该模块是基于神经科学理论优化能量函数,并用能量函数推导出的一种快速解析解,即将能量函数用于计算注意力机制的权值。其定义的能量函数  $e_i(\cdot)$  为:

$$e_i(w_i, b_i, y, x_i) = (y_i - \hat{t})^2 + \frac{1}{M-1} \sum_{i=1}^{M-1} (y_0 - \hat{x}_i)^2 \quad (1)$$

其中:

$$\begin{cases} \hat{t} = w_i t + b_i \\ \hat{x}_i = w_i x_i + b_i \end{cases}$$

式中:  $t$  和  $x_i$  分别为输入特征张量  $X$  的目标神经元和其他神经元,  $X \in R^{C \times H \times W}$ ,  $C$ 、 $H$ 、 $W$  分别为特征张量的通

道数、高度和宽度;  $i$  为某个通道上的神经元索引;  $M$  为某个通道上所有神经元的个数,  $M = H \times W$ ;  $w_i$  和  $b_i$  分别为目标神经元变换时的权重和偏置;  $y$ 、 $y_i$  和  $y_0$  均为标量数量,其中  $y_i$  与  $y_0$  为不同的值,本文引入二进制标签代替  $y_i$  和  $y_0$ ,其中  $y_i = 1$ 、 $y_0 = -1$ 。

最小化式(1)相当于训练同一通道内神经元与其他神经元之间的线性可分性。使用二值标签,并添加正则项之后的能量函数可转化为:

$$e_i(w_i, b_i, y, x_i) = \frac{1}{M-1} \sum_{i=1}^{M-1} [-1 - (w_i x_i + b_i)]^2 + [1 - (w_i t + b_i)]^2 + \lambda w_i^2 \quad (2)$$

式中:  $\lambda$  为正则化系数;  $w_i$  为第  $i$  个神经元变换时的权重。

式(2)的解析解为:

$$\begin{cases} w_i = -\frac{2(t-u_i)}{(t-u_i)^2 + 2\sigma_i^2 + 2\lambda} \\ b_i = -\frac{1}{2}(t+u_i)w_i \end{cases}$$

式中:  $u_t$  和  $\sigma_t^2$  均为中间变量。

其中:

$$\begin{cases} u_t = \frac{1}{M-1} \sum_{i=1}^{M-1} x_i \\ \sigma_t^2 = \frac{1}{M-1} \sum_{i=1}^{M-1} (x_i - u_t)^2 \end{cases}$$

将  $w_t$  和  $b_t$  代入式(2), 可求出最小能量  $e_t^*$ , 即:

$$e_t^* = \frac{4(\hat{\sigma}^2 + \lambda)}{(t - \hat{u})^2 + 2\hat{\sigma}^2 + 2\lambda}$$

将  $u_t$  和  $\sigma_t^2$  由其均值  $\hat{u} = \frac{1}{M} \sum_{i=1}^M x_i$  和方差  $\hat{\sigma}^2 =$

$\frac{1}{M} \sum_{i=1}^M (x_i - \hat{u})^2$  替代。能量越低, 目标神经元  $t$  与周围神经元的区别越大, 也越重要。神经元的重要性可以通过  $1/e_t^*$  得到, 然后通过式(3)对特征进行增强处理, 得到增强后的特征张量  $\tilde{X}$ , 即:

$$\tilde{X} = \text{sigmoid}\left(\frac{1}{E}\right) \odot X \quad (3)$$

式中:  $X$  为输入的特征张量;  $E$  为  $e_t^*$  在所有通道和空间维度的总和;  $\odot$  为 Hadamard 乘积。

式(3)中, 添加 sigmoid 函数来限制  $E$  的过大值, sigmoid 函数不会影响每个神经元的相对重要性。

图2所示为一个 SimAM 模块, 其可以被看作是一个计算单元, 旨在增强卷积神经网络中的特征表达能力, 可以将任何中间特征张量作为输入, 并转换输出具有相同大小、同时具有增强表征作用的特征张量, 图2中  $X$  为输入的特征张量。该模块最大的优点是基于所定义的能量函数选择。




图2 SimAM 模块

## 2 实验设计与结果分析

### 2.1 实验设计

本文实验首先在东北大学钢铁缺陷数据集上进行, 然后在武汉某制造车间采集的冲压件缺陷数据集上验证模型的泛化能力。

东北大学钢铁缺陷数据集包含 6 种缺陷类别, 分别为龟裂、夹杂、点蚀、斑点、轧痕和划痕。每种缺陷类别的图像数量均为 300 张, 图像大小为  $200 \times 200$  像素点 (Pixels), 图3所示为东北大学钢铁 6 种缺陷图像示例。




图3 东北大学钢铁 6 种缺陷图像示例

在武汉某制造车间采集的冲压件缺陷数据集包含 8 种常见缺陷类别, 分别为点坑 (65 张)、断裂 (81 张)、划痕 (243 张)、孔洞 (149 张)、拉伤 (179 张)、麻点 (93 张)、毛刺 (58 张) 和起皱 (154 张), 图像大小为  $376 \times 376$  像素点 (Pixels), 图4所示为冲压件 8 种缺陷图像示例。




图4 冲压件 8 种缺陷图像示例

在本文实验过程中, 将 2 个缺陷数据集均分为训

练集、验证集和测试集三部分,图像数量比例为 6:2:2,用测试集正确率作为评价模型指标。

实验平台由某云服务器提供,其硬件为 CPU4 核 Intel(R) Xeon(R) CPU E5-2620 v4 @ 2.10 GHz 内存 16 GB, GPU TITAN Xp\* 1 显存 12 GB,所有模型单独运行 10 次取平均;镜像采用 PyTorch1.10.0, Cuda 11.3, Python3.8 深度学习框架, Numpy、Matplotlib 和 OpenCV 等深度学习库;模型中每次训练的批次 (batchsize) 大小为 32,训练 50 个 epoch;采用带动量的 SGD 优化器,动量为 0.9,学习率为 0.001;损失函数为交叉熵损失函数,反向传播更新模型的参数。

## 2.2 数据增广

数据增广是深度学习数据预处理过程中一种常用的扩充数据方法。由于现实条件制约,采集的数据样本数量有时较少,达不到深度学习的条件,或者无法包括所有情况;因此需要通过数据增广手段来扩充图像数量,降低数据采集成本。尤其是对于缺陷图像,在工业生产过程中更加难以采集。通过数据增广使有限的数据产生了更多变种,原始数据有了更多的表示,在一定程度上提高了分类准确率;因此,在小样本数据集输入网络模型训练之前,可以通过数据增广方法来扩大样本集数量,比较经典的图像数据库扩充方法有裁剪、镜像、色彩渲染、缩放、旋转、增加椒盐噪声或高斯噪声等图像变换技术,经过这些图像变换技术可获得更多的训练图像。

本文选用旋转、水平镜像和竖直镜像 3 种图像变换技术对缺陷数据集进行数据增广。图 5 所示为东北大学 6 种钢铁缺陷类别中的钢铁点蚀缺陷数据增广效果图,图 6 所示为武汉某制造车间 8 种冲压件缺陷类别中的冲压件划痕缺陷数据增广效果图。




图 5 钢铁点蚀缺陷数据增广效果图




图 6 冲压件划痕缺陷数据增广效果图

本文只对占比为 60% 的训练集进行数据增广,在验证集和测试集中未使用数据增广。本文通过 3 种数据增广方法,使原本用于训练阶段的数据集(训练集)分别扩充为原来数据集的 3 倍。

## 2.3 实验结果

以 ResNet34 网络为基准网络进行改进,实验对比了在引入 SimAM 模块前后训练误差损失及验证集正确率变化情况。在 ResNet34 网络模型中,加入 SimAM 模块的位置分别在 layer1 ~ layer4 的前、后和中间位置,得到的模型如下。

- 1) ResNet34 为原始网络模型。
- 2) ResNet34\_m 为在 layer1、layer2、layer3 和 layer4 中间位置各加入 1 个 SimAM 模块的混合网络模型。
- 3) ResNet34\_s\_e 为在 layer1 之前和 layer4 之后各加入 1 个 SimAM 模块的混合网络模型。

定义 ResNet34\_plus、ResNet34\_m\_plus 和 ResNet34\_s\_e\_plus 为上述 3 种网络模型使用数据增广后的结果。

### 2.3.1 钢铁缺陷数据集实验结果

图 7 所示为 3 种网络模型训练集误差与验证集正确率变化曲线。图 7a) 为 ResNet34 网络模型、ResNet34\_m 混合网络模型和 ResNet34\_s\_e 混合网络模型分别在东北大学钢铁缺陷数据集训练集上误差损失随迭代次数变化曲线,由图 7a) 可知 ResNet34\_s\_e 混合网络模型在训练过程中,训练集误差最低,ResNet34\_m 混合网络模型延缓了误差下降趋势,最终误差损失较大;图 7b) 为 ResNet34 原网络模型、ResNet34\_m 混合网络模型和 ResNet34\_s\_e 混合网络

模型这3种网络模型验证集正确率随迭代次数变化曲线。通过对比发现,ResNet34\_s\_e混合网络模型在验证过程中验证集正确率最高。




图7 3种网络模型训练集误差与验证集正确率变化曲线

ResNet34网络模型数据增广前后对比图如图8所示,ResNet34\_m混合网络模型数据增广前后对比图如图9所示,ResNet34\_s\_e混合网络模型数据增广前后对比图如图10所示。图8~图10中数据增广后用\_plus表示。

图8a)、图9a)和图10a)分别为3种网络模型使用数据增广前后训练集误差随迭代次数变化曲线,图8b)、图9b)和图10b)分别为3种网络模型验证集正确率随迭代次数变化曲线。可以看出,使用数据增广对训练集进行扩充,在3种网络模型中均加快了训练过程中的误差下降趋势,提高了验证集正确率。

### 2.3.2 冲压件缺陷数据集实验结果

ResNet34网络模型、ResNet34\_m混合网络模型和ResNet34\_s\_e混合网络模型这3种网络模型训练集误差与验证集正确率变化曲线如图11所示。图11a)为ResNet34网络模型、ResNet34\_m混合网络模型和ResNet34\_s\_e混合网络模型这3种网络模型在冲压件缺陷




图8 ResNet34网络模型数据增广前后对比图




图9 ResNet34\_m混合网络模型数据增广前后对比图




图 10 ResNet34\_s\_e 混合网络模型数据增广前后对比图




图 11 3 种网络模型训练集误差与验证集正确率变化曲线

数据集训练集上误差损失随迭代次数变化曲线, 同样 ResNet34\_s\_e 混合网络模型在训练过程中, 训练集误差最低, ResNet34\_m 混合网络模型延缓了误差下降趋势, 最终误差损失较大; 图 11b) 为 ResNet34 网络模型、ResNet34\_m 混合网络模型和 ResNet34\_s\_e 混合网络模型这 3 种网络模型的验证集正确率随迭代次数变化曲线, 通过对比发现, ResNet34\_s\_e 混合网络模型在验证过程中验证集正确率较高。

ResNet34 网络模型数据增广前后对比图如图 12 所示, ResNet34\_m 混合网络模型数据增广前后对比图如图 13 所示, ResNet34\_s\_e 混合网络模型数据增广前后对比图如图 14 所示。

图 12a)、图 13a) 和图 14a) 分别为 3 种网络模型使用数据增广前后训练集误差随迭代次数变化曲线, 图 12b)、图 13b)、图 14b) 分别为 3 种网络模型验证集正确率随迭代次数变化曲线。可以看出, 使用数据增广在 3 种网络模型中同样加快了训练过程误差损失下降趋势, 相同的迭代次数最终误差也较低, 提高了验证集正确率。且由于原采集的冲压数据样本较少, 使用数据增广对冲压件缺陷训练集进行扩充后, 对验证集正确率提升效果显著。

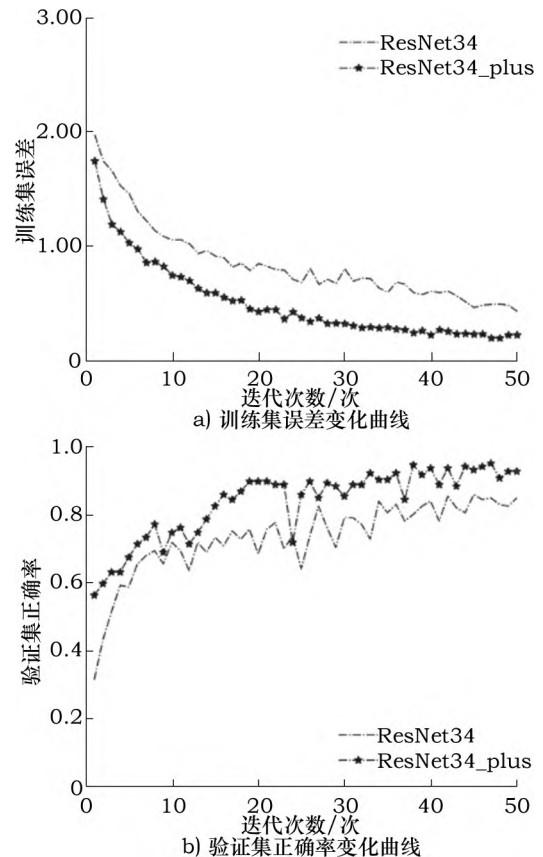


图 12 ResNet34 网络模型数据增广前后对比图




图13 ResNet34\_m混合网络模型数据增广前后对比图

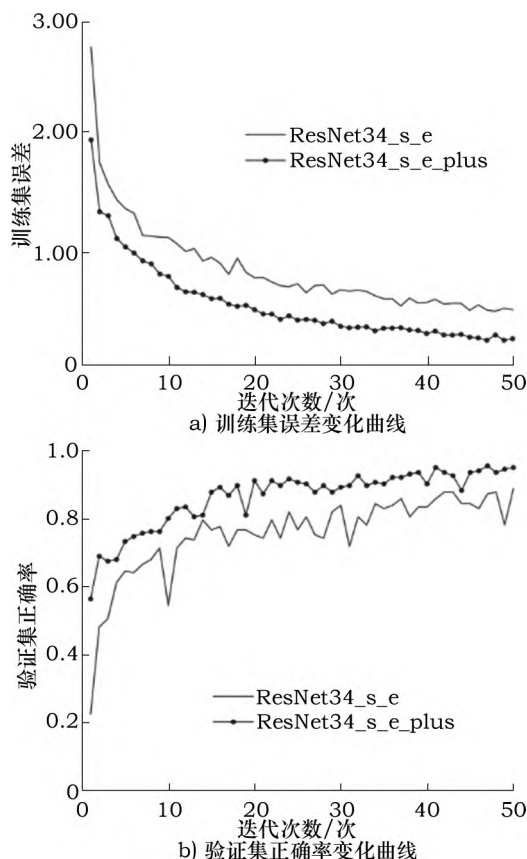


图14 ResNet34\_s\_e混合网络模型数据增广前后对比图

### 2.3.3 测试集正确率

表1所示为数据增广前后3种网络模型测试集正确率之间的对比,即2种缺陷数据集测试集在ResNet34网络模型、ResNet34\_m混合网络模型和ResNet34\_s\_e混合网络模型这3种网络模型上的分类正确率结果,以及在使用数据增广策略扩充数据后测试集在3种网络模型下的正确率结果。

表1 数据增广前后3种网络模型测试集正确率之间的对比

数据集	网络模型	测试集正确率对比结果/%	
		数据增广前	数据增广后
钢铁缺陷数据集	ResNet34	94.61	96.72
	ResNet34_m	94.42	96.09
	ResNet34_s_e	95.35	96.83
冲压件缺陷数据集	ResNet34	78.18	88.34
	ResNet34_m	74.56	86.96
	ResNet34_s_e	79.15	89.19

实验结果表明,ResNet34\_s\_e混合网络模型相比于原始ResNet34网络模型,在2种缺陷数据集上测试集正确率最高,能有效提高分类精度。而ResNet34\_m混合网络模型没有提升,甚至在2种缺陷数据集中,降低了测试集正确率即降低了识别的准确率。数据增广对2种缺陷数据集均有提升,由于冲压缺陷数据集样本较少,对冲压件缺陷数据集提升效果更大,因此数据增广可以有效解决小样本问题。

## 3 结语

本文主要基于深度学习的方法先后在东北大学钢铁缺陷数据集和武汉某制造车间采集的冲压件缺陷数据集上展开研究。以ResNet34网络模型作为基准模型,在网络卷积层后使用全局平均池化进行降维,消除了冗余特征。在数据预处理阶段使用数据增广策略扩充数据。加入SimAM模块进行改进,并对加入网络结构的位置进行研究,提出了ResNet34\_m、ResNet34\_s\_e这2种混合网络模型,通过实验对比发现ResNet34\_s\_e混合网络模型能够加快训练过程中误差的下降趋势并提升样本正确率,在钢铁缺陷和冲压件缺陷识别问题中均具有良好的适用性,取得了良好的识别效果。为工艺参数的优化以及生产调控管理的决策提供了准确的参考依据,可以有效确保产品出厂质量,避免因产品表面缺陷漏检误检而造成的不必要损失。

本文虽对2种缺陷数据集识别的准确率有所提升,但2种缺陷数据集的测试集正确率却有差距,在东北大学钢铁缺陷数据集表现较好,在冲压件缺陷数据



集上准确率仍有进一步提升的空间。初步分析是 2 种数据集缺陷类别不均匀问题。钢铁缺陷数据集每类缺陷样本相同, 冲压缺陷数据集的每类缺陷样本不同, 而以所有样本的测试集正确率为评价指标, 过于单一, 且在工业产品的实际生产过程中, 模型的好坏也会受到噪声、数据集的大小, 以及采集的缺陷图像质量高低缺失等因素影响, 在后续的研究中将对此方面展开研究。

#### 参考文献:

- [1] PARK J K, KWON B K, PARK J H, et al. Machine learning-based imaging system for surface defect inspection [J]. International Journal of Precision Engineering and Manufacturing-Green Technology, 2016, 3(3): 303-310.
- [2] WANG J, MA Y, ZHANG L, et al. Deep learning for smart manufacturing: Methods and applications [J]. Journal of Manufacturing Systems, 2018, 48: 144-156.
- [3] JIANG Q, SHAO F, LIN W, et al. Learning a referenceless stereopair quality engine with deep nonnegativity constrained sparse autoencoder [J]. Pattern Recognition, 2018, 76: 242-255.
- [4] TAO X, ZHANG D, WANG Z, et al. Detection of Power Line Insulator Defects Using Aerial Images Analyzed With Convolutional Neural Networks [J]. IEEE Transactions on Systems, Man, and Cybernetics: Systems, 2020, 50(4): 1486-1498.
- [5] 曾维国, 李曙华, 李岩, 等. 基于径向基函数神经网络预测模型评价油气水集输管道的均匀腐蚀缺陷 [J]. 腐蚀与防护, 2020, 41(10): 50-56.
- [6] HINTON G E, SALAKHUTDINOV R R. Reducing the dimensionality of data with neural networks [J]. Science, 2006, 313(5786): 504-507.
- [7] LECUN Y, BENGIO Y, HINTON G. Deep learning [J]. Nature, 2015, 521(7553): 436-444.
- [8] MASCI J, MEIER U, CIRESAN D. Steel Defect Classification with Max-Pooling Convolutional Neural Networks [C]//The 2012 International Joint Conference on Neural Networks (IJCNN). [S.l.]: [s.n.], 2012: 1-6.
- [9] GAO Y, GAO L, LI X, et al. A semi-supervised convolutional neural network-based method for steel surface defect recognition [J]. Robotics and Computer-Integrated Manufacturing, 2020, 61: 101825.
- [10] 何星辰, 郭勇, 李奇龙, 等. 基于深度学习的抗年龄干扰人脸识别 [J]. 自动化学报, 2022, 48(3): 877-886.
- [11] 仰梓淮, 黄海鸿, 刘贺, 等. 基于颜色直方图的电路板表面缺陷检测 [J/OL]. 计算机集成制造系统, 2022: 1-15(2022-04-11) [2022-07-06]. <https://kns.cnki.net/kcms/detail/detail.aspx?dbcode=CAPJ&dbname=CAPJLAST&filename=JSJJ20220408006&uniplatform=NZKPT&v=RxFrS6Ig2zLTfcoVUy-D4CLKBRAuy1u5jvcup0AG1JNp8Dx509Gl-Tbc-Ss7WsBi.com>.
- [12] HUANG J, REN L, ZHOU X, et al. An Improved Neural Network Based on SENet for Sleep Stage Classification [C]//IEEE J Biomed Health Inform. [S.l.]: [s.n.], 2022.
- [13] HE K, ZHANG X, REN S, et al. Deep Residual Learning for Image Recognition [C]//Proceeding of the IEEE Conference on Computer Vision and Pattern Recognition. [S.l.]: [s.n.], 2016: 770-778.
- [14] GLOROT X B Y. Understanding the difficulty of training deep feedforward neural networks [C]//Proceedings of the Thirteenth International Conference on Artificial Intelligence and Statistics. [S.l.]: [s.n.], 2010: 249-256.
- [15] YANG L, ZHANG R Y, LI L, et al. SimAM: A Simple, Parameter-Free Attention Module for Convolutional Neural Networks [C]//Proceedings of the 38th International Conference on Machine Learning. [S.l.]: [s.n.], 2021: 11863-11874.

作者简介: 朱传军, 博士, 副教授, 主要研究方向为制造信息、智能调度算法、决策分析和智能制造等。

刘荣光, 通信作者, 硕士研究生, 主要研究方向为深度学习、图像处理。

成佳闻, 硕士研究生, 主要研究为方向刀具磨损预测。

梁泽启, 硕士研究生, 主要研究为方向图像处理。

王林琳, 博士, 讲师, 主要研究为方向生产运作与管理。

E-mail: 102010153@hbust.edu.cn

收稿日期: 2022-07-06

#### 欢迎订阅 2023 年《现代制造工程》月刊

《现代制造工程》创刊于 1979 年, 是机械制造领域科技-学术期刊, 国际标准大 16 开本, 目前是中文核心期刊、中国科技核心期刊、中国科技论文统计源期刊等。

主要栏目有: 试验研究, 机器人技术, 虚拟制造技术, 新材料及其制备技术, 工业工程, 企业信息化, 数控加工技术, 车辆工程制造技术, 制造技术/工艺装备, 设备设计/诊断维修/再制造。

《现代制造工程》面向国内外公开发行, 全国各地邮局均可订阅, 国内邮发代号: 2-431, 定价 15 元/期, 180 元/年(12 期)。

联系电话: 010-67126028