



机电工程

Journal of Mechanical & Electrical Engineering

ISSN 1001-4551, CN 33-1088/TH

《机电工程》网络首发论文

题目: 基于 ResNet-ABiLSTM 的滚动轴承剩余寿命预测
作者: 刘文广, 司永战
网络首发日期: 2023-01-02
引用格式: 刘文广, 司永战. 基于 ResNet-ABiLSTM 的滚动轴承剩余寿命预测[J/OL]. 机电工程. <https://kns.cnki.net/kcms/detail//33.1088.TH.20221230.0953.006.html>



网络首发: 在编辑部工作流程中, 稿件从录用到出版要经历录用定稿、排版定稿、整期汇编定稿等阶段。录用定稿指内容已经确定, 且通过同行评议、主编终审同意刊用的稿件。排版定稿指录用定稿按照期刊特定版式 (包括网络呈现版式) 排版后的稿件, 可暂不确定出版年、卷、期和页码。整期汇编定稿指出版年、卷、期、页码均已确定的印刷或数字出版的整期汇编稿件。录用定稿网络首发稿件内容必须符合《出版管理条例》和《期刊出版管理规定》的有关规定; 学术研究成果具有创新性、科学性和先进性, 符合编辑部对刊文的录用要求, 不存在学术不端行为及其他侵权行为; 稿件内容应基本符合国家有关书刊编辑、出版的技术标准, 正确使用和统一规范语言文字、符号、数字、外文字母、法定计量单位及地图标注等。为确保录用定稿网络首发的严肃性, 录用定稿一经发布, 不得修改论文题目、作者、机构名称和学术内容, 只可基于编辑规范进行少量文字的修改。

出版确认: 纸质期刊编辑部通过与《中国学术期刊 (光盘版)》电子杂志社有限公司签约, 在《中国学术期刊 (网络版)》出版传播平台上创办与纸质期刊内容一致的网络版, 以单篇或整期出版形式, 在印刷出版之前刊发论文的录用定稿、排版定稿、整期汇编定稿。因为《中国学术期刊 (网络版)》是国家新闻出版广电总局批准的网络连续型出版物 (ISSN 2096-4188, CN 11-6037/Z), 所以签约期刊的网络版上网络首发论文视为正式出版。

基于 ResNet-ABiLSTM 的滚动轴承剩余寿命预测*

刘文广，司永战

(内蒙古科技大学 机械工程学院，内蒙古 包头 014010)

摘要：传统数据驱动的方法过度依赖先验知识且特征提取能力不足，从而导致预测精度不高等后果。针对这一问题，提出了一种带有自注意力机制(Self-Attention)的残差网络(ResNet)与双向长短时记忆网络(BiLSTM)结合的剩余使用寿命(RUL)预测方法(ResNet-ABiLSTM)。首先，对采集的原始监测信号进行了标准化处理，并采用滑窗法对处理后的数据进行了重采样，以实现数据的扩充；然后，通过采用残差网络和双向长短时记忆网络，分别提取了数据空间维度和时间维度上的深层特征，同时引入了自注意力机制，关注了时空维度上反映设备退化趋势的更重要的特征；最后，采用 PHM2012 轴承数据集对预测效果进行了验证，并将其结果与 CNN-LSTM、ResNet-BiLSTM、HI-GRNN、CNN-HI、ResNet-CBAM、DRN-BiGRU 等方法的预测结果进行了对比分析。研究表明：采用 ResNet-ABiLSTM 方法的两项误差值(RMSE、MAE)分别取得了 0.037、0.029 的最低值，其效果显著优于其他对比方法；该结果验证了 ResNet-ABiLSTM 方法对轴承 RUL 预测的准确性和有效性。

关键词：滚动轴承；剩余使用寿命；残差网络；双向长短时记忆网络；自注意力机制

中图分类号：TH133.33；TH17

文献标识码：A

Residual life prediction of rolling bearing based on ResNet-ABiLSTM

LIU Wen-guang, SI Yong-zhan

(School of Mechanical Engineering, Inner Mongolia University of Science and Technology, Baotou 014010, China)

Abstract: Aiming at the problem that traditional data-driven methods over-rely on prior knowledge and lack feature extraction ability, which leads to low prediction accuracy, a residual service life prediction method (ResNet-ABiLSTM) combining residual network (ResNet) with self-attention mechanism (Self-Attention) and bidirectional long and short time memory network (BiLSTM) was proposed. Firstly, the original monitoring signals were standardized and resampled by sliding window method to realize data expansion. Then, the residual network and the bidirectional long and short time memory network were used to extract the deep features of the data in the spatial dimension and the temporal dimension respectively, and the self-attention mechanism was introduced to focus on the more important features reflecting the equipment degradation trend in the spatial and temporal dimension. Finally, the PHM2012 bearing data set was used for verification, and the results were compared with the predicted results of CNN-LSTM, ResNet-BiLSTM, HI-GRNN, CNN-HI, ResNet-CBAM, DRN-BiGRU and other methods. The results show that the two error values (RMSE and MAE) of ResNet-ABiLSTM method are 0.037 and 0.029, respectively, which are significantly superior to other comparison methods. The results verify the accuracy and effectiveness of the proposed method for predicting bearing RUL.

Key words: rolling bearing; remaining useful life (RUL); residual network (ResNet); bidirectional long and short duration memory network (BiLSTM); self-attention mechanism (Self-Attention)

***基金项目：**内蒙古自然科学基金资助项目 (2020LH05025)

作者简介：刘文广 (1977—)，男，河北尚义人，博士，副教授，主要从事煤矿机械故障诊断方面的研究。E-mail: myshine@imust.edu.cn

0 引言

滚动轴承作为旋转机械的关键部件,广泛应用于现代工业设备。在设备运行过程中,由于受到磨损、负载、温度等内外部因素的综合作用,将会引起轴承的退化失效,轴承一旦失效将会对设备安全造成巨大的威胁^[1]。因此,在轴承失效前开展剩余使用寿命(remaining useful life, RUL)预测研究,对保障设备安全运行具有重大意义。

一般来说,剩余寿命预测方法主要分为 3 类:基于物理模型的方法、基于数据驱动的方法及二者混合的方法。基于物理模型的方法主要通过构建数学模型来描述设备的失效机理,结合特定的先验知识及缺陷增长方程来实现设备的剩余寿命预测^[2,3]。基于物理模型的方法能准确预测设备 RUL,但较难获得设备的失效机理,因此该方法不具有普适性。

相反,随着互联网和大数据的快速发展,为数据驱动的 RUL 预测方法提供了发展机遇^[4,5]。基于数据驱动的方法是通过传感器采集到的数据,深入分析数据间潜在的联系和规律,从而实现在线预测^[6]。

何庆飞等人^[7]将改进的灰色预测方法和神经网络预测方法相结合,实现了对液压泵寿命的预测,但该方法难以提取能够反映液压泵健康状态的寿命因子。RAI A 等人^[8]提出了一种基于自组织映射(Self-organizing feature Map, SOM)的退化指标用于轴承的性能退化评估,并利用支持向量机(Support Vector Machines, SVR)估计了轴承的剩余使用寿命,但该方法难以确定轴承失效阈值。

上述方法虽然取得了一定的效果,但对先验知识要求高,并且模型结构较为简单,导致预测精度低,因此不具备通用性。

近年来,深度学习以其强大的特征提取与非线性拟合能力在故障诊断、图像处理、语音识别等领域得到了广泛的应用^[9]。

张继冬等人^[10]提出了一种基于全卷积神经网络的方法,该方法将传统卷积神经网络(convolutional neural network, CNN)的全连接层全部换成卷积层与池化层,并用于滚动轴承的剩余寿命预测。但 CNN 层数较深时容易出现网络退化现象。为此,HE K 等人^[11]构造了残差网络(residual neural network, ResNet)。莫仁鹏等人^[12]将残差网络用在了滚动轴承的剩余寿命预测上,取得了较高的预测精度。

此外,长短时记忆网络(long short-term memory network, LSTM)在处理序列信息时具有长期记忆功能,在剩余寿命预测领域得到了广泛的应用。如王欣等人^[13]将 LSTM 用于航空发动机的剩余寿命预测,并取得了理想的效果。但设备退化信息具有很强的前后关联性, LSTM 在处理序列信息时仅提取了前向信息特征,未考虑后向信息特征。而双向长短时记忆网络(bi-long short-term memory network, BiLSTM)则可以同时考虑数据上下文信息,可以更全面地提取设备退化特征。

同时,自注意力机制(Self-Attention)可以在空间维度和时间维度上强化对输出结果更重要的特征,有效提高模型预测的准确率。

基于以上考虑,笔者提出一种带有自注意力机制的残差网络与双向长短时记忆网络结合的网络模型(ResNet-ABiLSTM)。

该模型利用残差网络和双向长短时记忆网络充分提取数据空间维度和时间维度上的深层特征,并引入自注意力机制分配模型权重,强化对轴承 RUL 预测的关键信息;采用一组公开的轴承数据集,以验证所提方法对轴承 RUL 预测的有效性和可行性。

1 理论介绍

1.1 残差网络

卷积神经网络(convolutional neural network,

CNN)由于其强大的特征提取能力被广泛应用于图像处理、故障诊断等领域^[14]。但 CNN 网络过深时容易出现网络退化现象。

为了解决该问题，残差网络(residual neural network, ResNet)被提出。ResNet 通过在 CNN 上引入残差模块，实现了网络间的跨层跳跃连接，这种跳跃连接结构使得 ResNet 在提取特征的同时保留了原始输入信息，避免网络过深时信息丢失。

残差网络结构如图 1 所示。




图 1 残差网络结构

残差网络公式如下式所示：

$$H(x) = F(x) + x \quad (1)$$

式中： x —输入值； $H(x)$ —输出值； $F(x)$ —经过权重层映射后的值，即为残差，当残差为零时可以得到最佳输出值。

1.2 双向长短时记忆网络

由于循环神经网络 (Recurrent Neural Network, RNN) 在处理长序列信息时容易发生梯度消失和梯度爆炸现象，使得 RNN 只能实现短期记忆。

为此，HOCHREITER S 等人^[15]提出了长短时记忆网络(long short-term memory, LSTM)。LSTM 通过在神经元细胞中引入“遗忘门”、“输入门”、“输出门”等 3 种门结构，在处理长序列信息时可以实现长期记忆。

LSTM 网络结构如图 2 所示。

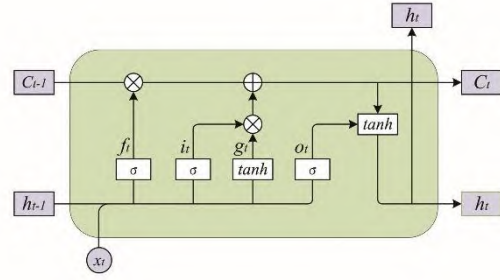


图 2 LSTM 网络结构

x_t —当前输入； h_{t-1} —上一时刻状态值输出； h_t —当前时刻状态值输出； c_{t-1} —上一时刻记忆单元； c_t —当前时刻记忆单元； f_t —遗忘门； i_t —输入门； o_t —输出门

LSTM 计算步骤为：（1）首先利用上一时刻的状态值 h_{t-1} 与当前时刻输入信息 x_t 求出 3 个门的值；（2）结合遗忘门 f_t 和输入门 i_t 的值更新记忆单元 c_t ；（3）结合记忆单元 c_t 和输出门 o_t 更新状态值 h_t ，并输出至下一时刻。

LSTM 公式如下式所示：

$$f_t = \sigma(W_f [x_t, h_{t-1}] + b_f) \quad (2)$$

$$i_t = \sigma(W_i [x_t, h_{t-1}] + b_i) \quad (3)$$

$$g_t = \tanh(W_g [x_t, h_{t-1}] + b_g) \quad (4)$$

$$o_t = \sigma(W_o [x_t, h_{t-1}] + b_o) \quad (5)$$

$$c_t = f_t \times c_{t-1} + i_t \times g_t \quad (6)$$

$$h_t = o_t \times \tanh(c_t) \quad (7)$$

式中： $\sigma(\cdot)$ —sigmoid 激活函数； W_f —遗忘门的权重矩阵； W_i —输入门的权重矩阵； W_o —输出门的权重矩阵； b_f —遗忘门的偏置； b_i —输入门的偏置； b_o —输出门的偏置。

由于设备的退化是随时间发展的，设备退化信

息具有很强的前后关联性。但 LSTM 在处理序列信息时仅提取了前向信息特征，因此 LSTM 存在一定的不足。而双向长短时记忆网络(BiLSTM)则可以综合利用数据上下文信息。

BiLSTM 结构如图 3 所示。




图 3 BiLSTM 网络结构

BiLSTM 由一个正向和一个反向的 LSTM 组合而成，在前向层进行正向传播的同时，将输入的序列反转，重新按照 LSTM 的方式在反向层计算一遍，最终结果为正向 LSTM 和反向 LSTM 输出的堆叠。因此与 LSTM 模型相比，BiLSTM 提取的特征更加全面。

1.3 自注意力机制

自注意力机制(Self-Attention)是基于注意力机制的改进，在图像识别及自然语言处理领域得到了广泛的应用^[16]。自注意力机制可以自动判别不同特征之间的关系，并根据重要程度分配相应的权重，在网络中引入自注意力机制可以提高模型准确率。

Self-Attention 计算步骤分为 3 步：

步骤 1. 将 Q (query)和 K (key)进行点积计算得到权重；

步骤 2. 对得到的权重进行 Softmax 归一化；

步骤 3. 基于归一化得到的权重，对 V (value)中所有值进行加权求和，得到 Attention 向量。

Self-Attention 公式如下式所示：

$$Attention(Q, K, V) = Soft\ max(\frac{QK^T}{\sqrt{d_k}})V \quad (8)$$

式中： Q 一查询矩阵； K 一键矩阵； V 一值矩阵；

d_k — Q 、 K 和 V 的向量维度。

其中： Q 、 K 、 V 由输入矩阵 X 分别与权重矩阵 W^q 、 W^K 和 W^V 相乘得到。

1.4 加权平均降噪法

模型输入为原始振动信号，由于信号中包含着大量噪声，会导致预测结果出现较大误差，因此需要对预测结果进行降噪处理。

笔者采用加权平均降噪法^[17]。其原理为：在对某一时刻的预测值进行降噪时，用该时刻之前一段时间预测值的加权平均值代替该时刻的预测值；此外，在对最新时刻的预测值进行降噪时，采用已降噪过的结果进行迭代运算。

加权平均降噪法公式如下式所示：

$$Y_m = \left(\sum_{i=1}^{m-1} \omega_i Y_i + \omega_m P_m \right) / \sum_{i=1}^m \omega_i \quad (9)$$

式中： m 一时间窗口长度； ω_i 一权重，是一个等差数列； Y_i 一已降噪结果； P_m 一未降噪的预测值；

笔者选取时间窗长度为 7。

2 剩余使用寿命预测模型

轴承退化过程复杂多变，传统基于数据驱动的方法过度依赖先验知识且需要人为提取特征，笔者采用 ResNet-ABiLSTM 模型对轴承退化数据进行自适应特征提取。笔者提出的模型主要由 ResNet 层、BiLSTM 层、Self-Attention 层及全连接层构成。

剩余使用寿命预测模型如图 4 所示。




图 4 ResNet-ABiLSTM 剩余寿命预测模型

剩余使用寿命预测具体步骤如下：

步骤 1。数据预处理。为了消除数据异常值对结果的影响，使数据具有相同的量纲，对数据进行 Z-Score 标准化处理，经过标准化后的数据呈均值为 0，标准差为 1 的分布。

Z-Score 标准化公式如下式所示：

$$x_{\text{norm}} = \frac{x - \mu}{\delta} \quad (10)$$

式中： x —原始数据样本； μ —原始数据的均值； δ —原始数据的标准差； x_{norm} —经过标准化处理后的数据；

步骤 2。滑窗法数据重采样。为了提高模型预测精度，笔者采用滑窗法对数据进行重采样，以实现数据集的扩充。笔者选取窗口长度为 3，步长为 1，如原始数据长度为 2 560，经过滑窗后的数据长度变为 7 674。

滑窗法示意图如图 5 所示：



图 5 滑窗法示意图

步骤 3。模型训练。将数据划分为训练集和测试集，将训练集输入已经配置好参数的模型中进行训练，在训练时通过反向传播算法优化模型参数和

权重；

步骤 4。轴承 RUL 预测。将测试集输入训练好的模型中进行轴承的 RUL 预测，并对预测结果进行降噪处理。最后，对预测值添加寿命标签，将预测的寿命值映射到 0~1 之间，以实现“端到端”的 RUL 预测。

寿命标签公式如下式所示：

$$Y_i = \frac{N - i}{N} \quad (11)$$

式中： N —滑窗后的样本数，即轴承实际寿命长度；

i —采样点； Y_i —第 i 个采样点对应的寿命标签。

3 实验验证

3.1 实验数据介绍

为了验证 ResNet-ABiLSTM 模型对 RUL 预测的效果，笔者采用 PHM2012 数据集^[18]进行了实验，即将数据输入 ResNet-ABiLSTM 模型。

该数据集来自 PRONOSTIA 轴承加速度试验台，试验台如图 6 所示。




图 6 PRONOSTIA 试验台

实验数据由安装在轴承座上的水平加速度传感器和垂直加速度传感器采集所得。笔者选取水平方向采集的数据。加速度传感器每隔 10 s 采集一次，采样频率为 25.6 kHz,每次采样时长为 0.1 s,即每次采集 2 560 个数据点。当振动信号幅值大于 20g 时

认定轴承失效，目的是避免轴承振动信号幅度过大时损坏实验平台。该数据集包含 3 种工况，共 17 个轴承，其中每种工况的前两个轴承数据作为训练集，其他轴承数据为测试集。

数据集具体描述如表 1 所示。

表 1 轴承数据集

数据集工 况	工况 1	工况 2	工况 3
训练集	Bearing1_1	Bearing2_1	Bearing3_1
	Bearing1_2	Bearing2_2	Bearing3_2
测试集	Bearing1_3	Bearing2_3	Bearing3_3
	Bearing1_4	Bearing2_4	

表 2 模型参数结构表

网络结构	网络名称	卷积核大小	卷积核数目	激活函数
ResNet	Conv1d	2	8	Relu
	ResNet1	2	16	Relu
	MaxPool1d	—	—	—
	ResNet2	2	32	Relu
	ResNet3	2	64	Relu
	MaxPool1d	—	—	—
	ResNet4	2	128	Relu
	ResNet5	2	256	—
	MaxPool1d	—	—	—
	BN	—	—	—
BiLSTM	BiLSTM1_BN	—	20	tanh
	BiLSTM2_BN	—	20	tanh
Self-Attention	Self-Attention_BN	—	—	—
Dense	Dense1_BN	—	—	Relu
	Dense2_BN	—	—	Relu
	Dense3	—	—	Sigmoid

模型训练过程选取均方误差(mean square error, MSE)作为损失函数，选择 Adam 算法作为优化器。经过实验确定最佳超参数为：学习率为 0.0005，dropout 率为 0.3, batch_size 为 64, 训练轮次为 50。

Bearing1_5	Bearing2_5
Bearing1_6	Bearing2_6
Bearing1_7	Bearing2_7

3.2 实验参数设置

基于 ResNet-ABiLSTM 模型，笔者设计了以下参数：1 层卷积网络、5 层残差网络、2 层 BiLSTM 网络、1 层 Self-Attention 网络以及 3 层全连接层，其中最后一层为输出层。此外，笔者在网络中加入了批标准化（BatchNormalization，BN）层和随机失活(dropout)函数，目的是防止过拟合和增强网络鲁棒性。

模型具体参数如表 2 所示。

此外，实验所用计算机配置如下：CPU 型号为 i5-11320H@3.2GHz, 内存为 16 GB; GPU 为 Nvidia® MX450, 显存为 2 GB；操作系统为 Microsoft® Windows 11(64 位)；程序语言为 Python3.8.13(64

位), 基于 PyTorch1.9.1 深度学习框架实现, 训练过程使用了 GPU 加速训练。

3.3 性能评价指标

为了衡量所提方法对轴承 RUL 的预测效果, 笔者选用均方根误差(root mean square error, RMSE) 和平均绝对误差(mean absolute error, MAE)作为评价指标。

RMSE 和 MAE 公式如下式所示:

$$RMSE = \sqrt{\frac{1}{N} \sum_{i=1}^N (y_i - \hat{y}_i)^2} \quad (12)$$

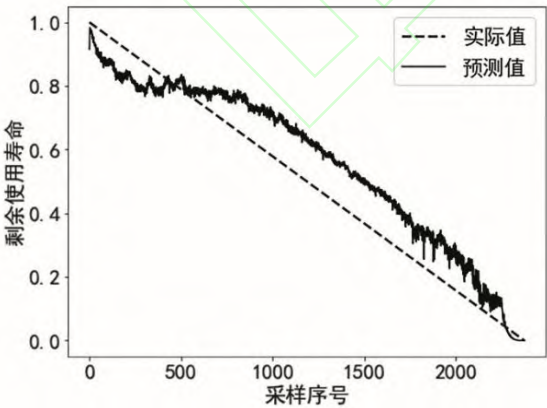
$$MAE = \frac{1}{N} \sum_{i=1}^N |y_i - \hat{y}_i| \quad (13)$$

式中: N 一样本数量; y_i 一第 i 个样本的真实 RUL 标签值; \hat{y}_i 一第 i 个样本的预测 RUL 标签值。


3.4 结果分析

为了评估所提模型的性能, 笔者选取工况 1 的轴承数据进行实验, 将轴承 1_1 和轴承 1_2 作为训练集, 轴承 1_3 作为测试集。同时, 为了验证所提模型的优越性, 笔者将其与 CNN-LSTM 和 ResNet-BiLSTM 两种模型进行对比分析。


3 种模型的预测结果如图 7 所示。



(a) CNN-LSTM 预测结果



(b) ResNet-BiLSTM 预测结果



(c) ResNet-ABiLSTM 预测结果

图 7 3 种模型在轴承 1_3 上的剩余寿命预测结果

图 7 为 3 种模型在轴承 1_3 上的剩余寿命预测结果, 且都经过了降噪处理。

从图 7 可以看出: ResNet-ABiLSTM 模型的剩余寿命预测精度最高。去掉自注意力机制后, 预测精度有所下降, 这验证了自注意力机制可以改善模型性能, 提高预测精度。

为了更直观地反映 3 种模型的优劣, 笔者采用 RMSE 和 MAE 两种评价指标对模型性能进行评价。

3 种模型的 RMSE 和 MAE 值如表 3 所示。

表 3 3 种模型的 RMSE 和 MAE 值

评价 指标	CNN-LSTM	ResNet-BiLSTM	ResNet-ABiLSTM
RMSE	0.106	0.048	0.037
MAE	0.093	0.038	0.029

从表 3 可以看出: ResNet-ABiLSTM 模型的

RMSE 和 MAE 取得了 0.037 和 0.029 的最低值。相较于 CNN-LSTM 和 ResNet-BiLSTM，所提方法的 RMSE 值分别降低了 65.09%和 22.92%，MAE 值分别降低了 68.82%和 23.68%，证明了所提方法对轴承 RUL 预测的准确性。

为了进一步观察所提方法在轴承 RUL 预测领域的效果,将其与文献[19]、文献[20]、文献[12]7-8、文献[21]等方法的预测结果进行了对比，对比结果如表 4 所示。

表 4 5 种模型的 RMSE 和 MAE 值

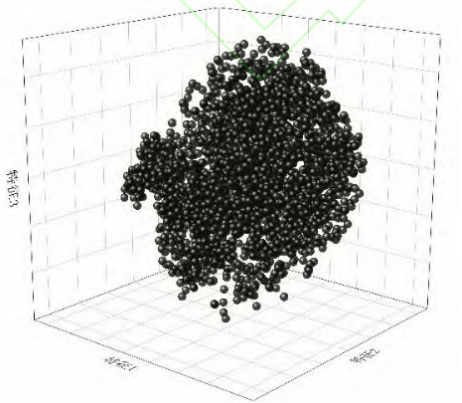
评价指标	HI-GRNN	CNN-HI	ResNet-CBAM	DRN-BiGRU	ResNet-ABiLSTM
RMSE	0.174	0.133	0.051	0.044	0.037
MAE	0.07	0.11	0.041	0.036	0.029

从表 4 可以看出：ResNet-ABiLSTM 模型的预测精度最高。相较于 HI-GRNN、CNN-HI、ResNet-CBAM、DRN-BiGRU 方法，所提方法的 RMSE 值分别降低了 78.74%、72.18%、27.45%、15.91%；MAE 值分别降低了 58.57%、73.64%、29.27%、19.44%，充分验证了所提方法对轴承 RUL 预测的优越性。


3.5 可视化分析

为了进一步分析 ResNet-ABiLSTM 模型的特征提取能力，笔者采用 t-SNE 算法对模型不同隐藏层的输出特征进行降维可视化分析。笔者选取的层分别为输入层、Self_Attention 层、Dense2 层以及输出层。

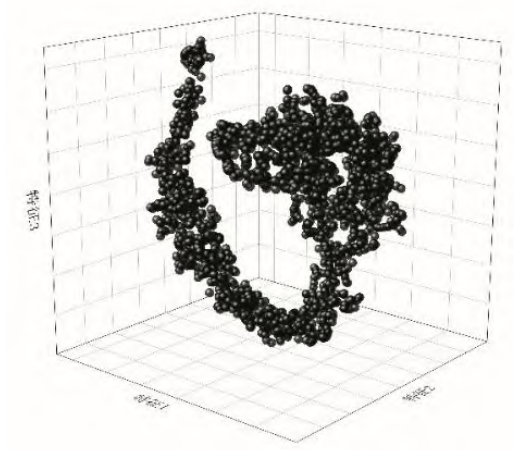
各隐藏层提取的特征可视化结果如图 8 所示。




(a)输入层



(b) Self_Attention 层



(c) Dense2 层



(d) 输出层

图 8 隐藏层特征可视化

图 8 中：每个点表示不同时刻的特征，点的灰度表示该点的健康状态。

从图 8 可以看出：随着网络层数的不断加深，提取的特征由无序逐渐向有序转变，反映了所提方法优秀的特征提取能力。

4 结束语

针对传统数据驱动的方法过度依赖先验知识且自适应特征提取能力差等问题，笔者结合残差网络、双向长短时记忆网络 and 自注意力机制的优势，提出了一种新的用于对轴承 RUL 预测的模型—ResNet-ABiLSTM；通过 PHM2012 轴承数据集对所提方法进行了验证。

研究结果如下：

(1)残差网络和双向长短时记忆网络可以充分提取数据时空维度上的深层特征；自注意力机制可以关注时空维度上更重要的特征，提高模型预测精度；

(2) ResNet-ABiLSTM 模型的两项误差值(RMSE、MAE)分别取得了 0.037、0.029 的最低值，其效果显著优于其他对比方法，充分验证了所提方法对轴承 RUL 预测的优越性；

(3) 笔者采用 t-SNE 算法对模型不同隐藏层的输出特征进行降维可视化分析，输出特征随着网络层数的加深由无序逐渐向有序转变，进一步说明了

所提方法具有优秀的特征提取能力。

笔者研究所用的轴承数据为定转速、定载荷数据，但在实际工业生产中存在着许多变转速、变负载的情况。因此，在后续研究中，笔者将考虑对变载荷、变转速工况下的轴承进行 RUL 预测。

参考文献

- [1]胡昌华, 张浩, 喻勇, 等. 基于深度学习的复杂退化系统剩余寿命预测研究现状与挑战[J]. 电光与控制, 2021,28(2):1-6.
- [2] FAN J, YUNG K C, PECHT M. Physics-of-Failure-Based Prognostics and Health Management for High-Power White Light-Emitting Diode Lighting[J]. **IEEE Transactions on Device and Materials Reliability**, 2011,11(3):407-416.
- [3]李天梅, 司小胜, 刘翔, 等. 大数据下数模联动的随机退化设备剩余寿命预测技术[J]. 自动化学报, 2022,48(9):2119-2141.
- [4]ZEMING L, JIANMIN G, HONGQUAN J, et al. A similarity-based method for remaining useful life prediction based on operational reliability[J]. **Applied Intelligence**, 2018,48(9):2983-2995.
- [5]ZHAO R, YAN R, CHEN Z, et al. Deep learning and its applications to machine health monitoring[J]. **Mechanical Systems and Signal Processing**, 2019,115:213-237.
- [6]梁伟阁, 张钢, 王健, 等. 复杂机械设备健康状态预测方法研究综述[J]. 兵器装备工程学报, 2022,43(7):67-77.
- [7]何庆飞, 陈桂明, 陈小虎, 等. 基于改进灰色神经网络的液压泵寿命预测[J]. 中国机械工程, 2013,24(4):500-506.
- [8]RAI A, UPADHYAY S H. Intelligent bearing performance degradation assessment and remaining useful life prediction based on

- self-organising map and support vector regression[J]. **Proceedings of the Institution of Mechanical Engineers, Part C: Journal of Mechanical Engineering Science**, 2018, 232(6): 1118-1132.
- [9] LI H. Deep learning for natural language processing: advantages and challenges[J]. **National Science Review**, 2018, 5(1): 24-26.
- [10] 张继冬, 邹益胜, 邓佳林, 等. 基于全卷积层神经网络的轴承剩余寿命预测[J]. **中国机械工程**, 2019, 30(18): 2231-2235.
- [11] HE K, ZHANG X, REN S, et al. Deep Residual Learning for Image Recognition[C]//2016 IEEE Conference on Computer Vision and Pattern Recognition (CVPR). Piscataway, NJ, USA: IEEE, 2016: 770-778.
- [12] 莫仁鹏, 李天梅, 司小胜, 等. 采用残差网络与卷积注意力机制的设备剩余寿命预测方法[J]. **西安交通大学学报**, 2022, 56(4): 194-202.
- [13] 王欣, 孟天宇, 周俊曦, 等. 基于注意力与LSTM的航空发动机剩余寿命预测[J]. **科学与技术工程**, 2022, 22(7): 2784-2792.
- [14] 张伟. 基于卷积神经网络的轴承故障诊断算法研究[D]. 哈尔滨: 哈尔滨工业大学机电工程学院, 2017.
- [15] HOCHREITERS, SCHMIDHUBER J. Long short-term memory[J]. **Neural computation**, 1997, 9(8): 1735-1780.
- [16] SHAW P, USZKOREIT J, VASWANI A. Self-Attention with Relative Position Representations[C]//**NAACL-HLT**2018. New Orleans: [s.n.], 2018: 1403-1409.
- [17] JIANG G, ZHOU W, CHEN Q, et al. Dual residual attention network for remaining useful life prediction of bearings[J]. **Measurement**, 2022, 199: 111-124.
- [18] NECTOUX P, GOURIVEAU R, MEDJAHED K, et al. PRONOSTIA : An Experimental Platform for Bearings Accelerated Degradation Tests[C]//IEEE International Conference on Prognostics and Health Management. Denver, Colorado, USA: [s.n.], 2012: 1-8.
- [19] YANG C, MA J, WANG X, et al. A novel based-performance degradation indicator RUL prediction model and its application in rolling bearing[J]. **ISA transactions**, 2022, 121: 349-364.
- [20] NIE L, ZHANG L, XU S, et al. Remaining useful life prediction for rolling bearings based on similarity feature fusion and convolutional neural network[J]. **Journal of the Brazilian Society of Mechanical Sciences and Engineering**, 2022, 44(8): 328-343.
- [21] 陈倩倩, 林天然. 基于DRN-BiGRU模型的滚动轴承剩余寿命预测[J]. **机电工程**, 2022, 39(11): 1575-1581.

【编辑：李辉】